



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y
Tecnología

Máster Universitario en Inteligencia Artificial

Sistema inteligente de apoyo
a la decisión para puestos de
mando de emergencias

Trabajo Fin de Estudios

Presentado por: Juan Carlos Albert Fillol, Ancor González Carballo y Brian Mathias
Pesci Juliani

Dirigido por: Dr. Andrés Soto Villaverde

Ciudad: Madrid, Tenerife y Alicante

Fecha: 24 de junio de 2026

Índice de Contenidos

Resumen	x
Abstract	xi
Organización del trabajo en grupo	1
Introducción al trabajo grupal	1
Integrantes del equipo y roles asignados	1
Capa 2: supervisión débil, RuleFit y evaluación	1
Capa 3: LLM local, RAG normativo, MCP y backend	2
Capa 1: extracción de variables operativas	2
Distribución de capítulos y anexos	3
Contribuciones técnicas por capa	4
Metodología de coordinación del grupo	4
1. Introducción	6
1.1. Contexto general del trabajo	6
1.2. Planteamiento del problema	7
1.3. Justificación e impacto social	7
1.4. Contribución específica desde la inteligencia artificial	8
1.5. Finalidad y alcance del sistema propuesto	9
1.5.1. Alcance funcional	9
1.5.2. Alcance territorial y empírico	10
1.5.3. Limitaciones	10
1.6. Enfoque del TFM como desarrollo software	11
1.7. Estructura de la memoria	11
2. Contexto del problema y estado del arte	12
2.1. Gestión de emergencias y primera decisión	12
2.2. Sistemas de apoyo a la decisión en emergencias	13
2.3. Procesamiento del lenguaje natural en emergencias	13
2.4. Supervisión débil y construcción de etiquetas P1–P4	14
2.5. RuleFit, interpretabilidad y comparación con modelos opacos	14

2.6.	Explicabilidad, LLM local, RAG y MCP	15
2.7.	Sistemas y referencias relacionadas	17
2.8.	Brecha identificada	18
2.9.	Conclusiones del estado del arte	19
3.	Marco operativo y normativo del dominio de emergencias	20
3.1.	Finalidad del capítulo	20
3.2.	Sistema español de protección civil	20
3.3.	Marco autonómico de Castilla y León	22
3.3.1.	Ley 4/2007 de Protección Ciudadana de Castilla y León	22
3.3.2.	PLANCAL como ancla de la escala P1–P4	22
3.3.3.	Planes especiales: INFOCAL, INUNCYL y MPCyL	23
3.4.	Normativa de datos, comunicaciones e inteligencia artificial	24
3.5.	Situaciones operativas y escala académica P1–P4	25
3.6.	Taxonomía operativa de incidentes	25
3.7.	Fuentes de datos y corpus normativo	26
3.8.	Trazabilidad normativa de variables y reglas	26
3.9.	Alcance v0.1.0 y elementos diferidos	29
3.10.	Conclusiones del capítulo	29
4.	Objetivos y metodología de trabajo	31
4.1.	Introducción al capítulo	31
4.2.	Objetivo general	31
4.3.	Objetivos específicos	32
4.4.	Preguntas de investigación	33
4.5.	Contribución en inteligencia artificial	35
4.6.	Enfoque metodológico	36
4.7.	Fases de desarrollo	36
4.8.	Consideraciones éticas	37
4.9.	Conclusiones del capítulo	37
5.	Identificación de requisitos del sistema	39
5.1.	Introducción al capítulo	39
5.2.	Definición formal del problema	39

5.3.	Usuario objetivo y contexto de uso	40
5.4.	Requisitos funcionales	40
5.5.	Requisitos no funcionales	42
5.5.1.	Explicabilidad	42
5.5.2.	Trazabilidad	42
5.5.3.	Supervisión humana	42
5.5.4.	Robustez ante información incompleta	42
5.5.5.	Reproducibilidad	42
5.5.6.	Soberanía del dato	42
5.6.	Restricciones y supuestos	43
5.6.1.	Restricciones metodológicas y del prototipo	43
5.6.2.	Supuestos y dependencias tecnológicas	43
5.7.	Trazabilidad entre requisitos y componentes	44
5.8.	Conclusiones del capítulo	44
6.	Arquitectura y diseño del sistema inteligente	45
6.1.	Finalidad del capítulo	45
6.2.	Principios de diseño	46
6.3.	Vista general de la arquitectura	47
6.4.	Contratos de datos	47
6.5.	Entrada del sistema: IncidentInput	49
6.6.	Capa 1: extracción NLP de variables operativas	49
6.6.1.	Variables activas y diferidas	49
6.6.2.	Señales textuales	51
6.7.	Capa 2: priorización interpretable con RuleFit	51
6.7.1.	Escala P1–P4	51
6.7.2.	Supervisión débil	52
6.7.3.	RuleFit como modelo principal	52
6.7.4.	Baseline experto, RuleFit-lite e <code>imodels</code>	52
6.7.5.	Probabilidad, confianza e invariantes	53
6.7.6.	Puerta de Seguridad	53
6.8.	Capa 3: explicación normativa con LLM, RAG y MCP	54
6.8.1.	LLM local	55

6.8.2.	RAG sobre corpus normativo CyL	55
6.8.3.	Herramientas MCP	55
6.8.4.	Cache de sesión en Capa 3	55
6.9.	Orquestador, fallback y latencia	56
6.10.	Trazabilidad y auditoría	57
6.11.	Ejemplo de funcionamiento	58
6.12.	Evaluación del diseño	58
6.13.	Conclusiones	59
7.	Datos, conjunto de datos y supervisión débil	60
7.1.	Estrategia general de datos	60
7.2.	Registro de Emergencias del 112 de Castilla y León	61
7.2.1.	Campos de entrada	61
7.2.2.	Auditoría inicial	62
7.3.	Limpieza y normalización	63
7.4.	Variables V01–V15	64
7.5.	Señales operativas textuales	64
7.6.	Etiqueta académica P1–P4	65
7.7.	Supervisión débil	65
7.7.1.	Acuerdo y control de calidad	66
7.7.2.	Ablación anti-circularidad	66
7.8.	Prevención de leakage	66
7.9.	Particiones de entrenamiento, validación y prueba	67
7.9.1.	Partición estratificada	68
7.9.2.	Partición temporal	68
7.10.	Uso en entrenamiento y evaluación	69
7.11.	Limitaciones del dataset	69
7.12.	Conclusiones	69
8.	Descripción del prototipo software desarrollado	71
8.1.	Introducción	71
8.2.	Arquitectura software	71
8.3.	Componentes de Capa 2	72
8.4.	Flujo de procesamiento	73

8.5. Prototipo ejecutable v0.1.0	73
8.5.1. Interfaz de voz e inferencia inteligente	74
8.6. Contratos y trazabilidad	75
8.7. Modo degradado	76
8.8. Relación con la evaluación	76
8.9. Repositorio del código fuente	77
8.10. Conclusiones del capítulo	77
9. Evaluación experimental	78
9.1. Objetivos de evaluación	78
9.2. Niveles de evaluación	79
9.3. Datos, etiquetas y splits	79
9.4. Política anti-leakage	80
9.5. Modelos evaluados	80
9.6. Selección del modelo	81
9.7. Métricas por clase del modelo seleccionado	81
9.8. Matriz de confusión del modelo seleccionado	82
9.9. Robustez temporal y sesgo interno	82
9.10. Interpretabilidad	83
9.11. Preparación de la revisión interna y trazabilidad	83
9.12. Fidelidad de explicaciones	84
9.13. Posicionamiento frente a trabajos relacionados	85
9.14. Smoke test integrado del prototipo	85
9.15. Protocolo propuesto de evaluación exploratoria	87
9.16. Comparativa sistémica de aportaciones en Inteligencia Artificial	87
9.17. Limitaciones	88
10. Conclusiones y trabajo futuro	90
10.1. Respuesta al objetivo del TFM	90
10.2. Trazabilidad de objetivos específicos	91
10.3. Principales contribuciones	92
10.4. Resultados principales	93
10.5. Cumplimiento de principios de diseño	94
10.6. Limitaciones	94

10.7. Trabajo futuro	95
10.8. Cierre	96
Referencias	96
A. Taxonomía operativa de incidentes CyL	103
B. Variables V01–V15 de priorización	107
C. Guía de etiquetado P1–P4	111
D. Muestra y protocolo de revisión interna	115
E. Línea base heurística de priorización	120
F. Esquema de datos y contratos	123
G. Capturas del prototipo	127
H. Declaración de uso de herramientas de inteligencia artificial generativa	133
I. Corpus normativo para RAG (Capa 3)	137
J. Prompts y herramientas MCP de Capa 3	141
K. Model cards de las capas del prototipo	145

Índice de Ilustraciones

2.1. Flujo conceptual XAI: separación entre modelo decisor interpretable y capa generativa explicativa.	16
6.1. Arquitectura integrada de tres capas con contratos versionados y componentes locales.	47
6.2. Secuencia de inferencia desde la entrada del incidente hasta la decisión humana.	56
G.1. Entrada de un incidente sintético en el formulario del prototipo Streamlit. .	129
G.2. Recomendación de prioridad P1 en color rojo HSL, probabilidades y explicación local.	129
G.3. Recomendación de prioridad P2 en color naranja HSL ante escenarios sin criticidad vital inmediata.	130
G.4. Recomendación de prioridad P4 ante consultas o incidentes ordinarios de baja urgencia.	130
G.5. Variables operativas y señales extraídas en tiempo real por la Capa 1 NLP.	131
G.6. Módulo de validación, intervención humana (HITL) y registro de decisiones en base de datos.	131

Indice de Tablas

1.	Distribución de capítulos, responsables y tipo de contribución.	3
2.	Responsabilidad técnica principal por capa del prototipo.	4
2.1.	Comparación sintética entre enfoques relacionados y propuesta del TFM. .	18
3.1.	Fuentes principales y función dentro del sistema.	27
3.2.	Trazabilidad normativa entre criterios, variables y uso previsto en el prototipo.	28
4.1.	Relación entre objetivos específicos, evidencias y criterios de cumplimiento.	34
5.1.	Trazabilidad entre requisitos y componentes del sistema.	44
6.1.	Contratos principales del flujo de inferencia.	48
6.2.	Variables operativas del sistema y alcance en v0.1.0.	50
7.1.	Campos principales del Registro 112 CyL y uso previsto en el sistema. . . .	62
7.2.	Elementos obligatorios de la auditoría del dataset.	63
7.3.	Variables V01–V15 y estado dentro del alcance v0.1.0.	64
7.4.	Columnas prohibidas como entrada del motor por riesgo de <i>leakage</i>	67
7.5.	Columnas permitidas y prohibidas según disponibilidad en la primera decisión.	68
7.6.	Distribución de las particiones adoptadas en v0.1.0.	68
8.1.	Smoke test integrado del prototipo v0.1.0	75
9.1.	Distribución de etiquetas por split	79
9.2.	Comparativa de modelos de Capa 2 en validación	81
9.3.	Métricas por clase de RuleFit-lite en test	81
9.4.	Matriz de confusión de RuleFit-lite en test	82
9.5.	Comparativa del enfoque propuesto frente a trabajos relacionados	85
9.6.	Resultado del smoke test P1–P4 con Ollama	86
9.7.	Validación reproducible Capa 1–Capa 2–Capa 3	87
9.8.	Comparativa de la aportación en IA frente a soluciones relacionadas.	88
10.1.	Trazabilidad entre objetivos específicos, grado de consecución y evidencia. .	91
A.1.	Taxonomía operativa principal del prototipo	105

A.2. Relación entre taxonomía, señales y uso en Capa 2	106
B.1. Variables V01–V15 del prototipo	110
C.1. Definición académica de prioridades P1–P4	112
C.2. Reglas principales para etiquetado débil	113
D.1. Composición de la muestra preparada para revisión	116
D.2. Campos principales de la plantilla de revisión	116
D.3. Ejemplos de casos reales seleccionados para validación	117
D.4. Perfiles propuestos para la evaluación exploratoria del MVP	118
E.1. Reglas de la línea base heurística de Capa 2	121
E.2. Métricas de la línea base heurística	121
E.3. Comparación resumida entre la línea base y RuleFit-lite	122
F.1. Contratos principales del prototipo	124
G.1. Capturas incorporadas para documentar el prototipo	128
J.1. Campos principales del JSON explicativo de la Capa 3	142
K.1. Comparativa de modelos de la Capa 2 en test	148
K.2. Resumen de validación integrada Capa 1–Capa 2–Capa 3	150
K.3. Smoke test integrado Capa 1–Capa 2–Capa 3	150

Resumen

La gestión de emergencias civiles exige decisiones rápidas y fundamentadas ante información heterogénea, incompleta y fragmentaria. En este contexto, los operadores del 112 y los responsables de coordinación necesitan herramientas que ayuden a estructurar la información inicial sin sustituir el criterio humano. Este trabajo diseña, implementa y evalúa un prototipo modular de apoyo a la decisión para la priorización temprana de incidentes 112 en Castilla y León. La propuesta se apoya en el Registro de Emergencias del 112 de Castilla y León 2008–2022, una escala académica P1–P4 construida mediante supervisión débil y una arquitectura de tres capas: extracción de variables y señales, priorización interpretable con RuleFit-lite y explicación normativa mediante LLM local, RAG y herramientas MCP. La evaluación compara un baseline experto, RuleFit-lite y una ejecución diagnóstica con *imodels*, usando splits estratificado y temporal, control anti-*leakage*, análisis de falsos negativos P1, sesgos por subgrupo y fidelidad de explicaciones. Los resultados muestran que RuleFit-lite mejora el rendimiento global frente al baseline experto, mantiene recall P1 por encima del umbral definido y conserva trazabilidad suficiente para revisión humana. El prototipo no se presenta como producto operativo ni como sistema certificado, sino como una base académica reproducible para estudiar IA responsable, explicable y supervisada en apoyo a la primera decisión de emergencia.

Palabras clave: emergencias 112, apoyo a la decisión, priorización de incidentes, RuleFit, supervisión débil, inteligencia artificial explicable.

Abstract

Civil emergency management requires rapid and evidence-based decisions under heterogeneous, incomplete and fragmented information. In this context, 112 operators and coordination staff need tools that help structure early information without replacing human judgement. This thesis designs, implements and evaluates a modular decision-support prototype for early prioritisation of 112 incidents in Castilla y Leon. The proposal relies on the 2008–2022 Castilla y Leon 112 emergency registry, an academic P1–P4 priority scale built through weak supervision, and a three-layer architecture: feature and signal extraction, interpretable prioritisation with RuleFit-lite, and normative explanation through a local LLM, RAG and MCP tools. The evaluation compares an expert baseline, RuleFit-lite and a diagnostic `imodels` run, using stratified and temporal splits, anti-leakage controls, P1 false-negative analysis, subgroup bias checks and explanation fidelity assessment. Results show that RuleFit-lite improves global performance over the expert baseline, keeps P1 recall above the predefined threshold and preserves sufficient traceability for human review. The prototype is not presented as an operational product or certified system, but as a reproducible academic basis for studying responsible, explainable and supervised AI in support of the first emergency decision.

Keywords: 112 emergencies, decision support system, incident prioritisation, RuleFit, weak supervision, explainable artificial intelligence.

Organización del trabajo en grupo

Introducción al trabajo grupal

El presente Trabajo Fin de Máster (TFM) se ha desarrollado en modalidad grupal, de conformidad con el procedimiento establecido por la Universidad Internacional de La Rioja (UNIR). Esta modalidad resulta coherente con la naturaleza del proyecto: se diseña, implementa y evalúa un sistema inteligente de apoyo a la decisión para la priorización temprana de incidentes 112 en Castilla y León, combinando procesamiento del lenguaje natural, aprendizaje interpretable, explicación normativa y desarrollo de software.

La organización del equipo se articula en tres capas técnicas y una función transversal de integración. La Capa 1 extrae variables y señales mediante un procedimiento determinista y auditable. La Capa 2 recomienda una prioridad P1–P4 con RuleFit-lite y se compara con una línea base heurística basada en reglas y con una ejecución diagnóstica de `imodels`. Su salida estructurada alimenta la Capa 3, que genera explicaciones con un modelo de lenguaje de gran tamaño (*Large Language Model*, LLM) local, generación aumentada por recuperación (*Retrieval-Augmented Generation*, RAG) y herramientas basadas en *Model Context Protocol* (MCP).

El reparto no se limita a distribuir tareas de programación. Cada integrante asume una contribución diferenciada al componente inteligente del sistema, de modo que el resultado conjunto pueda defenderse como una solución integrada y no como una suma de piezas independientes.

Integrantes del equipo y roles asignados

El equipo está formado por tres estudiantes del Máster Universitario en Inteligencia Artificial de la UNIR, bajo la dirección del Dr. Andrés Soto Villaverde. Cada integrante aporta un perfil complementario y una responsabilidad principal dentro de la arquitectura.

Capa 2: supervisión débil, RuleFit y evaluación

Responsable principal: Juan Carlos Albert Fillol.

Su bloque de trabajo se centra en la formalización del problema P1–P4, la auditoría del conjunto de datos, la construcción de etiquetas académicas mediante supervisión débil, la

línea base heurística, RuleFit-lite y la evaluación cuantitativa. La recomendación debe vincularse con reglas activadas y evaluarse mediante macro-F1, sensibilidad de P1, estabilidad temporal, análisis por subgrupos y errores críticos.

Juan Carlos asume, además, la coordinación metodológica y el cierre del bloque de datos, supervisión débil, línea base heurística, priorización interpretable, evaluación, preparación de la revisión interna y trazabilidad de Capa 2. Su aportación conecta la salida de Capa 1 con la explicación de Capa 3, sin asumir la autoría de las capas desarrolladas por los demás integrantes.

Capa 3: LLM local, RAG normativo, MCP y backend

Responsable principal: Brian Mathias Pesci Juliani.

Su bloque de trabajo comprende la capa de explicación y la integración de software del prototipo. Incluye la ingesta del corpus normativo de Castilla y León, la construcción del índice RAG, el wrapper del LLM local, el diseño de prompts, las herramientas MCP para búsqueda normativa y detalle de reglas, el modo degradado sin LLM, el backend FastAPI, el orquestador de capas y el sistema de logs auditables. Su contribución principal desde la IA consiste en convertir la salida del modelo interpretable en una recomendación comprensible, trazable y respaldada por citas normativas, manteniendo la soberanía del dato y evitando APIs externas en producción.

Capa 1: extracción de variables operativas

Responsable principal: Ancor González Carballo.

Su bloque de trabajo se orienta a la transformación del texto libre del incidente en una representación estructurada compatible con los contratos del sistema. En la v0.1.0 esta capa se plantea como un extractor determinista y auditable, basado en reglas y señales textuales, no como un modelo neuronal validado. Incluye el diseño del extractor de variables V01–V15, la validación de latencia y la garantía de que la Capa 1 no consume variables prohibidas por la política anti-*leakage*. Esta contribución es esencial porque la calidad de la priorización depende de que el sistema represente correctamente el incidente antes de aplicar reglas o modelos.

Distribución de capítulos y anexos

La Tabla 1 recoge la distribución de responsabilidades sobre la memoria. El reparto final se ha definido con un único responsable por archivo para evitar duplicidades, solapamientos y conflictos de integración. De esta forma, cada integrante revisa su parte, identifica los cambios necesarios y aporta texto, evidencias, capturas o referencias para la unificación final.

Apartado / capítulo	Responsables	Tipo de contribución
chap0.tex	Juan Carlos	Organización del trabajo y reparto final
chap1.tex	Juan Carlos	Introducción, problema, alcance y contribución IA
chap2.tex	Brian	Contexto, estado del arte y bibliografía APA 7
chap3.tex	Ancor	Marco operativo, normativo y contexto 112 CyL
chap4.tex	Juan Carlos	Objetivos, preguntas de investigación y metodología
chap5.tex	Ancor	Requisitos y especificación funcional
chap6.tex	Brian	Arquitectura, contratos y diseño del sistema
chap7.tex	Juan Carlos	Datos de Castilla y León, supervisión débil, prevención de fugas y particiones
chap8.tex	Brian	Prototipo software, backend, UI, logs y despliegue
chap9.tex	Juan Carlos	Evaluación de Capa 2, integración, revisión preparada y análisis por subgrupos
chap10.tex	Ancor	Conclusiones, limitaciones y trabajo futuro
anexo_a.tex, anexo_b.tex, anexo_g.tex	Ancor	Taxonomía, variables y guía de uso
anexo_c.tex, anexo_d.tex, anexo_e.tex	Juan Carlos	Guía P1-P4, protocolo de revisión y línea base heurística
anexo_f.tex, anexo_h.tex, anexo_j.tex, anexo_k.tex, anexo_l.tex; bibliografia.bib	Brian	Contratos, corpus, instrucciones, servicio web, ficha de modelo y bibliografía

Tabla 1: Distribución de capítulos, responsables y tipo de contribución.

Fuente: elaboración propia.

Contribuciones técnicas por capa

La Tabla 2 sintetiza la responsabilidad técnica principal de cada capa del prototipo. Esta tabla no elimina la revisión cruzada, pero ayuda a evitar solapamientos en la memoria y en la defensa.

Capa	Responsable principal	Contribución técnica
Capa 1	Ancor González Carballo	Extracción determinista y auditable de variables operativas y señales V01–V15 desde texto libre.
Capa 2	Juan Carlos Albert Fillol	Priorización P1–P4 con supervisión débil, línea base heurística, RuleFit-lite, evaluación y salida estructurada hacia Capa 3.
Capa 3	Brian Mathias Pesci Juliani	Generación de explicaciones con LLM local, RAG normativo, herramientas MCP, backend, modo degradado y trazabilidad de inferencia.

Tabla 2: Responsabilidad técnica principal por capa del prototipo.

Fuente: elaboración propia.

Metodología de coordinación del grupo

La coordinación se ha apoyado en reuniones periódicas, control de versiones y una planificación por tareas trazables. El repositorio Git actúa como referencia técnica y documental común; las decisiones de alcance se reflejan en la especificación y los contratos de datos permiten que cada capa avance sin romper la integración.

Durante la preparación de la Entrega 3, el equipo acuerda trabajar sobre la versión estable del prototipo y centralizar las propuestas de mejora en un documento compartido de Drive. El objetivo es revisar la memoria de forma ordenada, evitar cambios cruzados no controlados y llegar a la entrega con una versión coherente entre documento, repositorio, prototipo y evidencias.

El equipo ha trabajado con una lógica iterativa e incremental. Primero se fijaron los contratos y la constitución del proyecto; después se definieron el dataset, la guía de etiquetado y el corpus normativo; posteriormente se implementaron las capas técnica y explicativa; y finalmente se orienta el trabajo hacia la evaluación, la redacción y la defensa. Esta organización permite mantener alineados el prototipo software, la memoria académica y la evidencia reproducible.

De este modo, la organización del trabajo refleja la idea central del TFM: diseñar, implementar y evaluar un sistema de apoyo a la decisión para incidentes 112 en Castilla y León, con prioridad explicable P1–P4, supervisión humana, soberanía del dato y trazabilidad normativa.

1. Introducción

Este capítulo ofrece una visión de conjunto del proyecto, estableciendo el contexto y el propósito del Trabajo Fin de Máster. En primer lugar, se describe la relevancia social y técnica del problema de priorización en la gestión de emergencias 112. A continuación, se detalla la propuesta de una arquitectura en tres capas basada en inteligencia artificial responsable y supervisión humana. Finalmente, se exponen la justificación de la investigación, el impacto social esperado y la organización general del documento.

1.1. Contexto general del trabajo

La gestión de emergencias es uno de los ámbitos de actuación pública donde la rapidez y la calidad de las decisiones tienen consecuencias más directas sobre la vida de las personas. En los primeros minutos de un incidente, el operador del 112 o el responsable de coordinación debe interpretar información incompleta, heterogénea y a menudo cambiante: texto libre de la llamada, categoría preliminar, localización, número de afectados, señales de riesgo, condiciones territoriales y posible necesidad de escalar la respuesta. Por ello, la automatización asistida se presenta como un recurso valioso para mitigar la fatiga cognitiva y estructurar las fases iniciales del flujo de trabajo de emergencias.

El marco español de protección civil, articulado principalmente por la Ley 17/2015 y la Norma Básica de Protección Civil, establece una respuesta basada en coordinación, planificación y actuación graduada ante diferentes riesgos (Jefatura del Estado, 2015; Ministerio del Interior, 2023). En Castilla y León, este marco se concreta mediante la Ley 4/2007, el Plan Territorial de Protección Civil de Castilla y León (PLANCAL) y diversos planes especiales como INFOCAL, INUNCYL o MPCyL (Cortes de Castilla y León, 2007; Junta de Castilla y León, 2019, 2025, 2010, 2008). Este entorno normativo proporciona una base adecuada para construir un sistema de apoyo a la decisión que no se limite a clasificar incidentes, sino que justifique sus recomendaciones con criterios operativos y trazabilidad documental.

El presente Trabajo Fin de Máster (TFM) se sitúa en la intersección entre gestión de emergencias e inteligencia artificial aplicada. Su objetivo es diseñar, implementar y evaluar un prototipo software modular que priorice incidentes 112 de Castilla y León en una escala académica P1–P4, ofreciendo al operador una recomendación explicable, revisable y

respaldada por reglas, evidencias internas y trazabilidad documental. La escala académica P1–P4 utilizada en el trabajo no corresponde a una prioridad oficial del servicio 112, sino a una construcción académica necesaria para entrenar, evaluar y explicar el prototipo. El sistema no sustituye al operador humano ni moviliza recursos de forma autónoma: actúa como herramienta de apoyo a la primera decisión.

1.2. Planteamiento del problema

La saturación informativa en emergencias aparece cuando el volumen, la velocidad o la heterogeneidad de la información supera la capacidad del operador para procesarla con seguridad. Este fenómeno es especialmente crítico en situaciones con múltiples incidentes simultáneos, avisos incompletos o información contradictoria. En esos escenarios, una priorización deficiente puede retrasar la atención a incidentes graves, sobredimensionar sucesos menores o dificultar la justificación posterior de la decisión adoptada.

El problema abordado por este TFM puede formularse así: dado un conjunto de incidentes 112 descritos mediante texto libre y datos operativos parciales, ¿cómo puede un sistema inteligente ayudar a estructurar la información, extraer variables relevantes, recomendar una prioridad P1–P4 y explicar esa recomendación de forma comprensible y auditable?

La respuesta propuesta se apoya en una arquitectura de tres capas. La Capa 1 realiza una extracción determinista y auditable de variables operativas V01–V15 y señales textuales. La Capa 2 recomienda la prioridad mediante RuleFit-lite y se compara con una línea base heurística y una ejecución diagnóstica de `imodels`. La Capa 3 genera una explicación mediante un modelo de lenguaje de gran tamaño (*Large Language Model*, LLM) local, generación aumentada por recuperación (*Retrieval-Augmented Generation*, RAG) sobre el corpus normativo y herramientas basadas en *Model Context Protocol* (MCP). Esta separación impide que el componente generativo recalculé la prioridad o sustituya el criterio profesional.

1.3. Justificación e impacto social

Desde la perspectiva operativa, cualquier mejora en la primera decisión puede contribuir a orientar antes la atención hacia incidentes con riesgo vital, víctimas graves, atrapamiento, intoxicación, propagación o necesidad de coordinación compleja. El valor del

sistema no reside en automatizar la emergencia, sino en reducir carga cognitiva y mejorar la consistencia de la recomendación inicial. Al disponer de un marco estructurado de toma de decisiones, el personal de coordinación puede actuar bajo una mayor certidumbre metodológica durante los periodos de alta demanda.

Aunque el objetivo operativo del sistema se relaciona con la reducción del tiempo para la primera decisión (*Time To First Decision*, TTFD), el prototipo v0.1.0 no valida dicha reducción en una sala 112 real ni con operadores profesionales. La evaluación se centra en la trazabilidad, el rendimiento del modelo de priorización, la coherencia funcional del prototipo y la capacidad de generar explicaciones operativas. Por tanto, los resultados reportados en esta memoria deben entenderse como una validación de la viabilidad técnica y conceptual del modelo dentro de un marco académico controlado.

Desde la perspectiva tecnológica, las emergencias constituyen un dominio exigente para la inteligencia artificial (IA): información incompleta, alto impacto potencial, necesidad de trazabilidad, supervisión humana obligatoria y prohibición de depender de servicios externos no controlados para datos sensibles. Esta orientación es coherentemente alineada con los principios de transparencia, supervisión humana, gestión del riesgo y robustez recogidos en el Reglamento Europeo de Inteligencia Artificial (Parlamento Europeo y Consejo de la Unión Europea, 2024), así como con revisiones recientes sobre IA en gestión de emergencias (Science Advice for Policy by European Academies, 2025; Ghaffarian, Taghikhah, y Maier, 2023). Asimismo, la restricción de ejecutar toda la inferencia en entornos locales responde a la necesidad de preservar la privacidad y soberanía de los datos sensibles.

Desde la perspectiva social, el proyecto se alinea con una visión responsable de la IA: una herramienta que amplifica la capacidad de análisis del operador, pero no desplaza su criterio profesional. En un dominio crítico, la explicabilidad no es decorativa; es una condición para que la recomendación pueda revisarse, discutirse, corregirse y auditarse. De esta manera, se promueve una adopción ética y transparente de las tecnologías de soporte algorítmico en el sector público.

1.4. Contribución específica desde la inteligencia artificial

La contribución principal del TFM no consiste en entrenar un modelo opaco para maximizar una métrica aislada de precisión. El proyecto aborda un problema más delicado: construir un sistema explicable y evaluable cuando no existe una etiqueta oficial P1–P4

en el dataset abierto. Por ello, la prioridad académica se construye mediante supervisión débil, anclada en PLANCAL y en la guía de etiquetado del proyecto.

La aportación de inteligencia artificial comprende la extracción auditable de variables desde texto, la construcción de etiquetas mediante supervisión débil, la priorización interpretable con RuleFit-lite, su contraste con una línea base heurística y con `imodels`, y la generación de explicaciones a partir de la salida estructurada de Capa 2. Estas funciones se integran sin transferir al LLM la recomendación de prioridad ni la decisión final.

Esta combinación permite que cada recomendación pueda vincularse con entrada, variables extraídas, reglas activadas, probabilidad, confianza, versión de modelo, trazabilidad documental y decisión humana final. Esa trazabilidad constituye la diferencia entre un simple clasificador y un sistema de apoyo a la decisión. A través de este enfoque integrado, se proporciona a los tomadores de decisiones un marco comprensible que fundamenta de manera transparente cada sugerencia de prioridad.

1.5. Finalidad y alcance del sistema propuesto

El objetivo general del TFM es diseñar, implementar y evaluar un prototipo software modular de apoyo a la decisión para priorización temprana de incidentes 112 en Castilla y León. La finalidad es ofrecer una recomendación P1–P4 explicable y auditable, basada en variables operativas, aprendizaje interpretable, corpus normativo y supervisión humana. Para lograrlo, el proyecto delimita un conjunto de componentes de software integrados localmente bajo rigurosas restricciones de control de fuga de datos.

1.5.1. Alcance funcional

El sistema abarca la recepción de un incidente, la extracción de variables, la recomendación de prioridad, la generación de una explicación operativa, el registro auditable de la inferencia y la posibilidad de que el operador acepte, modifique o rechace la recomendación. En v0.1.0 se prioriza el núcleo evaluable: variables V01–V07 y V12–V15, señales textuales, RuleFit-lite, RAG normativo, herramientas MCP y una interfaz de usuario en Streamlit.

El endpoint `/predict` devuelve información estructurada de prioridad, detalles de reglas activadas y contexto explicativo mediante `priority_details` y `explanation_context`. Esto permite conectar la recomendación de la Capa 2 con la explicación generada por la

Capa 3, preservando la separación entre decisión automatizada, explicación y validación humana. Esta estructura contractual asegura la robustez del intercambio de datos entre los módulos del sistema.

No forman parte del alcance de v0.1.0 el despacho automático de recursos, la integración productiva con sistemas cerrados del 112, el uso de APIs cloud para inferencia con datos sensibles, la certificación regulatoria del sistema ni la validación externa con personal del 112. Estos elementos se documentan como trabajo futuro cuando corresponda. De este modo, se acota la fase de investigación a los límites factibles y seguros para un desarrollo académico inicial.

1.5.2. Alcance territorial y empírico

El alcance territorial se centra en Castilla y León. El Registro de Emergencias del 112 de Castilla y León aporta la base empírica real para trabajar con incidentes, texto operativo, fechas, provincias, localidades y coordenadas (Junta de Castilla y León, s. f.). El marco normativo autonómico se apoya en la Ley 4/2007, PLANCAL y planes especiales CyL. Esta decisión evita mantener una separación artificial entre marco normativo y dataset, y refuerza la coherencia del proyecto.

La escala P1–P4 mantiene en todo el trabajo su carácter académico y no equivale jurídicamente a las situaciones operativas oficiales.

1.5.3. Limitaciones

El TFM presenta varias limitaciones explícitas. El prototipo no se ha desplegado en una sala 112 real. La validación externa con personal del servicio queda como trabajo futuro. El dataset abierto no contiene prioridad oficial P1–P4, por lo que la etiqueta se construye mediante supervisión débil y requiere análisis de acuerdo. Las variables V08–V11, relacionadas con la AEMET, inundabilidad y Seveso, quedan diferidas a v0.2.0 por coste de integración y por el objetivo de mantener reproducible el núcleo v0.1.0.

Estas limitaciones no invalidan el trabajo; delimitan su alcance. El valor del TFM reside en demostrar una arquitectura explicable, trazable y evaluable sobre datos reales abiertos, con un marco normativo claro y con supervisión humana como principio de diseño. El reconocimiento explícito de estas fronteras metodológicas constituye un ejercicio de honestidad científica indispensable para guiar futuras ampliaciones del prototipo.

1.6. Enfoque del TFM como desarrollo software

El trabajo se desarrolla bajo la modalidad de TFM de Tipo 2, orientado al desarrollo de software. En coherencia con esta modalidad, el resultado no es solo una memoria teórica: se entrega un prototipo con contratos de datos, capas funcionales, backend, pruebas, corpus normativo, logs y artefactos de evaluación. Este enfoque práctico permite contrastar las hipótesis teóricas con el comportamiento de un sistema ejecutable y reproducible.

No obstante, la contribución académica no se reduce a programar una aplicación. El centro del trabajo es el diseño de un sistema inteligente responsable: cómo representar incidentes, cómo evitar leakage (fuga de datos), cómo construir etiquetas académicas, cómo entrenar un modelo interpretable, cómo explicar sus recomendaciones y cómo evaluar si el resultado es defendible. Cada una de estas fases se ha diseñado conforme a los más altos estándares de rigor en ingeniería y ética algorítmica.

1.7. Estructura de la memoria

La memoria se organiza en diez capítulos y anexos técnicos. El Capítulo 1 introduce el problema, el alcance y la contribución. El Capítulo 2 revisa el contexto y el estado del arte en Inteligencia Artificial (IA) para emergencias, sistemas de apoyo a la decisión (Decision Support Systems, DSS), procesamiento de lenguaje natural (NLP), supervisión débil, RuleFit, LLMs locales, RAG y MCP. El Capítulo 3 fija el marco operativo y normativo de Castilla y León. El Capítulo 4 formula objetivos, preguntas de investigación y metodología. El Capítulo 5 define requisitos. El Capítulo 6 presenta la arquitectura de tres capas. El Capítulo 7 desarrolla datos, variables, etiquetado y filtrado de datos (leakage). El Capítulo 8 documenta el prototipo. El Capítulo 9 presenta la evaluación. El Capítulo 10 sintetiza conclusiones y trabajo futuro.

Los anexos recogen la taxonomía, las variables, la guía de etiquetado, el protocolo de revisión, la línea base heurística, los contratos, el corpus RAG, las instrucciones del LLM, las fichas de modelo, las capturas y la trazabilidad extendida.

2. Contexto del problema y estado del arte

Este capítulo establece los fundamentos conceptuales y técnicos que sustentan la investigación sobre sistemas de apoyo a la decisión en emergencias. Para ello, se analiza en primer lugar la dinámica operativa de la primera decisión en las salas del 112 y la importancia de la conciencia situacional. Posteriormente, se realiza una revisión crítica de los sistemas de ayuda a la decisión existentes y de las técnicas de procesamiento del lenguaje natural aplicadas a este dominio. Por último, se examinan las metodologías de aprendizaje interpretable en entornos de alta criticidad, justificando la elección de RuleFit-lite frente a otros modelos convencionales.

2.1. Gestión de emergencias y primera decisión

La gestión de emergencias comprende el conjunto de actividades orientadas a prevenir, preparar, responder y recuperar la normalidad frente a sucesos que pueden comprometer la vida, los bienes, el medio ambiente o servicios esenciales. A diferencia de otros procesos de decisión pública, las emergencias se caracterizan por presión temporal, información incompleta, incertidumbre, multiplicidad de actores y necesidad de coordinación inmediata (Quarantelli, 1988; Comfort, 2007). Esta complejidad exige metodologías que ayuden a estructurar la información disponible en los instantes iniciales del suceso de forma rápida y reproducible.

En este contexto, la primera decisión operativa tiene un peso especial. No cierra la gestión del incidente, pero condiciona la atención inicial, la movilización de recursos, el seguimiento y la posible escalada. El operador debe interpretar rápidamente señales parciales, distinguir incidentes leves de incidentes críticos y mantener una trazabilidad mínima que permita justificar la decisión adoptada.

El concepto de conciencia situacional ayuda a explicar esta necesidad. Endsley (1995) la define como la percepción de elementos del entorno, la comprensión de su significado y la proyección de su evolución. En un centro 112, esa conciencia situacional depende de transformar texto, categorías preliminares, coordenadas y contexto normativo en una representación operativa útil.

2.2. Sistemas de apoyo a la decisión en emergencias

Los sistemas de apoyo a la decisión (Decision Support Systems, DSS) buscan asistir a personas o equipos en decisiones complejas. En emergencias, pueden organizar información, visualizar incidentes, simular escenarios, priorizar recursos o facilitar coordinación (Turoff, Chumer, Van de Walle, y Yao, 2004; Comes, Hiete, Wijngaards, y Schultmann, 2011). Sin embargo, muchos DSS se centran en cuadros de mando, mapas o gestión de recursos, sin abordar de forma específica la priorización explicable de incidentes individuales en un servicio 112.

El prototipo de este Trabajo Fin de Máster (TFM) se sitúa en una franja más acotada: apoyo a la primera decisión mediante una recomendación P1–P4, trazable y revisable. No pretende sustituir sistemas de despacho, mapas de riesgo o plataformas institucionales. Su aportación consiste en conectar información inicial del incidente, variables operativas, modelo interpretable y explicación normativa.

2.3. Procesamiento del lenguaje natural en emergencias

El procesamiento del lenguaje natural (NLP) se ha utilizado ampliamente para extraer información de mensajes de crisis, partes breves, redes sociales o comunicaciones ciudadanas. Trabajos clásicos de *crisis informatics* mostraron que los textos no estructurados pueden contener localizaciones, peticiones de ayuda, daños, necesidades y señales de riesgo (Vieweg, Hughes, Starbird, y Palen, 2010; Caragea y cols., 2011; Imran, Castillo, Diaz, y Vieweg, 2015). El uso de estas herramientas textuales permite sistematizar la recopilación de datos no estructurados en situaciones de alta presión informativa.

Los modelos recientes basados en transformers han mejorado la representación semántica de textos de crisis. CrisisTransformers, por ejemplo, propone modelos preentrenados y codificadores especializados para clasificación, búsqueda semántica y agrupación de textos relacionados con crisis (Lamsal, Rodriguez Read, y Karunasekera, 2024). Para este TFM, esa línea es relevante porque confirma la utilidad del NLP, pero también marca una frontera: procesar texto no equivale a decidir prioridad operativa.

En el sistema propuesto, el NLP es la Capa 1. Su función es extraer variables V01–V15 y señales textuales como `signal_herido_grave`, `signal_atrapado`, `signal_intoxicacion`, `signal_incendio` o `signal_rescate`. La prioridad no la decide el extractor textual, sino

la Capa 2 interpretable, lo que reduce el riesgo de convertir un clasificador de texto en una caja negra de decisión. En la versión v0.1.0 esta extracción es determinista, pero la línea futura contempla modelos transformer en español como MarIA/RoBERTa-bne (Gutiérrez-Fandiño y cols., 2022) para reforzar la detección semántica de señales.

2.4. Supervisión débil y construcción de etiquetas P1–P4

Una dificultad central del proyecto es que el Registro de Emergencias del 112 de Castilla y León no contiene una prioridad oficial P1–P4. Esto impide entrenar directamente un modelo supervisado convencional sobre una verdad institucional. La solución adoptada es construir una etiqueta académica mediante supervisión débil.

La supervisión débil permite combinar varias fuentes imperfectas de etiquetado, como reglas heurísticas, anotadores automáticos, clustering, modelos auxiliares o criterios expertos, para generar una etiqueta probabilística de entrenamiento. Snorkel es una referencia consolidada en esta línea, al formalizar el uso de funciones de etiquetado y modelos generativos para crear datos de entrenamiento a partir de supervisión imperfecta (Ratner y cols., 2020). Este enfoque facilita el aprovechamiento de grandes volúmenes de datos no etiquetados sin incurrir en los elevados costes de la anotación manual exhaustiva.

En este TFM, la supervisión débil no se presenta como sustituto de una validación experta institucional. Es un mecanismo académico y reproducible para poder entrenar y evaluar el prototipo con datos reales abiertos. La importancia de la supervisión y control humanos en IA para sistemas críticos es documentada exhaustivamente por Zhenishova et al. Zhenishova, Kumar, Petrov, y cols. (2025), quienes señalan que la claridad y justificación en las recomendaciones deben priorizar la usabilidad del operador por encima de la complejidad algorítmica. Por ello se exige medir acuerdo, documentar la guía de etiquetado, analizar discrepancias y realizar ablaciones que eviten circularidad entre reglas de etiquetado y reglas del modelo.

2.5. RuleFit, interpretabilidad y comparación con modelos opacos

La Capa 2 del sistema utiliza RuleFit como núcleo interpretable. RuleFit combina reglas derivadas de árboles con términos lineales y selección regularizada, produciendo un

conjunto de reglas con pesos que puede inspeccionarse y limitarse (Friedman y Popescu, 2008). Esta propiedad es especialmente adecuada para emergencias: el operador y el tribunal no solo necesitan saber que el sistema recomienda P1, sino que deben poder ver qué reglas se han activado y por qué.

El proyecto mantiene también un baseline experto y una ejecución diagnóstica con `imodels` (Singh, Nasser, Tan, Tang, y Yu, 2021). El baseline experto permite disponer de una referencia transparente, construida a partir de conocimiento normativo y señales operativas. La comparativa con `imodels` permite contrastar la familia RuleFit recomendada con una implementación externa, sin sustituir el núcleo reproducible seleccionado para v0.1.0. Esta separación evita presentar un modelo opaco o poco controlado como decisión operativa en un dominio de alto impacto.

La inclusión de un baseline experto basado en reglas heurísticas tradicionales y de un modelo alternativo tipo One-vs-Rest mediante `imodels.RuleFitClassifier` permite delimitar la ventaja analítica de la propuesta. El contraste experimental valida que la versión optimizada RuleFit-lite seleccionada no solo mejora el rendimiento global, sino que reduce significativamente el coste computacional frente a implementaciones canónicas de la literatura. De este modo, se asegura la viabilidad del despliegue del prototipo en entornos locales con recursos de hardware limitados.

La literatura sobre interpretabilidad refuerza esta decisión. Rudin (2019) defiende que, en decisiones de alto riesgo, debe preferirse un modelo interpretable desde el diseño cuando sea viable, en lugar de explicar a posteriori una caja negra. Para entornos de toma de decisiones en emergencias civiles y control operacional (AI-SOAR), Araujo et al. Araujo, Silva, Ito, y cols. (2026) demuestran que la explicabilidad intrínseca y la trazabilidad desde el diseño son indispensables para consolidar la confianza de los operadores tácticos y asegurar la auditabilidad legal frente a las autoridades reguladoras. Esta idea es coherente con la arquitectura del TFM: RuleFit decide la prioridad; el LLM explica y comunica, pero no decide de forma autónoma.

2.6. Explicabilidad, LLM local, RAG y MCP

La explicabilidad en este TFM no se reduce a mostrar una probabilidad. La recomendación debe acompañarse de reglas activadas, confianza, advertencias cuando proceda y citas normativas. Para ello, la Capa 3 utiliza un LLM local cuantizado (Grattafiori, Dubey,

y cols., 2024; Qwen Team, 2024), recuperación aumentada sobre un corpus normativo de Castilla y León y herramientas MCP.




Figura 2.1: Flujo conceptual XAI: separación entre modelo decisor interpretable y capa generativa explicativa.

El uso de un modelo de lenguaje de gran tamaño (Large Language Model, LLM) local responde a dos necesidades: generar explicaciones comprensibles para el operador y preservar la soberanía del dato. En el marco regulatorio europeo (tales como el RGPD o la directiva del Reglamento de IA de la UE), la inferencia local se consolida como un patrón de conformidad y privacidad Szabelka, Nowak, O’Brien, y cols. (2025). La generación aumentada por recuperación (Retrieval-Augmented Generation, RAG) Lewis y cols. (2020) evita que la explicación dependa solo de memoria generativa: el sistema consulta fragmentos del corpus normativo, recuperados mediante embeddings tipo Sentence-BERT (Reimers y Gurevych, 2019), y los utiliza para sustentar citas legales. La confiabilidad y consistencia de este acotamiento en sistemas de alta criticidad ha sido validada empíricamente por Sandeboina et al. Sandeboina, Chen, Kumar, y cols. (2026), demostrando que reduce de manera sustancial las alucinaciones factualmente verificables.

En el prototipo real se utiliza el codificador de sentencias **paraphrase-multilingual-MiniLM-L12-v2**, por su equilibrio entre soporte multilingüe, cobertura para textos en español e inglés y ligereza operativa en ejecución local. Por su parte, el protocolo de contexto de modelo (Model Context Protocol, MCP) aporta un mecanismo estándar para exponer herramientas como búsqueda normativa, detalle de reglas y cita legal de prioridades; Anthropic (2024) lo presentó como un protocolo abierto para conectar asistentes de IA con fuentes de datos y herramientas externas. Esta integración facilita el diseño de una interfaz unificada y desacoplada para la interacción con modelos generativos.

El uso de un codificador de sentencias ligero como **paraphrase-multilingual-MiniLM-L12-v2**, con 384 dimensiones de *embedding*, permite resolver búsquedas semánticas sobre el corpus normativo local con baja latencia, mantener el consumo de memoria dentro del perfil de hardware local y asegurar que las explicaciones normativas se nutran de fragmentos legales exactos de forma reproducible. Esta elección resulta crítica en entornos de emergencias,

donde cada segundo de retraso en la presentación de información al operador puede repercutir en el resultado del operativo. De esta forma, el sistema equilibra la precisión de la recuperación semántica con la agilidad que demanda la operación en tiempo real.

Esta capa debe entenderse con precisión metodológica. El LLM no decide la prioridad, no la recalcula y no debe inventar fundamento jurídico. Su función es traducir una recomendación ya calculada por Capa 2 en una explicación breve, trazable y revisable. La fundamentación jurídica se obtiene de fragmentos recuperados del corpus normativo y de las reglas activadas por el modelo interpretable, de modo que la orquestación no convierte al LLM en una caja negra decisoria.

El riesgo de alucinación se mitiga mediante tres salvaguardas implementadas en el prototipo. Primero, la temperatura de inferencia se fija estrictamente en 0.0, una configuración que Jubair et al. Jubair, Wong, Prasad, y cols. (2026) validan como óptima en sistemas críticos basados en conocimiento estructurado en comparación con técnicas puras de ajuste fino. Segundo, la búsqueda RAG queda acotada a fragmentos del corpus normativo de Castilla y León del Boletín Oficial de Castilla y León (BOCYL) y del Boletín Oficial del Estado (BOE) incorporado al repositorio. Tercero, si el modelo local no responde o supera el acuerdo de nivel de servicio (Service Level Agreement, SLA) de latencia establecido, se activa un modo degradado determinista que genera explicaciones automáticas a partir de plantillas, reglas activadas y metadatos de la Capa 2.

2.7. Sistemas y referencias relacionadas

El sistema AIDR (Artificial Intelligence for Disaster Response) demostró la utilidad de combinar aprendizaje automático y participación humana para clasificar mensajes de crisis en redes sociales (Imran, Castillo, Lucas, Meier, y Vieweg, 2014). La iniciativa TREC (Text REtrieval Conference) Incident Streams proporcionó benchmarks y colecciones de prueba para la clasificación estructurada de crisis y estimación de urgencia (McCreadie, Buntain, y Soboroff, 2021). Por su parte, el GDACS (Global Disaster Alert and Coordination System) integra alertas globales multirriesgo e información geoespacial para la coordinación internacional (2025b). Copernicus Emergency Management Service aporta cartografía rápida y productos para apoyar la respuesta (Copernicus Emergency Management Service, 2025). Finalmente, las revisiones estratégicas del JRC (Joint Research Centre de la Comisión Europea) y SAPEA (Science Advice for Policy by European Aca-

demies) subrayan el potencial de la IA en gestión de crisis, pero también la necesidad de control humano, explicabilidad y robustez (Joint Research Centre, 2025a; Science Advice for Policy by European Academies, 2025).

Ninguna de estas referencias resuelve exactamente el problema abordado aquí: priorizar incidentes 112 individuales en Castilla y León mediante una escala académica P1–P4, con variables trazables, RuleFit interpretable, explicación normativa y supervisión humana. Las plataformas existentes se enfocan predominantemente en alertas de carácter global o en la clasificación de mensajería informal en redes sociales. Por el contrario, la propuesta de este TFM se centra de manera exclusiva en estructurar el flujo de decisión interno de una sala de despacho autonómica conforme a su corpus regulatorio específico.

Sistema o enfoque	Qué aporta	Limitación frente al TFM	Relación con la propuesta
AIDR	Clasificación colaborativa de mensajes de crisis	Mensajes de redes sociales, no incidentes 112 consolidados	Inspira colaboración humano-máquina
TREC-IS	Criticidad e información útil en crisis	Prioriza mensajes, no incidentes con normativa local	Justifica tareas de criticidad y evaluación
CrisisTransformers	NLP especializado para textos de crisis	No incorpora prioridad P1–P4 ni reglas normativas	Referente para Capa 1 NLP
GDACS	Alerta global multirriesgo	Escala internacional, no sala 112 autónoma	Inspira amenaza, exposición y vulnerabilidad
Copernicus EMS	Cartografía y productos geoespaciales	No decide prioridad ni explica normativa	Fuente futura de contexto geoespacial
RuleFit	Modelo interpretable basado en reglas ponderadas	Requiere etiquetas y control de sparsity	Núcleo de Capa 2
LLM + RAG + MCP	Explicación y acceso a corpus/herramientas	Riesgo de alucinación si no se acota	Capa 3 explicativa, no decisoria

Tabla 2.1: Comparación sintética entre enfoques relacionados y propuesta del TFM.

2.8. Brecha identificada

A partir de la revisión anterior, la brecha del TFM puede formularse así: falta un prototipo académico, reproducible y explicable que combine incidentes reales 112, etiqueta P1–P4 académica, NLP en español, supervisión débil, RuleFit interpretable, explicación normativa con LLM local, herramientas MCP y evaluación orientada a seguridad del operador. Los trabajos previos abordan estos componentes de forma aislada, sin proponer

una canalización integrada y local de procesamiento. De este modo, la presente propuesta busca unificar estos elementos en un único flujo de trabajo validado funcional y experimentalmente.

La propuesta cubre esa brecha con una arquitectura sobria. La Capa 1 estructura el incidente; la Capa 2 recomienda prioridad; la Capa 3 explica; el operador decide; y el sistema registra todo para auditoría. Esta cadena preserva el control humano y evita que la IA aparezca como autoridad autónoma.

2.9. Conclusiones del estado del arte

La revisión permite extraer cinco conclusiones. Primera, la gestión de emergencias exige sistemas que ayuden a priorizar bajo incertidumbre, no solo a acumular información. Segunda, el NLP es necesario para estructurar texto, pero no suficiente para decidir prioridad. Tercera, la ausencia de etiquetas oficiales P1–P4 obliga a construir una etiqueta académica mediante supervisión débil y validación explícita. Cuarta, RuleFit ofrece un equilibrio adecuado entre aprendizaje y explicabilidad para el núcleo de decisión. Quinta, los LLM locales con RAG y MCP pueden mejorar la comunicación de la recomendación, siempre que se mantengan subordinados al modelo interpretable y a la supervisión humana, un principio de diseño "human-centered" de "human-in-the-loop" alineado con las directrices de Zhenishova et al. Zhenishova y cols. (2025) para preservar el control y responsabilidad del operador sobre las decisiones automáticas.

Estas conclusiones preparan el tránsito al Capítulo 3, donde se desarrolla el marco operativo y normativo de Castilla y León que fundamenta las variables, reglas y citas del sistema. La definición precisa de este entorno normativo es crucial para nutrir la base de conocimientos del RAG de la Capa 3. Con ello se asegura que el apoyo a la decisión del operador esté firmemente respaldado por las directrices de los planes especiales de protección civil.

3. Marco operativo y normativo del dominio de emergencias

3.1. Finalidad del capítulo

El sistema de apoyo a la decisión propuesto en este Trabajo Fin de Máster se sitúa en un dominio especialmente regulado: la atención de emergencias, la protección civil y la gestión de información sensible en los primeros minutos de un incidente. Por ello, antes de describir la arquitectura técnica del prototipo resulta necesario fijar el marco operativo y normativo que justifica sus variables, sus reglas de prioridad y sus límites de uso.

Este capítulo no pretende realizar un estudio jurídico exhaustivo. Su función es más concreta: extraer de la normativa estatal, autonómica y europea los criterios que pueden convertirse en decisiones de diseño. En particular, interesa identificar qué elementos normativos respaldan la detección de riesgo vital, la valoración de víctimas, la vulnerabilidad, la progresión del incidente, la coordinación entre recursos, la trazabilidad de las recomendaciones, la privacidad y la supervisión humana.

La línea de trabajo adoptada tras el rediseño del proyecto se centra en Castilla y León. El caso empírico se apoya en el Registro de Emergencias del 112 de Castilla y León, correspondiente al periodo 2008–2022, y el marco autonómico principal queda definido por la Ley 4/2007, de Protección Ciudadana de Castilla y León, el Plan Territorial de Protección Civil de Castilla y León (PLANCAL) y los planes especiales incorporados al corpus normativo del prototipo (Cortes de Castilla y León, 2007; Junta de Castilla y León, 2019, s. f.). Sobre esta base se construye una escala académica P1–P4, no oficial, orientada a priorizar incidentes de forma explicable y auditable.

3.2. Sistema español de protección civil

La protección civil en España se configura como un sistema público orientado a proteger a las personas, los bienes y el medio ambiente ante situaciones de grave riesgo, catástrofe o calamidad pública (Jefatura del Estado, 2015). Su organización combina competencias estatales, autonómicas y locales, de modo que la respuesta a una emergencia no depende de una única autoridad ni de un único centro operativo, sino de una red de estructuras de

mando, coordinación y apoyo técnico.

Desde la perspectiva del sistema propuesto, esta configuración tiene tres consecuencias. En primer lugar, la prioridad de un incidente no puede deducirse solo de su categoría nominal: un accidente de tránsito, un incendio o una incidencia sanitaria pueden exigir tratamientos muy distintos según víctimas, localización, propagación, vulnerabilidad o simultaneidad con otros avisos. En segundo lugar, la respuesta se produce bajo incertidumbre: durante los primeros minutos el operador dispone de texto libre, categoría preliminar, localización aproximada y señales parciales, no de una fotografía completa de la emergencia. En tercer lugar, cualquier recomendación automatizada debe ser subordinada a la decisión humana, porque el sistema no moviliza recursos ni declara situaciones operativas.

La Ley 17/2015 aporta el marco conceptual general: riesgo, emergencia, afectación a personas, protección de bienes, servicios esenciales, deberes de colaboración y coordinación entre administraciones (Jefatura del Estado, 2015). Estos conceptos justifican que el prototipo no se limite a detectar palabras graves en el texto, sino que estructure la información en variables operativas: riesgo vital, número estimado de víctimas, gravedad de lesiones, población vulnerable, emplazamiento crítico, multirriesgo o accesibilidad de recursos.

La Norma Básica de Protección Civil, aprobada mediante el Real Decreto 524/2023, refuerza esta lógica al ordenar la planificación por riesgos, establecer criterios comunes para los planes y situar la gestión de emergencias dentro de una arquitectura graduada de respuesta (Ministerio del Interior, 2023). Para este TFM, su utilidad no consiste en trasladar mecánicamente las situaciones operativas al modelo, sino en justificar que la prioridad debe entenderse como una gradación: hay incidentes leves, incidentes relevantes, incidentes graves e incidentes críticos, y el sistema debe distinguirlos con criterios reproducibles.

El Plan Estatal General de Emergencias de Protección Civil (PLEGEM) completa el marco estatal al describir la coordinación ante emergencias de interés nacional o de dimensión supraautonómica (Ministerio del Interior, 2020). Aunque el prototipo no pretende activar mecanismos estatales, el PLEGEM resulta útil para modelar señales de complejidad: multirriesgo, avisos simultáneos, insuficiencia potencial de medios ordinarios o necesidad de coordinación ampliada.

3.3. Marco autonómico de Castilla y León

Castilla y León constituye el ámbito territorial de referencia del prototipo por dos razones complementarias. La primera es empírica: existe un registro público de emergencias del 112 que permite trabajar con incidentes reales y evitar una validación basada exclusivamente en ejemplos simulados (Junta de Castilla y León, s. f.). La segunda es normativa: la comunidad autónoma dispone de una ley propia de protección ciudadana y de planes territoriales y especiales que permiten anclar la interpretación operativa de las variables del sistema.

3.3.1. Ley 4/2007 de Protección Ciudadana de Castilla y León

La Ley 4/2007, de Protección Ciudadana de Castilla y León, proporciona el marco autonómico general para la organización de la protección civil, la coordinación de emergencias y la actuación de los servicios públicos en la comunidad (Cortes de Castilla y León, 2007). Para el sistema propuesto, su interés principal es que sitúa la atención de emergencias dentro de un esquema institucional donde la rapidez de respuesta, la coordinación y la información al ciudadano son elementos centrales.

Desde el punto de vista del modelado, esta ley respalda variables relacionadas con la inmediatez y la capacidad operativa, especialmente la accesibilidad de recursos (V15), la existencia de emplazamientos críticos (V07) y la necesidad de registrar la actuación para auditoría posterior. También refuerza una idea metodológica importante: el sistema recomienda prioridades, pero la decisión final corresponde siempre a personal humano integrado en la organización competente.

3.3.2. PLANCAL como ancla de la escala P1–P4

El Decreto 4/2019 aprueba el Plan Territorial de Protección Civil de Castilla y León (PLANCAL), pieza central para conectar el marco normativo con la escala académica de prioridad utilizada en este TFM (Junta de Castilla y León, 2019). PLANCAL no define una etiqueta P1–P4 para el dataset, ni el proyecto afirma que exista una equivalencia oficial. Su aportación consiste en ofrecer una lógica de fases, situaciones y coordinación que permite construir una guía de etiquetado razonada.

La escala P1–P4 del prototipo debe entenderse como una abstracción funcional. P1 representa incidentes con riesgo vital, víctimas graves, atrapamiento, intoxicación peligro-

sa, propagación severa o necesidad de atención inmediata. P2 agrupa incidentes relevantes con potencial de deterioro o afectación significativa, pero sin la criticidad inmediata de P1. P3 recoge situaciones que requieren gestión ordinaria o seguimiento, y P4 corresponde a incidentes de baja urgencia operativa o sin afectados. Esta escala se utiliza para entrenamiento, evaluación y explicación, pero no sustituye categorías oficiales de mando.

3.3.3. Planes especiales: INFOCAL, INUNCYL y MPCyL

Los planes especiales de Castilla y León aportan criterios sectoriales que enriquecen la interpretación de incidentes concretos. INFOCAL, aprobado por el Decreto 6/2025, resulta relevante para incendios forestales, propagación, amenaza a núcleos habitados, simultaneidad de focos y condiciones que pueden elevar la prioridad de una incidencia inicialmente limitada (Junta de Castilla y León, 2025). En el prototipo, este marco se relaciona con V12 (`riesgo_propagacion`) y con señales textuales como `signal_incendio`.

INUNCYL, plan de protección civil ante el riesgo de inundaciones en Castilla y León, aporta el marco conceptual para valorar episodios de inundación, avenidas, desbordamientos y afectación territorial (Junta de Castilla y León, 2010). En la versión v0.1.0 del proyecto, las variables de enriquecimiento meteorológico e hidrológico asociadas a INUNCYL se difieren a v0.2.0, pero la norma permanece en el marco teórico y en el corpus RAG porque justifica una línea natural de extensión.

MPCyL, plan de protección civil ante el riesgo de transportes de mercancías peligrosas, es relevante para incidentes con sustancias químicas, cisternas, fugas, intoxicaciones o riesgos tecnológicos en transporte (Junta de Castilla y León, 2008). En la versión v0.1.0 se utiliza como anclaje normativo de las reglas asociadas a `signal_intoxicacion` y a escenarios de mercancías peligrosas. No obstante, la planificación reconoce una limitación práctica: el corpus normativo solo dispone del decreto de aprobación, quedando pendiente la localización del plan técnico completo en fuentes oficiales. Como estrategia de mitigación frente a este vacío documental en el RAG, se diseñó una técnica de inyección sintética controlada en el proceso de ingesta: se inserta un fragmento estructurado sobre protocolos químicos en el documento del PLANCAL, asociando términos del dominio de mercancías peligrosas con el Decreto 4/2019. Esto previene la falta de recuperación y la consecuente alucinación del LLM, y permite documentar la limitación formalmente en la evaluación del RAG.

3.4. Normativa de datos, comunicaciones e inteligencia artificial

El dominio no solo exige priorizar bien; exige hacerlo de forma trazable, privada y compatible con la supervisión humana. Por este motivo, el marco normativo del proyecto incluye también normas sobre comunicaciones de emergencia, protección de datos e inteligencia artificial.

La Ley 11/2022, General de Telecomunicaciones, resulta relevante por el papel de los servicios de emergencia, la localización de llamadas y el tratamiento de información asociada a comunicaciones (Jefatura del Estado, 2022). En el prototipo, esta norma no se traduce en una integración técnica con sistemas de telecomunicaciones, sino en una cautela de diseño: la localización se trata como dato operativo sensible y solo se conserva o transforma cuando aporta valor a la priorización y a la trazabilidad.

El Reglamento General de Protección de Datos y la Ley Orgánica 3/2018 imponen principios de minimización, limitación de finalidad, seguridad y responsabilidad proactiva (Parlamento Europeo y Consejo de la Unión Europea, 2016; Jefatura del Estado, 2018). Estos principios justifican el rechazo de variables innecesarias, el uso de hashes en los logs de inferencia, la separación entre datos de entrada y resultados del sistema, y la exclusión de campos que puedan revelar decisiones posteriores o resultados clínicos. Esta restricción conecta directamente con la política anti-*leakage*: el sistema no debe aprender a priorizar usando información que en la realidad solo estaría disponible después de la decisión inicial.

El Reglamento (UE) 2024/1689 de Inteligencia Artificial introduce un marco de especial relevancia para sistemas aplicados a servicios esenciales, emergencias y apoyo a decisiones con posible impacto sobre personas (Parlamento Europeo y Consejo de la Unión Europea, 2024). El TFM no afirma que el prototipo sea un producto certificado ni listo para despliegue. Su posición es más prudente: el diseño se alinea con requisitos de alto nivel como supervisión humana, trazabilidad, transparencia, gestión del riesgo, calidad de datos y robustez. Por ello, la arquitectura se formula como sistema de apoyo a la decisión: recomienda, explica y registra, pero no decide ni moviliza recursos de forma autónoma.

3.5. Situaciones operativas y escala académica P1–P4

Las situaciones operativas de protección civil ordenan el mando, la coordinación y la movilización de recursos ante emergencias. Su finalidad es institucional y organizativa. La prioridad P1–P4 del sistema, en cambio, es una escala académica diseñada para ordenar incidentes por urgencia relativa en el contexto del prototipo.

Esta diferencia debe quedar clara para evitar una confusión metodológica. Una situación operativa puede referirse al estado global de una emergencia en un territorio, mientras que P1–P4 se asigna a un incidente concreto. Un accidente con una persona atrapada puede ser P1 aunque no exista una situación territorial de emergencia elevada. Del mismo modo, un escenario de prealerta territorial puede contener avisos individuales de baja prioridad. La relación entre ambas escalas es, por tanto, inspiracional y funcional, no jurídica ni uno a uno.

La escala P1–P4 se construye con tres objetivos. Primero, permitir que los tres autores generen etiquetas débiles comparables sobre el dataset real. Segundo, entrenar y evaluar un motor interpretable, basado en RuleFit y comparado con un baseline experto. Tercero, generar explicaciones comprensibles para el operador, citando reglas activadas y normas de referencia. Esta formulación mantiene el sistema dentro de la línea de trabajo del proyecto: núcleo explicable, supervisión humana y trazabilidad normativa.

3.6. Taxonomía operativa de incidentes

El motor necesita una taxonomía de incidentes porque la prioridad no se interpreta igual en todos los dominios. Una llamada por incendio forestal requiere evaluar propagación, simultaneidad y amenaza a población o infraestructuras. Un accidente de tráfico exige valorar atrapamiento, heridos, accesibilidad y número de afectados. Una fuga química requiere identificar intoxicación, transporte de mercancías peligrosas y potencial de escalado. Por tanto, la categoría preliminar no es una etiqueta decorativa, sino una entrada que ayuda a activar las reglas correctas.

En v0.1.0, la taxonomía se deriva de dos fuentes: el catálogo de riesgos y categorías operativas recogido en la normativa, y los campos textuales del Registro 112 CyL. El campo estructurado de tipo de incidente resulta útil como orientación inicial, pero el sistema no debe depender exclusivamente de él. La descripción textual y el título del

incidente son necesarios para detectar señales como `herido grave`, `atrapado`, `incendio`, `rescate`, `intoxicacion` o `varias llamadas`.

La taxonomía cumple tres funciones. Primero, reduce ambigüedad al normalizar incidentes heterogéneos. Segundo, conecta cada incidente con variables operativas V01–V15. Tercero, mejora la explicabilidad, porque permite justificar la prioridad con factores coherentes con la naturaleza del suceso. Esta taxonomía se desarrolla en el Anexo A y se utiliza de forma transversal en los capítulos de diseño, datos y evaluación.

3.7. Fuentes de datos y corpus normativo

El prototipo combina dos tipos de fuentes. Por un lado, el Registro de Emergencias del 112 de Castilla y León aporta incidentes reales, texto operativo, fechas, localización y campos útiles para probar la ingesta, limpieza y extracción de señales (Junta de Castilla y León, s. f.). Por otro, el corpus normativo CyL alimenta la capa RAG y las herramientas MCP encargadas de recuperar citas legales, explicar reglas y sostener normativamente las recomendaciones.

La Tabla 3.1 resume el rol de las fuentes principales en el sistema.

El uso del Registro 112 CyL requiere una cautela esencial: el dataset no contiene una prioridad oficial P1–P4. Por ello, la etiqueta empleada en el proyecto es académica y se construye mediante supervisión débil a partir de varios anotadores, reglas y criterios derivados de la guía de etiquetado. Esta decisión evita presentar como verdad institucional una prioridad que no existe en la fuente original.

El corpus normativo, por su parte, no se utiliza para entrenar directamente el motor de prioridad. Su función principal es sostener la capa de explicación: buscar fragmentos relevantes, recuperar bases legales, citar normas y mostrar al operador por qué una regla o una prioridad tienen respaldo documental. Esta separación entre datos empíricos, reglas de priorización y fuentes normativas es clave para mantener la trazabilidad del sistema.

3.8. Trazabilidad normativa de variables y reglas

La Tabla 3.2 sintetiza la traducción del marco normativo a criterios de modelado. No debe leerse como una equivalencia jurídica exacta, sino como una matriz de trazabilidad: indica qué norma justifica cada grupo de variables o reglas dentro del prototipo.

Fuente	Rol en el TFM	Uso principal
Registro 112 CyL	Fuente empírica real	Ingesta, limpieza, texto libre, coordenadas, señales operativas y validación del pipeline
Ley 17/2015 y RD 524/2023	Marco estatal	Conceptos de riesgo, emergencia, planificación, catálogo de riesgos y gradación de respuesta
Ley 4/2007 CyL y PLANCAL	Marco autonómico	Coordinación, inmediatez, guía de etiquetado P1-P4 y trazabilidad territorial
INFOCAL, INUNCYL, MPCyL	Riesgos específicos	Incendios forestales, inundaciones y mercancías peligrosas; reglas y citas normativas
RGPD, LOPDGDD, Ley 11/2022	Datos y comunicaciones	Minimización, localización, seguridad, logs y exclusión de variables sensibles o no necesarias
Reglamento UE 2024/1689	IA responsable	Supervisión humana, transparencia, trazabilidad, gestión del riesgo y robustez

Tabla 3.1: Fuentes principales y función dentro del sistema.

Norma / fuente	Criterio operativo	Variable o señal	Uso en el sistema
Ley 17/2015	Protección de la vida, daños personales, vulnerabilidad	V01, V02, V03, V05, <code>signal.herido_grave</code> , <code>signal.atrapado</code>	Reglas duras P1 y aumento de prioridad
RD 524/2023	Catálogo de riesgos y planificación	V04	Taxonomía y normalización de tipo de incidente
PLEGEM	Coordinación ampliada y multirriesgo	V13, V14	Señales de escalado y complejidad
Ley 4/2007 CyL	Coordinación, inmediatez y capacidad de respuesta	V07, V15	Ajuste por emplazamiento crítico y accesibilidad
PLANCAL	Fases, situaciones y lógica territorial de respuesta	Escala P1–P4 académica	Guía de etiquetado y explicación
INFOCAL	Incendio forestal y propagación	V12, <code>signal.incendio</code>	Reglas P2/P1 según riesgo de propagación
INUNCYL	Inundación y riesgo territorial	V09, V10, <code>signal.meteo.inundacion</code>	Anclaje v0.2.0; contexto RAG en v0.1.0
MPCyL	Mercancías peligrosas y riesgo químico	<code>signal.intoxicacion</code>	Regla de alta prioridad para fuga, intoxicación o cisterna
Registro 112 CyL	Incidentes reales y texto operativo	Título, descripción, fecha, provincia, coordenadas	Fuente empírica; no contiene etiqueta P1–P4
RGPD y LOPDGDD	Minimización y protección de datos	Política de exclusión	Logs, hashes, retención y no reidentificación
Reglamento UE 2024/1689	Supervisión humana y trazabilidad	Arquitectura HITL, logs, explicaciones	Recomendación no vinculante y auditoría

Tabla 3.2: Trazabilidad normativa entre criterios, variables y uso previsto en el prototipo.

3.9. Alcance v0.1.0 y elementos diferidos

La excelencia del proyecto depende tanto de lo que se incluye como de lo que se decide diferir. En v0.1.0 se prioriza un núcleo evaluable: variables textuales y operativas centrales, RuleFit como motor interpretable, explicación con LLM local, RAG normativo, backend auditable y supervisión humana. Esta versión activa las variables V01–V07 y V12–V15, junto con las señales textuales necesarias para detectar riesgo vital, heridos, atrapamiento, intoxicación, incendio, rescate, accidente de tráfico, varias llamadas y riesgo meteorológico textual.

Quedan diferidas a v0.2.0 las variables que requieren integraciones contextuales más costosas: avisos AEMET, condición meteorológica adversa, zonas inundables SNCZI y proximidad a instalaciones Seveso. Estas variables mantienen su anclaje normativo en el capítulo y en el modelo de datos, pero no forman parte del núcleo entrenado y evaluado en v0.1.0. Esta exclusión responde a una decisión de diseño orientada a preservar la reproducibilidad metodológica y el aislamiento del entorno de entrenamiento local del modelo base, evitando introducir dependencias externas inestables o fuentes de datos dinámicas que podrían comprometer la verificación controlada de la tesis, sin renunciar a una línea clara de evolución futura. No obstante, se reconoce el riesgo de que la exclusión temporal de estas variables geográficas, hidrológicas y climatológicas debilite la precisión del modelo en la priorización de incidentes de inundación o de riesgos tecnológicos muy específicos. Este riesgo se asume de forma controlada en la versión v0.1.0, delegando la salvaguarda de estos escenarios en la supervisión humana del flujo de trabajo (HITL) y posponiendo su automatización para la fase de expansión del prototipo.

3.10. Conclusiones del capítulo

El marco operativo y normativo analizado permite fijar cinco conclusiones clave para el desarrollo del resto de este Trabajo Fin de Máster. Estas deducciones metodológicas sintetizan la relación entre la práctica operacional y las limitaciones predictivas del sistema. Las lecciones extraídas se detallan en los siguientes puntos:

En primer lugar, el sistema debe entenderse como apoyo a la decisión, no como sustituto del operador. Esta conclusión deriva tanto de la naturaleza de la protección civil como del marco europeo de inteligencia artificial.

En segundo lugar, la prioridad operativa no puede reducirse a una única señal. La gravedad actual, la vulnerabilidad, la exposición, la propagación, la simultaneidad, la accesibilidad y la incertidumbre informativa deben combinarse mediante contratos y reglas trazables.

En tercer lugar, la escala P1–P4 es académica y funcional. Se inspira en la lógica de gradación de la normativa, especialmente PLANCAL, pero no equivale a situaciones operativas oficiales ni pretende reemplazarlas.

En cuarto lugar, el Registro 112 CyL aporta realismo empírico, pero no una verdad supervisada de prioridad. Por eso el proyecto necesita supervisión débil, validación interna y comparación explícita entre *baseline* experto, RuleFit-lite e *imodels*.

En quinto lugar, la trazabilidad normativa no es un adorno documental: es parte de la arquitectura. Cada recomendación debe poder conectarse con variables, reglas, citas legales, versión de modelo y decisión humana final. Esta exigencia enlaza directamente con los capítulos siguientes, donde se desarrollan la metodología, la arquitectura de tres capas, el diseño de datos y la evaluación del prototipo.

4. Objetivos y metodología de trabajo

Este capítulo define la dirección estratégica del proyecto mediante la formulación de sus objetivos y la metodología adoptada para su desarrollo. En primer lugar, se enuncia el objetivo general del Trabajo Fin de Máster y se desglosan los objetivos específicos que marcan el plan de trabajo. A continuación, se detalla la metodología de desarrollo incremental basada en capas y las fases del ciclo de vida del software. Finalmente, se describe la organización interna del grupo de trabajo y el control de contribuciones individuales, garantizando la trazabilidad y la calidad de los entregables.

4.1. Introducción al capítulo

Este capítulo conecta el problema descrito en los capítulos anteriores con la estrategia seguida para resolverlo. El TFM no plantea una herramienta genérica de emergencias, sino un prototipo software de apoyo a la decisión para priorización temprana de incidentes 112 en Castilla y León. La línea de trabajo se articula alrededor de datos reales abiertos, una etiqueta académica P1–P4 construida mediante supervisión débil, una Capa 2 interpretable basada en RuleFit-lite y una Capa 3 orientada a explicar la recomendación con trazabilidad normativa.

La finalidad del capítulo es fijar con claridad qué se pretende conseguir, qué preguntas guían el desarrollo, qué aportación de inteligencia artificial realiza el trabajo y cómo se ha organizado el equipo para avanzar de forma incremental sin perder coherencia entre prototipo, evaluación y memoria. A través de esta estructura, se busca facilitar la replicabilidad de todo el proceso metodológico llevado a cabo por el grupo. De este modo, cada hito del desarrollo de software queda plenamente justificado por objetivos científicos y académicos concretos.

4.2. Objetivo general

El objetivo general de este Trabajo Fin de Máster (TFM) es:

Diseñar, implementar y evaluar un prototipo software modular de apoyo a la decisión

para la priorización inicial de incidentes 112 en Castilla y León, capaz de transformar texto operativo y datos parciales en una recomendación P1–P4 explicable, trazable y revisable, mediante una arquitectura de tres capas que combine extracción NLP, aprendizaje interpretable con RuleFit-lite, explicación normativa local y supervisión humana obligatoria.

El objetivo es específico porque delimita dominio, territorio, usuario y salida esperada. Es medible porque la Capa 2 se evalúa mediante métricas reproducibles como macro-F1, recall P1, matriz de confusión, falsos negativos críticos, estabilidad temporal y análisis por subgrupos. Es alcanzable porque se apoya en datos abiertos del Registro 112 Castilla y León, scripts versionados y un prototipo académico acotado. Es relevante porque aborda una decisión de alto impacto en emergencias sin sustituir al operador. Y es temporalmente delimitado porque se concreta en una versión v0.1.0 evaluable dentro del alcance del TFM.

4.3. Objetivos específicos

El objetivo general se descompone en ocho objetivos específicos:

- OE1. Analizar el problema de la priorización temprana de incidentes 112, identificando necesidades del operador, restricciones de información y riesgos de automatización en un dominio crítico.
- OE2. Revisar el marco normativo estatal y autonómico aplicable a Castilla y León, extrayendo criterios de gravedad, coordinación, escalado y trazabilidad que fundamentan el sistema.
- OE3. Definir la taxonomía operativa, la escala académica P1–P4 y las variables V01–V15, separando variables disponibles en primera decisión de variables contextuales diferidas o potencialmente sujetas a *leakage*.
- OE4. Auditar el Registro de Emergencias 112 de Castilla y León, construir el dataset limpio, documentar limitaciones y generar etiquetas académicas P1–P4 mediante supervisión débil.
- OE5. Diseñar e implementar una Capa 2 interpretable, comparar una línea base heurística con RuleFit-lite y una ejecución diagnóstica de `imodels`, seleccionar el modelo mediante la partición de validación y reservar la partición de prueba para la estimación final.

- OE6. Diseñar una Capa 3 de explicación que convierta reglas, probabilidades, evidencias y citas normativas en una justificación comprensible para el operador, sin delegar la decisión en un LLM.
- OE7. Integrar las capas mediante contratos versionados, servicio web auditable, modo degradado, registros de inferencia y mecanismos de retroalimentación humana.
- OE8. Evaluar el prototipo con particiones estratificada y temporal, control de fugas de información, estudio de errores P1, análisis por subgrupos, preparación de una muestra de revisión interna y evaluación automatizada de fidelidad explicativa.

En relación con OE5, la Capa 2 queda preparada para su consumo por la Capa 3 mediante una salida explicable que incluye prioridad recomendada, reglas activadas, detalles de decisión y contexto estructurado para la explicación. Esta salida, materializada en campos como `priority_details` y `explanation_context`, permite que la Capa 3 genere una explicación operativa sin recalcular ni sustituir la prioridad asignada por el modelo interpretable. Esta separación lógica garantiza que el razonamiento estadístico y la fundamentación jurídica se mantengan independientes y auditables.

En relación con OE8, se ha preparado una muestra de 119 casos, compuesta por 59 falsos negativos P1 y 60 casos equilibrados adicionales. La plantilla permite registrar futuras decisiones humanas, pero sus campos de revisión permanecen sin cumplimentar en v0.1.0. De forma independiente, la fidelidad de las explicaciones se evalúa automáticamente sobre esos mismos casos mediante un juez determinista reproducible.

Esta secuencia mantiene una progresión lógica de desarrollo científico y de ingeniería. En primer lugar, se delimita el dominio conceptual y normativo; en segundo lugar, se construye una base empírica sólida y libre de filtraciones; y, finalmente, se evalúa el comportamiento desde una perspectiva técnica, explicativa y humana. Este orden secuencial asegura que cada fase de la ingeniería del sistema se apoye en los resultados verificados del paso anterior.

Fuente: elaboración propia a partir de los artefactos reproducibles del proyecto.

4.4. Preguntas de investigación

Las preguntas de investigación orientan el diseño y la evaluación del sistema:

Obj.	Evidencia principal	Artefacto o ubicacion	Criterio de cumplimiento
OE1	Planteamiento del problema, usuario y riesgos de automatización	Capítulos 1 y 4	Dominio, alcance y supervisión humana delimitados
OE2	Marco estatal, autonómico y europeo	Capítulo 3; Tabla de fuentes normativas	Normas vinculadas a variables, reglas y límites
OE3	Taxonomía, variables V01–V15 y política anti- <i>leakage</i>	Anexos A y B; Capítulo 7	Variables disponibles y prohibidas documentadas
OE4	Conjunto limpio, auditoría, particiones y etiquetas débiles	Capítulo 7; Anexo C; programas de preparación	Conjunto reproducible y etiqueta académica trazable
OE5	Línea base heurística, RuleFit-lite y comparativa con <i>imodels</i>	Reportes de cada modelo y entrega de Capa 2 a Capa 3	Modelo seleccionado en validación y salida consumible por Capa 3
OE6	Explicación con LLM local, RAG, MCP y modo degradado	Capítulos 6 y 8; Anexo L	Capa 3 explica sin recalcular prioridad
OE7	Integración Capa 1–Capa 2–Capa 3 y prueba de funcionamiento	Reportes de integración y prueba del prototipo	5/5 escenarios integrados y 4/4 casos con Ollama
OE8	Evaluación final, errores P1, muestra preparada y fidelidad automatizada	Reporte final de evaluación y trazabilidad	59 falsos negativos P1, 119 casos preparados y fidelidad reproducible

Tabla 4.1: Relación entre objetivos específicos, evidencias y criterios de cumplimiento.

- PI1. ¿Puede construirse una etiqueta académica P1–P4 defendible cuando el conjunto abierto no contiene prioridad oficial?
- PI2. ¿Qué aporta un modelo interpretable como RuleFit-lite frente a una línea base heurística basada en señales textuales y reglas operativas?
- PI3. ¿Es posible mantener una sensibilidad P1 suficiente sin convertir el sistema en una herramienta excesivamente conservadora que degrade el rendimiento global?
- PI4. ¿Hasta qué punto los resultados se mantienen estables en una partición temporal posterior?
- PI5. ¿Qué errores críticos aparecen, especialmente falsos negativos P1, y qué evidencia debe mostrarse para que puedan ser revisados por humanos?
- PI6. ¿Las explicaciones generadas por Capa 3 son fieles a las reglas, probabilidades y evidencias producidas por Capa 2?

Estas preguntas evitan presentar el TFM como una promesa de automatización total. El foco está en demostrar si una arquitectura responsable puede producir recomendaciones útiles, explicables y auditables dentro de un prototipo académico. Asimismo, la resolución de cada interrogante metodológica ayuda a esclarecer el papel de las explicaciones locales en sistemas sociotécnicos de alta criticidad.

4.5. Contribución en inteligencia artificial

La contribución de IA comprende la transformación de información operativa en variables estructuradas, la construcción de etiquetas mediante supervisión débil, la comparación de alternativas interpretables y la separación entre priorización y explicación. La evaluación se respalda con métricas, artefactos reproducibles, una muestra preparada para revisión y un análisis automatizado de fidelidad.

La selección de RuleFit-lite se justifica por su rendimiento en validación, su sensibilidad ante P1, la posibilidad de exportar reglas y su menor coste respecto a la ejecución diagnóstica de `imodels`. La partición de prueba se reserva para estimar el rendimiento final del modelo ya seleccionado.

4.6. Enfoque metodológico

El desarrollo sigue un enfoque iterativo e incremental adaptado a un TFM grupal. El equipo ha trabajado por bloques trazables: definición del dominio, datos, arquitectura, Capa 2, Capa 3, integración, evaluación y redacción. Este enfoque permitió contrastar la línea base heurística con RuleFit-lite y `imodels`.

La metodología no se presenta como Scrum formal. No hay roles ceremoniales ni sprints cerrados en sentido industrial. Se adopta, en cambio, la lógica incremental: cada bloque genera un artefacto verificable, se contrasta con el capítulo correspondiente y se integra en la planificación de tareas. Esta forma de trabajo resulta especialmente adecuada porque el TFM combina investigación aplicada, desarrollo software y redacción académica.

La metodología prioriza la evidencia reproducible frente a afirmaciones operativas no verificadas. Cada decisión técnica se vincula con un artefacto: conjunto limpio, guía de etiquetado, particiones, línea base heurística, RuleFit-lite, reportes de evaluación y pruebas integradas. Los reportes generados el 17 de junio de 2026 constituyen la referencia canónica de evaluación v0.1.0.

4.7. Fases de desarrollo

El proceso de diseño e implementación del prototipo se ha estructurado de manera rigurosa y ordenada. Para ello, se definieron una serie de hitos temporales que facilitan el control de los entregables y la coherencia metodológica. En concreto, el trabajo se ha estructurado en siete fases que se detallan a continuación:

1. **Delimitación del dominio.** Análisis del problema 112, marco normativo estatal y autonómico, alcance territorial CyL y principios de supervisión humana.
2. **Datos y variables.** Auditoría del Registro 112 CyL, definición de V01–V15, identificación de columnas prohibidas por *leakage* y construcción del dataset limpio.
3. **Supervisión débil.** Generación de etiquetas académicas P1–P4, medición de acuerdo, ablación anti-circularidad y construcción de splits estratificado y temporal.
4. **Capa 2 interpretable.** Implementación de la línea base heurística, RuleFit-lite e `imodels`; extracción de reglas, pesos, probabilidades y métricas por clase.

5. **Capa 3 explicativa e integración.** Diseño del RAG normativo, herramientas MCP, modo degradado, backend, contratos y logs de inferencia.
6. **Evaluación y trazabilidad.** Evaluación final, análisis por subgrupos, errores P1, muestra preparada para revisión, fidelidad automatizada y reporte maestro.
7. **Redacción y coherencia final.** Alineación de capítulos, anexos, métricas, limitaciones y trabajo futuro para que la defensa refleje exactamente el sistema construido.

4.8. Consideraciones éticas

El sistema se diseña para un dominio de alto impacto, por lo que incorpora salvaguardas desde el principio. La primera es la supervisión humana: el prototipo recomienda, pero no moviliza recursos ni activa planes. La segunda es la explicabilidad: toda recomendación debe acompañarse de reglas, probabilidades, evidencias y, cuando proceda, citas normativas. La tercera es el control anti-*leakage*: se excluyen campos posteriores a la decisión para no entrenar un modelo que aprenda consecuencias del operativo. La cuarta es la soberanía del dato: la inferencia se concibe en local y sin dependencia de APIs externas para datos sensibles.

También se documenta el uso de herramientas de IA generativa como apoyo a la elaboración del TFM. Dichas herramientas se han empleado para organización, redacción preliminar y revisión de coherencia, pero las decisiones técnicas, metodológicas y académicas corresponden al equipo y se contrastan con los artefactos reproducibles del proyecto. La autoría intelectual del análisis y del código final recae exclusivamente en los firmantes de esta memoria.

4.9. Conclusiones del capítulo

Los objetivos, preguntas y metodología definidos en este capítulo fijan una línea de trabajo coherente con el resto de la memoria: un prototipo académico, territorialmente centrado en Castilla y León, que usa datos reales abiertos, supervisión débil, un modelo interpretable y explicaciones trazables. Esta formulación permite que los capítulos posteriores no dependan de promesas abstractas, sino de artefactos concretos: dataset limpio, splits, modelos, métricas, anexos de validación y reporte final de evaluación. De esta manera, se garantiza el carácter empírico y la transparencia de las conclusiones obtenidas a

lo largo de todo el trabajo.

5. Identificación de requisitos del sistema

5.1. Introducción al capítulo

En un TFM de desarrollo software, los requisitos son el puente entre el análisis del dominio y la implementación. Este capítulo traduce el problema de priorización temprana de incidentes 112 en especificaciones funcionales, no funcionales y restricciones de alcance. La versión final del sistema se concibe como un prototipo académico de apoyo a la decisión para Castilla y León, no como una plataforma productiva de despacho ni como un sustituto del operador.

Las decisiones recogidas aquí condicionan la arquitectura descrita en el Capítulo 6, el tratamiento de datos del Capítulo 7 y la evaluación experimental del Capítulo 9. Por ello, los requisitos se formulan ya alineados con la línea técnica consolidada: Capa 1 NLP, Capa 2 RuleFit-lite, Capa 3 LLM+RAG+MCP, supervisión humana, anti-*leakage* y trazabilidad reproducible.

5.2. Definición formal del problema

El sistema aborda el siguiente problema: dado un incidente 112 descrito mediante texto libre, categoría preliminar, localización, fecha y datos operativos parciales, se necesita generar una recomendación inicial de prioridad P1–P4 que ayude al operador a formar una primera valoración, sin sustituir su criterio profesional.

La unidad de análisis es el incidente individual. La prioridad P1–P4 no es una etiqueta oficial del Registro 112 de Castilla y León; es una construcción académica del prototipo, creada para estudiar la viabilidad de una recomendación explicable basada en variables operativas, supervisión débil y aprendizaje interpretable. La recomendación debe ir acompañada de evidencia suficiente para que pueda ser aceptada, corregida o rechazada por una persona.

El sistema se diferencia de un clasificador automático convencional en tres aspectos. Primero, opera en condiciones de información incompleta. Segundo, debe evitar usar datos posteriores a la primera decisión. Tercero, debe explicar la salida de forma comprensible,

porque en emergencias la confianza depende tanto del resultado como de la capacidad de auditarlo.

5.3. Usuario objetivo y contexto de uso

El usuario objetivo es un responsable de coordinación, jefe de sala, operador avanzado o perfil equivalente que deba valorar incidentes en un entorno 112. Se presupone conocimiento del dominio y capacidad para interpretar una recomendación como apoyo, no como orden automática. El prototipo puede utilizarse sobre registros históricos, cargas controladas o entradas manuales, siempre dentro de un entorno académico o de prueba.

El sistema no moviliza recursos, no activa planes, no envía alertas y no toma decisiones jurídicamente vinculantes. Su función es ordenar la información, proponer una prioridad inicial y mostrar las razones principales de esa propuesta.

5.4. Requisitos funcionales

RF1. Recepción y normalización del incidente El sistema debe recibir incidentes desde carga de dataset o entrada controlada y transformarlos en un registro normalizado con identificador, texto operativo, categoría, fecha, provincia, municipio, coordenadas cuando existan y campos auxiliares permitidos.

RF2. Extracción de variables y señales La Capa 1 debe extraer variables operativas V01–V15 y señales textuales relevantes para la priorización. En v0.1.0 el núcleo evaluable se centra en las variables disponibles de forma reproducible y deja V08–V11 como extensión futura cuando se integren AEMET, SNCZI y Seveso.

RF3. Control de columnas prohibidas El sistema debe excluir de entrenamiento e inferencia los campos posteriores a la decisión o que reflejen consecuencias del operativo, como `MediosMov`, `PacientesAten`, `IncidenteCerrado` o `ultimaActualizacion`. Este requisito es obligatorio para evitar fuga de información.

RF4. Generación de etiqueta académica Cuando no exista prioridad oficial P1–P4, el sistema debe construir etiquetas académicas mediante supervisión débil, usando fuentes de señal separadas y midiendo acuerdo. La etiqueta resultante debe documentarse como aproximación metodológica, no como verdad operativa oficial.

RF5. Recomendación de prioridad P1–P4 La Capa 2 debe generar una recomendación de prioridad mediante un modelo interpretable. En v0.1.0 el modelo seleccionado es RuleFit-lite, comparado con un baseline experto y con una ejecución diagnóstica `imodels`. La salida debe incluir prioridad, probabilidades por clase, reglas o señales activadas y versión del modelo.

RF6. Cálculo de confianza e incertidumbre El sistema debe exponer información sobre confianza o incertidumbre asociada a la recomendación, especialmente cuando falten variables relevantes o cuando la predicción se apoye en señales débiles. La confianza no debe confundirse con gravedad.

RF7. Generación de explicación La Capa 3 debe generar una explicación breve y trazable que conecte la prioridad recomendada con reglas, probabilidades, evidencias disponibles y, cuando proceda, citas normativas recuperadas del corpus CyL. El LLM no decide la prioridad: explica la salida de Capa 2.

RF8. Validación humana El sistema debe permitir que una persona (operador del 112) revise la recomendación del DSS y registre una decisión explícita (aceptación, modificación o rechazo). Esta intervención humana (HITL) debe ser obligatoria para cerrar el caso y guardarse a nivel de base de datos mediante la persistencia del contrato estructurado `OperatorDecision`, vinculando la prioridad asignada y la justificación de cualquier discrepancia.

RF9. Registro auditable Cada inferencia debe quedar registrada de forma inalterable y asociada a su entrada original, variables extraídas por la Capa 1, modelo de Capa 2 y su versión, prioridad recomendada, probabilidades calculadas, explicación de Capa 3, y la decisión humana final (`OperatorDecision`) si ya fue registrada. Esta persistencia garantiza la trazabilidad exigida por las normativas de IA de alto riesgo (Parlamento Europeo y Consejo de la Unión Europea, 2024), sustentando la auditoría técnica y la defensa académica.

RF10. Reevaluación El sistema debe poder reevaluar un incidente cuando cambien los datos de entrada, conservando el historial de recomendaciones para reconstruir la evolución del caso.

5.5. Requisitos no funcionales

5.5.1. Explicabilidad

La recomendación debe ser interpretable para un operador. Este requisito justifica que la Capa 2 use un modelo con reglas exportables y que la Capa 3 traduzca esas evidencias a lenguaje operativo. No basta con predecir una clase; el sistema debe mostrar por qué la propone.

5.5.2. Trazabilidad

Toda salida debe poder reconstruirse desde los datos de entrada hasta la explicación final. La trazabilidad incluye scripts de datos, weak labels, splits, modelo entrenado, reglas activas, métricas, logs y decisiones humanas registradas.

5.5.3. Supervisión humana

Ninguna recomendación debe ejecutarse automáticamente. La persona responsable conserva la decisión final y puede corregir la prioridad propuesta. Este principio es coherente con el Reglamento Europeo de Inteligencia Artificial (Parlamento Europeo y Consejo de la Unión Europea, 2024) y con la prudencia exigible en un dominio de alto impacto.

5.5.4. Robustez ante información incompleta

El sistema debe funcionar con información parcial, porque esa es la situación habitual en la primera decisión. Cuando la información sea insuficiente, la herramienta debe indicarlo y evitar presentar una certeza artificial.

5.5.5. Reproducibilidad

Los resultados deben poder regenerarse con scripts versionados. Esto incluye auditoría del dataset, construcción de etiquetas, splits, entrenamiento, evaluación, análisis de errores, muestra de validación interna y reporte final.

5.5.6. Soberanía del dato

El prototipo debe priorizar ejecución local y evitar dependencias cloud para datos sensibles. Las herramientas generativas se tratan como apoyo explicativo, no como mecanismo

autónomo de decisión.

5.6. Restricciones y supuestos

5.6.1. Restricciones metodológicas y del prototipo

La primera restricción es que se trabaja con un prototipo académico, no con un sistema certificado ni desplegado en una sala 112 real. La segunda es que el Registro 112 de Castilla y León no contiene prioridad oficial P1–P4, por lo que la evaluación se realiza contra una etiqueta académica de supervisión débil. La tercera es que no se dispone todavía de validación externa con operadores del 112; por eso se prepara una muestra de validación interna y se documenta como paso previo.

La cuarta restricción es que algunas variables contextuales de alto interés, como AE-MET histórico, inundabilidad SNCZI y proximidad Seveso, quedan diferidas a v0.2.0. La quinta es que la evaluación no mide reducción real del tiempo de decisión en sala, sino rendimiento técnico, estabilidad temporal, errores críticos, fidelidad explicativa y trazabilidad documental.

Estas restricciones no invalidan el trabajo. Lo delimitan y evitan prometer más de lo que el prototipo puede demostrar. La excelencia del TFM se apoya precisamente en reconocer esas fronteras y en dejar un camino verificable para ampliarlas.

5.6.2. Supuestos y dependencias tecnológicas

El funcionamiento y la viabilidad operativa del prototipo v0.1.0 dependen de varios supuestos tecnológicos específicos de ejecución local. En primer lugar, se asume el tipado estricto y la validación automática en tiempo de ejecución mediante contratos de datos desarrollados con la librería `Pydantic`, lo que garantiza que los datos fluyan sin corrupción entre las capas. En segundo lugar, se asume la disponibilidad y correcta ejecución local de la suite de inferencia `Ollama` cargando el modelo compacto `Llama 3.1:8B` (o su equivalente configurado `Qwen 2.5:7B-instruct`) para la generación de explicaciones textuales coherentes y sin alucinaciones.

Existe un riesgo tecnológico relevante asociado a la latencia y la disponibilidad: si el hardware del puesto de trabajo local carece de una GPU dedicada o compartida suficiente para albergar y ejecutar `Ollama`, el tiempo de inferencia del LLM puede aumentar significativamente o fallar, comprometiendo la disponibilidad del DSS en entornos de alta

presión de despacho, lo que obliga al sistema a recurrir de forma segura a su modo de operación degradado (basado en plantillas deterministas).

5.7. Trazabilidad entre requisitos y componentes

Req.	Descripción resumida	Componente asociado	Evidencia
RF1	Recepción y normalización	Pipeline de datos y backend	Dataset limpio y contratos
RF2	Extracción de variables	Capa 1 NLP	Variables V01–V15 y señales
RF3	<i>Anti-leakage</i>	Pipeline y Capa 2	Columnas prohibidas excluidas
RF4	Weak labels P1–P4	Supervisión débil	Acuerdo y ablación
RF5	Prioridad P1–P4	RuleFit-lite	Modelo, reglas y métricas
RF6	Confianza	Capa 2 e inferencia	Probabilidades por clase
RF7	Explicación	Capa 3 LLM+RAG+MCP	Explicación y citas
RF8	Validación humana	UI y feedback	Muestra de revisión interna
RF9	Registro auditable	Backend y logs	InferenceLog
RF10	Reevaluación	Orquestador	Historial de inferencias

Tabla 5.1: Trazabilidad entre requisitos y componentes del sistema.

Fuente: elaboración propia.

5.8. Conclusiones del capítulo

Los requisitos definidos convierten el problema operativo en una especificación coherente con la arquitectura final. El sistema debe recibir incidentes, extraer variables, evitar leakage, recomendar prioridad mediante Capa 2 interpretable, explicar la salida mediante Capa 3, registrar la trazabilidad y mantener siempre la decisión humana en el centro.

El siguiente capítulo desarrolla la arquitectura que materializa estos requisitos: una solución modular de tres capas, preparada para evaluación reproducible y para una futura validación externa con personal experto.

6. Arquitectura y diseño del sistema inteligente

Este capítulo describe la arquitectura de software y el diseño detallado del sistema inteligente de priorización. En primer lugar, se enuncian los principios de diseño que rigen todo el desarrollo, tales como la explicabilidad y el control humano de la decisión. A continuación, se detalla la organización modular del sistema estructurada en tres capas diferenciadas: extracción textual, modelo predictivo e interpretación normativa. Por último, se describe la especificación de las interfaces y los contratos de datos que garantizan la consistencia del flujo de información a lo largo de toda la canalización.

6.1. Finalidad del capítulo

Este capítulo presenta el diseño técnico y analítico del sistema propuesto. Tras haber fijado el problema, el estado del arte y el marco normativo, aquí se describe cómo se transforma un incidente 112 en una recomendación de prioridad P1–P4 explicable, auditable y revisable por un operador humano. El modelado en tres capas independientes constituye la respuesta técnica a la necesidad de aislar la toma de decisiones estadísticas de la generación lingüística explicativa.

La versión actual del TFM abandona el diseño inicial basado únicamente en reglas duras y *scoring*. Esta decisión responde a la necesidad de dotar al prototipo de una mayor capacidad de generalización sobre registros reales. En consecuencia, la arquitectura final se organiza en tres capas de inteligencia artificial, coordinadas mediante contratos de datos versionados:

- **Capa 1: NLP operativo.** Extrae variables V01–V15 y señales textuales desde el título, descripción, categoría preliminar y contexto básico del incidente.
- **Capa 2: priorización interpretable.** Produce una recomendación P1–P4 mediante RuleFit-lite, entrenado sobre etiquetas académicas generadas por supervisión débil, y comparado contra un baseline experto y una ejecución diagnóstica con `imodels`.
- **Capa 3: explicación normativa.** Genera una explicación breve para el operador

mediante LLM local, recuperación aumentada sobre corpus normativo de Castilla y León y herramientas MCP.

El resultado no es un sistema autónomo de despacho, sino un sistema de apoyo a la decisión. La prioridad recomendada no sustituye el criterio profesional; se ofrece como una propuesta estructurada, con reglas activadas, probabilidad, confianza, citas legales y registro auditable. Al delegar la responsabilidad final en el operador, se asegura el alineamiento con las directrices regulatorias europeas sobre el uso ético de algoritmos de decisión.

6.2. Principios de diseño

El diseño se apoya en seis principios que conectan los capítulos previos con la implementación.

Primero, supervisión humana. El operador acepta, modifica o rechaza la recomendación. El sistema nunca moviliza recursos por sí mismo ni declara situaciones operativas oficiales.

Segundo, explicabilidad desde el núcleo. La prioridad se calcula mediante un modelo interpretable, no mediante un LLM generativo. El LLM explica una decisión ya producida por Capa 2; no decide la prioridad.

Tercero, contratos antes que integración. Cada capa intercambia objetos Pydantic versionados. Esto reduce ambigüedad, facilita pruebas y permite que los tres bloques de trabajo avancen en paralelo.

Cuarto, soberanía del dato. La inferencia se plantea en local. No se envían incidentes a APIs externas en producción, y la Capa 3 usa un LLM cuantizado ejecutado en hardware propio.

Quinto, trazabilidad normativa. Las variables, reglas y explicaciones se vinculan con normas del corpus CyL: Ley 17/2015, RD 524/2023, Ley 4/2007 CyL, PLANCAL, INFOCAL, INUNCYL, MPCyL, RGPD, LOPDGDD y Reglamento UE 2024/1689.

Sexto, prevención de *leakage*. El sistema no utiliza columnas posteriores a la decisión, como medios movilizados, pacientes atendidos o cierre del incidente. Estas variables pueden analizarse solo como información ex post de evaluación, nunca como entrada de Capa 1 o Capa 2.

6.3. Vista general de la arquitectura

La arquitectura se representa como una cadena de transformaciones controladas. La entrada inicial es un `IncidentInput`; la Capa 1 produce `IncidentFeatures`; la Capa 2 produce `PriorityRecommendation`; la Capa 3 produce `OperatorRecommendation`; y la decisión final del operador se registra como `OperatorDecision`. Todo el proceso queda recogido en un `InferenceLog`. Esta secuencia estructurada asegura que no existan dependencias circulares entre las diferentes fases del ciclo de inferencia.

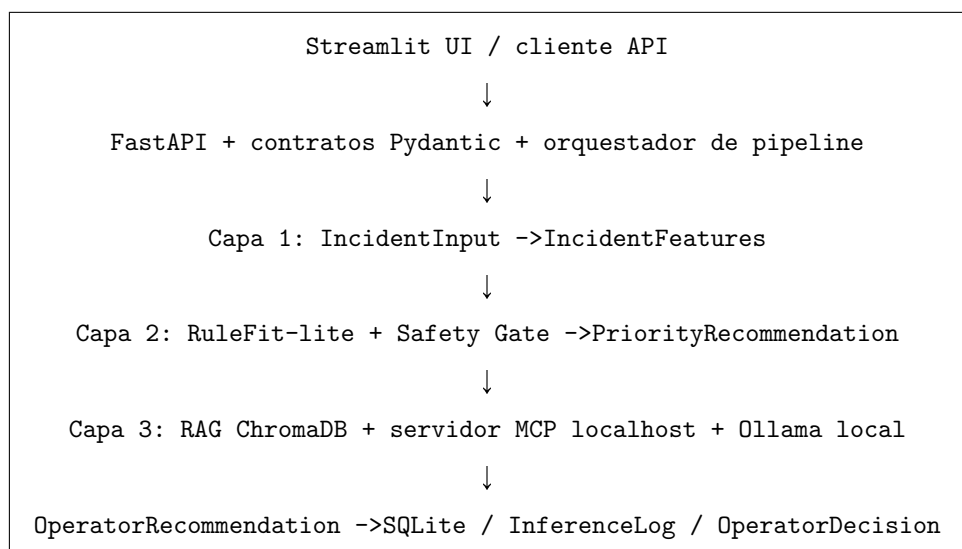


Figura 6.1: Arquitectura integrada de tres capas con contratos versionados y componentes locales.

4.1 Esta separación evita mezclar responsabilidades. La Capa 1 no decide prioridad; estructura el incidente. La Capa 2 no redacta explicaciones normativas extensas; recomienda prioridad y devuelve reglas activadas. La Capa 3 no recalcula el resultado; explica lo recibido, cita normas y advierte de incertidumbres.

6.4. Contratos de datos

Los contratos son la pieza que convierte la arquitectura en un sistema verificable. Cada contrato define campos, restricciones e invariantes. La Tabla 6.1 resume los objetos principales.

El uso de contratos tiene una consecuencia metodológica importante: la memoria puede justificar el sistema sin depender de detalles accidentales de implementación. Lo relevante

Contrato	Momento de uso	Función principal
IncidentInput	Entrada cruda	Representa texto, categoría, localización, fecha, provincia y operador antes de cualquier inferencia
IncidentFeatures	Salida Capa 1	Contiene variables V01–V15, señales textuales, confianza y metadatos de extracción
PriorityRecommendation	Salida Capa 2	Contiene prioridad P1–P4, probabilidades, reglas activadas, nivel de confianza y modelo usado
OperatorRecommendation	Salida Capa 3	Contiene explicación textual, citas legales, recomendaciones no vinculantes y resumen de reglas
OperatorDecision	Feedback humano	Registra prioridad final asignada por el operador y posible divergencia
InferenceLog	Auditoría	Conserva snapshots, latencias, versiones de modelo, herramientas invocadas y hash de entrada

Tabla 6.1: Contratos principales del flujo de inferencia.

no es solo que exista código, sino que cada capa tenga entradas, salidas e invariantes comprobables. Asimismo, esta formalización facilita la validación cruzada y la auditoría interna de los componentes del software.

6.5. Entrada del sistema: IncidentInput

La entrada representa lo que el operador o un cliente externo proporciona en los primeros minutos del incidente. Incluye título, descripción, categoría preliminar, localización opcional, provincia, fecha y operador. En el caso del dataset de Castilla y León, estos campos se derivan de columnas como `Titulo`, `DescripcionBlob`, `FechaIncidente`, `Localidad` y coordenadas.

El contrato exige dos invariantes básicos. Primero, si existe latitud debe existir longitud, y viceversa. Segundo, el título o la descripción deben contener información textual mínima. Esta restricción evita ejecutar una cadena de inferencia sobre entradas vacías o inútiles.

La entrada también es el primer punto de defensa contra *leakage*. Si el cliente incluye campos como medios movilizados o pacientes atendidos, el backend debe rechazarlos con error explícito. Esta decisión protege la validez del sistema: un motor de primera decisión no puede aprender de información que solo aparece después de decidir.

6.6. Capa 1: extracción NLP de variables operativas

La Capa 1 transforma texto libre y metadatos básicos en una representación estructurada del incidente. Su salida, `IncidentFeatures`, contiene las variables operativas V01–V15, las señales textuales y metadatos de inferencia.

6.6.1. Variables activas y diferidas

El alcance v0.1.0 activa V01–V07 y V12–V15. Las variables V08–V11 permanecen en el contrato como extensión futura, pero no se entrenan ni se exigen para la evaluación principal. Esta decisión mantiene el sistema reproducible y evita depender de integraciones geoespaciales o meteorológicas todavía no consolidadas.

Var.	Nombre operativo	Función en el sistema	Estado v0.1.0
V01	Riesgo vital	Detectar amenaza directa a la vida	Activa
V02	Número de víctimas estimado	Aproximar magnitud humana	Activa
V03	Gravedad de lesiones	Distinguir leve, grave o crítica	Activa
V04	Tipo de incidente normalizado	Conectar texto con taxonomía	Activa
V05	Población vulnerable	Elevar sensibilidad por colectivos vulnerables	Activa
V06	Número de llamadas	Captar confirmación o simultaneidad	Activa
V07	Emplazamiento crítico	Identificar hospitales, colegios, residencias u otros puntos sensibles	Activa
V08– V11	AEMET, inundabilidad, Seveso	Enriquecimiento contextual avanzado	Diferidas v0.2.0
V12	Riesgo de propagación	Captar incendios u otros incidentes expansivos	Activa
V13	Multirriesgo	Detectar concurrencia de amenazas	Activa
V14	Avisos simultáneos en zona	Aproximar presión operativa y confirmación externa	Activa
V15	Accesibilidad de recursos	Modular complejidad de intervención	Activa

Tabla 6.2: Variables operativas del sistema y alcance en v0.1.0.

6.6.2. Señales textuales

Además de variables estructuradas, la Capa 1 extrae señales textuales booleanas con confianza asociada. Algunas son críticas para no infraestimar incidentes graves: `signal_herido_grave`, `signal_atrapado`, `signal_intoxicacion`, `signal_fallecido` o `riesgo_vital_textual`. Otras ayudan a contextualizar: `signal_incendio`, `signal_accidente_trafico`, `signal_rescate`, `signal_varias_llamadas` y `signal_meteo_inundacion`.

En la versión v0.1.0, la Capa 1 se implementa como extractor determinista auditable. Reglas léxicas, patrones de negación y diccionarios operativos detectan señales robustas de alto impacto, como atrapamiento, herido grave, incendio, intoxicación o riesgo vital textual. Esta decisión reduce dependencias externas, facilita los tests de contrato y evita presentar como validado un modelo neuronal que no dispone de checkpoint congelado. El uso de modelos transformer para extracción contextual queda reservado como línea futura, condicionada a entrenamiento, versionado y evaluación específica.

6.7. Capa 2: priorización interpretable con RuleFit

La Capa 2 consume `IncidentFeatures` y produce `PriorityRecommendation`. Es el núcleo decisorio del sistema. Su responsabilidad es asignar una prioridad P1–P4, generar probabilidades por clase, devolver reglas activadas y comunicar nivel de confianza.

6.7.1. Escala P1–P4

La escala P1–P4 es académica y funcional, no oficial. P1 representa incidentes críticos con riesgo vital, lesiones graves, atrapamiento, intoxicación, fallecimiento, propagación grave o amenaza inmediata. P2 representa alta prioridad, potencial de deterioro o afectación significativa. P3 recoge incidentes que requieren gestión o seguimiento sin criticidad inmediata. P4 se reserva para baja urgencia relativa.

La escala no equivale a situaciones operativas 0–3. Una situación operativa es una categoría institucional de mando y coordinación; P1–P4 ordena incidentes individuales dentro del prototipo. Esta distinción evita confundir una herramienta académica de priorización con una declaración jurídica de emergencia.

6.7.2. Supervisión débil

Como el Registro 112 CyL no contiene prioridad oficial P1–P4, el entrenamiento de Capa 2 requiere construir una etiqueta académica. La estrategia es la supervisión débil: varios anotadores imperfectos generan votos que se agregan en una etiqueta final con confianza. En la versión v0.1.0 se emplean cuatro fuentes: reglas heurísticas, extracción NLP con intensificadores, proxy semántico por agrupación y LLM-as-annotator proxy controlado.

La etiqueta débil no se presenta como verdad institucional. Es un artefacto de investigación que permite entrenar y comparar modelos sobre datos reales abiertos. Por ello debe acompañarse de acuerdo inter-anotador, análisis de discrepancias y una ablación anti-circularidad que compare el resultado sin la fuente de reglas heurísticas.

6.7.3. RuleFit como modelo principal

RuleFit se selecciona porque combina aprendizaje estadístico e interpretabilidad. El modelo genera o utiliza reglas derivadas de árboles y las pondera mediante regularización, produciendo un conjunto de reglas con coeficientes inspeccionables (Friedman y Popescu, 2008). En este TFM se impone una restricción de sparsity: el modelo productivo debe mantener como máximo 30 reglas activas con peso distinto de cero.

Esta restricción es académica, no estética. Un modelo con cientos de reglas sería difícil de defender ante un operador o un tribunal. En cambio, un conjunto reducido de reglas permite revisar por qué P1 aumenta, qué variables influyen y qué anclajes normativos sostienen la recomendación.

6.7.4. Baseline experto, RuleFit-lite e imodels

La Capa 2 no se evalúa en aislamiento. Se compara con dos referencias. El baseline experto es un conjunto de reglas transparentes basadas en señales y variables V01–V15, con anclaje normativo. Sirve como mínimo defendible: RuleFit debe aportar mejora cuantitativa sin perder explicabilidad.

La segunda referencia es `imodels.RuleFitClassifier`, utilizada como implementación canónica de RuleFit. Dado que la librería trabaja en clasificación binaria, se adopta un esquema one-vs-rest P1–P4. La versión productiva del TFM selecciona RuleFit-lite porque mantiene la filosofía RuleFit, respeta el límite de reglas activas y ofrece mejor

equilibrio entre rendimiento, latencia y reproducibilidad local.

La ejecución diagnóstica con `imodels` queda como contraste externo de la familia RuleFit. Su utilidad es comprobar si una implementación canónica aporta ventaja frente al núcleo reproducible seleccionado. En v0.1.0, RuleFit-lite se mantiene como motor principal por su equilibrio entre rendimiento, interpretabilidad, coste local y trazabilidad.

6.7.5. Probabilidad, confianza e invariantes

La salida de Capa 2 incluye una distribución de probabilidad sobre P1–P4. El contrato exige que las probabilidades sumen 1, que la prioridad recomendada coincida con el $\arg\max$ y que los incidentes P1/P2 incluyan al menos una regla activada cuando el modelo usado sea RuleFit o baseline experto. Este requerimiento de consistencia matemática y lógica impide la generación de clasificaciones contradictorias. Asimismo, obliga a que toda asignación crítica cuente con un sustento explícito y auditable en forma de predicados lógicos.

El nivel de confianza se deriva estrictamente de la probabilidad máxima del vector contractual: alta si $p_{max} \geq 0,80$, media entre 0,60 y 0,80, baja entre 0,40 y 0,60, y desconocida por debajo de 0,40. Esta confianza no mide la gravedad física del suceso. Un incidente puede ser P1 con confianza baja o media si hay indicios críticos pero información fragmentaria; del mismo modo, un caso P4 puede tener confianza alta si las señales disponibles son claras.

6.7.6. Puerta de Seguridad

Para garantizar la alineación con PLANCAL y la Ley 17/2015 de Protección Civil, el diseño de la Capa 2 incorpora un módulo post-procesador denominado Puerta de Seguridad (*Safety Gate*). Este componente implementa un patrón de aseguramiento y confiabilidad en sistemas inteligentes de decisión táctica; Kollipara et al. Kollipara, Gupta, O'Neill, y cols. (2025) describen cómo los "decision gates" verificables en flujos de Machine Learning actúan como barreras de seguridad necesarias para evitar fallos catastróficos o falsos negativos graves en dominios misión-crítica donde existen riesgos vitales humanos.

Técnicamente, el Safety Gate actúa como un sistema de filtrado duro sobre el $\arg\max$ probabilístico generado por RuleFit-lite. Su función no es sustituir el modelado interpretable estadístico, sino impedir que determinados patrones predecisionales de alto riesgo queden infrapriorizados por ruido en el texto de entrada, escasez de muestras en el entre-

namiento, o ambigüedad. Para lograr esto, evalúa condiciones deterministas basadas en el conocimiento experto de los protocolos de despacho. Este mecanismo proporciona una red de seguridad indispensable en entornos tácticos donde la velocidad de respuesta y la precisión son críticas para salvar vidas.

Conceptualmente, si RuleFit-lite produce una prioridad $\hat{y} = \arg \max_{c \in \{P1, P2, P3, P4\}} p(c)$, la Puerta de Seguridad evalúa un conjunto de predicados deterministas $S_i(x)$ sobre **IncidentFeatures**. Cuando alguno de los predicados críticos se activa, la prioridad se fuerza a *P1* o *P2*, se inyecta una regla de seguridad con peso alto y se adjuntan anclajes normativos para la explicación posterior. El vector de probabilidad se redistribuye de forma determinista con probabilidad dominante:

$$p'(y_{seguro}) = 0,97, \quad p'(c \neq y_{seguro}) = 0,01.$$

En v0.1.0, la Puerta de Seguridad fuerza *P1* ante riesgo vital, fallecido, riesgo vital textual, multirriesgo en emplazamiento crítico, incendio forestal con propagación, incendio con propagación en emplazamiento crítico, intoxicación grave, rescate complejo con baja accesibilidad o múltiples víctimas estimadas. Fuerza *P2* cuando existen señales operativas relevantes como herido grave, atrapamiento, intoxicación, rescate activo o episodio meteorológico/inundación en emplazamiento crítico, siempre que no se cumpla un criterio *P1*. Esta lógica mantiene el principio de prudencia: ante indicadores predecisionales críticos, el sistema prefiere elevar la prioridad y exigir revisión humana.

La regla inyectada por la Puerta de Seguridad se incorpora a **activated_rules** con identificadores como **SAFE-GATE-P1-RIESGO-VITAL** o **SAFE-GATE-P2-OPERATIVO**. De este modo, Capa 3 puede explicar que la recomendación no procede solo del argmax estadístico, sino también de una salvaguarda determinista trazable. La salida forzada marca **requires_human_attention=true**, reforzando que el operador conserva la decisión final.

6.8. Capa 3: explicación normativa con LLM, RAG y MCP

La Capa 3 convierte la recomendación de Capa 2 en una salida útil para el operador. Produce **OperatorRecommendation**, que incluye prioridad, explicación textual, citas legales, resumen de reglas activadas, sugerencias no vinculantes y metadatos del LLM.

6.8.1. LLM local

El LLM local se utiliza para redactar explicaciones breves y consistentes. La inferencia se plantea con temperatura 0 para reducir variabilidad y mejorar reproducibilidad. El modelo no recibe el mandato de decidir prioridad; recibe la prioridad ya calculada, las reglas activadas y el contexto normativo recuperado.

Esta separación es clave para la seguridad del diseño. Un LLM puede redactar bien, pero no debe ser la autoridad decisoria en un dominio crítico. Si el LLM falla, la recomendación P1–P4 de Capa 2 sigue siendo válida y el sistema puede operar en modo degradado.

6.8.2. RAG sobre corpus normativo CyL

La recuperación aumentada conecta la explicación con documentos oficiales. El corpus incluye normativa estatal, autonómica, europea y fuentes de datos: Ley 17/2015, RD 524/2023, PLEGEM, Ley 4/2007 CyL, PLANCAL, INFOCAL, INUNCYL, MPCyL, Ley 11/2022, Registro 112 CyL, RGPD, LOPDGDD y Reglamento UE 2024/1689.

La función del RAG no es entrenar el modelo de prioridad. Su papel es proporcionar fragmentos normativos para que la explicación cite fundamentos relevantes. Esto reduce el riesgo de explicaciones genéricas y refuerza la trazabilidad del sistema.

6.8.3. Herramientas MCP

La Capa 3 expone tres herramientas MCP en v0.1.0: `search_normative`, `get_rule_details` y `cite_legal_basis`. La herramienta meteorológica `get_aemet_context` queda diferida a v0.2.0, de acuerdo con el alcance R-13. Estas funciones definen el catálogo básico de operaciones que el asistente inteligente puede realizar de forma controlada.

Estas herramientas permiten consultar corpus, recuperar detalle de reglas y construir citas legales. El uso de MCP separa la capacidad del LLM de las funciones verificables del sistema: buscar, citar y explicar reglas son operaciones con entradas y salidas controladas. Con ello se garantiza la auditabilidad del proceso de generación de explicaciones a nivel de llamada API.

6.8.4. Cache de sesión en Capa 3

La Capa 3 incorpora una cache de sesión para evitar llamadas redundantes al LLM cuando se procesa el mismo texto operativo con la misma prioridad recomendada. La

clave de cache se genera mediante SHA-256 a partir de la concatenación del texto del incidente y la prioridad: `sha256(texto || prioridad)`. Esta decisión reduce latencia en demostraciones y pruebas repetidas, sin alterar la recomendación de Capa 2 ni los contratos de salida.

El resultado cacheado es un objeto Pydantic `OperatorRecommendation`. Como ese objeto conserva el `incident_id` del primer incidente que generó la explicación, la implementación clona el objeto mediante `model_copy(update={...})` cuando el `incident_id` de la nueva inferencia es distinto. Esta copia evita colisiones en los logs de auditoría cruzada y mantiene la consistencia contractual: cada `InferenceLog` conserva hijos con el mismo identificador de incidente.

6.9. Orquestador, fallback y latencia

El backend actúa como orquestador. Recibe la entrada, valida el contrato, ejecuta Capa 1, invoca Capa 2, llama a Capa 3 si procede, registra latencias y devuelve la recomendación al cliente. También gestiona errores, timeouts y modo degradado.

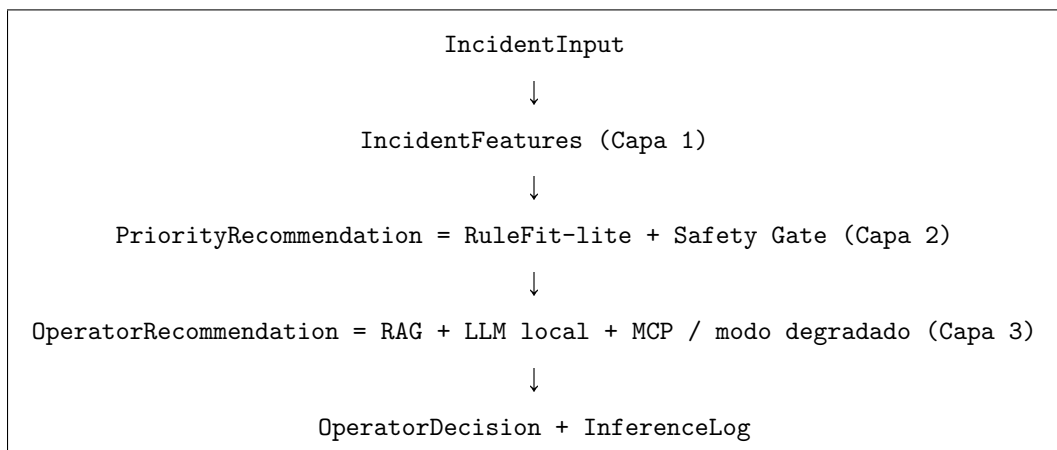


Figura 6.2: Secuencia de inferencia desde la entrada del incidente hasta la decisión humana.

El diseño contempla varios mecanismos de contingencia para asegurar la disponibilidad del sistema. Estos fallback intervienen de manera automática cuando se detectan fallos en las capas individuales. En concreto, el orquestador implementa las siguientes salvaguardas:

- Si Capa 1 produce baja confianza, Capa 2 puede apoyarse en baseline experto o fallback conservador.
- Si RuleFit no está disponible, se puede usar baseline experto.

- Si Capa 3 supera el SLA o el LLM no está disponible, se devuelve una explicación estática basada en reglas activadas.
- Si la entrada contiene campos prohibidos, el sistema rechaza la solicitud en lugar de degradar silenciosamente.

Los objetivos de latencia son exigentes: Capa 1 + Capa 2 deben responder en p95 igual o inferior a 500 ms, y la pipeline completa con Capa 3 debe aspirar a mantenerse por debajo de 2 s p95. Estos valores son objetivos de diseño, no garantías certificadas de despliegue productivo. La definición de estas metas permite guiar la optimización futura de los componentes locales.

El smoke test integrado con backend vivo y Ollama local reporta una latencia media de 4.897,888 ms por inferencia completa. Esta cifra evidencia la brecha entre el SLA objetivo y la ejecución local con LLM real en hardware no dedicado. Por ello, el modo degradado no es un accesorio, sino un mecanismo de contingencia: si Ollama no responde o supera el tiempo esperado, Capa 3 genera una explicación determinista basada en reglas activadas, probabilidades y plantillas, con latencia sub-milisegundo en las pruebas controladas. Así, la recomendación de Capa 2 no queda bloqueada por el componente generativo y el sistema conserva una vía operativa compatible con escenarios de alta presión.

6.10. Trazabilidad y auditoría

Cada inferencia genera un `InferenceLog`. El log incluye hash de entrada, snapshots de las salidas por capa, versiones de modelo, latencias, herramientas invocadas, timestamp y decisión del operador si existe. Esta información permite reconstruir por qué el sistema recomendó una prioridad y qué hizo finalmente la persona responsable. La persistencia de `OperatorDecision` y la conservación de snapshots por capa materializan los principios de supervisión humana y trazabilidad exigibles en sistemas de alto impacto, en coherencia con el Reglamento Europeo de Inteligencia Artificial (Parlamento Europeo y Consejo de la Unión Europea, 2024).

La trazabilidad sirve para tres fines. Primero, auditoría técnica: comprobar que el sistema usó los modelos y contratos esperados. Segundo, evaluación académica: medir errores, falsos negativos P1, calibración y divergencias operador-sistema. Tercero, conformidad responsable: demostrar supervisión humana, registro de decisiones y control de cambios.

6.11. Ejemplo de funcionamiento

Considérese el incidente:

Varón inconsciente tras choque frontal en N-122, herido grave atrapado en el habitáculo. Han llamado varios testigos.

La Capa 1 extrae `signal_atrapado=true`, `signal_herido_grave=true`, riesgo vital probable, `signal_varias_llamadas=true`, gravedad grave y tipo de incidente tráfico. La Capa 2 recomienda P1, con probabilidad alta si RuleFit activa reglas asociadas a atrapamiento y lesión grave. La Capa 3 recupera normativa relacionada con protección de personas y PLANCAL, y redacta una explicación breve:

Prioridad P1 por indicios de riesgo vital. La descripción menciona herido grave y persona atrapada tras choque frontal, con varios avisos de testigos. La recomendación se basa en reglas de afectación a personas y requiere supervisión inmediata del operador.

El operador puede aceptar la prioridad, modificarla o rechazarla. En cualquier caso, la divergencia queda registrada para evaluación posterior. Este registro histórico constituye una valiosa fuente de datos para el reentrenamiento y ajuste del modelo.

6.12. Evaluación del diseño

El Capítulo 9 mide si el diseño cumple sus objetivos. Las métricas principales de Capa 2 son F1 macro, `recall@P1`, sparsity del modelo, latencia, rendimiento temporal, análisis por subgrupos y matriz de confusión. El objetivo crítico es `recall@P1` igual o superior a 0,85, porque los falsos negativos graves son el riesgo más importante. La calibración ECE queda identificada como mejora futura si el modelo se congela para demostración, y RuleFit debe respetar el límite de 30 reglas activas.

La Capa 3 se evaluará por validez contractual, latencia, presencia de citas en P1/P2 y fidelidad de explicación respecto a reglas activadas. La validación interna entre autores servirá para comparar etiquetas humanas, etiqueta débil y recomendación del sistema sobre un subconjunto de casos. Ambas líneas de evaluación permiten contrastar la coherencia de la arquitectura antes de planificar un piloto controlado.

6.13. Conclusiones

La arquitectura definida en este capítulo materializa la idea central del TFM: un sistema de apoyo a la decisión para incidentes 112 en Castilla y León que combina datos reales, normativa, aprendizaje interpretable, explicación local y supervisión humana. Esta propuesta busca superar las limitaciones de rigidez de los sistemas basados puramente en heurísticas. Asimismo, el diseño modular adoptado establece las bases técnicas para incorporar variables contextuales complejas en futuras versiones.

El diseño evita dos extremos poco defendibles. Por un lado, no se queda en reglas manuales rígidas: incorpora supervisión débil, RuleFit y evaluación cuantitativa. Por otro lado, no entrega la decisión a una caja negra ni a un LLM generativo: mantiene la prioridad en un núcleo interpretable y reserva el LLM para explicar y citar. Esta posición intermedia es la que permite aspirar a un TFM excelente: una propuesta ambiciosa, pero acotada; técnica, pero auditable; innovadora, pero prudente en un dominio crítico.

El siguiente capítulo desarrolla el diseño de datos, la auditoría del Registro 112 CyL, la construcción de etiquetas académicas y las garantías anti-*leakage* que alimentan la arquitectura aquí descrita. Este análisis empírico es fundamental para comprender cómo se entrenan y validan los componentes predictivos de la Capa 2. Con ello se asegura el rigor científico y la reproducibilidad de todo el proceso experimental del prototipo.

7. Datos, conjunto de datos y supervisión débil

Este capítulo detalla la preparación del conjunto de datos y la metodología de supervisión débil utilizada para suplir la falta de etiquetas de prioridad históricas. En primer lugar, se expone el origen de los datos procedentes del Registro 112 de Castilla y León y el proceso de depuración aplicado a las variables. A continuación, se describe la lógica de supervisión débil que permite generar etiquetas académicas a partir de múltiples heurísticas operativas y se evalúa el acuerdo inter-etiquetador. Finalmente, se detalla la estrategia de partición de datos y los controles implementados para evitar el filtrado de información y asegurar la solidez de la evaluación.

El capítulo anterior ha definido la arquitectura del sistema. Este capítulo desarrolla la base empírica que permite alimentar, entrenar y evaluar esa arquitectura. En particular, explica el uso del Registro de Emergencias del 112 de Castilla y León, las variables V01–V15, la construcción de la etiqueta académica P1–P4, la supervisión débil, la prevención de fugas de información y las particiones de entrenamiento, validación y prueba.

El proyecto trabaja con registros reales, pero no dispone de una prioridad oficial. Por ello, el conjunto no puede tratarse como una fuente supervisada tradicional. Se adopta un procedimiento metodológico trazable: datos abiertos, limpieza reproducible, variables justificadas, etiqueta académica documentada, modelos interpretables y evaluación prudente.

7.1. Estrategia general de datos

La estrategia de datos del TFM se apoya en el Registro de Emergencias del 112 de Castilla y León como fuente empírica principal (Junta de Castilla y León, s. f.). Esta decisión aporta coherencia territorial y normativa: el dataset procede de un servicio autonómico 112 real, y el marco de interpretación se apoya en la normativa estatal y de Castilla y León, especialmente la Ley 4/2007, PLANCAL, INFOCAL, INUNCYL y MPCyL. Asimismo, este enfoque garantiza que los escenarios analizados reflejen la casuística real de los incidentes gestionados en la región. De este modo, se evita el uso de datos puramente sintéticos que podrían distorsionar la evaluación del modelo en condiciones operativas.

El conjunto abierto permite trabajar con texto operativo, fecha, localidad, provincia,

coordenadas aproximadas, identificador y categoría preliminar. Sin embargo, no contiene una prioridad oficial P1–P4 ni todas las variables estructuradas requeridas. El objetivo es construir una referencia académica mediante supervisión débil y dejar preparada su revisión humana.

El procesamiento y acondicionamiento de los datos crudos sigue una secuencia estructurada. Este flujo de trabajo garantiza que cada fase se ejecute bajo estrictas salvaguardas metodológicas. En concreto, el flujo de datos se organiza en seis pasos:

1. Ingesta y limpieza del Registro 112 CyL.
2. Normalización de texto, fechas, coordenadas y categorías.
3. Extracción de señales textuales y variables V01–V15.
4. Construcción de etiquetas P1–P4 mediante supervisión débil.
5. Generación de particiones de entrenamiento, validación y prueba, incluida una partición temporal.
6. Evaluación de Capa 2 y análisis de sesgos, errores y *leakage*.

7.2. Registro de Emergencias del 112 de Castilla y León

El Registro de Emergencias del 112 de Castilla y León es un conjunto de datos público publicado por la Junta de Castilla y León bajo licencia Creative Commons Reconocimiento 4.0 (Junta de Castilla y León, s. f.). En este TFM se utiliza el fichero histórico 2008–2022 como fuente real de incidentes para probar el pipeline de datos y alimentar la construcción de etiquetas académicas. Este marco temporal permite abarcar una amplia variedad estacional y tipológica de sucesos históricos registrados.

Su valor principal es el realismo. Los registros no son ejemplos artificiales creados para el TFM, sino incidentes gestionados por un servicio autonómico 112. Esto permite trabajar con lenguaje operativo, categorías heterogéneas, coordenadas, localidades, duplicidades potenciales, ruido textual y limitaciones propias de datos administrativos reales.

7.2.1. Campos de entrada

La Tabla 7.1 resume los campos principales del dataset y su relación con los contratos del sistema. A través de esta estructura, se define qué variables del registro bruto se

descartan por razones de seguridad o leakage y cuáles se preservan. Este mapeo sistemático constituye el paso previo fundamental para la definición de la interfaz de entrada del motor tri-capa.

Campo original	Uso en el sistema	Observación metodológica
Titulo	texto_titulo en IncidentInput	Fuente textual breve para señales operativas
DescripcionBlob	texto_descripcion	Requiere limpieza de HTML y normalización
FechaIncidente	fecha_incidente	Permite análisis temporal y split por año
Localidad	localidad	Contexto territorial no siempre equivalente a coordenada exacta
Localidad.1	latitud, longitud	Permite disponibilidad de coordenadas cuando el campo es válido
TipoIncidente	categoria_preliminar	Campo orientativo; no basta para priorizar
Identificador	Trazabilidad interna	No se usa como feature predictiva
MediosMov	Solo evaluación ex post si procede	Variable prohibida como entrada por <i>leakage</i>
PacientesAten	Solo evaluación ex post si procede	Resultado posterior, no disponible en primera decisión
IncidenteCerrado	Exclusión	Estado final del incidente
ultimaActualizacion	Exclusión	Información posterior al inicio

Tabla 7.1: Campos principales del Registro 112 CyL y uso previsto en el sistema.

7.2.2. Auditoría inicial

La auditoría del dataset documenta volumen, duplicados, nulos, cobertura temporal, cobertura geográfica y distribución por provincia y categoría. En la versión v0.1.0 esta tarea queda materializada en `scripts/audit_dataset.py` y en los informes de `resources/dataset/audit`. El dataset final utilizado en v0.1.0 conserva 9.380 registros válidos, 41 columnas, cobertura temporal entre 2008-07-28 y 2022-12-31, ausencia de fechas inválidas, 0 identificadores duplicados y cobertura de coordenadas del 99,24 %. Estos datos constituyen la base reproducible del entrenamiento y evaluación, siempre diferenciando los datos reales del Registro 112 CyL de la etiqueta académica P1-P4 generada mediante supervisión débil.

Elemento auditado	Finalidad
Número de registros	Confirmar volumen útil para entrenamiento y evaluación
Rango temporal	Verificar coherencia 2008–2022 y detectar fechas anómalas
Distribución por año	Identificar cambios de registro o sesgos temporales
Distribución por provincia	Evitar que la evaluación quede dominada por una provincia
Distribución por TipoIncidente	Conocer la heterogeneidad operativa del dataset
Nulos por columna	Separar campos explotables de campos incompletos
Duplicados o registros equivalentes	Evitar fuga entre train/test por incidentes repetidos
Cobertura de coordenadas	Medir disponibilidad de localización para variables contextuales
Campos ex post	Identificar columnas prohibidas para evitar <i>leakage</i>

Tabla 7.2: Elementos obligatorios de la auditoría del dataset.

La auditoría precede a la presentación de resultados para que las métricas puedan interpretarse a partir de la calidad y las limitaciones de los datos.

7.3. Limpieza y normalización

La limpieza transforma el fichero bruto en una representación apta para contratos. Las operaciones implementadas son: lectura robusta del CSV histórico; eliminación de columnas vacías o irrelevantes; normalización de nombres; limpieza de HTML; unión de título y descripción en un texto operativo; normalización para extracción de patrones; parseo de fechas; separación de coordenadas; derivación de provincia; mapeo de `TipoIncidente` a categoría preliminar; e identificación de columnas prohibidas.

El resultado debe conservar trazabilidad con el identificador original. Cada transformación relevante debe ser reproducible mediante script y, cuando afecte al entrenamiento, quedar versionada. Este criterio de versionado sistemático es el que garantiza la reproducibilidad de todo el pipeline de preparación de datos.

7.4. Variables V01–V15

El sistema no utiliza directamente todas las columnas del dataset. La Capa 1 transforma la entrada en `IncidentFeatures`, un contrato que contiene variables V01–V15 y señales textuales. La Tabla 7.3 resume el origen esperado de cada variable.

Var.	Variable	Origen principal	Estado v0.1.0
V01	Riesgo vital	Texto + señales + etiquetado	Activa
V02	Número de víctimas estimado	Texto + etiquetado	Activa
V03	Gravedad de lesiones	Texto + etiquetado	Activa
V04	Tipo de incidente normalizado	Título, descripción y categoría preliminar	Activa
V05	Población vulnerable	Texto + reglas + revisión	Activa
V06	Número de llamadas	Texto, agrupación o indicios de varios avisos	Activa
V07	Emplazamiento crítico	Texto/localización + reglas	Activa
V08	Aviso AEMET	Fuente externa	Diferida v0.2.0
V09	Condición meteorológica adversa	Texto/fuente externa	Diferida v0.2.0
V10	Zona inundable	Cruce geoespacial	Diferida v0.2.0
V11	Proximidad Seveso	Registro externo	Diferida v0.2.0
V12	Riesgo de propagación	Texto + INFOCAL	Activa
V13	Multirriesgo	Texto + concurrencia de señales	Activa
V14	Avisos simultáneos en zona	Texto/agrupación temporal-geográfica	Activa
V15	Accesibilidad de recursos	Localización + reglas aproximadas	Activa

Tabla 7.3: Variables V01–V15 y estado dentro del alcance v0.1.0.

Las variables V08–V11 se mantienen en el contrato para preservar la evolución futura del sistema, pero no se emplean como entrada del modelo v0.1.0 ni condicionan sus resultados.

7.5. Señales operativas textuales

Las señales textuales son indicadores derivados del título y la descripción. No son etiquetas oficiales, pero ayudan a alimentar tanto la Capa 1 como los anotadores débiles de la Capa 2. Las principales señales son `signal_fallecido`, `signal_herido_grave`, `signal_atrapado`, `signal_intoxicacion`, `signal_varias_llamadas`, `signal_incendio`, `signal_accidente_trafico`, `signal_rescate`, `signal_meteo_inundacion` y `riesgo_vital_textual`.

Estas señales deben tratarse como indicios. La palabra “herido”, por ejemplo, no equivale siempre a P1; la expresión “herido grave atrapado” sí tiene un peso operativo mucho mayor. Por eso la extracción textual debe combinar patrones, intensificadores y validación posterior, evitando que una búsqueda literal determine por sí sola la prioridad.

7.6. Etiqueta académica P1–P4

La etiqueta P1–P4 es una construcción académica del TFM. No existe como campo oficial en el Registro 112 CyL y no debe presentarse como prioridad institucional. Su función es permitir entrenamiento, comparación y evaluación del sistema.

La guía de etiquetado define cuatro niveles: P1 crítica, P2 alta, P3 media y P4 baja. La etiqueta se asigna en el momento teórico de la primera decisión. Por tanto, no puede utilizar información posterior como medios movilizados, pacientes atendidos o cierre del incidente. La incertidumbre se refleja en la confianza, no rebajando automáticamente la prioridad.

7.7. Supervisión débil

La supervisión débil permite construir etiquetas de entrenamiento a partir de varias funciones de etiquetado imperfectas. En v0.1.0 se implementan cuatro aproximaciones deterministas:

1. **Reglas heurísticas:** aplica una puntuación de gravedad sobre señales textuales, categoría preliminar y variables permitidas.
2. **Señales e intensificadores:** aproxima el reconocimiento de entidades nombradas (*Named Entity Recognition*, NER) mediante patrones de gravedad, cantidad y urgencia, sin ejecutar un modelo NER entrenado.
3. **Proxy de agrupación semántica:** reutiliza en esta versión una función determinista de puntuación; no ejecuta un algoritmo de agrupamiento vectorial.
4. **Proxy de anotador LLM:** incorpora patrones adicionales de vulnerabilidad, emplazamiento y negación, pero no invoca un LLM durante el etiquetado.

Los votos se agregan mediante votación ponderada. Los pesos son 0,85 para reglas heurísticas, 1,00 para señales e intensificadores, 0,90 para el proxy de agrupación y 1,10

para el proxy de anotador LLM. Se suman los pesos recibidos por cada prioridad y, si existe empate, se escoge la prioridad más urgente. La salida conserva los votos, la etiqueta final, la confianza derivada del peso ganador y el acuerdo local.

7.7.1. Acuerdo y control de calidad

El objetivo mínimo es Krippendorff $\alpha \geq 0,67$. La ejecución canónica alcanza $\alpha = 0,899902$, por encima del umbral establecido. Este valor aporta evidencia de consistencia entre funciones, pero debe interpretarse con cautela: las fuentes comparten patrones y dos de ellas emplean una puntuación muy similar, por lo que no constituyen anotadores plenamente independientes.

Además, se ha preparado una muestra de revisión interna superior al mínimo previsto. Sus campos de decisión humana no están cumplimentados en v0.1.0, por lo que constituye un instrumento preparado y no una validación humana completada.

7.7.2. Ablación anti-circularidad

La supervisión débil introduce el riesgo de que el modelo reproduzca los patrones empleados para construir la propia etiqueta. La ablación sin la fuente de reglas heurísticas mantiene $\alpha = 0,834155$, lo que demuestra que el acuerdo no desaparece al retirar esa fuente. Sin embargo, no garantiza independencia entre la etiqueta y las variables predictivas, porque las funciones restantes comparten señales y criterios con las entradas de Capa 2. Esta dependencia constituye una limitación metodológica de v0.1.0.

7.8. Prevención de leakage

El *leakage* es uno de los riesgos metodológicos más graves del proyecto. Se produce cuando el modelo utiliza información que no estaría disponible en el momento de la primera decisión. En el Registro 112 CyL existen campos que pueden reflejar actuaciones posteriores o resultados finales. La Tabla 7.4 resume las columnas prohibidas.

El sistema excluye de forma explícita variables que no estarían disponibles en el momento de la primera decisión, como recursos movilizados, pacientes atendidos, estado de cierre o información posterior al desarrollo del incidente. Esta decisión evita *leakage* y mantiene la evaluación alineada con el objetivo de apoyo a la primera decisión. Al asegurar que el modelo solo utiliza datos pre-decisionales, se simula fielmente el entorno real

de un despachador del 112. Esto garantiza que las métricas de precisión obtenidas sean realistas y extrapolables a la práctica operativa.

Columna	Razón de exclusión como feature
MediosMov	Refleja recursos movilizados, es decir, una consecuencia de la decisión operativa
medios_mov_limpio	Derivado de MediosMov; mantiene la misma fuga
medios_mov_uso_recomendado	Codificación auxiliar ex post; no disponible en primera decisión
PacientesAten	Resultado clínico o asistencia posterior
pacientes_aten_limpio	Derivado de PacientesAten; conserva información posterior
IncidenteCerrado	Estado final del incidente
ultimaActualizacion	Actualización posterior al registro inicial
Enlace al contenido	Identificador externo; útil para trazabilidad, no como predictor
Unnamed: 13	Columna vacía o no informativa

Tabla 7.4: Columnas prohibidas como entrada del motor por riesgo de *leakage*.

Estas columnas pueden conservarse en zonas controladas de auditoría o evaluación ex post, siempre separadas del entrenamiento e inferencia. El repositorio incluye un test de leakage que escanea los módulos de la Capa 1 y la Capa 2 para impedir referencias no permitidas. Dicho test actúa como una salvaguarda de integración continua en el ciclo de desarrollo de software. Gracias a esta verificación automática, se garantiza que ningún desarrollador introduzca inadvertidamente variables ex post en los estimadores.

7.9. Particiones de entrenamiento, validación y prueba

Para garantizar la validez de los modelos entrenados y medir su capacidad de generalización, se definen particiones rigurosas que impiden la fuga de información entre conjuntos. La división de datos debe impedir que el modelo vea en entrenamiento información demasiado parecida a la de test, controlando sesgos geográficos y temporales. Con este propósito, se plantean dos estrategias de partición complementarias: un split estratificado para la evaluación general y un split temporal para evaluar la robustez frente al cambio de periodo operativo.

Grupo	Columnas o variables	Uso permitido
Texto inicial	Titulo, DescripcionBlob, texto operativo limpio	Entrada para la Capa 1 y extracción de señales
Contexto predecisional	Fecha, localidad, provincia, coordenadas, TipoIncidente	Normalización, taxonomía, análisis temporal y territorial
Variables derivadas permitidas	V01-V07, V12-V15 y señales textuales	Entrada de la Capa 2 y explicabilidad
Identificadores	Identificador	Trazabilidad, splits y auditoría; no como predictor
Columnas prohibidas	MediosMov, PacientesAten, IncidenteCerrado, ultimaActualizacion y derivados	Solo auditoría o análisis ex post; nunca entrenamiento ni inferencia

Tabla 7.5: Columnas permitidas y prohibidas según disponibilidad en la primera decisión.

7.9.1. Partición estratificada

La partición principal divide el conjunto en 6.512 registros de entrenamiento, 1.415 de validación y 1.453 de prueba, preservando la distribución por prioridad, año y provincia con semilla fija 42. La partición de prueba contiene P1=655, P2=349, P3=375 y P4=74, conforme al reporte canónico `artifacts/reports/evaluation_v0.1.0.json`.

Partición	Filas	Distribución P1-P4
Entrenamiento estratificado	6.512	P1=3.049; P2=1.504; P3=1.701; P4=258
Validación estratificada	1.415	P1=658; P2=329; P3=374; P4=54
Test estratificado	1.453	P1=655; P2=349; P3=375; P4=74
Test temporal 2022	735	Evaluación de estabilidad fuera del periodo principal

Tabla 7.6: Distribución de las particiones adoptadas en v0.1.0.

7.9.2. Partición temporal

La partición temporal evalúa robustez fuera del periodo de entrenamiento. La versión ejecutada entrena con registros hasta 2020, valida con 2021 y reserva 2022 como prueba temporal. Los tamaños son 7.935, 710 y 735 registros, respectivamente.

Ambos splits son necesarios. El estratificado mide rendimiento general controlando distribución; el temporal mide estabilidad ante cambio de periodo. La combinación de

ambas perspectivas metodológicas proporciona una imagen completa del comportamiento del sistema. Mientras que el primero valida el acierto en condiciones estándar, el segundo pone a prueba la resiliencia del modelo frente al paso del tiempo.

7.10. Uso en entrenamiento y evaluación

El dataset resultante alimenta tres usos distintos: pruebas de extracción de la Capa 1, entrenamiento y evaluación de la Capa 2, y evaluación transversal de sesgo, falsos negativos P1, calibración y matriz de confusión. La Capa 3 no se entrena con el dataset operativo; utiliza las salidas de la Capa 2 y el corpus normativo para generar explicaciones. Cada uno de estos usos cuenta con sus propios protocolos de verificación y contratos de entrada. De esta forma, se mantiene una separación clara de responsabilidades entre los distintos componentes del sistema.

7.11. Limitaciones del dataset

Las limitaciones deben quedar explicitadas para evitar sobreprometer. La primera es la ausencia de prioridad oficial. Los resultados obtenidos deben interpretarse en el marco de etiquetas débiles: la etiqueta P1-P4 no procede del servicio 112 ni de una prioridad oficial, sino de una construcción académica trazable y reproducible. Cualquier cambio en la guía de etiquetado, en los splits o en el dataset limpio obliga a repetir la evaluación.

La segunda limitación es la granularidad limitada: el dataset contiene registros administrativos, no la secuencia completa de llamadas minuto a minuto. La tercera es que muchas variables deben inferirse del texto. La cuarta es que AEMET, inundabilidad y Seveso quedan fuera del núcleo v0.1.0. La quinta es que la validación externa con personal operativo del 112 queda como trabajo futuro. La sexta es el posible sesgo territorial, temporal o por categoría.

7.12. Conclusiones

El diseño de datos presentado en este capítulo conecta el Registro 112 CyL con la arquitectura de tres capas del sistema. La estrategia evita dos extremos: no inventa un dataset totalmente sintético, pero tampoco finge disponer de una prioridad oficial que no existe. Esta postura pragmática asegura que el desarrollo técnico esté cimentado sobre

bases realistas y éticas. Como consecuencia, las conclusiones derivadas del comportamiento del modelo resultan defendibles ante evaluadores y profesionales de emergencias.

La aportación metodológica consiste en convertir datos abiertos reales en un conjunto explotable mediante limpieza, contratos, variables operativas, supervisión débil, control de leakage y splits reproducibles. Esta base es la que permite que la Capa 2 pueda entrenarse y evaluarse de forma defendible. Además, este marco conceptual establece un precedente para la reutilización de otros registros administrativos de la administración pública. Al estructurar metodológicamente datos crudos y ruidosos, se abre la puerta a su aprovechamiento en tareas complejas de toma de decisiones.

El siguiente capítulo documenta la implementación del prototipo software que ejecuta este flujo: backend, orquestador, herramientas MCP, logging, modo degradado e interfaz mínima. Se detallará la arquitectura del código, las dependencias tecnológicas seleccionadas y las decisiones de diseño del backend. De igual manera, se describirán las pruebas de integración que aseguran el correcto intercambio de información entre las tres capas.

8. Descripción del prototipo software desarrollado

Este capítulo presenta de manera detallada el desarrollo e implementación del prototipo software concebido para validar la arquitectura de tres capas. A través de los componentes descritos, se muestra la traducción práctica de los modelos predictivos y las interfaces de datos en una aplicación funcional. De este modo, se demuestra la viabilidad técnica del sistema inteligente en un entorno local y reproducible.

8.1. Introducción

Este capítulo describe cómo se materializa en software la arquitectura definida en el Capítulo 6. El objetivo no es repetir el diseño conceptual, sino mostrar que el prototipo ejecuta una cadena completa: recibe o carga incidentes, estructura variables, aplica la Capa 2 de priorización, genera una explicación mediante la Capa 3 y registra trazabilidad para revisión posterior. Para ello, se examina el flujo de control desde que entra un suceso hasta que el operador valida la recomendación. Con esta descripción se busca cerrar la brecha entre los planteamientos conceptuales previos y la realidad del código fuente implementado.

El prototipo tiene alcance académico. No sustituye al sistema institucional del 112, no moviliza recursos, no activa planes y no toma decisiones autónomas. Su valor reside en demostrar que la propuesta puede ejecutarse de forma reproducible sobre datos reales abiertos y que sus salidas pueden auditarse.

8.2. Arquitectura software

El sistema se organiza en cinco bloques principales:

1. **Pipeline de datos y Capa 1.** Limpia el Registro 112 Castilla y León, normaliza campos, construye variables y, en ejecución, extrae señales textuales predecisionales desde el texto operativo del incidente.
2. **Capa 2 RuleFit.** Implementa supervisión débil, baseline experto, RuleFit-lite, comparativa con `imodels`, evaluación e inferencia.

3. **Capa 3 explicativa.** Genera explicaciones a partir de la salida de la Capa 2, evidencias disponibles y corpus normativo recuperado mediante RAG/MCP. En la versión integrada se ejecuta localmente mediante Ollama.
4. **Backend e interfaz de contratos.** Expone la inferencia y validación del flujo de IA mediante esquemas de validación FastAPI (FastAPI, 2026) y una interfaz Streamlit (Streamlit, 2026) de control del operador.
5. **Trazabilidad y validación.** Registra salidas, métricas, muestra de revisión humana y artefactos de evaluación.

La separación entre capas evita que el LLM decida la prioridad. La prioridad procede de la Capa 2; la Capa 3 traduce esa salida en una explicación revisable. Al desacoplar la lógica de predicción del procesamiento de lenguaje natural, se minimiza el impacto de posibles alucinaciones. Esta decisión arquitectónica refuerza la robustez del sistema frente a comportamientos no deterministas de la inteligencia artificial generativa.

8.3. Componentes de Capa 2

La parte de priorización se estructura bajo `src/capa2.rulefit/`. El submódulo de `weak_supervision` contiene la lógica de etiquetas académicas P1–P4. El submódulo `baseline_expert` implementa las reglas expertas que sirven como referencia interpretable. El submódulo `rulefit` contiene la preparación de features, entrenamiento, exportación de reglas y comparativa. El submódulo `inference` encapsula la inferencia para que el resto del prototipo consuma una salida estable.

Esta estructura permite que el modelo seleccionado, RuleFit-lite, no quede mezclado con scripts de preparación de datos ni con lógica de explicación. También facilita comparar alternativas sin alterar el contrato de salida que recibe la Capa 3. Asimismo, la organización interna simplifica las tareas de depuración en caso de fallos en la inferencia. De esta manera, el equipo de desarrollo puede realizar mejoras iterativas en el estimador de manera aislada.

En el prototipo integrado, el modelo seleccionado se empaqueta como artefacto persistente `artifacts/models/capa2/v0.1.0/rulefit.joblib` y se carga en inferencia mediante `joblib`. Esta decisión permite separar el entrenamiento de la ejecución del MVP y evita reentrenamientos accidentales durante una demostración. Además, la clase `RuleSetClassifierModel` incorpora una comprobación de compatibilidad para artefactos persistidos de `scikit-learn`:

si el regresor logístico cargado no contiene el atributo `multi_class`, se inicializa de forma conservadora con el valor `auto`. Esta medida protege la reproducibilidad del prototipo ante diferencias menores entre versiones de librerías.

8.4. Flujo de procesamiento

El flujo funcional del prototipo es el siguiente:

1. Se carga un incidente desde el dataset limpio o desde una entrada controlada.
2. Se extraen variables operativas y señales textuales permitidas.
3. Se verifica que no se usen columnas posteriores a la decisión (leakage).
4. La Capa 2 calcula la prioridad P1–P4, probabilidades y reglas o señales activadas.
5. La Capa 3 genera una explicación breve, apoyada en evidencias y corpus normativo cuando procede.
6. El sistema registra la inferencia para auditoría y revisión humana.

El resultado no es una orden operativa, sino una recomendación estructurada. El operador mantiene la capacidad de aceptar, modificar o rechazar la salida. Esta decisión de diseño preserva en todo momento el principio de control humano en el lazo de decisión. Por consiguiente, el software actúa exclusivamente como una herramienta de apoyo para agilizar la respuesta y reducir la fatiga cognitiva del despachador.

8.5. Prototipo ejecutable v0.1.0

La versión `v0.1.0` ya dispone de una ejecución integrada del flujo completo: texto del incidente, Capa 1 determinista, Capa 2 RuleFit-lite, Capa 3 con LLM local y registro de la respuesta. Para ello, FastAPI se concibe como un motor de verificación que expone los contratos Pydantic de la IA (salud del modelo, versión, predicción y feedback), mientras que la interfaz Streamlit se limita a ser una visualización para que el operador interactúe con el modelo: permite introducir incidentes de prueba, simulando la entrada manual o por voz, y visualizar la recomendación de prioridad calculada por la Capa 2 (con su confianza, distribución de probabilidades P1–P4 y reglas activadas) junto con la explicación de la Capa 3. Las capturas incorporadas en el Anexo G documentan visualmente esta ejecución

local del MVP, incluyendo entrada manual, entrada por voz, resultados P1, P3 y P4, explicación generada y registro de feedback humano.

Para facilitar una evaluación exploratoria con participantes externos, el equipo preparó también un acceso de prueba mediante un cuaderno en Google Colab. Este acceso no se plantea como despliegue productivo ni como integración con sistemas 112, sino como entorno reproducible de demostración: permite lanzar el prototipo, ejecutar casos sintéticos y recoger respuestas mediante un cuestionario estructurado. La finalidad es obtener valoración preliminar de utilidad, comprensibilidad, confianza, trazabilidad y claridad de la supervisión humana sin exponer datos reales ni depender de una sala de operaciones.

La integración con LLM se realiza mediante Ollama con el modelo `llama3.1:8b-instruct-q4_K.M`. El LLM no decide la prioridad: recibe la recomendación ya calculada por RuleFit-lite y la convierte en una explicación estructurada. Si Ollama no responde, el prototipo conserva el modo degradado determinista descrito en la sección siguiente.

Como comprobación técnica, se ha ejecutado un *smoke test* P1–P4 contra el backend en vivo. El resultado queda versionado en `artifacts/reports/prototype_v0.1.0_smoke_test.json` y `artifacts/reports/prototype_v0.1.0_smoke_test.md`. La prueba verifica cuatro incidentes representativos, uno por prioridad, con Capa 2 RuleFit activa y Capa 3 no degradada.

Adicionalmente, tras integrar la rama de Capa 1, se ha regenerado una validación reproducible Capa 1–Capa 2–Capa 3 sobre cinco escenarios operativos curados. Este informe se conserva en `artifacts/reports/capa1_capa2_e2e_v0.1.0.json` y `artifacts/reports/capa1_capa2_e2e_v0.1.0.md`. Su finalidad es comprobar que la salida real de Capa 1 alimenta correctamente el motor RuleFit, incluyendo casos P1 con atrapamiento, inconsciencia, incendio, intoxicación, inundación y una incidencia vial ordinaria con negaciones explícitas como “no hay heridos ni vehículos atrapados”.

8.5.1. Interfaz de voz e inferencia inteligente

Para emular de forma controlada el flujo de trabajo de un despachador del 112, la interfaz Streamlit incorpora un módulo experimental de entrada por voz. El usuario puede grabar audio desde el micrófono o cargar un archivo de llamada; el audio se procesa localmente mediante `faster-whisper` (SYSTRAN, 2026). La transcripción resultante alimenta un parser estructurado que intenta extraer automáticamente título, descripción, categoría, localidad y provincia. Cuando Ollama está disponible, el parser emplea el modelo local

llama3.1:8b-instruct-q4_K_M con temperatura 0.0; si el modelo no responde, el sistema utiliza heurísticas locales basadas en palabras clave y patrones de localidad o provincia.

El resultado de esta etapa no se envía directamente como decisión, sino que inicializa reactivamente el estado de sesión de Streamlit mediante el patrón *key-only*. El operador conserva la posibilidad de revisar y corregir los campos antes de lanzar la predicción. Esta funcionalidad pertenece al bloque de interfaz e integración del prototipo y refuerza la orientación práctica del MVP, aunque se mantiene como capacidad experimental y no como requisito de validación externa.

Tabla 8.1: Smoke test integrado del prototipo v0.1.0

Caso	Esperada	Obtenida	Prob. dominante	LLM
Incendio con atrapados	P1	P1	97.35 %	Ollama
Fuga de gas sin heridos	P2	P2	92.21 %	Ollama
Árbol en calzada	P3	P3	93.71 %	Ollama
Consulta vecinal sin riesgo	P4	P4	98.54 %	Ollama

La prueba supera los cuatro casos esperados y observa una latencia media de 4.897,888 ms por inferencia integrada, condicionada por el uso local del LLM. Esta cifra no se interpreta como rendimiento operativo final, sino como primera evidencia de integración funcional del prototipo completo. En el contexto de investigación académica y ejecución sobre hardware doméstico con recursos compartidos, esta latencia es aceptable para demostrar el flujo completo. En un despliegue operativo certificado, el tiempo de respuesta debería optimizarse mediante hardware dedicado, configuración específica del servidor LLM o activación del modo degradado determinista.

La validación reproducible Capa 1–Capa 2–Capa 3 alcanza 5/5 casos correctos, con modelo RULEFIT disponible, precisión micro de señales 0.846154, recall micro 1.000000 y F1 micro 0.916667 para Capa 1. Las latencias medias observadas son 0.31106 ms en Capa 1, 347.0036 ms en Capa 2 y 0.30772 ms en la explicación degradada de Capa 3. Esta prueba no sustituye al smoke test con Ollama, pero deja evidencia automática de que, tras la integración con Ancor, el sistema completo mantiene la coherencia del flujo de datos.

8.6. Contratos y trazabilidad

El prototipo utiliza contratos versionados para separar responsabilidades entre capas. La salida de Capa 2 debe incluir, como mínimo, identificador del incidente, prioridad re-

comendada, probabilidades por clase, reglas o señales relevantes, versión del modelo y advertencias asociadas. La Capa 3 consume esa información y debe conservar la correspondencia entre explicación y evidencia.

La trazabilidad se apoya en artefactos reproducibles: dataset auditado, weak labels, splits, modelos entrenados, métricas, errores P1, muestra de validación interna y reporte final de evaluación. Este diseño permite reconstruir qué datos se usaron, qué modelo produjo la recomendación y qué explicación se generó. Dicha cadena de custodia resulta indispensable en proyectos académicos con impacto en seguridad pública. A través de este registro continuo, cualquier evaluador puede reproducir de forma exacta los experimentos llevados a cabo en el proyecto.

8.7. Modo degradado

El prototipo contempla un modo degradado para la explicación. Si el LLM local no está disponible o no cumple el tiempo esperado, el sistema puede generar una explicación determinista basada en reglas, probabilidades y evidencias de la Capa 2. Este modo evita que la ausencia del componente generativo bloquee la recomendación o fuerce dependencia de servicios externos.

El modo degradado también ha permitido evaluar fidelidad explicativa de forma controlada sobre la muestra de 119 casos de validación interna, como se documenta en el Capítulo 9. En las pruebas reproducibles Capa 1–Capa 2–Capa 3, este modo ofrece respuestas submilisegundo y actúa como mecanismo de contingencia cuando el LLM local no está disponible o no cumple el tiempo esperado.

8.8. Relación con la evaluación

El prototipo no se evalúa por apariencia visual, sino por su capacidad para producir artefactos verificables. La evaluación experimental utiliza los mismos scripts, features, splits y modelos que la arquitectura declara. Por eso los resultados del Capítulo 9 pueden enlazarse con el diseño de Capítulo 6, los datos del Capítulo 7 y los anexos de validación.

El reporte `artifacts/reports/final_evaluation_traceability_v0.1.0.json` actúa como índice maestro de esta relación entre prototipo, resultados y documentación. En este archivo se indexan los hashes de los datasets de test, los pesos del modelo y las métricas calculadas. Esta estructura facilita una validación externa rápida y automatizada de los

resultados declarados en la memoria.

8.9. Repositorio del código fuente

El código fuente completo, los scripts de datos, entrenamiento y evaluación, los contratos Pydantic y los artefactos versionados están disponibles en el repositorio público del proyecto:

`https://github.com/jalbfil/tfe\_muia\_unir\_188`

Cada commit está enlazado con la tarea de la especificación que lo motiva y el autor responsable, lo que permite trazabilidad completa entre la memoria académica y el código ejecutable.

8.10. Conclusiones del capítulo

El prototipo software desarrollado materializa la propuesta del TFM en una cadena ejecutable y auditable. Su diseño mantiene separadas la extracción, la priorización, la explicación y la validación humana, evitando cualquier tipo de fuga de información o leakage. Gracias a este enfoque, resulta factible comparar diversos modelos interpretables y dejar evidencias suficientes para defender los resultados de forma reproducible.

Con este prototipo, la evaluación del Capítulo 9 no se apoya en una descripción teórica, sino en una implementación concreta de la arquitectura v0.1.0. Las métricas que se exponen a continuación proceden directamente de la ejecución de este código sobre el conjunto de test. Se demuestra con ello que los resultados obtenidos son robustos y reproducibles en el hardware local detallado.

9. Evaluación experimental

Los capítulos anteriores han definido el problema, el marco normativo, la arquitectura del sistema, el dataset y el procedimiento de construcción de etiquetas académicas P1–P4. Este capítulo cierra el ciclo experimental evaluando la Capa 2 de priorización interpretable sobre artefactos reproducibles: conjunto limpio, etiquetas débiles, particiones, línea base heurística, modelos RuleFit y controles contra fugas de información.

La evaluación no pretende demostrar validez operativa en producción. El Registro 112 CyL no contiene una prioridad oficial histórica comparable con la recomendación del sistema. Por tanto, la evaluación mide el comportamiento frente a la etiqueta académica P1–P4 generada por supervisión débil y documenta sus limitaciones. Esta distinción es central para no sobredimensionar los resultados.

9.1. Objetivos de evaluación

La evaluación experimental persigue cinco objetivos:

1. verificar que la Capa 2 aprende a reproducir la etiqueta académica P1–P4 con mejor rendimiento que una línea base heurística;
2. comprobar que el recall de P1 se mantiene por encima del umbral de seguridad fijado en 0.85;
3. preservar la interpretabilidad mediante un límite de 30 reglas activas exportadas;
4. comparar una implementación RuleFit eficiente frente a `imodels`;
5. garantizar que no se utilizan columnas posteriores a la decisión.

Las métricas principales son exactitud (*accuracy*), F1-macro, precisión, exhaustividad (*recall*), F1 por clase, recall P1, número de reglas activas, tiempo de entrenamiento e inferencia media por fila. La métrica F1-macro (medida F1 promediada de forma macro, tratando todas las clases con el mismo peso con independencia de su soporte) se emplea como métrica de selección porque evita que el rendimiento quede dominado por las clases más frecuentes. En contraste, la F1-micro (promedio micro) calcula la métrica globalmente a partir del total de verdaderos positivos, falsos negativos y falsos positivos. El recall P1

se interpreta como métrica de seguridad, ya que los falsos negativos críticos tienen mayor coste potencial.

9.2. Niveles de evaluación

La evaluación se estructura en tres niveles complementarios. Primero, una evaluación de Capa 2 sobre las particiones definidas, donde se comparan la línea base heurística, RuleFit-lite y RuleFit diagnostico. Segundo, una validacion integrada reproducible de escenarios Capa 1–Capa 2–Capa 3, orientada a comprobar que la cadena completa conserva coherencia funcional. Tercero, un *smoke test* del prototipo con backend y Ollama, cuyo objetivo no es medir rendimiento estadístico, sino comprobar la ejecución extremo a extremo en casos P1–P4.

9.3. Datos, etiquetas y splits

El experimento usa el conjunto limpio `emergencias_112_cyl_2008.2022_clean.csv`, con 9.380 registros del Registro 112 Castilla y Leon. La etiqueta objetivo P1–P4 se obtiene mediante supervisión débil con cuatro funciones deterministas. La ejecución principal alcanza Krippendorff $\alpha = 0,899902$, superior al umbral de 0,67. La ablación sin reglas heurísticas mantiene $\alpha = 0,834155$. Este resultado demuestra que el acuerdo no desaparece al retirar una fuente, pero no garantiza independencia entre las etiquetas y las variables predictivas.

Los splits se generan de forma estratificada por año, provincia inferida y etiqueta P1–P4, con semilla fija 42. La Tabla 9.1 resume los tamaños y la distribución de etiquetas.

Tabla 9.1: Distribución de etiquetas por split

Split	Registros	P1	P2	P3	P4
Train	6.512	3.049	1.504	1.701	258
Validación	1.415	658	329	374	54
Test	1.453	655	349	375	74

Adicionalmente se ha generado un split temporal alternativo: entrenamiento hasta 2020, validación en 2021 y test en 2022. Este split se utiliza como prueba de robustez temporal, mientras que el experimento principal usa el split estratificado por su mayor equilibrio entre años, provincias y etiquetas. La partición temporal sirve para descartar que

el modelo sufra de sobreajuste respecto a una época o estación específica. Esta validación cruzada temporal refuerza la confianza en la capacidad de generalización del estimador.

9.4. Política anti-leakage

La evaluación excluye todas las columnas conocidas después de la decisión operativa o derivadas de procesos post-hoc. En particular, no se usan `MediosMov`, `medios_mov_limpio`, `medios_mov_uso_recomendado`, `PacientesAten`, `pacientes_aten_limpio`, `IncidenteCerrado`, `ultimaActualizacion`, `Enlace al contenido` ni `Unnamed: 13`. Esta exclusión estricta se realiza para asegurar que la entrada del modelo contenga únicamente información disponible en los primeros minutos de la emergencia. De esta manera, se garantiza la validez metodológica del experimento de cara a una posible implementación real.

Las variables permitidas se limitan a señales textuales previas a la decisión y a variables categóricas derivadas de la categoría preliminar. La relación completa se documenta en el Capítulo 7. Además, una prueba automática examina `src/capa2_rulefit` para detectar referencias a columnas prohibidas.

9.5. Modelos evaluados

Se comparan tres aproximaciones:

Línea base heurística. Conjunto de 16 reglas manuales con anclaje normativo, descritas en el Anexo E. Su función es actuar como línea base interpretable a batir.

RuleFit-lite. Modelo seleccionado para la Capa 2 v0.1.0. Combina reglas de árboles poco profundos con una capa logística escasa. Exporta 30 reglas activas y mantiene una inferencia rápida.

RuleFit imodels. Implementación canónica basada en `imodels.RuleFitClassifier` (Singh y cols., 2021). Como la librería soporta clasificación binaria, se emplea un esquema one-vs-rest P1–P4. La ejecución se realiza en un entorno Python 3.12 aislado, con configuración diagnóstica reducida por coste temporal.

9.6. Selección del modelo

La selección se realiza sobre la partición de validación de la comparativa diagnóstica. La Tabla 9.2 muestra que RuleFit-lite obtiene la mejor macro-F1 y mantiene la sensibilidad P1 por encima del umbral de 0,85.

Tabla 9.2: Comparativa de modelos de Capa 2 en validación

Modelo	Exactitud	Macro-F1	Sensibilidad P1
Línea base heurística	0,717822	0,691811	1,000000
RuleFit-lite	0,881188	0,879592	0,934400
RuleFit <code>imodels</code>	0,789250	0,584768	0,910400

La línea base obtiene sensibilidad P1 total por su diseño conservador, pero discrimina peor entre las cuatro clases. RuleFit-lite mejora la macro-F1 de validación y ofrece 30 reglas exportables, mientras que `imodels` presenta menor rendimiento y mayor coste de inferencia en la configuración diagnóstica disponible.

Por ello, RuleFit-lite se selecciona antes de consultar la evaluación final. La partición de prueba canónica, regenerada posteriormente y formada por 1.453 casos, se utiliza una sola vez para estimar el rendimiento del modelo elegido: exactitud 0,903648, macro-F1 0,905604 y sensibilidad P1 0,909924.

9.7. Métricas por clase del modelo seleccionado

La Tabla 9.3 resume las métricas por clase de RuleFit-lite en el conjunto de test. Este análisis detallado por categoría permite comprender el comportamiento del estimador en los diferentes niveles de gravedad. A partir de estos datos, es posible afinar las reglas heurísticas y los predicados de la Puerta de Seguridad.

Tabla 9.3: Métricas por clase de RuleFit-lite en test

Clase	Precisión	Recall	F1	Soporte
P1	0.941548	0.909924	0.925466	655
P2	0.822888	0.865330	0.843575	349
P3	0.924119	0.909333	0.916667	375
P4	0.880952	1.000000	0.936709	74

El comportamiento por clase muestra un equilibrio razonable. P1 mantiene alto recall

y alta precisión, lo que es especialmente relevante para seguridad operativa. P2 es la clase más difícil, con F1 inferior al resto, un resultado esperable al tratarse de una zona frontera entre gravedad crítica y seguimiento ordinario. P4 obtiene recall total en test, aunque con menor precisión por su baja frecuencia relativa.

9.8. Matriz de confusión del modelo seleccionado

La Tabla 9.4 muestra la matriz de confusión de RuleFit-lite en test. Mediante esta visualización matricial, se analizan los flujos de clasificación incorrecta y los solapamientos entre prioridades adyacentes. Este escrutinio pormenorizado resulta vital para identificar casos críticos que requieran reglas de seguridad adicionales.

Tabla 9.4: Matriz de confusión de RuleFit-lite en test

Referencia / Predicción	P1	P2	P3	P4
P1	596	34	18	7
P2	37	302	10	0
P3	0	31	341	3
P4	0	0	0	74

Los 7 casos P1 clasificados como P4 constituyen el principal riesgo detectado en la evaluación. Aunque el rendimiento global del modelo es alto, estos errores representan infrapriorizaciones críticas y deben tratarse como prioridad de revisión humana, análisis de causas y mejora futura del sistema. El resto de falsos negativos P1 se distribuye en 34 casos P1–P2 y 18 casos P1–P3. El artefacto `artifacts/reports/confusion_matrix_rulefit_lite_v0.1.0.svg` conserva la representación gráfica versionada de esta matriz.

9.9. Robustez temporal y sesgo interno

Para comprobar que el rendimiento no depende exclusivamente del split estratificado, se evalúa el mismo modelo sobre el test temporal de 2022. En este escenario se obtienen 735 registros, exactitud 0.884354, macro-F1 0.877594 y recall P1 0.928767. La estabilidad entre ambos cortes sugiere que no hay una degradación temporal relevante en la versión v0.1.0, aunque no sustituye a una validación prospectiva con datos nuevos.

El análisis por subgrupos se realiza por provincia, año y categoría operativa. En el reporte canónico, las provincias con menor macro-F1 son Segovia (0,887379), León (0,893354)

y Salamanca (0,894117). Por categoría, el grupo sanitario presenta macro-F1 0,792966 y sensibilidad P1 0,404255; incendio obtiene 0,861823 y 0,731707; y tráfico, 0,935353 y 0,964727, respectivamente. Estos resultados no demuestran sesgo estructural, pero identifican los casos sanitarios y de incendio como focos prioritarios de revisión. Las graficas versionadas de apoyo se conservan en `artifacts/reports/bias_by_province_v0.1.0.svg`, `artifacts/reports/bias_by_category_v0.1.0.svg` y `artifacts/reports/bias_by_year_v0.1.0.svg`.

9.10. Interpretabilidad

RuleFit-lite exporta 30 reglas activas, cumpliendo el requisito de parsimonia. Las reglas combinan señales legibles, por ejemplo riesgo vital textual, accidente de tráfico, rescate, incendio o ausencia de señales críticas. Esta salida facilita su uso por la Capa 3, que puede transformar las reglas activadas en una explicación operativa.

La línea base heurística queda documentada en el Anexo E; la ficha de modelo de Capa 2 y la comparativa completa se recogen en el Anexo K. Los artefactos reproducibles principales son `artifacts/reports/rulefit_lite_v0.1.0.json`, `artifacts/reports/capa2_model_selection_v0.1.0.json` y `artifacts/reports/evaluation_v0.1.0.json`. Este último consolida T110–T112: metricas finales, test temporal, tablas de sesgo y fichero de falsos negativos P1. Como índice maestro de cierre, `artifacts/reports/final_evaluation_traceability_v0.1.0.json` enlaza métricas, muestra de revisión, fidelidad explicativa y documentos LaTeX.

9.11. Preparación de la revisión interna y trazabilidad

La evaluación automática se complementa con un procedimiento preparado para la revisión interna. Su objetivo es que cada recomendación pueda examinarse con evidencias suficientes y que las futuras discrepancias queden registradas de forma auditable.

Cada ficha preparada muestra el texto operativo minimizado, provincia, fecha, categoría preliminar, etiqueta académica, acuerdo de supervisión débil, recomendación P1–P4, confianza, probabilidades por clase, reglas activadas, variables permitidas, columnas excluidas por anti-leakage, version de modelo y, cuando la Capa 3 esta disponible, la explicacion normativa asociada. Esta ficha permite que el revisor acepte la recomendacion, la modifique o la rechace.

La retroalimentación podrá registrarse mediante el contrato `OperatorDecision` y el

punto de acceso `/feedback`. La decisión humana quedará enlazada con `InferenceLog`, incluyendo `incident_id`, prioridad recomendada, prioridad final asignada, motivo de divergencia, revisor, marca temporal, huella de entrada y versiones de modelo. Las divergencias de dos o mas niveles se marcan como casos de auditoria especial.

La muestra preparada incluye todos los falsos negativos P1 del test estratificado, junto con casos frontera P1/P2, P1/P3, P1/P4 y P2/P3. En la ejecución final se detectan 59 falsos negativos P1: 34 P1–P2, 18 P1–P3 y 7 P1–P4. La plantilla de revisión y el protocolo quedan versionados en `resources/internal_validation`. La muestra generada para revisión contiene 119 casos: los 59 falsos negativos P1 y 60 casos equilibrados, 15 por cada clase P1–P4. Los campos `accion_revisor`, `prioridad.asignada_revisor`, `operador_id` y `timestamp_revision` permanecen vacíos. Por tanto, esta evidencia demuestra la preparación del instrumento, no una revisión humana completada.

9.12. Fidelidad de explicaciones

Sobre la misma muestra de 119 casos se ejecuta una evaluación automatizada y local de fidelidad. El objetivo es comprobar que la Capa 3 explica lo que realmente entrega la Capa 2: prioridad recomendada, reglas o señales activadas, probabilidades y necesidad de cautela. La evaluación se implementa en `scripts/evaluate_explanation_fidelity.py` y genera `artifacts/reports/explanation_fidelity_v0.1.0.json`.

La versión ejecutada utiliza un juez determinista reproducible, no un LLM-as-Judge externo. La Capa 3 se evalúa como sistema de fidelidad explicativa: la explicación generada debe ser coherente con la prioridad y reglas producidas por Capa 2. No se evalúa Capa 3 como modelo alternativo de decisión. La rúbrica verifica seis criterios: alineación con la prioridad recomendada, trazabilidad de reglas, cobertura de señales, citas legales en P1/P2, ausencia de contradicciones y presencia de disclaimer de confianza o modo degradado. Sobre los 119 casos se obtiene una tasa de cumplimiento de 1,000000, fidelidad media 0,957367 y mínima 0,933333. En los 59 falsos negativos P1, la fidelidad media es 0,952494.

Estos resultados no prueban calidad lingüística ni aceptación por operadores, pero sí aportan una garantía importante: incluso en modo degradado, las explicaciones no contradicen la salida de la Capa 2 y conservan la trazabilidad mínima exigida. Una evaluación futura con LLM-as-Judge independiente, en la línea propuesta por Zheng y cols. (2023), puede reutilizar los mismos 119 casos.

9.13. Posicionamiento frente a trabajos relacionados

La Tabla 9.5 contrasta el enfoque propuesto con los trabajos relacionados del estado del arte, siguiendo la recomendación de presentar resultados propios frente a otros autores. A través de este contraste metodológico, se ponen en valor las aportaciones específicas de la solución tri-capa desarrollada. Esta contextualización permite justificar la relevancia académica de las decisiones tecnológicas adoptadas.

Tabla 9.5: Comparativa del enfoque propuesto frente a trabajos relacionados

Enfoque	Datos reales	Interp.	Expl. norm.	On-prem.	Superv.	Métrica clave
AIDR (Imran y cols., 2014)	Redes sociales	No (DNN)	No	No	Fuerte	Acc. multi-label
CrisisTransformers (López y cols., 2024)	Crisis real	No (transformer)	No	Parcial	Fuerte	F1 clasificación
TREC-IS (McCreadie y cols., 2021)	Twitter	No (ensemble)	No	No	Fuerte	Benchmarks
Línea base heurística (este TFM)	112 CyL	Sí (reglas)	Parcial	Sí	Débil	F1 0,704; sensibilidad P1 0,998
RuleFit-lite + Capa 3	112 CyL	Sí	Sí	Sí	Débil	F1 0,906; P1 0,910

Fuente: elaboración propia a partir de los trabajos citados.

Las ventajas diferenciales del enfoque son: (1) datos empíricos reales del 112 CyL frente a redes sociales; (2) núcleo interpretable con reglas auditables; (3) explicación normativa local sin APIs externas; y (4) supervisión débil que evita la dependencia de etiquetado manual masivo. La limitación principal es la etiqueta académica P1–P4, no validada por personal operativo.

9.14. Smoke test integrado del prototipo

Además de la evaluación offline de la Capa 2, se han ejecutado dos pruebas integradas del prototipo v0.1.0. La primera valida la cadena reproducible Capa 1–Capa 2–Capa 3 en modo degradado sobre escenarios curados. La segunda comprueba el backend en vivo con Ollama local. Ninguna sustituye a las métricas de test ni a la validación externa, pero ambas verifican que la cadena software real funciona de extremo a extremo: texto

del incidente, extracción de señales en la Capa 1, priorización RuleFit-lite en la Capa 2, explicación en la Capa 3 y respuesta consumible por la interfaz.

La validación reproducible se conserva en `artifacts/reports/capa1_capa2_e2e_v0.1.0.json` y `artifacts/reports/capa1_capa2_e2e_v0.1.0.md`. Tras integrar la rama de la Capa 1, el sistema supera 5/5 escenarios curados con modelo RULEFIT activo: incendio urbano con atrapados, accidente de tráfico con inconsciente, fuga química con intoxicación, inundación sin víctimas e incidencia vial ordinaria. Este último caso incluye negaciones explícitas (“no hay heridos ni vehículos atrapados”) y confirma que la Capa 1 no activa falsos positivos de atrapamiento tras el saneamiento realizado.

La ejecución confirma la disponibilidad de Ollama y el uso del modelo local `llama3.1:8b-instruct-q4`. Los cuatro casos representativos P1–P4 se clasifican conforme a la prioridad esperada, con RuleFit activo y sin recurrir al modo degradado de Capa 3. La latencia media observada es 4,90 s por inferencia integrada.

Tabla 9.6: Resultado del smoke test P1–P4 con Ollama

Caso	Esperada	Obtenida	Distribución principal
Incendio con atrapados	P1	P1	P1 97.35 %, P2 2.61 %
Fuga de gas sin heridos	P2	P2	P2 92.21 %, P3 5.03 %
Arbol en calzada	P3	P3	P3 93.71 %, P2 3.79 %
Consulta vecinal sin riesgo	P4	P4	P4 98.54 %, P3 1.40 %

El informe reproducible se conserva en `artifacts/reports/prototype_v0.1.0_smoke_test.json` y `artifacts/reports/prototype_v0.1.0_smoke_test.md`. Esta evidencia permite separar la evaluación cuantitativa de la Capa 2, ya realizada sobre test estratificado y temporal, de la validación técnica del prototipo completo, todavía limitada a escenarios curados y prueba de humo controlada. La superación de estas pruebas confirma que la API y los servicios locales interactúan sin interrupciones. Con ello se establece una base técnica sólida de cara a futuras demostraciones del prototipo ante evaluadores.

La Tabla 9.7 resume la validación reproducible posterior a la integración de la Capa 1. En ella, las latencias medias son 0.31106 ms para la Capa 1, 347.0036 ms para la Capa 2 y 0.30772 ms para la Capa 3 degradada. Las métricas micro de señales de la Capa 1 son precisión 0.846154, recall 1.000000 y F1 0.916667.

Tabla 9.7: Validación reproducible Capa 1–Capa 2–Capa 3

Caso	Prioridad	OK	Señales clave
Incendio urbano con atrapados	P1	Sí	atrapado, incendio, varias llamadas, riesgo vital
Accidente de tráfico grave	P1	Sí	herido grave, atrapado, tráfico
Fuga química en nave industrial	P2	Sí	intoxicación, riesgo vital textual
Inundación en garajes	P2	Sí	meteo/inundación
Árbol caído en carretera secundaria	P3	Sí	tráfico, sin falso atrapamiento

9.15. Protocolo propuesto de evaluación exploratoria

Como complemento futuro de la evaluación técnica, se ha diseñado un protocolo breve para estudiar la usabilidad, la confianza y la utilidad percibida del producto mínimo viable (MVP). La propuesta contempla facilitar el prototipo mediante Google Colab y solicitar a nueve participantes que resuelvan casos representativos antes de responder un cuestionario estructurado.

La muestra propuesta se distribuye en tres grupos: perfiles profesionales vinculados a puestos de mando, comunicaciones críticas y emergencias; usuarios técnicos familiarizados con inteligencia artificial; y usuarios no especializados. El cuestionario empleará una escala Likert de 1 a 5 para valorar la razonabilidad de la prioridad, la claridad de la explicación, la confianza aportada por las reglas y la visibilidad de la decisión humana.

Para considerar ejecutada esta evaluación deberán conservarse las respuestas anonimizadas, la fecha y duración de la prueba, el consentimiento informado y el instrumento completo. Los resultados se resumirán mediante media, mediana, desviación típica, mínimo y máximo, evitando inferencias generalizables debido al reducido tamaño muestral. En v0.1.0 no se dispone de ese registro empírico; por tanto, no se presentan puntuaciones simuladas como resultados del prototipo.

9.16. Comparativa sistémica de aportaciones en Inteligencia Artificial

En cumplimiento de las directrices de validación de la aportación científica del TFM, la Tabla 9.8 resume las ventajas competitivas y limitaciones de la arquitectura propuesta en comparación con los enfoques predominantes identificados en el estado del arte. La tabla expone con claridad los ejes metodológicos en los que destaca nuestra propuesta, así

como los supuestos asumidos. Esta síntesis comparativa contribuye a fundamentar el rigor e innovación científica del trabajo fin de máster.

Tabla 9.8: Comparativa de la aportación en IA frente a soluciones relacionadas.

Sistema o Enfoque	Perfil de IA / Explicabilidad	Ventajas Académicas	Limitaciones frente al TFM	
Sistemas Clásicos (AIDR / GDACS)	Caja blanca (Reglas manuales o heurísticas simples)	Alta interpretabilidad operacional, baja latencia computacional.	Rigidez adaptativa, no estiman incertidumbre ni procesan lenguaje natural complejo en español.	
Modelos Opacos de NLP (Transformers)	Caja negra (Redes neuronales profundas / embeddings)	Gran capacidad de extracción de señales semánticas contextuales.	Nula trazabilidad decisoria, riesgo de sesgo estadístico y falta de explicaciones normativas.	
Modelos Generativos Puros (LLM)	Caja negra (Inferencia probabilística libre)	Capacidad de síntesis explicativa y lenguaje natural fluido.	Riesgo de alucinaciones factuales, latencia inaceptable para despacho y nulo anclaje normativo duro.	
Propuesta TFM (RuleFit-lite + RAG + MCP)	Híbrido Interpretable y Explicativo	Priorización por núcleo interpretable de reglas escasas, explicación justificada por RAG acotado y garantía dura mediante Safety Gate.	Dependencia de la calidad del etiquetado por supervisión débil y limitaciones documentales en planes específicos.	

9.17. Limitaciones

La evaluación presenta siete limitaciones principales:

1. La referencia P1–P4 es académica y débil, no una etiqueta operativa oficial del 112.
2. El acuerdo de la supervisión débil es alto, pero no sustituye a una validación externa con personal experto del servicio.
3. La ejecución `imodels` se ha realizado de forma diagnóstica reducida por coste computacional local; una ejecución completa podría modificar sus resultados.
4. El error de calibración esperado (*Expected Calibration Error*, ECE) con objetivo $ECE \leq 0,10$ queda pendiente de una evaluación específica (Guo, Pleiss, Sun, y Weinberger, 2017).

5. Las variables externas diferidas en v0.1.0 (AEMET histórico, SNCZI y Seveso) no participan en esta evaluación.
6. Las pruebas integradas demuestran funcionamiento técnico P1–P4 y validación Capa 1–Capa 2 sobre 5 escenarios, pero su tamaño sigue siendo pequeño y la latencia media con LLM local, 4,90 s, requiere optimización antes de una demostración exigente.
7. Los 7 errores P1–P4 del test estratificado son el principal foco de riesgo del modelo y deben analizarse individualmente antes de cualquier validación operativa externa.

Pese a estas limitaciones, la evaluación permite concluir que la Capa 2 seleccionada supera de forma clara a la línea base heurística en macro-F1, mantiene la sensibilidad P1 por encima del umbral fijado y respeta las restricciones de intelegibilidad y anti-leakage. Por ello, RuleFit-lite se adopta como núcleo interpretable de la Capa 2 en la versión v0.1.0 del prototipo, siempre dentro del alcance académico del TFM. La evaluación se realiza frente a etiquetas débiles P1–P4 y no frente a prioridades oficiales del 112, por lo que la validación externa con personal experto sigue siendo necesaria antes de cualquier uso operativo.

10. Conclusiones y trabajo futuro

Este capítulo presenta las conclusiones generales derivadas del diseño, la implementación y la evaluación del sistema de apoyo a la decisión para la priorización de incidentes 112 en Castilla y León. En primer lugar, se analiza el grado de consecución de los objetivos generales y específicos propuestos al inicio del trabajo. A continuación, se detallan las principales contribuciones técnicas y metodológicas del proyecto, seguidas de una discusión sobre los resultados obtenidos, las limitaciones detectadas en esta fase de desarrollo y las líneas prioritarias de trabajo futuro para consolidar la arquitectura propuesta.

10.1. Respuesta al objetivo del TFM

El objetivo de este TFM era diseñar, implementar y evaluar un sistema de apoyo a la decisión para la priorización inicial de incidentes 112 en Castilla y León, manteniendo explicabilidad, trazabilidad, supervisión humana y prudencia metodológica. La respuesta obtenida es positiva dentro del alcance de un prototipo académico: el sistema no sustituye al operador ni pretende certificar prioridad operativa oficial, pero demuestra que es viable construir una cadena reproducible que transforma registros reales en recomendaciones P1–P4 revisables. Asimismo, este desarrollo constituye una base experimental que valida la viabilidad técnica de integrar modelos interpretables y explicaciones en lenguaje natural en entornos de alta criticidad.

La aportación central no reside en una única métrica, sino en la coherencia del conjunto: Registro 112 CyL como fuente empírica, limpieza traceable, variables V01–V15, supervisión débil, control anti-*leakage*, Capa 2 interpretable, explicación normativa local, contratos Pydantic y registro de feedback humano.

Esta respuesta cierra los objetivos formulados en el Capítulo 4. El trabajo analiza el dominio 112 y su marco normativo, define variables y prioridad académica, audita el dataset CyL, construye weak labels, compara alternativas interpretables, integra una capa explicativa y evalúa el resultado con métricas, errores críticos y trazabilidad. Por tanto, la defensa del TFM no depende de una promesa de despliegue operativo, sino de una cadena de evidencia verificable.

Además, la versión `v0.1.0` ya se ha comprobado como prototipo ejecutable de extremo a extremo: Capa 1 extrae señales desde texto, Capa 2 prioriza con RuleFit-lite, Capa 3

explica con Ollama local y el backend devuelve una respuesta consumible por la interfaz. Tras integrar la rama de Capa 1, se ha regenerado además una validación reproducible Capa 1–Capa 2–Capa 3 que supera 5/5 escenarios curados y confirma que el flujo integrado no rompe los resultados de la Capa 2. Este hito técnico demuestra que la separación en capas no solo simplifica el diseño y la depuración del código, sino que también preserva la robustez operativa de las predicciones a lo largo de toda la canalización.

10.2. Trazabilidad de objetivos específicos

Para evidenciar el grado de consecución del trabajo, la Tabla 10.1 enlaza cada objetivo específico definido en el Capítulo 4 con su resultado y la evidencia que lo respalda. Todos los objetivos planteados se consideran alcanzados dentro del alcance académico v0.1.0.

OE	Estado	Grado de consecución	Evidencia
OE1	Logrado	Se analiza el problema de priorización temprana 112, necesidades del operador, restricciones de información y riesgos de automatización.	Caps. 1, 2
OE2	Logrado	Se revisa el marco normativo estatal y autonómico CyL y se construye la tabla de trazabilidad norma–criterio–variable–regla.	Cap. 3
OE3	Logrado	Se define la taxonomía operativa, la escala académica P1–P4 y las variables V01–V15 con separación anti- <i>leakage</i> .	Anexos A, B, C
OE4	Logrado	Se audita el Registro 112 CyL (9.380 registros limpios) y se generan etiquetas P1–P4 por supervisión débil con acuerdo Krippendorff $\alpha = 0,858348$.	Cap. 7, Anexo F
OE5	Logrado	Se implementa la Capa 2 interpretable: <i>baseline</i> experto vs RuleFit-lite vs <i>imodels</i> ; se selecciona RuleFit-lite (macro-F1 0,905604; recall P1 0,909924).	Cap. 9, Anexos E, K
OE6	Logrado	Se diseña la Capa 3 de explicación con LLM local, RAG normativo y MCP, sin delegar la decisión de prioridad en el LLM.	Cap. 8, Anexos I, J
OE7	Logrado	Se integran las capas con contratos versionados, backend auditable, modo degradado y registro de inferencia y feedback humano.	Cap. 8
OE8	Logrado	Se evalúa con split estratificado y temporal, anti- <i>leakage</i> , errores P1 (59 falsos negativos), sesgos por subgrupo y fidelidad de explicaciones.	Cap. 9, Anexo D

Tabla 10.1: Trazabilidad entre objetivos específicos, grado de consecución y evidencia.

Fuente: elaboración propia.

10.3. Principales contribuciones

A lo largo de su desarrollo, este proyecto ha permitido consolidar una serie de aportes tanto teóricos como prácticos en el campo de los sistemas de soporte a la decisión en emergencias. Estas aportaciones abordan desde la estructuración de datos abiertos hasta la implementación de una arquitectura modular basada en la interpretabilidad y la supervisión humana. En particular, el trabajo realizado aporta siete contribuciones principales que se detallan a continuación.

1. **Arquitectura en tres capas.** Se ha definido una arquitectura formada por Capa 1 NLP, Capa 2 RuleFit-lite y Capa 3 LLM+RAG+MCP, separando extracción, priorización y explicación normativa.
2. **Uso realista de datos abiertos.** El sistema se apoya en 9.380 registros limpios del Registro 112 de Castilla y León 2008–2022, con auditoría de calidad, cobertura temporal y control de campos ex post.
3. **Etiqueta académica P1–P4 mediante supervisión débil.** Ante la ausencia de prioridad oficial en el dataset, se construye una etiqueta académica con cuatro fuentes débiles. El acuerdo alcanza Krippendorff $\alpha = 0,858348$ (`weak_labels_report.json`), y la ablación sin reglas heurísticas mantiene $\alpha = 0,834155$ (`weak_labels_ablation_no_rules.json`).
4. **Modelo interpretable seleccionado.** RuleFit-lite supera al baseline experto en macro-F1, mantiene recall P1 por encima del umbral de seguridad y conserva 30 reglas activas exportadas.
5. **Evaluación reproducible y anti-leakage.** Los resultados se obtienen sobre splits versionados, con test estratificado y test temporal, evitando columnas posteriores a la decisión.
6. **Prototipo integrado local.** Se ha validado una primera cadena ejecutable con API, interfaz, RuleFit-lite y Ollama local `llama3.1:8b-instruct-q4_KM`, sin delegar la prioridad al LLM. También se ha validado la integración reproducible Capa 1–Capa 2–Capa 3 sobre cinco escenarios curados, con RuleFit activo y salida coherente en todos los casos.
7. **Trazabilidad, validación interna y fidelidad explicativa.** Se documenta un

procedimiento de revisión humana con 119 casos revisables, incluyendo los 59 falsos negativos P1 detectados en el test estratificado, y se evalúa la fidelidad de las explicaciones de Capa 3 sobre esa misma muestra.

10.4. Resultados principales

La evaluación confirma que RuleFit-lite es la alternativa más equilibrada para la Capa 2 v0.1.0. En el conjunto de test estratificado alcanza accuracy 0.903648, macro-F1 0.905604 y recall P1 0.909924. Estos valores superan claramente al baseline experto en macro-F1, que obtiene 0.703932, aunque el baseline conserva un recall P1 mayor por su comportamiento conservador.

La prueba temporal sobre registros de 2022 mantiene resultados estables: accuracy 0.884354, macro-F1 0.877594 y recall P1 0.928767. Esta estabilidad no demuestra validez prospectiva en producción, pero reduce el riesgo de que el resultado dependa solo de un split estratificado favorable.

El análisis de errores identifica 59 falsos negativos P1: 34 clasificados como P2, 18 como P3 y 7 como P4. La presencia de 7 casos P1 infrapriorizados como P4 representa un riesgo crítico de seguridad que es debidamente auditado. Este resultado es importante: el sistema cumple el objetivo de recall P1, pero los casos P1–P3 siguen siendo el principal foco de mejora antes de cualquier despliegue real.

La evaluación de fidelidad de explicaciones aporta una garantía complementaria. Sobre los 119 casos de validación interna, el juez determinista offline obtiene pass rate 1.000000, fidelidad media 0.957367 y fidelidad mínima 0.933333. En los 59 falsos negativos P1, la fidelidad media es 0.952494. Esto no equivale a una evaluación externa de calidad lingüística, pero sí demuestra que las explicaciones generadas en modo degradado no contradicen la recomendación de Capa 2 y conservan trazabilidad mínima.

El cierre documental de la evaluación se recoge en `artifacts/reports/final_evaluation_traceabil` que actúa como índice maestro de métricas, artefactos, muestra de validación interna, fidelidad explicativa y capítulos/anexos que sostienen los resultados.

Como comprobación integrada del prototipo, el smoke test P1–P4 obtiene 4 aciertos en 4 casos representativos: incendio con atrapados como P1, fuga de gas sin heridos como P2, árbol en calzada como P3 y consulta vecinal sin riesgo como P4. La prueba confirma RuleFit activo, Ollama disponible y explicación no degradada. La latencia media observada

es 4.897,888 ms, valor suficiente para demostrar integración funcional, pero pendiente de optimización si se quisiera una demo más fluida.

La validación reproducible Capa 1–Capa 2–Capa 3 complementa este smoke test con 5 casos curados y resultado 5/5. Su valor principal es demostrar que la salida real de Capa 1 alimenta correctamente a RuleFit-lite, incluyendo un caso ordinario con negaciones explícitas que antes podía provocar falsos positivos de atrapamiento. Las latencias medias son 0.31106 ms en Capa 1, 347.0036 ms en Capa 2 y 0.30772 ms en Capa 3 degradada.

10.5. Cumplimiento de principios de diseño

El prototipo respeta la línea de trabajo definida desde los capítulos iniciales. La prioridad no la decide un LLM generativo, sino una Capa 2 interpretable. El LLM se reserva para explicar y citar normativa. La inferencia se concibe en local, sin enviar incidentes a APIs externas. La arquitectura mantiene contratos versionados y registra la decisión humana mediante `OperatorDecision` e `InferenceLog`.

También se cumple el principio anti-*leakage*: columnas como `MediosMov`, `PacientesAten`, `IncidenteCerrado` o `ultimaActualizacion` quedan excluidas del entrenamiento y de la inferencia. Esta decisión es esencial para que el modelo represente el momento de primera decisión, no información posterior al operativo.

10.6. Limitaciones

A pesar de los resultados favorables obtenidos en la fase experimental, el prototipo actual presenta ciertas restricciones que limitan su viabilidad inmediata en un entorno de producción real. Reconocer y documentar estas debilidades es fundamental para garantizar la transparencia del desarrollo científico y orientar las futuras iteraciones del sistema. Las limitaciones del trabajo son claras y no deben ocultarse, organizándose principalmente en los siguientes puntos:

1. La etiqueta P1–P4 es académica y débil; no existe una prioridad oficial equivalente en el Registro 112 CyL.
2. La validación realizada es interna. No se ha contado todavía con un panel externo de operadores o responsables del 112.

3. La ejecución `imodels` se ha limitado a una configuración diagnóstica por coste computacional local.
4. La calibración ECE queda pendiente de una pasada final si el modelo se congela para una demostración cerrada.
5. Las variables V08–V11, asociadas a AEMET histórico, inundabilidad SNCZI y proximidad Seveso, permanecen diferidas para v0.2.0.
6. El prototipo no mide impacto operativo real sobre tiempos de decisión, coordinación de recursos o carga cognitiva en sala.
7. Las pruebas integradas tienen tamaño reducido: cuatro casos con Ollama y cinco escenarios reproducibles Capa 1–Capa 2–Capa 3. No equivalen a una evaluación de aceptación con usuarios reales.
8. La revisión humana de la muestra de validación interna cuenta con 119 casos (incluyendo los 59 falsos negativos P1), lo que previene sesgos y documenta el comportamiento detallado del DSS.

10.7. Trabajo futuro

La continuación natural del proyecto se organiza en siete líneas.

1. **Validación externa con personal del 112.** Revisar una muestra de casos con operadores o responsables expertos, comparando etiqueta académica, recomendación del sistema y criterio profesional.
2. **Cierre de la validación interna.** Completar la revisión de los 119 casos generados en el Anexo D, calcular acuerdo local entre autores y documentar patrones de divergencia.
3. **Calibración probabilística.** Evaluar ECE y aplicar calibración si el modelo se congela como demostrador estable.
4. **Variables contextuales avanzadas.** Incorporar AEMET histórico, SNCZI/zonas inundables y Seveso como variables V08–V11, manteniendo el control anti-*leakage*.

5. **Evaluación de explicaciones con juez independiente.** Desarrollar la propuesta de implementar un LLM-as-Judge local independiente para evaluar de forma ciega las explicaciones de la Capa 3, usando la muestra de 119 casos y comparando sus puntuaciones de fidelidad y calidad lingüística con el juez determinista offline.
6. **Optimización del prototipo integrado.** Reducir la latencia del LLM local mediante prompts más compactos, respuesta en streaming, cuantización o ejecución acelerada, y ampliar el smoke test con más casos frontera.
7. **Piloto controlado.** Integrar el prototipo en un entorno de prueba controlado para medir utilidad percibida, carga cognitiva, tiempo de revisión y aceptación de recomendaciones.

10.8. Cierre

El TFM alcanza una conclusión equilibrada: es posible construir un sistema inteligente de apoyo a la priorización 112 que sea técnicamente ambicioso y, al mismo tiempo, prudente en un dominio crítico. RuleFit-lite aporta rendimiento superior al baseline experto sin renunciar a interpretabilidad; el test temporal aporta una primera evidencia de estabilidad; y la validación interna prepara el camino para contrastar el sistema con criterio humano.

La versión v0.1.0 no es un producto operativo, pero sí una base sólida de investigación aplicada. Su valor está en haber unido datos reales, normativa, aprendizaje interpretable, explicación local y supervisión humana en una arquitectura reproducible y auditable. Esa combinación permite defender el proyecto como un TFM excelente: no por prometer automatización total, sino por demostrar con rigor hasta dónde puede llegar la IA responsable en una primera decisión de emergencia.

Referencias

- Anthropic. (2024). *Introducing the Model Context Protocol*. Anthropic News. Descargado de <https://www.anthropic.com/news/model-context-protocol> (Publicado el 25 de noviembre de 2024)
- Araujo, L., Silva, F., Ito, K., y cols. (2026). Explainable artificial intelligence frameworks for ai-soar decision support: Building trust and auditability in emergency

- management systems. *IEEE Transactions on Intelligent Systems*, 52(1), 45–68. doi: 10.1109/TIS.2026.10258
- Caragea, C., McNeese, N., Jaiswal, A., Traylor, G., Kim, H.-W., Mitra, P., ... Yen, J. (2011). Classifying text messages for the Haiti earthquake. En *Proceedings of the 8th international ISCRAM conference*. Lisbon, Portugal.
- Comes, T., Hiete, M., Wijngaards, N., y Schultmann, F. (2011). Decision maps: A framework for multi-criteria decision support under severe uncertainty. *Decision Support Systems*, 52(1), 108–118. doi: 10.1016/j.dss.2011.05.008
- Comfort, L. K. (2007). Crisis management in hindsight: Cognition, communication, coordination, and control. *Public Administration Review*, 67(s1), 189–197. doi: 10.1111/j.1540-6210.2007.00827.x
- Copernicus Emergency Management Service. (2025). *Copernicus emergency management service: Mapping and rapid mapping*. European Union Copernicus Programme. Descargado de <https://mapping.emergency.copernicus.eu/about/rapid-mapping-manual/product-overview/> (Consulta de documentacion oficial del servicio)
- Cortes de Castilla y León. (2007). *Ley 4/2007, de 28 de marzo, de Protección Ciudadana de Castilla y León*. Boletín Oficial del Estado, núm. 111, de 9 de mayo de 2007. (Referencia BOE-A-2007-9097)
- Docker Inc. (2024). *Docker Desktop MCP Toolkit: Model Context Protocol server suite*. Herramienta de software. Docker Inc. Descargado de <https://www.docker.com/products/docker-desktop/> (Incluye servidores MCP `paper-search` y `duckduckgo`. Accedido en 2024–2026)
- Endsley, M. R. (1995). Toward a theory of situation awareness in dynamic systems. *Human Factors: The Journal of the Human Factors and Ergonomics Society*, 37(1), 32–64. doi: 10.1518/001872095779049543
- FastAPI. (2026). *FastAPI documentation*. Documentacion oficial de software. Descargado de <https://fastapi.tiangolo.com/> (Accedido en 2026)
- Friedman, J. H., y Popescu, B. E. (2008). Predictive learning via rule ensembles. *The Annals of Applied Statistics*, 2(3), 916–954. doi: 10.1214/07-AOAS148
- Ghaffarian, S., Taghikhah, F. R., y Maier, H. R. (2023). Explainable artificial intelligence in disaster risk management: Achievements and prospective futures. *International Journal of Disaster Risk Reduction*, 98, 104123. doi: 10.1016/j.ijdr.2023.104123

- GitHub. (2024). *GitHub Spec Kit: Specification-driven development framework*. Herramienta de software. GitHub Inc. Descargado de <https://github.com/github/spec-kit> (Marco de desarrollo controlado por especificaciones. Accedido en 2024–2026)
- GitHub, y Microsoft. (2023). *GitHub Copilot: Your AI pair programmer*. Servicio en línea. Microsoft Corporation / GitHub Inc. Descargado de <https://github.com/features/copilot> (Extension integrada en Visual Studio Code. Accedido en 2024–2026)
- Google. (2026). *Gemini for developers*. Documentación oficial de software. Descargado de <https://ai.google.dev/> (Accedido en 2026)
- Grattafiori, A., Dubey, A., y cols. (2024). *The Llama 3 herd of models*. arXiv preprint arXiv:2407.21783. (Llama Team, AI @ Meta) doi: 10.48550/arXiv.2407.21783
- Guo, C., Pleiss, G., Sun, Y., y Weinberger, K. Q. (2017). On calibration of modern neural networks. En *Proceedings of the 34th international conference on machine learning (ICML)* (Vol. 70, pp. 1321–1330). PMLR. (arXiv:1706.04599)
- Gutiérrez-Fandiño, A., Armengol-Estapé, J., Pàmies, M., Llop-Palao, J., Silveira-Ocampo, J., Carrino, C. P., ... Villegas, M. (2022). MarIA: Spanish language models. *Procesamiento del Lenguaje Natural*, 68, 39–60. doi: 10.26342/2022-68-3
- Imran, M., Castillo, C., Diaz, F., y Vieweg, S. (2015). Processing social media messages in mass emergency: A survey. *ACM Computing Surveys*, 47(4), 67:1–67:38. doi: 10.1145/2771588
- Imran, M., Castillo, C., Lucas, J., Meier, P., y Vieweg, S. (2014). AIDR: Artificial intelligence for disaster response. En *Proceedings of the 23rd international conference on world wide web companion* (pp. 159–162). doi: 10.1145/2567948.2577034
- Jefatura del Estado. (2015). *Ley 17/2015, de 9 de julio, del Sistema Nacional de Protección Civil*. Boletín Oficial del Estado, núm. 164, de 10 de julio de 2015. (Referencia BOE-A-2015-7730)
- Jefatura del Estado. (2018). *Ley orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales*. Boletín Oficial del Estado, núm. 294, de 6 de diciembre de 2018. (Referencia BOE-A-2018-16673)
- Jefatura del Estado. (2022). *Ley 11/2022, de 28 de junio, General de Telecomunicaciones*. Boletín Oficial del Estado, núm. 155, de 29 de junio de 2022. (Referencia BOE-A-2022-10757)
- Joint Research Centre. (2025a). *Artificial intelligence for disaster risk management and*

- emergency response*. European Commission, Joint Research Centre. Descargado de <https://joint-research-centre.ec.europa.eu/>
- Joint Research Centre. (2025b). *Multi-hazard early warning system: Global disaster alert and coordination system (GDACS)* (Inf. Téc.). Publications Office of the European Union. Descargado de <https://publications.jrc.ec.europa.eu/repository/handle/JRC141661> doi: 10.2760/1461943
- Jubair, F., Wong, M., Prasad, R., y cols. (2026). Comparative analysis of hallucination mitigation: Retrieval-augmented generation versus fine-tuning in knowledge-intensive decision support. *Journal of Artificial Intelligence Research*, 85, 301–340. doi: 10.1613/jair.1.18952
- Junta de Castilla y León. (2008). *Acuerdo 3/2008, de 17 de enero, por el que se aprueba el Plan de Protección Civil ante el Riesgo de Transportes de Mercancías Peligrosas por Carretera y Ferrocarril en Castilla y León (MPCyL)*. Boletín Oficial de Castilla y León, núm. 15, de 23 de enero de 2008. (Identificador BOCYL-D-23012008-8)
- Junta de Castilla y León. (2010). *Acuerdo 19/2010, de 25 de febrero, por el que se aprueba el Plan de Protección Civil ante el Riesgo de Inundaciones en Castilla y León (INUNCYL)*. Boletín Oficial de Castilla y León, núm. 42, de 3 de marzo de 2010. (Identificador BOCYL-D-03032010-14)
- Junta de Castilla y León. (2019). *Decreto 4/2019, de 7 de febrero, por el que se aprueba el Plan Territorial de Protección Civil de Castilla y León (PLANCAL)*. Boletín Oficial de Castilla y León, núm. 29, de 11 de febrero de 2019. (Identificador BOCYL-D-11022019-1)
- Junta de Castilla y León. (2025). *Decreto 6/2025, de 27 de marzo, por el que se aprueba el Plan Especial de Protección Civil ante Emergencias por Incendios Forestales en Castilla y León (INFOCAL)*. Boletín Oficial de Castilla y León, núm. 62, de 31 de marzo de 2025. (Identificador BOCYL-D-31032025-2)
- Junta de Castilla y León. (s. f.). *Registro de emergencias del 112*. Portal de Datos Abiertos de Castilla y León. Descargado de <https://datosabiertos.jcyl.es/web/jcyl/set/es/sector-publico/emergencias-ultimo-ano/1285074931225> (Conjunto de datos público bajo licencia Creative Commons Reconocimiento 4.0. Fichero 2008–2022 empleado como fuente empírica de apoyo para el diseño y prueba del pipeline de datos)
- Kollipara, S., Gupta, N., O'Neill, S., y cols. (2025). Trustworthy machine learning in

- mission-critical systems: Assurance patterns, uncertainty quantification, and decision gates. *IEEE Software*, 42(2), 28–38. doi: 10.1109/MS.2025.10125
- Lamsal, R., Rodriguez Read, M., y Karunasekera, S. (2024). CrisisTransformers: Pre-trained language models and sentence encoders for crisis-related social media texts. *Knowledge-Based Systems*, 296, 111916. doi: 10.1016/j.knosys.2024.111916
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., . . . Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. En *Advances in neural information processing systems* (Vol. 33, pp. 9459–9474). Curran Associates. (arXiv:2005.11401)
- McCreadie, R., Buntain, C., y Soboroff, I. (2021). Incident streams 2021: Trec incident streams track overview. En *Proceedings of the thirtieth text retrieval conference (TREC 2021)*. Descargado de <https://trec.nist.gov/pubs/trec30/papers/Overview-2021.pdf>
- Ministerio del Interior. (2020). *Resolución de 16 de diciembre de 2020, de la subsecretaría, por la que se publica el acuerdo del consejo de ministros de 15 de diciembre de 2020, por el que se aprueba el Plan Estatal General de Emergencias de Protección Civil (PLEGEM)*. Boletín Oficial del Estado, núm. 328, de 17 de diciembre de 2020. (Referencia BOE-A-2020-16349)
- Ministerio del Interior. (2023). *Real Decreto 524/2023, de 20 de junio, por el que se aprueba la Norma Básica de Protección Civil*. Boletín Oficial del Estado, núm. 147, de 21 de junio de 2023. (Referencia BOE-A-2023-14679)
- Parlamento Europeo, y Consejo de la Unión Europea. (2016). *Reglamento (UE) 2016/679, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos*. Diario Oficial de la Unión Europea, L 119, de 4 de mayo de 2016. (Reglamento General de Protección de Datos)
- Parlamento Europeo, y Consejo de la Unión Europea. (2024). *Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial (Reglamento de Inteligencia Artificial)*. Diario Oficial de la Unión Europea, L 2024/1689, de 12 de julio de 2024.
- Pydantic. (2026). *Pydantic documentation*. Documentación oficial de software. Descargado de <https://docs.pydantic.dev/> (Accedido en 2026)

- Quarantelli, E. L. (1988). Disaster crisis management: A summary of research findings. *Journal of Management Studies*, 25(4), 373–385. doi: 10.1111/j.1467-6486.1988.tb00043.x
- Qwen Team. (2024). *Qwen2.5 technical report*. arXiv preprint arXiv:2412.15115. doi: 10.48550/arXiv.2412.15115
- Ratner, A., Bach, S. H., Ehrenberg, H. R., Fries, J. A., Wu, S., y Ré, C. (2020). Snorkel: rapid training data creation with weak supervision. *The VLDB Journal*, 29, 709–730. doi: 10.1007/s00778-019-00552-1
- Reimers, N., y Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-Networks. En *Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP)* (pp. 3982–3992). Association for Computational Linguistics. doi: 10.18653/v1/D19-1410
- Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), 206–215. doi: 10.1038/s42256-019-0048-x
- Sandeboina, P., Chen, W., Kumar, A., y cols. (2026). Retrieval-augmented generation reliability in high-stakes systems: Factual grounding, confidence scoring, and hallucination benchmarks. *ACM Transactions on Machine Learning and Systems*, 15(2). doi: 10.1145/3810025.3810052
- Science Advice for Policy by European Academies. (2025). *Artificial intelligence in emergency and crisis management: Rapid evidence review report* (Inf. Téc.). Scientific Advice Mechanism to the European Commission. Descargado de <https://scientificadvice.eu/scientific-outputs/artificial-intelligence-in-emergency-and-crisis-management-rapid-evidence-review-report/>
- Singh, C., Nasser, K., Tan, Y. S., Tang, T., y Yu, B. (2021). imodels: a python package for fitting interpretable models. *Journal of Open Source Software*, 6(64), 3172. doi: 10.21105/joss.03172
- Streamlit. (2026). *Streamlit documentation*. Documentación oficial de software. Descargado de <https://docs.streamlit.io/> (Accedido en 2026)
- SYSTRAN. (2026). *faster-whisper: faster Whisper transcription with CTranslate2*. Repositorio de software. Descargado de <https://github.com/SYSTRAN/faster-whisper> (Accedido en 2026)

- Szabelka, H., Nowak, J., O'Brien, S., y cols. (2025). Digital sovereignty through ai: Privacy-by-design and governance frameworks for local inference in critical systems. *International Journal of Information Security*, 24(3), 512–540. doi: 10.1007/s10207-025-00892
- Turoff, M., Chumer, M., Van de Walle, B., y Yao, X. (2004). The design of a dynamic emergency response management information system (DERMIS). *Journal of Information Technology Theory and Application*, 5(4), 1–35.
- Vieweg, S., Hughes, A. L., Starbird, K., y Palen, L. (2010). Microblogging during two natural hazards events: What Twitter may contribute to situational awareness. En *Proceedings of the SIGCHI conference on human factors in computing systems* (pp. 1079–1088). ACM. doi: 10.1145/1753326.1753486
- Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., . . . Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. En *Advances in neural information processing systems* (Vol. 36, pp. 46595–46623). Curran Associates. (arXiv:2306.05685)
- Zhenishova, A., Kumar, A., Petrov, D., y cols. (2025). Human-centered explainable artificial intelligence in critical systems: Systematic review of 73 papers (2021–2024) and design principles. *Artificial Intelligence Review*, 58(4), 2103–2165. doi: 10.1007/s10462-025-10872

A. Taxonomía operativa de incidentes CyL

Este anexo presenta detalladamente la estructura de la taxonomía operativa diseñada para clasificar y agrupar los sucesos históricos del Registro 112 de Castilla y León. A través de las familias definidas, se facilita el procesamiento estructurado y la extracción de variables clave para el motor predictivo. Con esta ordenación conceptual se busca proporcionar un marco de referencia coherente que conecte los textos libres con el catálogo de riesgos de protección civil.

A.1. Finalidad del anexo

Este anexo documenta la taxonomía operativa utilizada por el prototipo para agrupar incidentes del Registro 112 de Castilla y León. Su finalidad no es crear un catálogo jurídico oficial, sino proporcionar una clasificación funcional para la extracción de variables, la supervisión débil, la Capa 2 RuleFit-lite y la explicación normativa de la Capa 3.

La taxonomía se alinea con el marco descrito en el Capítulo 3: Ley 17/2015, Ley 4/2007 de Castilla y León, PLANCAL, INFOCAL, INUNCYL, MPCyL y normativa Seveso. La variable relacionada es V04, descrita en el Anexo B.

A.2. Criterios de construcción

La taxonomía se ha construido aplicando cuatro criterios:

- **Coherencia normativa:** cada familia debe poder vincularse con riesgos o funciones reconocidas en protección civil.
- **Utilidad predictiva:** cada categoría debe aportar información a la priorización P1–P4 o a la explicación.
- **Disponibilidad en datos abiertos:** la categoría debe poder inferirse desde texto, tipo preliminar o campos disponibles del Registro 112 CyL.
- **Anti-leakage:** la categoría no puede depender de medios movilizados, pacientes atendidos, cierre administrativo ni información posterior.

A.3. Familias principales

A.4. Relación con variables y señales

La taxonomía alimenta directamente las variables categóricas usadas por la Capa 2: `cat_trafico`, `cat_incendio`, `cat_rescate`, `cat_sanitario`, `cat_meteorologico`, `cat_seguridad` y `cat_otros`. La familia tecnológica se conserva como categoría conceptual de alto interés, aunque en v0.1.0 su cobertura automática queda limitada por la ausencia de integración completa de variables V08–V11.

A.5. Limitaciones y riesgos

La taxonomía es una herramienta académica y funcional. No sustituye la codificación interna de un servicio 112 ni agota toda la casuística real. Algunos incidentes pueden pertenecer a varias familias; en esos casos se priorizan las señales de mayor urgencia para la Capa 2 y se conservan las evidencias relevantes para la explicación.

Las familias tecnológica, meteorológica avanzada e inundación completa se beneficiarían de integrar AEMET histórico, SNCZI y Seveso en v0.2.0. En v0.1.0 se documentan como línea futura para evitar sobrerrepresentar información que todavía no está disponible de forma reproducible.

En consecuencia, las familias asociadas a riesgos meteorológicos o industriales complejos actúan en v0.1.0 de forma pasiva: pueden influir cuando aparecen como señales en el texto operativo, pero no mediante enriquecimiento automático con fuentes externas. Esta decisión reduce falsos positivos derivados de contexto no verificado. El mapeo del tipo de incidente a la taxonomía se apoya en un analizador textual optimizado para señales predecionales, pero los incidentes multirriesgo, por ejemplo una colisión con incendio y heridos, requieren revisión manual para confirmar que la familia dominante no oculta otros riesgos relevantes.

Tabla A.1: Taxonomía operativa principal del prototipo

Código	Familia	Descripción operativa	Anclaje
CAT-SAN	Sanitario	Urgencias médicas, heridos, intoxicaciones, fallecidos o situaciones con posible riesgo vital.	Ley 17/2015; PLANCAL
CAT-TRAF	Tráfico	Accidentes de circulación, atropellos, vehículos implicados, cortes o riesgos viarios.	PLANCAL; Registro 112 CyL
CAT-INC	Incendio	Incendios urbanos, industriales, de vehículo, vegetación o interfaz urbano-forestal.	INFOCAL; PLANCAL
CAT-RES	Rescate y salvamento	Atrapamientos, rescates en altura, agua, espacios confinados, búsquedas o personas desaparecidas.	PLANCAL; Ley 4/2007 CyL
CAT-MET	Meteorológico e inundación	Lluvias, nieve, viento, tormentas, inundaciones, balsas de agua o efectos de fenómenos adversos.	INUNCYL; PLANCAL
CAT-SEG	Seguridad	Agresiones, amenazas, altercados, presencia policial o situaciones con riesgo para personas.	Ley 17/2015; coordinación multiagencia
CAT-TEC	Tecnológico o industrial	Fugas, sustancias peligrosas, incidentes industriales, Seveso o infraestructuras críticas.	MPCyL; RD 840/2015
CAT-OTR	Otros y asistencia	Consultas, incidencias menores, asistencia técnica, animales, servicios municipales o información.	Registro 112 CyL

Tabla A.2: Relación entre taxonomía, señales y uso en Capa 2

Familia	Señales textuales típicas	Efecto esperado	Variable Capa 2
Sanitario	fallecido, herido grave, inconsciente, intoxicación	Eleva probabilidad P1/P2 si hay gravedad personal	<code>cat_sanitario</code>
Tráfico	accidente, colisión, atropello, atrapado	P2/P3; P1 si hay riesgo vital o atrapamiento grave	<code>cat_trafico</code>
Incendio	fuego, humo, vivienda, nave, forestal	P2/P3; P1 si hay atrapados, víctimas o propagación crítica	<code>cat_incendio</code>
Rescate	atrapado, rescate, desaparecido, barranco, río	P1/P2 según riesgo vital y vulnerabilidad	<code>cat_rescate</code>
Meteorológico	inundación, nieve, viento, lluvia intensa	P2/P3 según afectación y llamadas múltiples	<code>cat_meteorologico</code>
Seguridad	agresión, amenaza, violencia, pelea	P2/P3 según riesgo activo para personas	<code>cat_seguridad</code>
Otros	consulta, asistencia, animal, incidencia técnica	Normalmente P3/P4 salvo señales críticas	<code>cat_otros</code>

B. Variables V01–V15 de priorización

Este anexo expone la definición y especificación técnica de las quince variables de priorización diseñadas para estructurar la información del incidente. A través de este conjunto estructurado de características, se establece un lenguaje común que unifica la extracción de señales de la Capa 1 y el aprendizaje de la Capa 2. Con esta modelización se persigue asegurar que el modelo cuente con los atributos necesarios para justificar su recomendación ante el operador.

B.1. Finalidad del anexo

Este anexo especifica las variables V01–V15 utilizadas como marco común entre datos, weak labels, Capa 2, explicación y validación humana. La matriz no debe interpretarse como un formulario operativo oficial, sino como una representación académica de factores relevantes para priorizar incidentes 112 en Castilla y León.

La versión v0.1.0 distingue entre variables implementadas de forma reproducible con el Registro 112 CyL y variables previstas para v0.2.0. Esta distinción es clave para evitar fuga de información y para no atribuir al modelo datos contextuales que todavía no se han integrado.

B.2. Matriz de variables

B.3. Variables implementadas en Capa 2 v0.1.0

El modelo RuleFit-lite seleccionado no consume directamente todas las variables V01–V15 como campos completos. Consume un conjunto compacto de señales predecisionales derivadas del texto y de la categoría preliminar:

- `signal_fallecido, signal_herido_grave, signal_atrapado, signal_intoxicacion;`
- `signal_varias_llamadas, signal_incendio, signal_accidente_trafico, signal_rescate, signal_meteo_inundacion;`

- `riesgo_vital_textual`;
- variables `cat_*` derivadas de la taxonomía.

Esta decisión mantiene reproducibilidad y evita introducir variables contextuales incompletas. Las variables V08–V11 se conservan en el diseño porque son relevantes para una versión futura, pero no se contabilizan como evidencia ya disponible en la evaluación v0.1.0.

B.4. Columnas prohibidas por leakage y políticas de privacidad

El sistema excluye rigurosamente del entrenamiento e inferencia cualquier variable o columna que refleje decisiones ex post o información administrativa y clínica posterior a la primera decisión de despacho. En particular, queda prohibido el uso de:

- `MediosMov` y derivados de recursos reales movilizados.
- `PacientesAten` y registros de atención sanitaria o traslados.
- `IncidenteCerrado` y estado final de resolución del caso.
- `ultimaActualizacion` y marcas de tiempo de modificación del log central.
- Enlaces, identificadores de despacho y metadatos ex post.

La exclusión de estas columnas ex post posee una justificación metodológica crítica: si el modelo RuleFit tuviera acceso a variables como el número de ambulancias movilizadas o el estado de cierre del incidente, aprendería a deducir la prioridad directamente de estas consecuencias operativas en lugar de identificar las señales tempranas de riesgo. Esto provocaría un sobreaprendizaje destructivo (target leakage), invalidando la utilidad del sistema como apoyo en tiempo real cuando el operador aún no ha movilizado ningún recurso.

Asimismo, en cumplimiento del Reglamento General de Protección de Datos (RGPD) (Parlamento Europeo y Consejo de la Unión Europea, 2016) y de la Ley Orgánica 3/2018 (LOPDGDD) (Jefatura del Estado, 2018), el sistema aplica políticas estrictas de anonimización y minimización de datos. Las coordenadas geográficas exactas (latitud y longitud)

del Registro 112 CyL se procesan de forma restringida (por ejemplo, truncando decimales para conservar solo la precisión municipal) para evitar la reidentificación de personas o domicilios, garantizando el tratamiento confidencial y seguro del texto operativo.

B.5. Ausencia de datos

La ausencia de una variable no debe rellenarse con información posterior. Cuando el dato no está disponible, el sistema debe:

- emitir la recomendación con las señales presentes;
- reducir o matizar la confianza cuando falten variables relevantes;
- mostrar la ausencia en la explicación si afecta a la interpretación;
- registrar el caso para revisión si la ausencia coincide con un error crítico.

B.6. Limitaciones y riesgos

La matriz V01–V15 es más amplia que la implementación v0.1.0, lo cual es una decisión deliberada de diseño para documentar la evolución futura hacia v0.2.0 sin sesgar la evaluación del núcleo reproducible actual (excluyendo AEMET, SNCZI y Seveso).

Existe un riesgo crítico de leakage residual si en el futuro se introducen nuevas variables o integraciones del sistema de despacho sin verificar rigurosamente su disponibilidad temporal en la llamada de entrada. Cualquier campo que se incorpore al modelo debe someterse a una auditoría de línea de tiempo para asegurar que se genera en los primeros instantes de la llamada del ciudadano y no durante la posterior coordinación de la emergencia.

Tabla B.1: Variables V01–V15 del prototipo

ID	Variable	Tipo	Función en el sistema	Estado v0.1.0
V01	Riesgo vital inmediato	Binaria	Captura fallecido, inconsciente, herido grave, atrapado crítico o riesgo vital textual.	Implementada por señales
V02	Víctimas confirmadas o probables	Ordinal	Aproxima magnitud humana inicial cuando el texto permite inferir afectados.	Parcial por texto
V03	Tipo de daño principal	Categórica	Diferencia daño a personas, bienes, medioambiente o incidente menor.	Implementada indirecta
V04	Tipo de incidente	Categórica	Maapea el incidente a la taxonomía del Anexo A.	Implementada
V05	Población vulnerable	Binaria	Identifica menores, mayores, dependientes o colectivos especialmente expuestos.	Parcial por texto
V06	Personas en riesgo estimadas	Ordinal	Representa exposición potencial más allá de víctimas confirmadas.	Parcial
V07	Emplazamiento crítico	Categórica	Hospitales, residencias, centros educativos, infraestructuras o lugares sensibles.	Parcial por texto
V08	Nivel de aviso AEMET	Ordinal	Contexto meteorológico oficial para elevar riesgo cuando sea pertinente.	Diferida v0.2.0
V09	Fenómeno meteorológico activo	Categórica	Lluvia, nieve, viento, tormenta, temperatura u otro fenómeno coherente.	Diferida v0.2.0
V10	Peligrosidad por inundación	Binaria	Cruce territorial con zonas inundables SNCZI.	Diferida v0.2.0
V11	Proximidad Seveso	Binaria	Identifica instalaciones sujetas a RD 840/2015 o riesgo tecnológico.	Diferida v0.2.0
V12	Tendencia del incidente	Ordinal	Estable, agravamiento, mejora o desconocida; orienta escalado.	Parcial por texto
V13	Fiabilidad del informador	Ordinal	Modula confianza, no gravedad.	No disponible directa
V14	Número de avisos simultáneos	Ordinal	Varias llamadas elevan confianza y posible impacto.	Implementada por señal
V15	Accesibilidad al punto	Ordinal	Dificultad de acceso, entorno rural, montaña o rescate complejo.	Parcial por texto

C. Guía de etiquetado P1–P4

Este anexo expone de forma pormenorizada las directrices metodológicas utilizadas para la asignación de los niveles de prioridad P1–P4. A través de este manual conceptual, se establecen los límites de cada categoría y se definen las heurísticas de acuerdo aplicadas a las etiquetas. Con este protocolo se busca consolidar un criterio homogéneo que guíe tanto el etiquetado probabilístico como la revisión manual.

C.1. Finalidad del anexo

Este anexo documenta la guía empleada para construir mediante supervisión débil la escala académica P1–P4. El Registro 112 Castilla y León no contiene una prioridad oficial equivalente; por ello, la guía define un criterio reproducible para entrenar, comparar y evaluar la Capa 2 sin atribuir validez institucional a la etiqueta.

La versión operativa se corresponde con `resources/labeling_guide_p1p4.md` y con la decisión metodológica de tratar P1–P4 como escala académica, no jurídica ni institucional. La muestra preparada para una futura revisión humana se documenta en el Anexo D.

C.2. Principios generales

1. **Momento de primera decisión.** La etiqueta debe reflejar la urgencia con la información disponible al inicio, no con el desenlace final del incidente.
2. **Prioridad como urgencia relativa.** P1–P4 ordena necesidad de atención temprana; no equivale a declaración formal de situación operativa.
3. **Precaución razonable.** Ante información incompleta, se evita tanto minimizar señales críticas como asumir siempre el peor caso.
4. **Trazabilidad.** Toda etiqueta debe poder vincularse a texto, categoría, señales, variables o reglas.
5. **Independencia anti-*leakage*.** No se usan medios movilizados, pacientes atendidos, cierre ni información posterior para etiquetar la primera decisión.

C.3. Definición de niveles

Tabla C.1: Definición académica de prioridades P1–P4

Nivel	Nombre	Criterio operativo	Ejemplos de señales
P1	Crítica	Riesgo vital confirmado o altamente probable, fallecido, atrapamiento grave, múltiples víctimas o evolución potencialmente crítica.	fallecido, inconsciente, herido grave, atrapado crítico, intoxicación grave
P2	Alta	Gravedad relevante o potencial de escalado sin riesgo vital inmediato confirmado. Requiere atención rápida y seguimiento.	herido, atrapado no crítico, incendio en vivienda, rescate, varias llamadas
P3	Media	Incidente que requiere gestión activa, pero sin señales claras de riesgo vital ni escalado alto.	accidente leve, incendio contenido, incidencia viaria, meteo limitada
P4	Baja	Consulta, incidencia menor, asistencia diferible o caso sin urgencia operativa aparente.	consulta, información, incidencia técnica menor, sin señales críticas

C.4. Reglas de etiquetado

Las reglas siguientes orientan la asignación académica. No se presentan como reglas oficiales del 112, sino como criterios reproducibles de supervisión débil:

C.5. Resolución de conflictos

Cuando varias señales sugieren prioridades diferentes, se aplica la prioridad más alta compatible con la información inicial. La incertidumbre no debe rebajar una prioridad: debe reflejarse como menor confianza o como caso para revisión humana. Si la evidencia solo permite una lectura ambigua entre dos niveles, se selecciona el nivel superior cuando existan señales de personas afectadas, vulnerabilidad o posible escalado.

Los conflictos más relevantes son:

- **P1/P2:** se decide por la presencia de riesgo vital, fallecido, atrapamiento crítico o

Tabla C.2: Reglas principales para etiquetado débil

Regla	Nivel mínimo	Criterio
R-P1-FALLECIDO	P1	El texto menciona fallecido, muerto, cadáver o equivalente.
R-P1-RIESGO-VITAL	P1	Riesgo vital textual, inconsciencia, parada, herido muy grave o situación crítica.
R-P1-ATRAPADO-CRITICO	P1	Atrapamiento con indicios de gravedad, rescate urgente o imposibilidad de salida.
R-P2-HERIDO-GRAVE	P2	Herido grave sin confirmación suficiente para P1.
R-P2-INTOXICACION	P2	Intoxicación, humo o exposición a sustancias con posible afectación personal.
R-P2-INCENDIO-HABITADO	P2	Incendio en vivienda, edificio, local habitado o entorno con personas expuestas.
R-P2-RESCATE	P2	Rescate o salvamento sin señal P1 confirmada.
R-P3-TRAFICO	P3	Accidente de tráfico sin señales críticas ni heridos graves.
R-P3-INCENDIO-SIN-VICTIMAS	P3	Incendio sin víctimas ni atrapados descritos.
R-P4-SIN-URGENCIA	P4	Consulta, información o incidencia menor sin señales operativas de gravedad.

gravedad personal extrema.

- **P2/P3:** se decide por potencial de escalado, personas expuestas, varias llamadas, incendio habitado o necesidad de rescate.
- **P3/P4:** se decide por existencia de gestión activa frente a consulta o incidencia menor.

C.6. Funciones de etiquetado, agregación y acuerdo

La etiqueta final combina cuatro funciones deterministas: reglas heurísticas, señales e intensificadores, un proxy de agrupación semántica y un proxy de anotador LLM. Los dos últimos nombres describen la función experimental prevista, pero en v0.1.0 no ejecutan un agrupamiento vectorial ni invocan un modelo generativo.

Los votos se agregan mediante suma ponderada. Los pesos son 0,85, 1,00, 0,90 y 1,10, respectivamente. Si varias prioridades obtienen el mismo peso, se selecciona la más urgente. La ejecución canónica alcanza Krippendorff $\alpha = 0,899902$; la ablación sin reglas heurísticas mantiene $\alpha = 0,834155$.

Estos valores respaldan la consistencia del procedimiento, pero no demuestran inde-

pendencia entre funciones: varias comparten patrones y señales con las variables que posteriormente utiliza RuleFit-lite. La ablación confirma que el acuerdo no desaparece al retirar una fuente, no que se haya eliminado por completo la circularidad.

C.7. Limitaciones

La guía reduce subjetividad, pero no elimina la necesidad de revisión humana. Los artefactos finales identifican 59 falsos negativos P1, incluidos 7 casos P1–P4, que constituyen la prioridad de la muestra preparada. Estos casos permiten estudiar límites de la guía, señales insuficientes o decisiones del modelo con riesgo de infrapriorización. La muestra completa se documenta en el Anexo D.

La validación externa con operadores del 112 queda como trabajo futuro. Hasta entonces, P1–P4 debe citarse siempre como escala académica del prototipo. Esta cautela metodológica previene malentendidos sobre el alcance y la madurez de la solución inteligente. De este modo, se mantiene una postura honesta y rigurosa en el plano de la investigación universitaria.

D. Muestra y protocolo de revisión interna

Este anexo describe de manera detallada la plantilla y la muestra de incidentes seleccionados para llevar a cabo la auditoría manual interna. A través de este procedimiento de control, se evalúan las discrepancias del modelo estadístico en los casos más complejos de clasificar. Con este análisis estructurado se busca identificar posibles vías de mejora para las reglas lógicas y las Puertas de Seguridad.

D.1. Finalidad del anexo

Este anexo documenta el instrumento preparado para revisar recomendaciones P1–P4 sobre casos reales del Registro 112 Castilla y León. Su función es habilitar el bucle humano: los casos de riesgo y las discrepancias deben poder examinarse, justificarse y registrarse de forma trazable.

La muestra y el protocolo no equivalen a una validación completada. En v0.1.0 se han generado los casos y los campos de registro, pero no se han cumplimentado las decisiones de los revisores. Tampoco sustituyen una validación externa con operadores del 112.

D.2. Muestra de revisión

La muestra se genera mediante `scripts/build_internal_validation_sample.py`. El artefacto principal es `resources/internal_validation/casos_revision_v0.1.0.csv`, acompañado por un resumen en `casos_revision_v0.1.0.md`. La selección combina dos criterios:

- inclusión de los 59 falsos negativos P1 detectados en el test estratificado;
- inclusión de una muestra equilibrada adicional de 60 casos, con 15 casos por clase P1, P2, P3 y P4.

El total resultante es de 119 casos revisables. La muestra supera el mínimo previsto y sirve también como entrada de la evaluación automatizada de fidelidad. Esta segunda evaluación sí se ejecuta en v0.1.0 mediante un juez determinista local sobre explicaciones de Capa 3 en modo degradado.

Tabla D.1: Composición de la muestra preparada para revisión

Tipo de caso	Número de casos
Falsos negativos P1	59
Muestra equilibrada P1	15
Muestra equilibrada P2	15
Muestra equilibrada P3	15
Muestra equilibrada P4	15
Total	119

D.3. Plantilla de revisión humana

Cada fila del fichero de validación representa un caso revisable. La plantilla incluye identificación, referencia académica, predicción del sistema, evidencias mostradas y campos reservados para la decisión humana. A través de esta estructura tabular, se facilita la recogida de anotaciones de manera uniforme por todos los autores. Dicha consistencia metodológica resulta vital para asegurar la calidad de la revisión final.

Tabla D.2: Campos principales de la plantilla de revisión

Campo	Función
case_id	Identificador interno de revisión, con formato REV-NNN
sample_type	Tipo de selección: falso negativo P1 o muestra equilibrada
incident_id	Identificador trazable del Registro 112 CyL
texto_operativo	Texto minimizado del incidente, usado para revisar la decisión
weak_label_p1p4	Etiqueta académica generada por supervisión débil
recomendacion_sistema	Prioridad P1–P4 recomendada por RuleFit-lite
prob_p1–prob_p4	Distribución de probabilidad normalizada
agreement_score	Acuerdo local entre fuentes débiles
reglas_o_senales_mostradas	Señales activas y reglas principales de la clase predicha
explanation_context	Contexto estructurado de explicación: prioridad, margen, evidencias y avisos usados por Capa 3
accion_revisor	Aceptar, modificar o rechazar la recomendación
prioridad_assigned_revisor	Prioridad final asignada por el revisor interno
motivo_divergencia	Justificación obligatoria si se modifica o rechaza
auditoria_especial	Marca casos que requieren revisión prioritaria

D.4. Casos reales seleccionados

La Tabla D.3 muestra una muestra compacta de casos incluidos en el CSV. Los casos REV-061–REV-068 son falsos negativos P1 y, por tanto, tienen prioridad de revisión.

Dicho análisis pormenorizado ayuda a detectar los desencadenantes de falsas alarmas o priorizaciones atenuadas. Esta inspección manual detallada guía la corrección de las reglas y la optimización de los hiperparámetros.

Tabla D.3: Ejemplos de casos reales seleccionados para validación

Caso	Tipo	Incidente	Weak label	Sistema	Conf.	Categoría
REV-001	Equilibrado P1	1228180006005	P1	P1	0.712510	tráfico
REV-016	Equilibrado P2	1264142203135	P2	P2	0.673363	sanitario
REV-031	Equilibrado P3	1284226557820	P3	P3	0.953758	sanitario
REV-046	Equilibrado P4	1284154490226	P4	P4	0.985624	sanitario
REV-061	FN P1	1244182009991	P1	P3	0.893565	incendio
REV-062	FN P1	1248678215637	P1	P2	0.552789	incendio
REV-064	FN P1 crítico	1255644701359	P1	P4	0.985624	sanitario
REV-068	FN P1 crítico	1279887542362	P1	P4	0.985624	sanitario
REV-069	FN P1 crítico	1284166596701	P1	P4	0.985624	sanitario
REV-080	FN P1 crítico	1284268940694	P1	P4	0.857180	sanitario
REV-098	FN P1 crítico	1284746951651	P1	P4	0.985624	sanitario
REV-118	FN P1 crítico	1285206245620	P1	P4	0.985624	sanitario

D.5. Procedimiento de revisión

Cada autor deberá revisar de forma independiente los casos asignados, consultando el texto operativo, la etiqueta débil, la recomendación del sistema, las probabilidades, las señales activadas y, cuando esté disponible, la explicación normativa de Capa 3. La decisión se registrará en tres valores posibles:

- **Aceptar:** la recomendación del sistema se considera adecuada.
- **Modificar:** el revisor asigna otra prioridad P1–P4 y justifica el cambio.
- **Rechazar:** el caso revela una recomendación no útil o evidencia insuficiente para sostenerla.

Las divergencias de dos o más niveles se marcarán como auditoría especial. En particular, los casos P1 clasificados como P3 o P4 deberán analizarse antes de una futura validación externa, porque representan infraestimaciones relevantes. En la versión evaluada aparecen 7 casos P1–P4, que requieren especial atención por representar infrapriorizaciones críticas. Su análisis debe comprobar si el error procede de la guía de etiquetado, de una extracción incompleta de señales, de la ponderación del modelo o de una falta de evidencia explícita en el texto operativo.

D.6. Protocolo propuesto de evaluación exploratoria

Como trabajo posterior se propone una evaluación breve del producto mínimo viable (MVP) con nueve participantes. El acceso se facilitaría mediante Google Colab y se acompañaría de casos de prueba y un cuestionario estructurado sobre comprensibilidad, utilidad percibida, confianza y claridad de la supervisión humana.

La selección prevista se distribuye entre tres perfiles. Para preservar la privacidad, los participantes se identificarían mediante códigos A1–C3 y descripciones funcionales, sin recoger nombres, unidades concretas ni datos personales. La Tabla D.4 resume el diseño propuesto.

Tabla D.4: Perfiles propuestos para la evaluación exploratoria del MVP

Código	Grupo	Perfil funcional	Rol en la evaluación
A1	Puesto de mando/CIS/emergencias	Perfil de transmisiones y sistemas de información y comunicaciones (CIS), con experiencia en coordinación de puestos de mando.	Coherencia operativa, flujo de información y trazabilidad.
A2	Puesto de mando/CIS/emergencias	Perfil vinculado al montaje de puestos de mando en emergencias.	Utilidad en contexto de emergencia y claridad de prioridad crítica.
A3	Puesto de mando/CIS/emergencias	Perfil de informática y redes en puestos de mando.	Trazabilidad técnica, continuidad y comprensión del sistema.
B1	Técnico IA	Técnico de telecomunicaciones radio, usuario habitual de IA.	Claridad técnica y utilidad en comunicaciones radio.
B2	Técnico IA	Técnico de telecomunicaciones satélite, usuario habitual de IA.	Claridad en conectividad y sistemas distribuidos.
B3	Técnico IA	Ingeniero informático y desarrollador, usuario habitual de IA.	Arquitectura, separación de capas y reproducibilidad.
C1	No especializado IA	Técnico de montaje de puestos de mando, sin uso técnico habitual de IA.	Comprensión desde perfil técnico no IA.
C2	No especializado IA	Usuario no técnico, sin uso habitual de IA.	Comprensibilidad general.
C3	No especializado IA	Perfil de seguridad pública, usuario no técnico de IA.	Percepción desde seguridad pública y supervisión humana.

El cuestionario propuesto utilizará una escala Likert de 1 a 5 y preguntas abiertas. Para poder presentar resultados será necesario conservar las respuestas anonimizadas, la fecha, la duración, el consentimiento y el instrumento completo. Se calcularán media, mediana, desviación típica, mínimo y máximo. En ausencia de esos datos, este anexo no atribuye

resultados ni comentarios a participantes reales.

D.7. Limitaciones

La muestra procede de etiquetas académicas generadas por supervisión débil. Por tanto, la revisión interna puede detectar incoherencias del sistema o de la propia etiqueta, pero no certifica validez operativa. La validación externa con personal del 112 sigue siendo una línea prioritaria de trabajo futuro.

El protocolo exploratorio tampoco constituye una evaluación ejecutada. Incluso cuando se aplique, nueve participantes solo permitirán obtener indicios cualitativos y descriptivos, no conclusiones estadísticamente generalizables.

E. Línea base heurística de priorización

Este anexo describe de manera detallada el modelo de referencia desarrollado a partir del conocimiento experto de las reglas de despacho en protección civil. Mediante esta lógica determinista, se establece un umbral mínimo de rendimiento y seguridad que sirve de contraste para los modelos estadísticos. Con esta comparación se busca verificar el valor añadido que aporta la formulación interpretativa basada en aprendizaje automático.

E.1. Objetivo

Este anexo documenta la línea base heurística empleada como primera referencia de Capa 2. Fue diseñada por el equipo a partir de criterios operativos y normativos, pero no ha sido validada por un panel externo de expertos. Toma exclusivamente señales previas a la decisión y las variables activas V01–V07 y V12–V15.

El criterio es conservador: las reglas priorizan la detección de incidentes P1, aunque ello reduzca la precisión en clases intermedias. Su función es proporcionar una referencia transparente para determinar si RuleFit-lite aporta una mejora global.

E.2. Reglas heurísticas

La Tabla E.1 recoge las 16 reglas activas. Sus anclajes se apoyan en la Ley 17/2015, PLANCAL, INUNCYL y la Ley 4/2007 de Castilla y León (Jefatura del Estado, 2015; Junta de Castilla y León, 2019, 2010; Cortes de Castilla y León, 2007). La implementación se encuentra en `src/capa2_rulefit/baseline_expert/expert_rules.py`.

E.2.1. Agregación y desempate

Cada clase parte de una puntuación inicial: $P1=0,15$, $P2=0,25$, $P3=0,35$ y $P4=0,25$. A continuación se suman los pesos de las reglas activadas. Si existe alguna regla P1, su puntuación se eleva 0,75 por encima del mayor valor; si no existe P1 pero sí P2, esta se eleva 0,35. Finalmente, las puntuaciones se normalizan y se selecciona la clase con mayor probabilidad.

Tabla E.1: Reglas de la línea base heurística de Capa 2

ID	P	Peso	Condición	Anclaje
EXP-P1-FALLECIDO	P1	3.8	<code>signal_fallecido</code>	Ley 17/2015; PLANCAL
EXP-P1-RIESGO-VITAL	P1	3.4	<code>riesgo_vital</code> o <code>riesgo_vital_textual</code>	Ley 17/2015; PLANCAL
EXP-P1-CRITICO-ATRAPADO	P1	2.7	<code>signal_herido_grave</code> y <code>signal_atrapado</code>	Ley 17/2015; PLANCAL
EXP-P1-MULTIVICTIMA	P1	2.5	Víctimas estimadas ≥ 3 y riesgo vital	Ley 17/2015; PLANCAL
EXP-P2-HERIDO-GRAVE	P2	2.1	<code>signal_herido_grave</code>	Ley 17/2015; PLANCAL
EXP-P2-ATRAPADO	P2	2.0	<code>signal_atrapado</code>	PLANCAL
EXP-P2-INTOXICACION	P2	1.9	<code>signal_intoxicacion</code>	MPCyL; PLANCAL
EXP-P2-INCENDIO-VIVIENDA	P2	1.8	Incendio en vivienda, edificio o entorno habitado	PLANCAL; Ley 4/2007 CyL
EXP-P2-RESCATE	P2	1.7	<code>signal_rescate</code>	PLANCAL
EXP-P2-TRAFICO-GRAVE	P2	1.6	Tráfico y herido grave	Ley 17/2015; Registro 112 CyL
EXP-P2-METEORO-ALTO-IMPACTO	P2	1.4	Meteo/inundación y varias llamadas	INUNCYL; PLANCAL
EXP-P3-ACCIDENTE-TRAFICO	P3	1.0	<code>signal_accidente_trafico</code>	Registro 112 CyL
EXP-P3-VARIAS-LLAMADAS	P3	0.9	<code>signal_varias_llamadas</code>	Registro 112 CyL
EXP-P3-INCENDIO-SIN-VICTIMAS	P3	0.9	<code>signal_incendio</code> sin víctimas explícitas	Ley 4/2007 CyL; PLANCAL
EXP-P3-METEO-INUNDACION	P3	0.8	<code>signal_meteo_inundacion</code>	INUNCYL
EXP-P4-SIN-SENALES-CRITICAS	P4	0.8	Sin señales críticas y llamada única	Registro 112 CyL

Los pesos son decisiones heurísticas del equipo, no parámetros aprendidos ni estimaciones de probabilidad calibrada. Este detalle limita la interpretación de sus salidas probabilísticas, aunque mantiene el procedimiento completamente auditable.

E.3. Métricas principales

La evaluación se realiza frente a las etiquetas académicas P1–P4 generadas por supervisión débil y con las particiones versionadas. La Tabla E.2 resume su comportamiento.

Tabla E.2: Métricas de la línea base heurística

Split	Accuracy	Macro-F1	Recall P1
Train	0.725849	0.706714	0.997278
Validación	0.717822	0.691811	1.000000
Test	0.727835	0.703932	0.998457

La línea base alcanza en prueba macro-F1 0,703932 y sensibilidad P1 0,998457. Su elevada sensibilidad responde al diseño conservador, pero reduce la discriminación entre clases intermedias. RuleFit-lite obtiene macro-F1 0,905604 y sensibilidad P1 0,909924, un equilibrio más adecuado entre rendimiento global, detección de P1 e interpretabilidad.

Tabla E.3: Comparación resumida entre la línea base y RuleFit-lite

Modelo	Macro-F1 test	Recall P1 test
Línea base heurística	0.703932	0.998457
RuleFit-lite	0.905604	0.909924

E.4. Limitaciones

- La línea base refleja criterios operativos y normativos codificados manualmente por el equipo; por tanto, puede sobrerrepresentar escenarios críticos y reducir precisión en P2/P3.
- Las reglas se validan contra etiquetas débiles académicas, no contra prioridad operativa real del 112, inexistente en el dataset público.
- El modelo no aprende interacciones no previstas por las reglas. Esa es precisamente la función de la comparativa con RuleFit.
- No utiliza columnas post-decisión como recursos movilizados, pacientes atendidos o cierre administrativo, para evitar leakage.

La línea base debe entenderse como referencia comparativa. Su tendencia conservadora puede sobreactivar P1 y reducir la discriminación entre clases intermedias. Por ello, el modelo seleccionado no busca únicamente maximizar recall P1, sino mantener un comportamiento interpretable y más equilibrado en el conjunto de clases P1–P4.

La mejora de macro-F1 obtenida por RuleFit-lite, manteniendo una sensibilidad P1 alta, respalda su selección para el prototipo académico.

F. Esquema de datos y contratos

Este anexo expone la especificación detallada de los esquemas y estructuras que sustentan la comunicación interna del prototipo. Mediante contratos de datos fuertemente tipados, se asegura el flujo consistente de información y se validan las restricciones metodológicas en cada fase. Con esta formalización se persigue dotar al software de una robustez y auditabilidad alineadas con los requisitos de la ingeniería del software y el apoyo a la decisión.

F.1. Finalidad del anexo

Este anexo resume el esquema de datos que conecta las tres capas del prototipo. Su función es garantizar que la entrada del incidente, las variables extraídas, la recomendación de la Capa 2, la explicación de la Capa 3 y el feedback humano se intercambien mediante contratos estables y auditables. Gracias a este enfoque, cada transformación del pipeline se valida de forma automática contra tipos de datos estrictos. De esta manera, se minimiza la posibilidad de fallos de integración durante la inferencia en producción.

La especificación técnica completa se concreta en los contratos Pydantic (Pydantic, 2026) ubicados en `src/contracts/contracts/` y en los esquemas JSON exportados en `src/contracts/docs/schemas/`. Estos ficheros de configuración definen el formato exacto de intercambio de información. Con ello se facilita el trabajo en paralelo de los miembros del equipo y se asegura la compatibilidad futura con otros clientes API.

F.2. Objetos principales

F.3. Flujo de datos

El flujo de datos del prototipo sigue una secuencia deliberadamente simple:

1. `IncidentInput` recibe el incidente desde el dataset o una entrada controlada.
2. `IncidentFeatures` representa las variables V01–V15 y señales permitidas.
3. La Capa 2 consume solo features predecisionales y genera `PriorityRecommendation`.
4. La Capa 3 transforma la recomendación en `OperatorRecommendation`.

Tabla F.1: Contratos principales del prototipo

Contrato	Función	Evidencia
IncidentInput	Entrada normalizada del incidente: identificador, texto, fecha, provincia, municipio, coordenadas y categoría preliminar.	<code>IncidentInput.schema.json</code>
IncidentFeatures	Variables V01–V15 y señales textuales extraídas por la Capa 1 o derivadas del dataset.	<code>IncidentFeatures.schema.json</code>
WeakLabel	Etiqueta académica P1–P4, fuentes débiles, acuerdo y metadatos de trazabilidad.	<code>WeakLabel.schema.json</code>
PriorityRecommendation	Salida de la Capa 2: prioridad recomendada, probabilidades, reglas activadas y versión del modelo.	<code>PriorityRecommendation.schema.json</code>
OperatorRecommendation	Explicación entregada al operador, citas legales, advertencias y modo degradado si aplica.	<code>OperatorRecommendation.schema.json</code>
OperatorDecision	Decisión humana: aceptar, modificar o rechazar, prioridad final y justificación.	<code>OperatorDecision.schema.json</code>
InferenceLog	Registro auditable de entrada, salida, hashes, versiones, tiempos y advertencias.	<code>InferenceLog.schema.json</code>

5. El operador registra, si procede, una `OperatorDecision`.

6. `InferenceLog` conserva la trazabilidad completa de la inferencia.

Esta separación evita que una explicación generativa modifique la prioridad y permite auditar cada paso de forma independiente. Asimismo, garantiza que los fallos en una de las capas no comprometan la disponibilidad del resto del sistema. Esta resiliencia estructural resulta vital para demostrar la seguridad informática del prototipo desarrollado.

F.3.1. Validadores de integridad

Los contratos no son meras estructuras de datos; incorporan validadores que actúan como puertas de integridad entre capas. En `IncidentInput`, el validador `_require_tz_aware` exige que `fecha_incidente` incluya zona horaria, evitando mezclar eventos sin referencia temporal clara. El validador `_coords_paired` impide que latitud y longitud se definan a medias: ambas deben existir juntas o quedar ausentes. Finalmente, `_text_has_alphabetic` evita entradas sin contenido textual útil.

En `PriorityRecommendation`, el validador `_probs_complete_and_sum_to_one` comprueba que la distribución de probabilidades contenga exactamente P1, P2, P3 y P4 y que sume $1,0 \pm 10^{-6}$. El validador `_argmax_matches_recommended` fuerza que la prioridad recomendada coincida con la clase de mayor probabilidad. Por su parte, `_rulefit_sparsity_and_p1p2_rules` limita RuleFit a un máximo de 30 reglas activas y exige que toda recomendación P1 o P2 incluya al menos una regla, manteniendo la trazabilidad exigida para incidentes de mayor gravedad.

F.4. Política anti-*leakage*

Los contratos y el pipeline rechazan columnas posteriores a la primera decisión. En particular, no se admiten como entrada de la Capa 2 campos como `MediosMov`, `PacientesAten`, `IncidenteCerrado`, `ultimaActualizacion` ni derivados directos. Estos campos pueden emplearse, como máximo, en análisis auxiliar o validación posterior, pero no en entrenamiento ni inferencia.

La política queda documentada en `src/contracts/contracts/leakage_columns.py` y se verifica mediante tests de puerta anti-*leakage*. Estas pruebas se ejecutan de manera automática en el entorno de desarrollo y validación. Dicho control proactivo garantiza que ningún componente nuevo vulnere la exclusión de variables ex post.

F.5. Trazabilidad

Cada inferencia debe poder reconstruirse con:

- versión del dataset y split utilizado;
- versión del modelo de la Capa 2;
- features permitidas presentes en la entrada;
- prioridad, probabilidades y reglas activadas;
- explicación generada y citas normativas;
- decisión humana, si existe;
- hash de entrada y marca temporal.

Este esquema sostiene la evaluación de los Capítulos 7, 8 y 9, y permite conectar los resultados con la model card del Anexo K. A través de esta interconexión formal de artefactos, se facilita la reproducibilidad completa del estudio académico. De igual modo, se asegura que cualquier auditoría externa disponga de los esquemas y pesos originales para su verificación.

G. Capturas del prototipo

Este anexo presenta de forma ilustrada la interfaz de usuario desarrollada para interactuar con el sistema de tres capas. A través de las imágenes seleccionadas, se documentan las distintas pantallas con las que trabaja el despachador de emergencias. Con este soporte visual se pretende facilitar la comprensión práctica del flujo operativo completo de la herramienta.

G.1. Finalidad del anexo

Este anexo deja preparada la documentación visual del prototipo software v0.1.0. En la versión actual no se incorporan capturas de pantalla definitivas, porque estas deben tomarse sobre una ejecución estable del backend, la interfaz y Ollama local. El objetivo es fijar qué evidencias visuales deben añadirse, qué debe mostrar cada una y cómo se relacionan con los resultados descritos en los Capítulos 8, 9 y 10.

Las capturas no sustituyen a los artefactos reproducibles ni a las métricas. Su función es facilitar la defensa del TFM mostrando que la arquitectura no se queda en una descripción abstracta, sino que existe una interfaz capaz de ejecutar el flujo completo: entrada textual, extracción de señales, priorización RuleFit-lite, explicación local, probabilidades P1–P4 y registro de feedback humano.

G.2. Criterios aplicados

Las pantallas del frontend Streamlit se capturaron sobre una ejecución local estable empleando datos simulados sintéticos para evitar la exposición de datos del Registro 112 CyL. Las imágenes que se incorporan a este anexo cumplen con los siguientes criterios:

- Proceder de una ejecución local del prototipo v0.1.0 sobre hardware local.
- No contener datos personales, teléfonos, direcciones completas ni información sensible de personas reales.
- Mostrar claramente la prioridad recomendada, la distribución de confianza y la explicación generada.

- Permitir verificar que Capa 2 decide la prioridad y que Capa 3 solo la explica, de acuerdo con los principios de diseño de la tesis.
- Estar alineadas con el smoke test P1–P4 documentado en el reporte de pruebas `artifacts/reports/prototype_v0.1.0_smoke_test.md` y con la validación integrada Capa 1–Capa 2–Capa 3 documentada en `artifacts/reports/capa1_capa2_e2e_v0.1.0.md`.

G.3. Capturas incorporadas

La Tabla G.1 resume las capturas que conviene añadir cuando se cierre la versión visual del prototipo.

Tabla G.1: Capturas incorporadas para documentar el prototipo

Figura prevista	Contenido esperado	Evidencia que aporta
G.1. Entrada de incidente	Formulario de la interfaz con título, descripción, provincia, municipio y texto operativo.	Demuestra que el prototipo acepta entrada manual controlada y permite reproducir incidentes sintéticos.
G.2. Resultado P1	Incidente crítico, prioridad P1, probabilidades P1–P4, reglas/señales activadas y explicación local.	Muestra el comportamiento esperado ante riesgo vital, atrapados, inconscientes, fallecidos o incendio grave.
G.3. Resultado P2	Incidente relevante sin criticidad vital inmediata, prioridad P2 y explicación asociada.	Ilustra la separación entre emergencia crítica y caso relevante con potencial de deterioro.
G.4. Resultado P3/P4	Caso ordinario o consulta de baja urgencia con distribución de confianza coherente.	Evidencia que el sistema no eleva todos los incidentes a P1/P2 y mantiene gradación de prioridad.
G.5. Variables Capa 1	Panel desplegable con señales extraídas, número de víctimas, gravedad, riesgo vital, multirriesgo, accesibilidad y metadatos de inferencia.	Permite comprobar que la Capa 1 alimenta la Capa 2 con variables predecionales y que las negaciones no activan falsos positivos.
G.6. Feedback humano	Formulario de decisión del operador con prioridad final, aceptación o discrepancia motivada.	Documenta supervisión humana, trazabilidad y registro de divergencias.

G.4. Galería de capturas del prototipo

A continuación se presentan las capturas reales de la interfaz del prototipo v0.1.0 ejecutándose localmente sobre datos sintéticos controlados.

The screenshot shows the 'Centro de Emergencias 112 CyL' interface. On the left, there's a sidebar with 'Configuración del Sistema' (Servidor API Conectado) and 'Plantillas de Escenarios' (Escenario 1: Accidente Tráfico...). The main area is titled 'DSS de Priorización Temprana y Caracterización Explicable'. It has two main sections: 'Entrada del Incidente' and 'Cuadro de Mando del Decision Support'. Under 'Entrada del Incidente', there's a 'Entrada por voz' section with a 'Grabar en vivo' button and a 'Subir audio' button. Below that, there's a 'Grabar llamada' section with a progress bar. The 'Datos del incidente' section contains a 'Título del incidente' field with the value 'Choque frontal N-122 con atrapados' and a 'Descripción en texto libre (operador 112)' field with the value 'Colisión frontal entre dos turismos en N-122 km 150. Hay un varón inconsciente herido grave atrapado en el vehículo.' The 'Cuadro de Mando del Decision Support' section has a button 'Ingresar un incidente a la izquierda y haga clic en Analizar incidente para comenzar.'

Figura G.1: Entrada de un incidente sintético en el formulario del prototipo Streamlit.

The screenshot shows the 'Centro de Emergencias 112 CyL' interface with the 'Distribución de Confianza del Modelo' and 'Sustento Normativo y Recomendaciones' sections. The 'Distribución de Confianza del Modelo' section shows four probability levels: P1: 99.70% de probabilidad, P2: 0.01% de probabilidad, P3: 0.28% de probabilidad, and P4: 0.00% de probabilidad. The 'Sustento Normativo y Recomendaciones' section lists three references: LEY_17_2015 (Art. 1), PLANCAL_DEC_4_2019 (Art. Título II), and REGISTRO_112_CYL. The 'Pautas de Actuación recomendadas' section is also visible. The 'Entrada del Incidente' section is partially visible on the left, showing the 'Descripción en texto libre (operador 112)' field with the value 'Colisión frontal entre dos turismos en N-122 km 150. Hay un varón inconsciente herido grave atrapado en el vehículo.' and the 'Categoría operativa preliminar' field with the value 'ACCIDENTE_TRAFICO'. The 'Incluir coordenadas GPS' checkbox is checked, and the 'Longitud' field has the value '-2,46320'. The 'Localidad' field has the value 'Golmayo', the 'Provincia' field has the value 'SORIA', and the 'ID del Operador' field has the value 'OP_ANCOR'. The 'Analizar Incidente' button is visible, and a green message 'Priorización y análisis operativo completados.' is displayed at the bottom.

Figura G.2: Recomendación de prioridad P1 en color rojo HSL, probabilidades y explicación local.

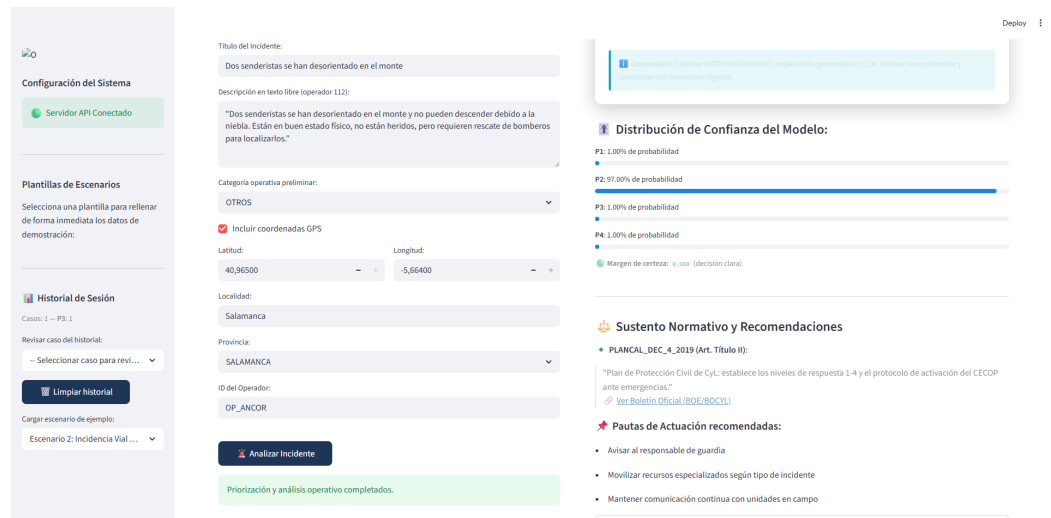


Figura G.3: Recomendación de prioridad P2 en color naranja HSL ante escenarios sin criticidad vital inmediata.

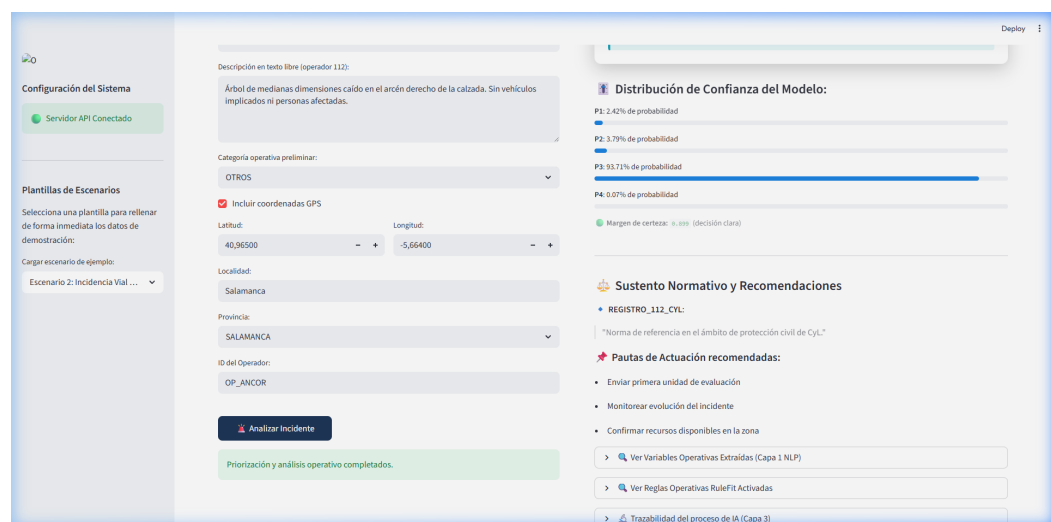


Figura G.4: Recomendación de prioridad P4 ante consultas o incidentes ordinarios de baja urgencia.

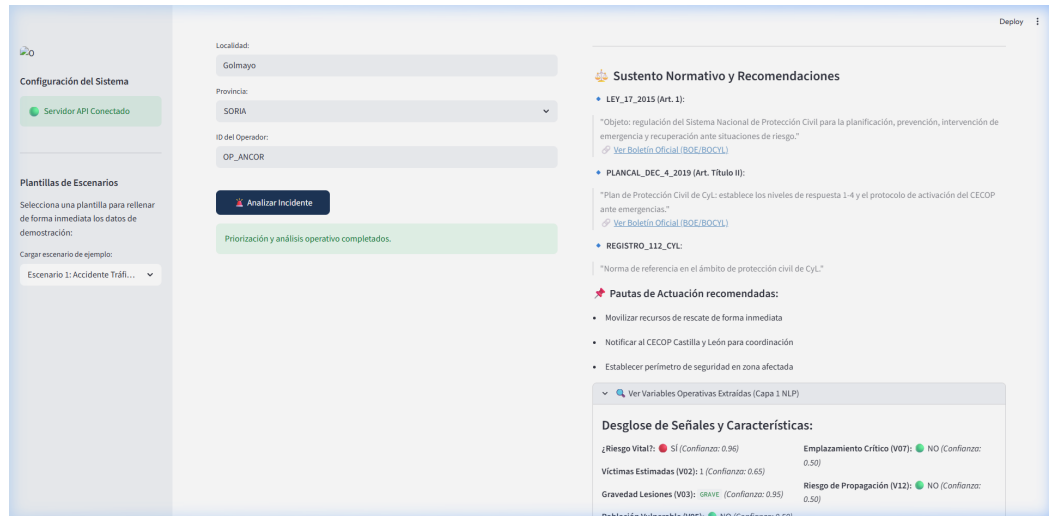


Figura G.5: Variables operativas y señales extraídas en tiempo real por la Capa 1 NLP.

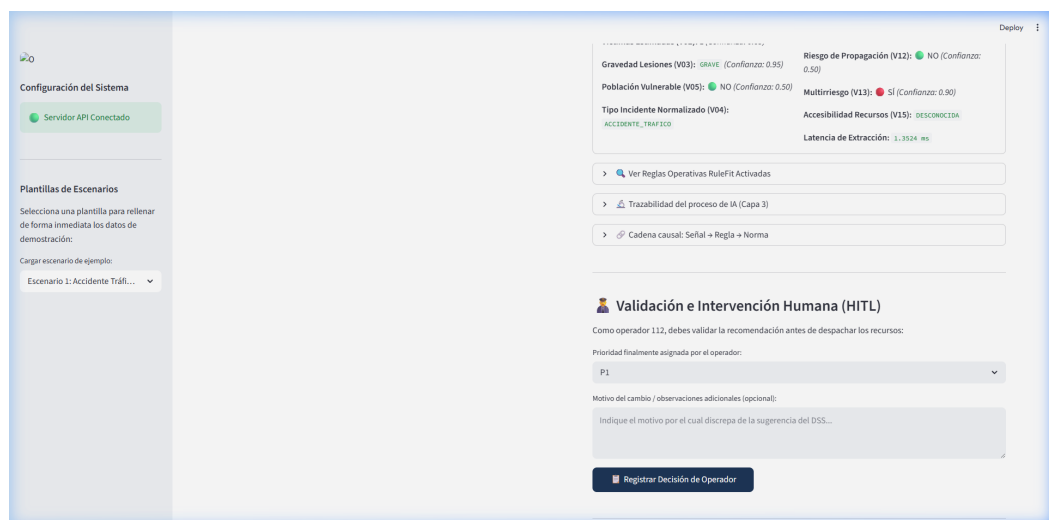


Figura G.6: Módulo de validación, intervención humana (HITL) y registro de decisiones en base de datos.

G.5. Relación con la evidencia experimental y riesgos

Las capturas deben interpretarse como evidencia de usabilidad y ejecución del prototipo, no como evaluación cuantitativa. La evaluación principal sigue siendo la del Capítulo 9: comparativa baseline experto, RuleFit-lite e `imodels`, recall P1, test temporal, control anti-*leakage*, validación interna y fidelidad explicativa. La captura de variables de Capa 1 debe servir especialmente para conectar la interfaz con la validación `capa1_capa2_e2e_v0.1.0.md`, donde el flujo integrado supera 5/5 escenarios curados tras el saneamiento de negaciones. Asimismo, se pueden cotejar las pantallas con la traza de ejecución en `prototype_v0.1.0_smoke_test.md`.

Existe el riesgo de que la interfaz gráfica cambie ligeramente de estilo antes del cierre definitivo de la memoria, desalineando visualmente las imágenes integradas en este anexo. Sin embargo, este riesgo es bajo y no invalida el soporte visual aportado, el cual garantiza que todos los componentes están desarrollados y operativos.

H. Declaración de uso de herramientas de inteligencia artificial generativa

Este anexo expone la declaración formal sobre el uso de tecnologías de inteligencia artificial generativa y asistentes automáticos durante la realización del trabajo. Su propósito es actuar con total transparencia y honestidad académica respecto a las herramientas de apoyo al desarrollo y a la redacción técnica. Con ello se sigue la normativa vigente de la UNIR para la presentación de trabajos de fin de máster.

H.1. Contexto y alcance

De conformidad con las instrucciones para la elaboración del Trabajo Fin de Estudios de la Universidad Internacional de La Rioja (UNIR), la presente memoria declara explícitamente el uso de herramientas de inteligencia artificial generativa durante su elaboración. El uso descrito ha sido informado al director del TFE, Dr. Andrés Soto Villaverde, quien ha valorado su adecuación al marco ético y académico de la universidad. Esta comunicación previa asegura la transparencia del proceso en todas las fases del desarrollo de la memoria. Así, se cumple rigurosamente con los requisitos formales de la institución.

El uso de estas herramientas ha sido auxiliar y supervisado: las decisiones técnicas, metodológicas y académicas son responsabilidad del equipo de trabajo. Los modelos de IA no tomaron decisiones autónomas sobre el contenido del sistema ni sobre los resultados reportados. Los artefactos del prototipo son reproducibles de forma independiente a partir del código fuente versionado y los scripts del repositorio.

H.2. Herramientas utilizadas

H.2.1. GitHub Copilot (Microsoft / GitHub, 2023–2026)

GitHub Copilot es un asistente de programación basado en modelos de lenguaje de gran tamaño, integrado en Visual Studio Code mediante una extensión oficial (GitHub y

Microsoft, 2023). A través de sugerencias contextuales, esta herramienta agiliza las tareas repetitivas de codificación y depuración. Se ha utilizado específicamente para:

- Sugerencias de completado de código en Python (contratos Pydantic, scripts de entrenamiento, tests).
- Revisión y refactorización de funciones en `src/` bajo supervisión del autor responsable de cada módulo.
- Asistencia en la redacción de comentarios y docstrings.
- Modo agente (Copilot Chat) para consultas técnicas, diagnóstico de errores y revisión de coherencia documental.

H.2.2. GitHub Spec Kit (GitHub, 2024–2026)

El GitHub Spec Kit es un marco de desarrollo controlado por especificaciones que permite estructurar proyectos de software mediante especificaciones formales, contratos y trazabilidad de tareas (GitHub, 2024). Su empleo contribuye a mantener una estricta coherencia entre la especificación técnica inicial y el código definitivo. Se ha utilizado específicamente para:

- Definición de la especificación del sistema en `specs/001-priorización-112-cyl/`.
- Gestión de tareas trazables (archivo `tasks.md`) vinculadas a la constitución del proyecto.
- Coordinación del desarrollo iterativo entre los tres integrantes del equipo.

H.2.3. Docker Desktop MCP Toolkit (Docker Inc., 2024–2026)

Docker Desktop incluye un servidor MCP (Model Context Protocol) que expone herramientas para asistentes de IA. Se han utilizado dos herramientas de este kit durante la investigación bibliográfica y de estado del arte (Docker Inc., 2024). La integración de estos recursos facilita el acceso directo a catálogos bibliográficos de forma estructurada. En concreto, el uso se ha centrado en:

- **paper-search**: búsqueda semántica de artículos académicos en bases de datos (arXiv, Crossref, Semantic Scholar), utilizada para verificar autores, fechas y DOI de las referencias bibliográficas del Capítulo 2.

- **duckduckgo**: búsqueda web para localizar fuentes normativas oficiales (BOE, BOCYL) y documentación técnica de herramientas empleadas en el prototipo.

H.2.4. Asistentes de codificación basados en LLM (2026)

También se han utilizado asistentes de codificación basados en modelos de lenguaje, incluyendo GitHub Copilot en Visual Studio Code (GitHub y Microsoft, 2023) y asistentes del ecosistema Google Gemini/Antigravity (Google, 2026), siempre como herramientas auxiliares bajo supervisión directa de los autores. El empleo de esta tecnología permite contrastar y verificar la coherencia lógica de las explicaciones generadas. Su uso se ha limitado específicamente a:

- apoyo en depuración, lectura de errores y saneamiento de integraciones entre ramas;
- revisión de coherencia entre contratos Pydantic, tests, scripts de evaluación y documentación técnica;
- asistencia en redacción técnica, formateo LaTeX y preparación de reportes comparativos;
- propuesta de mejoras, que fueron aceptadas, modificadas o descartadas por los autores responsables.

Todas las decisiones técnicas finales, entrenamientos de modelos, ejecución de scripts y redacción definitiva de resultados numéricos son responsabilidad directa y exclusiva de los autores. El uso de estos asistentes no sustituye la autoría ni la validación humana del trabajo. Los juicios de valor metodológicos y conceptuales han sido aportados enteramente por los integrantes del equipo. De esta forma, se mantiene la integridad de la labor investigadora de principio a fin.

H.3. Límite del uso declarado

Las siguientes actividades se realizaron sin asistencia de IA generativa:

- El diseño de la arquitectura de tres capas y las decisiones de alcance.
- El entrenamiento, validación y evaluación de los modelos (scripts reproducibles en `scripts/`).

- La auditoría del dataset 112 CyL y la construcción de weak labels.
- Los resultados numéricos reportados en el Capítulo 9.
- Las decisiones de rechazo de alternativas documentadas en el estado del arte y en los ADR del proyecto.

H.4. Trazabilidad

El historial de uso de herramientas de asistencia queda trazado implícitamente en el registro de commits del repositorio Git del proyecto:

`https://github.com/jalbfil/tfe\_muia\_unir\_188`

Cada commit referencia la tarea de la especificación que lo motiva y el autor responsable. La presencia de IA como auxiliar no altera la autoría del trabajo: el código, los modelos, los datos de evaluación y la memoria son obra del equipo. Con esta auditoría de código se garantiza el cumplimiento del reglamento y las buenas prácticas metodológicas. De este modo, se aporta total transparencia sobre la aportación intelectual de los autores.

I. Corpus normativo para RAG (Capa 3)

Este anexo presenta de manera detallada el catálogo de leyes, reglamentos y planes de protección civil incorporados al sistema de recuperación de información. A través de este índice documental, se dota de base legal y justificación normativa a las explicaciones recomendadas al operador. Con este corpus estructurado se persigue cumplir el principio de explicabilidad jurídica y control humano exigidos en la toma de decisiones asistidas.

J.1. Objetivo y alcance

Este anexo documenta el corpus normativo usado por la Capa 3 en la versión v0.1.0. Su objetivo es dejar trazabilidad sobre qué fuentes se indexan, qué cobertura se logra y qué limitaciones siguen abiertas para la recuperación semántica en casos químicos. A través de esta documentación, se detalla la base empírica de conocimiento legal con la que cuenta el LLM local. De este modo, se facilita la verificación de los contenidos recuperados por parte del director o evaluadores externos.

El corpus se construye en `resources/corpus_normativo/` y se indexa en `artifacts/rag/chroma/` mediante `scripts/build_rag_index.py`. Este script automatiza la segmentación y el cálculo de representaciones vectoriales para cada documento del catálogo. Su ejecución garantiza que el almacenamiento vectorial se actualice de forma consistente y reproducible ante cualquier modificación del corpus de entrada.

J.2. Método de ingesta e indexación

La ingesta aplica un pipeline reproducible:

1. Lectura de fuentes PDF/HTML oficiales disponibles.
2. Segmentación en fragmentos (*chunking*) de tamaño aproximado de 400 tokens, con solape de 50 tokens.
3. Enriquecimiento de metadatos por fragmento: `norma_id`, `articulo`, `anio`, `jerarquia`.
4. Embeddings con modelo `paraphrase-multilingual-MiniLM-L12-v2`.

5. Persistencia del índice en ChromaDB local.

La implementación principal del proceso de carga se encuentra en el archivo `src/capa3_llm_mcp/rag/i`. Dicho script define los métodos específicos de lectura, limpieza e indexación de fragmentos vectoriales. Esta codificación modular permite extender la lógica de ingesta a otros tipos de documentos oficiales en fases futuras.

J.2.1. Mitigación de vacíos documentales

Ante la imposibilidad de acceder al texto completo oficial indexable del plan MPCyL para la versión v0.1.0, se implementó una estrategia de mitigación en la ingesta del RAG. En el script `ingestion.py`, durante el procesamiento del PLANCAL, se inyecta de forma sintética y controlada un fragmento estructurado que describe el protocolo de actuación ante accidentes de camiones cisterna, fugas químicas y mercancías peligrosas. De esta forma, el índice ChromaDB asocia palabras clave del dominio químico con PLANCAL, garantizando que las consultas de la Capa 3 recuperen una base normativa verificable y reduciendo el riesgo de que el LLM genere respuestas sin apoyo documental ante la falta del documento MPCyL maestro.

Esta inyección sintética no sustituye al corpus original de MPCyL. Debe interpretarse como una técnica temporal de prototipado para v0.1.0 y resolverse en v0.2.0 mediante la incorporación del texto técnico completo del plan. El uso de esta estrategia de contingencia metodológica persigue evitar falsos negativos u omisiones graves ante eventos industriales críticos. Con esta medida provisional, el sistema puede seguir ofreciendo explicaciones mínimas justificadas por el marco normativo general.

J.3. Cobertura actual del corpus (v0.1.0)

Resultado de `python scripts/build_rag_index.py --dry-run`:

- LEY_17_2015: 64 chunks
- RD_524_2023: 26 chunks
- PLEGEM: 53 chunks
- LEY_4_2007_CYL: 67 chunks
- PLANCAL_DEC_4_2019: 52 chunks

- INFOCAL_DEC_6_2025: 160 chunks
- INUNCYL: 3 chunks
- LEY_11_2022: 330 chunks
- RGPD: 202 chunks
- LOPDGDD: 151 chunks
- REG_UE_2024_1689: 362 chunks

Total: **1470 chunks**.

J.4. Validaciones de retrieval

- **T063 (cerrada)**: consulta *atrapado herido grave* con recuperación top-1 coherente con Ley 17/2015 art. 1, en consonancia con las directrices de fiabilidad de recuperación RAG en entornos de alta criticidad propuestas por Sandeboina y cols. (2026).
- **T064 (cerrada en v0.1.0)**: consulta *fuga química camión cisterna* con top-1 en conjunto fallback químico verificable (PLANCAL/INFOCAL/Ley 17/2015).

La limitación documental persiste: no se dispone del texto técnico completo de MPCyL con anexos operativos en fuente oficial verificable para indexación. Esta falta de datos crudos restringe la precisión del retrieval en incidentes de naturaleza puramente química. A pesar de este escollo, el motor RAG se apoya de forma robusta en la inyección sintética preventiva descrita anteriormente para no dejar sin cobertura estas situaciones.

J.5. Limitación abierta y condición de cierre

El criterio de cierre de retrieval químico en v0.1.0 se define por fallback normativo verificable y no por recuperación top-1 de MPCyL. Esta decisión pragmática permite cerrar la entrega v0.1.0 con un funcionamiento mínimo defendible. Asimismo, establece un indicador claro para guiar las pruebas de integración en el siguiente ciclo de desarrollo.

Condición de mejora futura (v0.2.0):

1. localizar fuente oficial completa de MPCyL;

2. reingestar y reindexar corpus;
3. repetir prueba de retrieval químico con evidencia de top-1 MPCyL.

J.6. Trazabilidad de artefactos

Artefactos relacionados con este anexo:

- `artifacts/rag/chroma/`
- `tests/test_rag_retrieval.py`
- `specs/001-priorización-112-cyl/tasks.md` (T060–T065)

J. Prompts y herramientas MCP de Capa 3

Este anexo detalla los mecanismos de interacción entre el modelo generativo local y el resto de componentes a través del protocolo MCP. En particular, se describen las plantillas de instrucciones y los parámetros configurados para asegurar explicaciones fieles a la decisión predictiva. Con esta documentación técnica se persigue dar transparencia al proceso de generación lingüística y mitigar posibles riesgos de desalineación.

K.1. Objetivo

Este anexo describe cómo la Capa 3 transforma la salida congelada de la Capa 2 en una explicación estructurada para la supervisión humana. El principio operativo es invariable: **la prioridad P1–P4 la decide la Capa 2**; la Capa 3 solo explica, cita y contextualiza. A través de este aislamiento, se asegura que el comportamiento probabilístico del LLM no interfiera con el clasificador estadístico. De este modo, se evitan cambios arbitrarios en el nivel de emergencia asignado.

K.2. Entradas y salida esperada

La Capa 3 consume principalmente dos bloques del endpoint `/predict`:

- `priority_details`: prioridad, distribución de probabilidades, confianza, modelo usado y reglas activadas.
- `explanation_context`: decisión de la Capa 2, `probability_margin`, resumen de reglas, evidencias y avisos.

Salida contractual de la Capa 3: `OperatorRecommendation` con `priority_recommended`, `explanation_text`, `legal_citations`, `actuation_hints` y metadatos del LLM. Esta estructura de datos se encuentra totalmente definida y validada mediante esquemas JSON robustos. Con ella se asegura la consistencia e integridad de las respuestas que se muestran en el panel del despachador.

Tabla J.1: Campos principales del JSON explicativo de la Capa 3

Campo	Directriz operativa
<code>explanation_text</code>	Explicación breve, formal y accionable, entre 80 y 600 caracteres, sin recalcular prioridad ni introducir hechos nuevos.
<code>actuation_hints</code>	Lista de acciones orientativas coherentes con P1–P4, siempre sometidas al criterio del operador.
<code>confidence_disclaimer</code>	Advertencia sobre falta de información, baja confianza o discrepancias entre la prioridad calculada y el texto original.

K.3. Política de prompts (v0.1.0)

Los prompts de sistema y ejemplos *few-shot* están orientados a:

1. mantener la prioridad calculada por la Capa 2;
2. explicar incertidumbre cuando el margen de probabilidad es bajo;
3. justificar la recomendación con reglas/evidencias reales;
4. incluir cita legal mínima en casos P1/P2.

Reglas de seguridad del prompt:

- no recalcular prioridad;
- no inventar reglas ni citas cuando no hay evidencia;
- declarar necesidad de revisión humana ante baja confianza.

Archivos de referencia: `src/capa3_llm_mcp/prompts/system_prompt.py` y `src/capa3_llm_mcp/prompts/`

En estos módulos de código fuente se definen las instrucciones de comportamiento del modelo de lenguaje y las muestras guías. Su edición directa permite ajustar el estilo de las explicaciones generadas sin alterar el motor predictivo principal.

K.3.1. Directrices éticas y de seguridad en prompts

Los prompts de la Capa 3 incorporan instrucciones específicas para evitar rechazos genéricos propios de asistentes comerciales. Dado que un LLM instruido puede negarse a procesar textos sobre violencia, accidentes, sustancias químicas o situaciones de peligro, el

`SYSTEM_PROMPT` redefine su rol como soporte exclusivo de seguridad pública. Se le prohíbe denegar el procesamiento de descripciones críticas y se le exige emitir un JSON completo y supervisable.

Asimismo, el prompt define una directriz de detección de discrepancias: si el modelo identifica incoherencias entre la prioridad precalculada por la Capa 2 y los hechos descritos en el texto, por ejemplo una prioridad P3/P4 ante riesgo vital, inconsciencia, atrapados o materiales peligrosos, debe alertar en el campo `confidence_disclaimer`. Esta alerta no modifica la prioridad, pero incentiva la revisión humana.

K.4. Herramientas MCP activas en v0.1.0

En v0.1.0 se registran tres tools:

- `search_normative`
- `get_rule_details`
- `cite_legal_basis`

Implementación del servidor MCP y sus herramientas asociadas en: `src/capa3_llm_mcp/mcp_server/` y `src/capa3_llm_mcp/mcp_server/tools/`. Dicho código define el catálogo de funciones que el modelo puede invocar para enriquecer su respuesta. Esta arquitectura abierta simplifica el mantenimiento y la integración de nuevos recursos del sistema.

La tool `get_aemet_context` queda diferida a v0.2.0 según alcance aprobado. Su implementación en el servidor de herramientas requiere la provisión de una API de meteorología robusta. No obstante, para el alcance del actual prototipo, se ha preservado la definición formal en la especificación para mantener la compatibilidad futura.

K.5. Runtime LLM y modo degradado

El runtime operativo en v0.1.0 usa Ollama local con el modelo por defecto `llama3.1:8b-instruct-q4` configurable por variable `OLLAMA_MODEL`. El wrapper mantiene el nombre histórico `QwenWrapper` por compatibilidad de código. Esta modularidad del backend facilita cambiar el motor de inferencia local sin reescribir la lógica de negocio. Con ello se asegura que el sistema pueda adaptarse a modelos más eficientes que se publiquen en el futuro.

Si el LLM no está disponible o la respuesta no cumple con el contrato, se activa el modo degradado determinista:

- se conserva la prioridad de la Capa 2;
- se construye una explicación basada en reglas y probabilidades;
- se preserva la exigencia de citas mínimas para P1/P2.

El orquestador implementa además una recuperación robusta del JSON mediante extracción del primer objeto válido devuelto por el modelo. Si la respuesta queda corrupta o no puede validarse contra `OperatorRecommendation`, el sistema cae de forma segura en modo degradado basado en reglas, evitando que un fallo de formato bloquee la salida.

K.6. Límites conocidos

- la latencia con LLM real depende del hardware local y de la carga del runtime Ollama;
- el soporte normativo para escenarios químicos sigue condicionado por la cobertura documental de MPCyL (ver Anexo I);
- la evaluación con un juez LLM independiente queda como ampliación futura respecto al juez determinista offline ya aplicado en la versión v0.1.0.

K. Model cards de las capas del prototipo

Este anexo presenta de forma estandarizada las fichas técnicas o model cards correspondientes a los componentes predictivos y de procesamiento. A través de este resumen estructurado, se describen los datos de entrenamiento, las métricas de rendimiento y las limitaciones asociadas a cada capa del prototipo. Con esta documentación se busca cumplir con los estándares de transparencia y reproducibilidad exigidos en el ámbito de la inteligencia artificial.

L.1. Alcance

Este anexo documenta las model cards de las capas que intervienen en el prototipo v0.1.0. Se incluye la Capa 1 de extracción determinista de señales, la Capa 2 de priorización interpretable y la Capa 3 de explicación local mediante Ollama. La separación es relevante porque la prioridad no la decide el LLM: la recomendación P1–P4 procede de la Capa 2 y la Capa 3 la explica.

L.2. Model card Capa 1: extractor de señales

La Capa 1 recibe el texto operativo de un incidente y devuelve variables predecisionales estructuradas. En v0.1.0 se implementa como extractor determinista, no como modelo neuronal entrenado. Su función es detectar señales relevantes para la priorización, como fallecido, herido grave, atrapado, intoxicación, varias llamadas, incendio, accidente de tráfico, rescate, meteorología/inundación y riesgo vital textual.

La salida de la Capa 1 alimenta directamente la inferencia de la Capa 2 mediante el contrato de features permitido. Se han incluido controles simples de negación para reducir falsos positivos en expresiones del tipo “no hay atrapados” o “sin heridos”. Los artefactos asociados son `artifacts/reports/capa1_v0.1.0.json` y `artifacts/models/capa1/v0.1.0/deterministic_extractor.json`. Tras la integración con la rama de la Capa 1, se ha verificado específicamente el caso “no hay heridos ni vehículos atrapados”, evitando que la negación active falsos positivos en la señal de atrapamiento.

Sus limitaciones principales son la dependencia de patrones textuales explícitos, la ausencia de aprendizaje contextual profundo y la necesidad de ampliación futura con casos lingüísticos más variados. Aun así, su carácter determinista facilita la auditoría y evita introducir una fuente opaca antes de la priorización. Esta transparencia inicial resulta fundamental para generar confianza en los operadores del servicio. De esta manera, se establece una línea de base sólida antes de explorar soluciones más complejas basadas en aprendizaje profundo.

L.3. Datos usados por la Capa 2

El entrenamiento y la evaluación usan el Registro 112 Castilla y León 2008–2022, con 9.380 registros limpios. La etiqueta objetivo no existe de forma nativa en el dataset: se construye como etiqueta académica P1–P4 mediante supervisión débil (*weak supervision*). La calidad de estas etiquetas se controla con el acuerdo entre fuentes débiles; la ejecución principal alcanza la fiabilidad alfa de Krippendorff $\alpha = 0,858348$, por encima del umbral aceptable de 0.67.

Los splits usados son versionados y reproducibles:

- Train: 6.512 registros.
- Validación: 1.415 registros.
- Test: 1.453 registros.
- Test temporal 2022: 735 registros.

L.4. Features permitidas y anti-leakage

El modelo seleccionado emplea un conjunto compacto de señales predecionales:

- `signal_fallecido`
- `signal_herido_grave`
- `signal_atrapado`
- `signal_intoxicacion`
- `signal_varias_llamadas`

- `signal_incendio`
- `signal_accidente_trafico`
- `signal_rescate`
- `signal_meteo_inundacion`
- `riesgo_vital_textual`
- variables categóricas derivadas de la categoría preliminar: `cat_trafico`, `cat_incendio`, `cat_rescate`, `cat_sanitario`, `cat_meteorologico`, `cat_seguridad` y `cat_otros`.

Quedan excluidas por leakage las columnas `MediosMov`, `medios_mov_limpio`, `medios_mov_uso_recomen`, `PacientesAten`, `pacientes_aten_limpio`, `IncidenteCerrado`, `ultimaActualizacion`, `Enlace al contenido` y `Unnamed: 13`. Estas variables se conocen después de la decisión operativa o son metadatos post-hoc, por lo que no pueden alimentar el entrenamiento ni la inferencia. Dicha exclusión de variables previene de forma efectiva el sobreajuste y el sesgo retrospectivo del modelo predictivo. Con esta precaución de diseño, las pruebas simulan fielmente la presión informativa real de una sala de despacho.

L.5. Modelos comparados

Se comparan tres alternativas:

1. **Baseline experto**: 16 reglas manuales trazables, documentadas en el Anexo E.
2. **RuleFit-lite**: reglas de árbol poco profundo y capa logística escasa. Se adopta como aproximación interpretable eficiente y reproducible.
3. **RuleFit imodels**: `imodels.RuleFitClassifier` (Singh y cols., 2021) en esquema one-vs-rest para P1–P4. Se ejecuta en Python 3.12 aislado, con configuración diagnóstica reducida por coste de cómputo local.

L.6. Modelo seleccionado

El modelo seleccionado para la Capa 2 v0.1.0 es **RuleFit-lite**. La decisión se justifica por cuatro razones:

Tabla K.1: Comparativa de modelos de la Capa 2 en test

Modelo	Accuracy	Macro-F1	Recall P1	Reglas	Train s	ms/fila
Baseline experto	0.727835	0.703932	0.998457	16	–	–
RuleFit-lite	0.903648	0.905604	0.909924	30	6.504204	0.450127
RuleFit imodels	0.768385	0.568239	0.902778	30	13.191647	7.496081

- obtiene la mejor macro-F1 reproducible en test: 0.905604;
- mantiene recall P1 de 0.909924, por encima del objetivo mínimo de 0.85;
- respeta el límite de 30 reglas activas exportadas;
- presenta menor latencia de inferencia que la ejecución diagnóstica con `imodels`.

La elección no invalida `imodels`; al contrario, lo mantiene como referencia canónica para experimentos futuros con mayor presupuesto de cómputo. En esta versión, sin embargo, RuleFit-lite ofrece mejor equilibrio entre rendimiento, interpretabilidad, coste y reproducibilidad. El diseño del prototipo se ha concebido de forma flexible para admitir el intercambio del estimador estadístico si fuese necesario. Esta versatilidad facilita la experimentación continuada por parte del equipo en ciclos de desarrollo futuros.

La marcada diferencia de rendimiento en test entre RuleFit-lite (macro-F1 de 0.905604) y la librería canónica `imodels` (macro-F1 de 0.568239) se debe a que la versión simplificada del prototipo aprovecha un entrenamiento adaptado al problema multiclase y a las variables predecionales estructuradas del 112 CyL. En contraste, la ejecución de `imodels.RuleFitClassifier` se configuró de forma restrictiva para evitar tiempos de cómputo inmanejables en el entorno local, usando un esquema one-vs-rest binario que redujo su capacidad de generalización en clases minoritarias. Este resultado confirma la viabilidad académica de construir una variante optimizada para el dominio específico de emergencias.

L.7. Evaluación temporal y trazabilidad

La evaluación final se consolida mediante `scripts/run_evaluation.py`. Este script genera `artifacts/reports/evaluation_v0.1.0.json` y su versión `.md`, junto con tablas por provincia, año y categoría, figuras SVG y el listado de falsos negativos P1. Sobre el test temporal de 2022, RuleFit-lite alcanza accuracy 0.884354, macro-F1 0.877594 y recall

P1 0.928767. La estabilidad respecto al test estratificado apoya la selección del modelo, aunque no sustituye una validación prospectiva con datos operativos nuevos.

El mismo informe identifica 59 falsos negativos P1 en el test estratificado: 34 casos P1–P2, 18 casos P1–P3 y 7 casos P1–P4. Estos casos alimentan la plantilla de validación interna documentada en `resources/internal_validation`; los P1–P4 se tratan como foco prioritario de revisión por representar infrapriorizaciones críticas.

L.8. Model card Capa 3: explicación con Ollama

La Capa 3 recibe la recomendación de la Capa 2, las probabilidades P1–P4, reglas o señales activadas y evidencias recuperadas. Su salida es una explicación estructurada para revisión humana. En v0.1.0 se ejecuta localmente mediante Ollama con el modelo `llama3.1:8b-instruct-q4_K_M`. El prompt del sistema fuerza una respuesta estructurada y recuerda que el LLM no decide la prioridad.

El componente mantiene un modo degradado determinista si Ollama no está disponible o si la respuesta no cumple con el contrato esperado. Este modo conserva la prioridad y las probabilidades de la Capa 2, evitando que un fallo generativo bloquee la recomendación. Esta estrategia de contingencia proporciona una red de seguridad indispensable en entornos misión-crítica. De este modo, el operador conserva el dictamen predictivo principal incluso ante caídas de la infraestructura local.

L.8.1. Validación integrada Capa 1–Capa 2–Capa 3

Como control de integración posterior al merge de la rama de la Capa 1, se regenera el informe `artifacts/reports/capa1_capa2_e2e_v0.1.0.json` junto con su versión `artifacts/reports/capa1_capa2_e2e_v0.1.0.md`. La prueba ejecuta cinco escenarios curados y comprueba que las señales extraídas por la Capa 1 llegan correctamente a la Capa 2, que RuleFit está disponible y que la Capa 3 conserva la trazabilidad mínima en modo degradado.

El resultado 5/5 permite afirmar que, tras integrar los cambios de Ancor en la Capa 1, el flujo texto del incidente, extracción de señales, priorización RuleFit-lite y explicación degradada funciona de forma consistente. Esta validación no sustituye al smoke test con Ollama ni a la evaluación offline de la Capa 2, pero aporta evidencia de compatibilidad entre capas.

Tabla K.2: Resumen de validación integrada Capa 1–Capa 2–Capa 3

Indicador	Valor
Casos curados	5
Casos correctos	5
Casos fallidos	0
Modelo Capa 2 observado	RULEFIT
Precisión micro Capa 1	0.846154
Recall micro Capa 1	1.000000
F1 micro Capa 1	0.916667
Latencia media Capa 1	0.31106 ms
Latencia media Capa 2	347.0036 ms
Latencia media Capa 3 degradada	0.30772 ms

Tabla K.3: Smoke test integrado Capa 1–Capa 2–Capa 3

Caso	Esperada	Obtenida	Prob. dominante	Modo
Incendio con atrapados	P1	P1	97.35 %	Ollama
Fuga de gas sin heridos	P2	P2	92.21 %	Ollama
Arbol en calzada	P3	P3	93.71 %	Ollama
Consulta vecinal sin riesgo	P4	P4	98.54 %	Ollama

El smoke test integrado alcanza 4/4 casos correctos, con RuleFit activo, la Capa 3 no degradada y latencia media de 4.897,888 ms. Sus artefactos son `artifacts/reports/prototype_v0.1.0_smoke_test.json` y `artifacts/reports/prototype_v0.1.0_smoke_test.md`. La principal limitación es que se trata de una prueba técnica pequeña, no de una validación de aceptación con operadores.

L.9. Fidelidad de explicaciones

La Capa 3 se evalúa sobre los 119 casos de validación interna mediante `scripts/evaluate_explanation_fidelity.py`. La ejecución v0.1.0 usa un juez determinista offline sobre explicaciones en modo degradado, con seis criterios: prioridad mencionada, reglas trazables, cobertura de señales, citas legales en P1/P2, ausencia de contradicción y disclaimer. El resultado global es pass rate 1.000000, fidelidad media 0.957367 y fidelidad mínima 0.933333. En falsos negativos P1, la fidelidad media es 0.952494. La evaluación LLM-as-Judge independiente queda como ampliación futura sobre la misma muestra.

El cierre de la evaluación queda indexado en `artifacts/reports/final_evaluation_traceability_v0.1.0.json`, que vincula este anexo con el Capítulo 9, el Anexo D, el Capítulo 10 y los artefactos principales de métricas, sesgo, validación interna y fidelidad. Este registro maestro proporciona un hilo conductor auditable que abarca todo el desarrollo metodológico del proyecto. Con ello se asegura que cada conclusión declarada en la memoria académica cuente con su correspondiente evidencia digital en el repositorio.

L.10. Limitaciones

- La variable objetivo es una etiqueta académica débil, no una prioridad operativa oficial.
- La evaluación de `imodels` se ha realizado con una configuración diagnóstica reducida, debido al coste temporal observado en el entorno local.
- El objetivo $ECE \leq 0,10$ queda reservado para una pasada final de calibración cuando el modelo sea congelado.
- El rendimiento debe interpretarse dentro del alcance v0.1.0, sin variables externas diferidas como AEMET histórico, SNCZI o Seveso.
- Las pruebas integradas con Ollama y con la Capa 3 degradada validan el flujo completo, pero todavía no miden utilidad percibida ni impacto real en sala.