



Universidad Internacional de la Rioja (UNIR)

Escuela Superior de Ingeniería y Tecnología

Máster Universitario en Inteligencia Artificial

Sistema inteligente de apoyo
a la decisión para puestos de
mando de emergencias

Trabajo Fin de Estudios

Presentado por: Juan Carlos Albert Fillol, Ancor González Carballo y Brian Mathias Pesci Juliani

Dirigido por: Dr. Andrés Soto Villaverde

Ciudad: Madrid, Tenerife y Alicante

Fecha: 15 de julio de 2026

Índice de contenidos

Resumen	x
Abstract	xi
Organización del trabajo en grupo	1
Introducción al trabajo grupal	1
Integrantes del equipo y roles asignados	1
Capa 2: supervisión débil, RuleFit y evaluación	1
Capa 3: explicación generativa y recuperación normativa	2
Capa 1: extracción de variables operativas	2
Distribución de capítulos y anexos	2
Metodología de coordinación del grupo	3
1. Introducción	5
1.1. Contexto general del trabajo	5
1.2. Planteamiento del problema	6
1.3. Justificación e impacto social	6
1.4. Contribución específica desde la inteligencia artificial	7
1.5. Finalidad y alcance del sistema propuesto	8
1.5.1. Alcance funcional	8
1.5.2. Alcance territorial y empírico	8
1.5.3. Limitaciones	9
1.6. Enfoque del TFM como desarrollo software	9
1.7. Estructura de la memoria	9
2. Contexto del problema y estado del arte	11
2.1. Gestión de emergencias y primera decisión	11
2.2. Sistemas de apoyo a la decisión en emergencias	12
2.3. Procesamiento del lenguaje natural en emergencias	12
2.4. Supervisión débil y construcción de etiquetas P1–P4	13
2.5. RuleFit, interpretabilidad y comparación con modelos opacos	14
2.6. Explicabilidad, LLM local, RAG y MCP	15

2.7.	Sistemas y referencias relacionadas	16
2.8.	Brecha identificada	17
2.9.	Conclusiones del estado del arte	18
3.	Marco operativo y normativo del dominio de emergencias	20
3.1.	Finalidad del capítulo	20
3.2.	Sistema español de protección civil	20
3.3.	Marco autonómico de Castilla y León	22
3.3.1.	Ley 4/2007 de Protección Ciudadana de Castilla y León	22
3.3.2.	PLANCAL como ancla de la escala P1–P4	22
3.3.3.	Planes especiales: INFOCAL, INUNCYL y MPCyL	23
3.4.	Normativa de datos, comunicaciones e inteligencia artificial	24
3.5.	Situaciones operativas y escala académica P1–P4	25
3.6.	Taxonomía operativa de incidentes	25
3.7.	Fuentes de datos y corpus normativo	26
3.8.	Trazabilidad normativa de variables y reglas	28
3.9.	Alcance del prototipo y elementos diferidos	28
3.10.	Conclusiones del capítulo	29
4.	Objetivos y metodología de trabajo	31
4.1.	Introducción al capítulo	31
4.2.	Objetivo general	31
4.3.	Objetivos específicos	32
4.4.	Preguntas de investigación	33
4.5.	Contribución en inteligencia artificial	35
4.6.	Enfoque metodológico	35
4.7.	Fases de desarrollo	36
4.8.	Consideraciones éticas	36
4.9.	Conclusiones del capítulo	37
5.	Requisitos del sistema	38
5.1.	Introducción al capítulo	38
5.2.	Definición formal del problema	38
5.3.	Usuario objetivo y contexto de uso	39

5.4.	Requisitos funcionales	39
5.5.	Requisitos no funcionales	41
5.5.1.	Explicabilidad	41
5.5.2.	Trazabilidad	41
5.5.3.	Supervisión humana	41
5.5.4.	Robustez ante información incompleta	41
5.5.5.	Reproducibilidad	42
5.5.6.	Soberanía del dato	42
5.6.	Restricciones y supuestos	42
5.6.1.	Restricciones metodológicas y del prototipo	42
5.6.2.	Supuestos y dependencias tecnológicas	42
5.7.	Trazabilidad entre requisitos y componentes	43
5.8.	Conclusiones del capítulo	43
6.	Arquitectura y diseño del sistema inteligente	45
6.1.	Finalidad del capítulo	45
6.2.	Principios de diseño	46
6.3.	Vista general de la arquitectura	47
6.4.	Contratos de datos	47
6.5.	Entrada del sistema: IncidentInput	49
6.6.	Capa 1: extracción NLP de variables operativas	49
6.6.1.	Variables activas y diferidas	49
6.6.2.	Señales textuales	51
6.7.	Capa 2: priorización interpretable con RuleFit	51
6.7.1.	Escala P1–P4	51
6.7.2.	Supervisión débil	52
6.7.3.	RuleFit como modelo principal	52
6.7.4.	Línea base experta, RuleFit-lite e <code>imodels</code>	52
6.7.5.	Probabilidad, confianza e invariantes	53
6.7.6.	Puerta de Seguridad	53
6.8.	Capa 3: explicación normativa con LLM, RAG y MCP	55
6.8.1.	LLM local	55
6.8.2.	RAG sobre corpus normativo CyL	55

6.8.3.	Herramientas MCP	55
6.8.4.	Caché de sesión en Capa 3	56
6.9.	Orquestador, fallback y latencia	56
6.10.	Trazabilidad y auditoría	57
6.11.	Ejemplo de funcionamiento	58
6.12.	Evaluación del diseño	58
6.13.	Conclusiones	59
7.	Datos, conjunto de datos y supervisión débil	60
7.1.	Finalidad del capítulo	60
7.2.	Estrategia general de datos	60
7.3.	Registro de Emergencias del 112 de Castilla y León	61
7.3.1.	Campos de entrada	61
7.3.2.	Auditoría inicial	61
7.4.	Limpieza y normalización	63
7.5.	Variables V01–V15	63
7.6.	Señales operativas textuales	64
7.7.	Etiqueta académica P1–P4	65
7.8.	Supervisión débil	65
7.8.1.	Acuerdo y control de calidad	66
7.8.2.	Ablación anti-circularidad	66
7.9.	Prevención de leakage	66
7.10.	Particiones de entrenamiento, validación y prueba	68
7.10.1.	Partición estratificada	68
7.10.2.	Partición temporal	68
7.11.	Uso en entrenamiento y evaluación	69
7.12.	Limitaciones del conjunto de datos	69
7.13.	Conclusiones	69
8.	Prototipo integrado	71
8.1.	Introducción	71
8.2.	Arquitectura software	71
8.3.	Componentes de Capa 2	72
8.4.	Flujo de procesamiento	72

8.5. Prototipo ejecutable	73
8.5.1. Interfaz de voz e inferencia inteligente	74
8.6. Contratos y trazabilidad	75
8.7. Modo degradado	75
8.8. Relación con la evaluación	76
8.9. Repositorio del código fuente	76
8.10. Conclusiones del capítulo	76
9. Evaluación experimental	78
9.1. Objetivos de evaluación	78
9.2. Niveles de evaluación	79
9.3. Datos, etiquetas y particiones	79
9.4. Política anti-leakage	80
9.5. Modelos evaluados	80
9.6. Selección del modelo	81
9.7. Métricas por clase del modelo seleccionado	82
9.8. Matriz de confusión del modelo seleccionado	82
9.9. Robustez temporal y sesgo interno	83
9.10. Interpretabilidad	83
9.11. Revisión interna y trazabilidad	83
9.12. Fidelidad de explicaciones	84
9.13. Posicionamiento frente a trabajos relacionados	85
9.14. Pruebas integradas del prototipo	86
9.15. Evaluación exploratoria con participantes	87
9.16. Limitaciones	88
10. Conclusiones y trabajo futuro	91
10.1. Respuesta al objetivo del TFM	91
10.2. Trazabilidad de objetivos específicos	92
10.3. Principales contribuciones	93
10.4. Resultados principales	94
10.5. Cumplimiento de principios de diseño	95
10.6. Limitaciones	96
10.7. Trabajo futuro	97

10.8. Cierre	98
Referencias	98
A. Taxonomía de incidentes CyL	105
B. Variables V01–V15 de priorización	109
C. Guía de etiquetado P1–P4	113
D. Muestra y protocolo de revisión interna	117
E. Línea base heurística de priorización	123
F. Conceptos y software	126
G. Evidencias del prototipo	129
H. Declaración de uso de inteligencia artificial generativa	132
L. Fichas de las capas	134

Índice de ilustraciones

2.1. Flujo conceptual XAI: separación entre modelo decisor interpretable y capa generativa explicativa.	15
6.1. Arquitectura integrada de tres capas con contratos versionados y componentes locales.	47
6.2. Secuencia de inferencia desde la entrada del incidente hasta la decisión humana.	56
9.1. Secuencia metodológica del flujo de evaluación experimental.	79
G.1. Entrada manual de un incidente sintético en la interfaz del prototipo. . . .	129
G.2. Módulo experimental de entrada por voz mediante faster-whisper	130
G.3. Resultado de un incidente sintético clasificado como P1.	131
G.4. Formulario para registrar la decisión humana y una posible discrepancia. . .	131

Índice de tablas

1.	Distribución de capítulos, responsables y tipo de contribución.	3
2.1.	Comparación sintética entre enfoques relacionados y propuesta del TFM. .	18
3.1.	Fuentes principales y función dentro del sistema.	27
3.2.	Trazabilidad normativa entre criterios, variables y uso previsto en el prototipo.	28
4.1.	Relación entre objetivos específicos, evidencias y criterios de cumplimiento.	34
5.1.	Trazabilidad entre requisitos y componentes del sistema.	43
6.1.	Contratos principales del flujo de inferencia.	48
6.2.	Variables operativas del sistema y alcance evaluado.	50
7.1.	Campos principales del Registro 112 CyL y uso previsto en el sistema. . . .	62
7.2.	Elementos obligatorios de la auditoría del conjunto de datos.	63
7.3.	Variables V01–V15 y estado dentro del alcance evaluado.	64
7.4.	Columnas prohibidas como entrada del motor por riesgo de <i>leakage</i>	67
7.5.	Columnas permitidas y prohibidas según disponibilidad en la primera decisión.	67
7.6.	Distribución de las particiones adoptadas en el estudio.	68
8.1.	Prueba funcional integrada del prototipo	74
9.1.	Distribución de etiquetas por partición	80
9.2.	Comparativa de modelos de Capa 2 en validación	81
9.3.	Métricas por clase de RuleFit-lite en la partición de prueba	82
9.4.	Matriz de confusión de RuleFit-lite en la partición de prueba	82
9.5.	Comparativa del enfoque propuesto frente a trabajos relacionados	85
9.6.	Resultado de la prueba funcional integrada P1–P4 con LLM local	86
9.7.	Prueba reproducible Capa 1–Capa 2–Capa 3	87
9.8.	Resultados agregados de la evaluación exploratoria con participantes	88
9.9.	Síntesis final de la evaluación experimental	90
10.1.	Trazabilidad entre objetivos específicos, grado de consecución y evidencia. .	92
A.1.	Taxonomía operativa principal del prototipo	107

A.2. Relación entre taxonomía, señales y uso en Capa 2	108
B.1. Variables V01–V15 del prototipo	112
C.1. Definición académica de prioridades P1–P4	114
C.2. Reglas principales para etiquetado débil	115
D.1. Composición de la muestra revisada internamente	118
D.2. Campos principales de la plantilla de revisión	118
D.3. Ejemplos de casos reales seleccionados para revisión	119
D.4. Diseño intencional de perfiles para la evaluación exploratoria del MVP . . .	121
D.5. Puntuaciones individuales anonimizadas de la evaluación exploratoria . . .	121
E.1. Reglas de la línea base heurística de Capa 2	125
E.2. Métricas de la línea base heurística	125
E.3. Comparación resumida entre la línea base y RuleFit-lite	125
F.1. Correspondencia entre conceptos académicos, software y evidencias	127
F.2. Secuencia conceptual de los contratos del prototipo	128
H.1. Uso declarado de herramientas de IA generativa	132
L.1. Resultados de los modelos de Capa 2 en la partición de prueba	135

Resumen

La gestión de emergencias civiles exige decisiones rápidas y fundamentadas bajo presión temporal e incertidumbre. Este trabajo diseña, implementa y evalúa un prototipo modular de apoyo a la primera decisión para incidentes 112 en Castilla y León. El sistema utiliza el Registro de Emergencias de 2008–2022 y una escala académica P1–P4 construida mediante supervisión débil. La arquitectura consta de tres capas: una extracción simbólica y auditable de señales operativas, basada en detección semántica, tratamiento de negaciones, normalización y confianza; un núcleo de priorización interpretable con RuleFit-lite; y una capa de explicación normativa mediante un modelo de lenguaje local, generación aumentada por recuperación y Model Context Protocol. La evaluación compara una línea base de 19 reglas, RuleFit-lite y una implementación diagnóstica de `imodels`, mediante una partición estratificada y otra temporal, control anti-*leakage*, análisis por subgrupos y revisión de errores críticos. RuleFit-lite alcanza una macro-F1 de 0,905 y una sensibilidad P1 de 0,910; mejora el rendimiento global de la línea base y conserva una salida trazable. También se evalúa de forma automatizada la fidelidad de las explicaciones sobre una muestra de 119 casos revisada conjuntamente por los tres autores. Los resultados corresponden a un entorno académico controlado y no constituyen validación operativa ni certificación para su uso en un servicio 112 real.

Palabras clave: emergencias 112, sistemas de apoyo a la decisión (DSS), inteligencia artificial explicable (XAI), supervisión débil, RuleFit, reconocimiento del habla (ASR).

Abstract

Civil emergency management requires rapid, evidence-based decisions under time pressure and uncertainty. This thesis designs, implements, and evaluates a modular prototype to support the first decision for 112 incidents in Castile and Leon. The system uses the 2008–2022 Emergency Registry and an academic P1–P4 scale built through weak supervision. Its three layers provide symbolic and auditable extraction of operational signals through semantic detection, negation handling, normalization, and confidence estimation; interpretable prioritization with RuleFit-lite; and normative explanation through a local language model, retrieval-augmented generation, and Model Context Protocol. The evaluation compares a 19-rule baseline, RuleFit-lite, and a diagnostic `imodels` implementation using stratified and temporal partitions, anti-leakage controls, subgroup analysis, and critical-error review. RuleFit-lite achieves a macro-F1 of 0.905 and a P1 recall of 0.910; it improves the baseline’s overall performance while preserving traceable outputs. Explanation fidelity is also assessed automatically on a 119-case sample jointly reviewed by the three authors. These results were obtained in a controlled academic setting and do not constitute operational validation or certification for use in a real 112 service.

Keywords: 112 emergencies, decision support systems (DSS), explainable artificial intelligence (XAI), weak supervision, RuleFit, automatic speech recognition (ASR).

Organización del trabajo en grupo

Introducción al trabajo grupal

El presente Trabajo Fin de Máster (TFM) se ha desarrollado en modalidad grupal, de conformidad con el procedimiento establecido por la Universidad Internacional de La Rioja (UNIR). Esta modalidad resulta coherente con la naturaleza del proyecto: se diseña, implementa y evalúa un sistema inteligente de apoyo a la decisión para la priorización temprana de incidentes 112 en Castilla y León, combinando procesamiento del lenguaje natural, aprendizaje interpretable, explicación normativa y desarrollo de software.

La organización del equipo se articula en tres capas funcionales y una función transversal de integración. La Capa 1 estructura el texto operativo en variables y señales pre-decisionales. La Capa 2, desarrollada como bloque metodológico central, transforma esas señales en una recomendación P1–P4 interpretable y evaluable. La Capa 3 convierte la recomendación en una explicación operativa mediante un modelo de lenguaje de gran tamaño (*Large Language Model*, LLM) local, generación aumentada por recuperación (*Retrieval-Augmented Generation*, RAG) y herramientas basadas en *Model Context Protocol* (MCP).

El reparto no se limita a distribuir tareas de programación. Cada integrante asume una contribución diferenciada al componente inteligente del sistema, de modo que el resultado conjunto pueda defenderse como una solución integrada y no como una suma de piezas independientes.

Integrantes del equipo y roles asignados

El equipo está formado por tres estudiantes del Máster Universitario en Inteligencia Artificial de la UNIR, bajo la dirección del Dr. Andrés Soto Villaverde. Cada integrante aporta un perfil complementario y una responsabilidad principal dentro de la arquitectura.

Capa 2: supervisión débil, RuleFit y evaluación

Responsable principal: Juan Carlos Albert Fillol.

Su bloque de trabajo se centra en convertir datos reales e incompletos del Registro 112 Castilla y León en una recomendación de prioridad interpretable, evaluable y trazable. Para ello formaliza la escala académica P1–P4, audita el conjunto de datos, construye

etiquetas mediante supervisión débil, define una línea base heurística, selecciona RuleFit-lite como motor interpretable y evalúa el comportamiento del sistema mediante macro-F1, sensibilidad de P1, estabilidad temporal, análisis por subgrupos y errores críticos.

Juan Carlos asume, además, la coordinación metodológica y el cierre del bloque de datos, supervisión débil, línea base heurística, priorización interpretable, evaluación, revisión interna y trazabilidad de Capa 2. Su aportación conecta la salida de Capa 1 con la explicación de Capa 3, sin asumir la autoría de las capas desarrolladas por los demás integrantes.

Capa 3: explicación generativa y recuperación normativa

Responsable principal: Brian Mathias Pesci Juliani.

Su bloque de trabajo comprende la explicación y la integración conceptual del prototipo. Incluye la recuperación normativa, la explicación generativa local y la trazabilidad de la inferencia. Su contribución consiste en convertir la salida del modelo interpretable en una recomendación comprensible y revisable, sin modificar la prioridad calculada por Capa 2 y manteniendo la ejecución local de los datos sensibles.

Capa 1: extracción de variables operativas

Responsable principal: Ancor González Carballo.

Su bloque de trabajo se orienta a la transformación del texto libre del incidente en una representación estructurada compatible con la priorización posterior. Esta capa combina procesamiento del lenguaje natural auditable, detección de señales operativas, tratamiento de negaciones y normalización de variables V01–V15. En la versión evaluada se presenta como un extractor determinista y reproducible; la incorporación de clasificadores aprendidos queda como evolución futura sujeta a una validación específica. Esta contribución es importante porque la calidad de la priorización depende de que el sistema represente correctamente el incidente antes de aplicar reglas o modelos.

Distribución de capítulos y anexos

La Tabla 1 recoge la distribución de responsabilidades sobre la memoria. El reparto final se ha definido con un único responsable por archivo para evitar duplicidades, solapamientos y conflictos de integración. De esta forma, cada integrante revisa su parte, identifica los

cambios necesarios y aporta texto, evidencias, capturas o referencias para la unificación final.

Apartado / capítulo	Responsables	Tipo de contribución
chap0.tex	Juan Carlos	Organización del trabajo y reparto final
chap1.tex	Juan Carlos	Introducción, problema, alcance y contribución IA
chap2.tex	Brian	Contexto, estado del arte y bibliografía APA 7
chap3.tex	Ancor	Marco operativo, normativo y contexto 112 CyL
chap4.tex	Juan Carlos	Objetivos, preguntas de investigación y metodología
chap5.tex	Ancor	Requisitos y especificación funcional
chap6.tex	Brian	Arquitectura, contratos y diseño del sistema
chap7.tex	Juan Carlos	Datos de Castilla y León, supervisión débil, prevención de fugas y particiones
chap8.tex	Brian	Integración del prototipo y demostración funcional
chap9.tex	Juan Carlos	Evaluación de Capa 2, integración, revisión preparada y análisis por subgrupos
chap10.tex	Ancor	Conclusiones, limitaciones y trabajo futuro
anexo_a.tex, anexo_b.tex, anexo_g.tex	Ancor	Taxonomía, variables y guía de uso
anexo_c.tex, anexo_d.tex, anexo_e.tex	Juan Carlos	Guía P1-P4, protocolo de revisión y línea base heurística
anexo_f.tex, anexo_h.tex, anexo_l.tex; bibliografia.bib	Brian	Correspondencia conceptual-software, transparencia, corpus normativo consolidado, fichas de modelo y bibliografía

Tabla 1: Distribución de capítulos, responsables y tipo de contribución.

Fuente: elaboración propia.

Metodología de coordinación del grupo

La coordinación se ha apoyado en reuniones periódicas, control de versiones y una planificación por tareas trazables. Las decisiones de alcance se documentan de forma común

y los contratos de datos permiten que cada capa avance sin romper la integración.

El equipo ha trabajado con una lógica iterativa e incremental. Primero se fijaron los acuerdos de integración y la constitución del proyecto; después se definieron el conjunto de datos, la guía de etiquetado y el corpus normativo; posteriormente se implementaron las capas técnica y explicativa; y finalmente se orienta el trabajo hacia la evaluación, la redacción y la defensa. Esta organización permite mantener alineados el prototipo software, la memoria académica y la evidencia reproducible.

De este modo, la organización del trabajo refleja la idea central del TFM: diseñar, implementar y evaluar un sistema de apoyo a la decisión para incidentes 112 en Castilla y León, con prioridad explicable P1–P4, supervisión humana, soberanía del dato y trazabilidad normativa.

1. Introducción

1.1. Contexto general del trabajo

La gestión de emergencias es uno de los ámbitos de actuación pública donde la rapidez y la calidad de las decisiones tienen consecuencias más directas sobre la vida de las personas. En los primeros minutos de un incidente, el operador del 112 o el responsable de coordinación debe interpretar información incompleta, heterogénea y a menudo cambiante: texto libre de la llamada, categoría preliminar, localización, número de afectados, señales de riesgo, condiciones territoriales y posible necesidad de escalar la respuesta.

El marco español de protección civil, articulado principalmente por la Ley 17/2015 y la Norma Básica de Protección Civil, establece una respuesta basada en coordinación, planificación y actuación graduada ante diferentes riesgos (Jefatura del Estado, 2015; Ministerio del Interior, 2023). En Castilla y León, este marco se concreta mediante la Ley 4/2007, el Plan Territorial de Protección Civil de Castilla y León (PLANCAL) y diversos planes especiales como INFOCAL, INUNCYL o MPCyL (Cortes de Castilla y León, 2007; Junta de Castilla y León, 2019, 2025, 2010, 2008). Este entorno normativo proporciona una base adecuada para construir un sistema de apoyo a la decisión que no se limite a clasificar incidentes, sino que justifique sus recomendaciones con criterios operativos y trazabilidad documental.

El presente TFM se sitúa en la intersección entre gestión de emergencias e inteligencia artificial aplicada. Su objetivo es diseñar, implementar y evaluar un prototipo software modular que priorice incidentes 112 de Castilla y León en una escala académica P1–P4, ofreciendo al operador una recomendación explicable, revisable y respaldada por reglas, evidencias internas y trazabilidad documental. La escala P1–P4 utilizada en el trabajo no corresponde a una prioridad oficial del servicio 112, sino a una construcción académica necesaria para entrenar, evaluar y explicar el prototipo. El sistema no sustituye al operador humano ni moviliza recursos de forma autónoma: actúa como herramienta de apoyo a la primera decisión.

1.2. Planteamiento del problema

La saturación informativa en emergencias aparece cuando el volumen, la velocidad o la heterogeneidad de la información supera la capacidad del operador para procesarla con seguridad. Este fenómeno es crítico en situaciones con múltiples incidentes simultáneos, avisos incompletos o información contradictoria. En esos escenarios, una priorización deficiente puede retrasar la atención a incidentes graves, sobredimensionar sucesos menores o dificultar la justificación posterior de la decisión adoptada.

El problema abordado por este TFM puede formularse así: dado un conjunto de incidentes 112 descritos mediante texto libre y datos operativos parciales, ¿cómo puede un sistema inteligente ayudar a estructurar la información, extraer variables relevantes, recomendar una prioridad P1–P4 y explicar esa recomendación de forma comprensible y auditable?

La respuesta propuesta se apoya en una arquitectura de tres capas. La Capa 1 transforma texto operativo en variables y señales predecisionales mediante procesamiento del lenguaje natural auditable, detección de negaciones y normalización operativa. La Capa 2 recomienda la prioridad mediante RuleFit-lite y se compara con una línea base heurística y una implementación alternativa de la misma familia de modelos. La Capa 3 genera una explicación mediante un modelo de lenguaje de gran tamaño (*Large Language Model*, LLM) local, generación aumentada por recuperación (*Retrieval-Augmented Generation*, RAG) sobre el corpus normativo y herramientas basadas en *Model Context Protocol* (MCP). Esta separación impide que el componente generativo recalcule la prioridad o sustituya el criterio profesional.

1.3. Justificación e impacto social

Desde la perspectiva operativa, cualquier mejora en la primera decisión puede contribuir a orientar antes la atención hacia incidentes con riesgo vital, víctimas graves, atrapamiento, intoxicación, propagación o necesidad de coordinación compleja. El valor del sistema no reside en automatizar la emergencia, sino en reducir carga cognitiva y mejorar la consistencia de la recomendación inicial.

El *Time To First Decision* (TTFD) se utiliza únicamente como motivación del problema. El prototipo no mide ni demuestra una reducción de ese tiempo en una sala 112 real

o con operadores profesionales. La evaluación se centra en la trazabilidad, el rendimiento del modelo de priorización, la coherencia funcional del prototipo y la fidelidad de las explicaciones.

Desde la perspectiva tecnológica, las emergencias constituyen un dominio exigente para la IA: información incompleta, alto impacto potencial, necesidad de trazabilidad, supervisión humana obligatoria y prohibición de depender de servicios externos no controlados para datos sensibles. Esta orientación es coherente con los principios de transparencia, supervisión humana, gestión del riesgo y robustez recogidos en el Reglamento Europeo de Inteligencia Artificial (Parlamento Europeo y Consejo de la Unión Europea, 2024), así como con revisiones recientes sobre IA en gestión de emergencias (Science Advice for Policy by European Academies, 2025; Ghaffarian, Taghikhah, y Maier, 2023).

Desde la perspectiva social, el proyecto se alinea con una visión responsable de la IA: una herramienta que amplifica la capacidad de análisis del operador, pero no desplaza su criterio profesional. En un dominio crítico, la explicabilidad no es decorativa; es una condición para que la recomendación pueda revisarse, discutirse, corregirse y auditarse.

1.4. Contribución específica desde la inteligencia artificial

La contribución principal del TFM no consiste en entrenar un modelo opaco para maximizar una métrica aislada de precisión. El proyecto aborda un problema más delicado: construir un sistema explicable y evaluable cuando no existe una etiqueta oficial P1–P4 en el conjunto de datos abierto. Por ello, la prioridad académica se construye mediante supervisión débil, anclada en PLANCAL y en la guía de etiquetado del proyecto.

La aportación de inteligencia artificial comprende la extracción auditable de variables desde texto, la construcción de etiquetas mediante supervisión débil, la priorización interpretable con RuleFit-lite, su contraste con una línea base heurística y con una alternativa externa de la familia RuleFit, y la generación de explicaciones a partir de la salida estructurada de Capa 2. Estas funciones se integran sin transferir al LLM la recomendación de prioridad ni la decisión final.

Esta combinación permite que cada recomendación pueda vincularse con la información de entrada, las variables extraídas, las reglas activadas, el grado de confianza, la trazabilidad documental y la decisión humana final. Esa trazabilidad constituye la diferencia entre un simple clasificador y un sistema de apoyo a la decisión.

1.5. Finalidad y alcance del sistema propuesto

El objetivo general del TFM es diseñar, implementar y evaluar un prototipo software modular de apoyo a la decisión para priorización temprana de incidentes 112 en Castilla y León. La finalidad es ofrecer una recomendación P1–P4 explicable y auditable, basada en variables operativas, aprendizaje interpretable, corpus normativo y supervisión humana.

1.5.1. Alcance funcional

El sistema abarca la recepción de un incidente, la extracción de variables, la recomendación de prioridad, la generación de una explicación operativa, el registro auditable de la inferencia y la posibilidad de que el operador acepte, modifique o rechace la recomendación. El alcance evaluado prioriza el núcleo científicamente defendible: variables operativas reproducibles, señales textuales, priorización interpretable, explicación normativa local y una interfaz de demostración para revisar el flujo completo. Adicionalmente, el prototipo incorpora una entrada de voz experimental que transcribe audio de prueba y propone campos estructurados para revisión; no se ha validado con llamadas reales.

La salida de Capa 2 incluye prioridad recomendada, probabilidades, reglas activadas y contexto explicativo. Capa 3 utiliza esa información para explicar la recomendación sin recalcularla, y el operador conserva la decisión final: puede aceptarla, modificarla o rechazarla.

No forman parte del alcance el despacho automático de recursos, la integración productiva con sistemas cerrados del 112, el uso de APIs cloud para inferencia con datos sensibles, la certificación regulatoria del sistema ni la validación externa con personal del 112. Estos elementos se documentan como trabajo futuro cuando corresponde.

1.5.2. Alcance territorial y empírico

El alcance territorial se centra en Castilla y León. El Registro de Emergencias del 112 de Castilla y León aporta la base empírica real para trabajar con incidentes, texto operativo, fechas, provincias, localidades y coordenadas (Junta de Castilla y León, s. f.). El marco normativo autonómico se apoya en Ley 4/2007, PLANCAL y planes especiales CyL. Esta decisión evita mantener una separación artificial entre marco normativo y conjunto de datos, y refuerza la coherencia del proyecto.

La escala P1–P4 mantiene en todo el trabajo su carácter académico y no equivale jurídicamente a las situaciones operativas oficiales.

1.5.3. Limitaciones

El TFM presenta varias limitaciones explícitas. El prototipo no se ha desplegado en una sala 112 real. El conjunto de datos abierto no contiene prioridad oficial P1–P4, por lo que la etiqueta se construye mediante supervisión débil y requiere análisis de acuerdo. Las variables V08–V11, relacionadas con meteorología, inundabilidad y riesgo tecnológico, quedan diferidas por coste de integración y por el objetivo de mantener reproducible el núcleo evaluado.

Estas limitaciones no invalidan el trabajo; delimitan su alcance. El valor del TFM reside en demostrar una arquitectura explicable, trazable y evaluable sobre datos reales abiertos, con un marco normativo claro y con supervisión humana como principio de diseño.

1.6. Enfoque del TFM como desarrollo software

El trabajo se desarrolla bajo la modalidad de TFM de Tipo 2, orientado al desarrollo de software. En coherencia con esta modalidad, el resultado no es solo una memoria teórica: se entrega un prototipo modular, un corpus normativo, pruebas reproducibles y evidencias de evaluación.

No obstante, la contribución académica no se reduce a programar una aplicación. El centro del trabajo es el diseño de un sistema inteligente responsable: cómo representar incidentes, cómo evitar fugas de información, cómo construir etiquetas académicas, cómo entrenar un modelo interpretable, cómo explicar sus recomendaciones y cómo evaluar si el resultado es defendible.

1.7. Estructura de la memoria

La memoria se organiza en diez capítulos y anexos técnicos. El Capítulo 1 introduce el problema, el alcance y la contribución. El Capítulo 2 revisa el contexto y el estado del arte en IA para emergencias, DSS, NLP, supervisión débil, RuleFit, LLM locales, RAG y MCP. El Capítulo 3 fija el marco operativo y normativo de Castilla y León. El Capítulo 4 formula objetivos, preguntas de investigación y metodología. El Capítulo 5 define requisitos. El Capítulo 6 presenta la arquitectura de tres capas. El Capítulo 7

desarrolla datos, variables, etiquetado y leakage. El Capítulo 8 documenta el prototipo. El Capítulo 9 presenta la evaluación. El Capítulo 10 sintetiza conclusiones y trabajo futuro.

Los anexos recogen la taxonomía, las variables, la guía de etiquetado, el protocolo de revisión, la línea base heurística, los contratos, el corpus RAG, las instrucciones del LLM, las fichas de modelo, las capturas y la trazabilidad extendida.

2. Contexto del problema y estado del arte

Este capítulo establece los fundamentos conceptuales y técnicos que sustentan la investigación sobre sistemas de apoyo a la decisión en emergencias. Para ello, se analiza en primer lugar la dinámica operativa de la primera decisión en las salas del 112 y la importancia de la conciencia situacional. Posteriormente, se realiza una revisión crítica de los sistemas de ayuda a la decisión existentes y de las técnicas de procesamiento del lenguaje natural aplicadas a este dominio. Por último, se examinan las metodologías de aprendizaje interpretable en entornos de alta criticidad, justificando la elección de RuleFit-lite frente a otros modelos convencionales.

2.1. Gestión de emergencias y primera decisión

La gestión de emergencias comprende el conjunto de actividades orientadas a prevenir, preparar, responder y recuperar la normalidad frente a sucesos que pueden comprometer la vida, los bienes, el medio ambiente o servicios esenciales. A diferencia de otros procesos de decisión pública, las emergencias se caracterizan por presión temporal, información incompleta, incertidumbre, multiplicidad de actores y necesidad de coordinación inmediata (Quarantelli, 1988; Comfort, 2007). Esta complejidad exige metodologías que ayuden a estructurar la información disponible en los instantes iniciales del suceso de forma rápida y reproducible.

En este contexto, la primera decisión operativa tiene un peso especial. No cierra la gestión del incidente, pero condiciona la atención inicial, la movilización de recursos, el seguimiento y la posible escalada. El operador debe interpretar rápidamente señales parciales, distinguir incidentes leves de incidentes críticos y mantener una trazabilidad mínima que permita justificar la decisión adoptada.

El concepto de conciencia situacional ayuda a explicar esta necesidad. Endsley (1995) la define como la percepción de elementos del entorno, la comprensión de su significado y la proyección de su evolución. En un centro 112, esa conciencia situacional depende de transformar texto, categorías preliminares, coordenadas y contexto normativo en una representación operativa útil.

2.2. Sistemas de apoyo a la decisión en emergencias

Los sistemas de apoyo a la decisión (Decision Support Systems, DSS) buscan asistir a personas o equipos en decisiones complejas. En emergencias, pueden organizar información, visualizar incidentes, simular escenarios, priorizar recursos o facilitar coordinación (Turoff, Chumer, Van de Walle, y Yao, 2004; Comes, Hiete, Wijngaards, y Schultmann, 2011). Sin embargo, muchos DSS se centran en cuadros de mando, mapas o gestión de recursos, sin abordar de forma específica la priorización explicable de incidentes individuales en un servicio 112.

El prototipo de este Trabajo Fin de Máster (TFM) se sitúa en una franja más acotada: apoyo a la primera decisión mediante una recomendación P1–P4, trazable y revisable. No pretende sustituir sistemas de despacho, mapas de riesgo o plataformas institucionales. Su aportación consiste en conectar información inicial del incidente, variables operativas, modelo interpretable y explicación normativa.

2.3. Procesamiento del lenguaje natural en emergencias

El procesamiento del lenguaje natural (NLP) se ha utilizado ampliamente para extraer información de mensajes de crisis, partes breves, redes sociales o comunicaciones ciudadanas. Trabajos clásicos de *crisis informatics* mostraron que los textos no estructurados pueden contener localizaciones, peticiones de ayuda, daños, necesidades y señales de riesgo (Vieweg, Hughes, Starbird, y Palen, 2010; Caragea y cols., 2011; Imran, Castillo, Diaz, y Vieweg, 2015). El uso de estas herramientas textuales permite sistematizar la recopilación de datos no estructurados en situaciones de alta presión informativa.

Los modelos recientes basados en transformers han mejorado la representación semántica de textos de crisis. CrisisTransformers, por ejemplo, propone modelos preentrenados y codificadores especializados para clasificación, búsqueda semántica y agrupación de textos relacionados con crisis (Lamsal, Rodríguez Read, y Karunasekera, 2024). Para este TFM, esa línea es relevante porque confirma la utilidad del NLP, pero también marca una frontera: procesar texto no equivale a decidir prioridad operativa.

En el sistema propuesto, el procesamiento del lenguaje natural (NLP) corresponde a la Capa 1. Su función es extraer las variables V01–V15 y señales de heridos graves, atrapamiento, intoxicación, incendio o rescate. La prioridad no la decide el extractor textual,

sino la Capa 2 interpretable. La implementación evaluada adopta un enfoque simbólico y auditable que combina detección semántica basada en reglas, negaciones, normalización y confianza; cualquier modelo aprendido exigiría una evaluación independiente antes de incorporarse al sistema.

Por otra parte, la ingesta de información mediante canales de voz representa la entrada primaria en los centros de despacho 112. La literatura reciente destaca que el uso de modelos de reconocimiento automático del habla (Automatic Speech Recognition, ASR) ligeros y de código abierto, como la familia Whisper (Minulescu y Toma, 2025), permite realizar transcripciones locales de llamadas de emergencia en tiempo real con bajas tasas de error en entornos de ruido operacional. El preprocesamiento de estas transcripciones automáticas mediante correctores fonéticos o modelos de lenguaje estructuradores compactos facilita la corrección de topónimos locales y la extracción de entidades operativas previas a la decisión, sentando una línea de diseño robusta para interfaces multicanal en emergencias.

2.4. Supervisión débil y construcción de etiquetas P1–P4

Una dificultad central del proyecto es que el Registro de Emergencias del 112 de Castilla y León no contiene una prioridad oficial P1–P4. Esto impide entrenar directamente un modelo supervisado convencional sobre una verdad institucional. La solución adoptada es construir una etiqueta académica mediante supervisión débil.

La supervisión débil permite combinar varias fuentes imperfectas de etiquetado, como reglas heurísticas, anotadores automáticos, clustering, modelos auxiliares o criterios expertos, para generar una etiqueta probabilística de entrenamiento. Snorkel es una referencia consolidada en esta línea, al formalizar el uso de funciones de etiquetado y modelos generativos para crear datos de entrenamiento a partir de supervisión imperfecta (Ratner y cols., 2020). Este enfoque facilita el aprovechamiento de grandes volúmenes de datos no etiquetados sin incurrir en los elevados costes de la anotación manual exhaustiva.

En este TFM, la supervisión débil no se presenta como sustituto de una validación experta institucional. Es un mecanismo académico y reproducible para poder entrenar y evaluar el prototipo con datos reales abiertos. La importancia de la supervisión y control humanos en IA para sistemas críticos es documentada exhaustivamente por Kim et al. Kim, Maathuis, y Sent (2024), quienes señalan que la claridad y justificación en las re-

comendaciones deben priorizar la usabilidad del operador por encima de la complejidad algorítmica. Por ello se exige medir acuerdo, documentar la guía de etiquetado, analizar discrepancias y realizar ablaciones que eviten circularidad entre reglas de etiquetado y reglas del modelo.

2.5. RuleFit, interpretabilidad y comparación con modelos opacos

La Capa 2 del sistema utiliza RuleFit como núcleo interpretable. RuleFit combina reglas derivadas de árboles con términos lineales y selección regularizada, produciendo un conjunto de reglas con pesos que puede inspeccionarse y limitarse (Friedman y Popescu, 2008). Esta propiedad es especialmente adecuada para emergencias: el operador y el tribunal no solo necesitan saber que el sistema recomienda P1, sino que deben poder ver qué reglas se han activado y por qué.

El proyecto mantiene también una línea base experta y una ejecución diagnóstica con `imodels` (Singh, Nasseri, Tan, Tang, y Yu, 2021). La línea base proporciona una referencia transparente, construida a partir de conocimiento normativo y señales operativas. La comparativa con `imodels` permite contrastar la familia RuleFit recomendada con una implementación externa, sin sustituir el núcleo reproducible seleccionado. Esta separación evita presentar un modelo opaco o poco controlado como decisión operativa en un dominio de alto impacto.

La inclusión de una línea base experta basada en reglas heurísticas y de un modelo alternativo one-vs-rest mediante `imodels.RuleFitClassifier` permite delimitar la aportación de la propuesta. En la configuración evaluada, RuleFit-lite mejora el rendimiento global, mientras que la alternativa externa se conserva como prueba diagnóstica con una muestra de ajuste menor. La diferencia de tamaños impide comparar el coste computacional en condiciones equivalentes; la elección se fundamenta en el rendimiento de validación, la interpretabilidad y la reproducibilidad, sin implicar significación estadística ni viabilidad de despliegue operativo.

La literatura sobre interpretabilidad refuerza esta decisión. Rudin (2019) defiende que, en decisiones de alto riesgo, debe preferirse un modelo interpretable desde el diseño cuando sea viable, en lugar de explicar a posteriori una caja negra. Para entornos de toma de decisiones en emergencias civiles y control operacional (AI-SOAR), Araujo et al. Araujo,

Silva, Ito, y cols. (2026) demuestran que la explicabilidad intrínseca y la trazabilidad desde el diseño son indispensables para consolidar la confianza de los operadores tácticos y asegurar la auditabilidad legal frente a las autoridades reguladoras. Esta idea es coherente con la arquitectura del TFM: RuleFit decide la prioridad; el LLM explica y comunica, pero no decide de forma autónoma.

2.6. Explicabilidad, LLM local, RAG y MCP

La explicabilidad en este TFM no se reduce a mostrar una probabilidad. La recomendación debe acompañarse de reglas activadas, confianza, advertencias cuando proceda y citas normativas.

Para ello, la Capa 3 utiliza un LLM local cuantizado (Grattafiori, Dubey, y cols., 2024; Qwen Team, 2024), recuperación aumentada sobre un corpus normativo de Castilla y León y herramientas MCP.




Figura 2.1: Flujo conceptual XAI: separación entre modelo decisor interpretable y capa generativa explicativa.

El uso de un modelo de lenguaje de gran tamaño (Large Language Model, LLM) local responde a dos necesidades: generar explicaciones comprensibles para el operador y preservar la soberanía del dato. En el marco regulatorio europeo (tales como el RGPD o la directiva del Reglamento de IA de la UE), la inferencia local se consolida como un patrón de conformidad y privacidad Szabelka, Nowak, O'Brien, y cols. (2025). La generación aumentada por recuperación (Retrieval-Augmented Generation, RAG) Lewis y cols. (2020) evita que la explicación dependa solo de memoria generativa: el sistema consulta fragmentos del corpus normativo, recuperados mediante embeddings tipo Sentence-BERT (Reimers y Gurevych, 2019), y los utiliza para sustentar citas legales. La confiabilidad y consistencia de este acotamiento en sistemas de alta criticidad ha sido validada empíricamente por Sandeboina et al. Sandeboina, Chen, Kumar, y cols. (2026), demostrando que reduce de manera sustancial las alucinaciones factualmente verificables.

En el prototipo real se utiliza el codificador `paraphrase-multilingual-MiniLM-L12-v2`, por su equilibrio entre soporte multilingüe, cobertura para textos en español e inglés y

ligereza operativa en ejecución local. Por su parte, el protocolo de contexto de modelo (Model Context Protocol, MCP) aporta un mecanismo estándar para exponer herramientas como búsqueda normativa, detalle de reglas y cita legal de prioridades; Anthropic (2024) lo presentó como un protocolo abierto para conectar asistentes de IA con fuentes de datos y herramientas externas. Esta integración facilita el diseño de una interfaz unificada y desacoplada para la interacción con modelos generativos.

El uso de este codificador multilingüe ligero, con 384 dimensiones de *embedding*, permite resolver búsquedas semánticas sobre el corpus normativo local con baja latencia, mantener el consumo de memoria dentro del perfil de hardware local y asegurar que las explicaciones normativas se nutran de fragmentos legales exactos de forma reproducible. Esta elección resulta crítica en entornos de emergencias, donde cada segundo de retraso en la presentación de información al operador puede repercutir en el resultado del operativo. De esta forma, el sistema equilibra la precisión de la recuperación semántica con la agilidad que demanda la operación en tiempo real.

Esta capa debe entenderse con precisión metodológica. El LLM no decide la prioridad, no la recalcula y no debe inventar fundamento jurídico. Su función es traducir una recomendación ya calculada por Capa 2 en una explicación breve, trazable y revisable. La fundamentación jurídica se obtiene de fragmentos recuperados del corpus normativo y de las reglas activadas por el modelo interpretable, de modo que la orquestación no convierte al LLM en una caja negra decisoria.

El riesgo de alucinación se reduce mediante tres salvaguardas implementadas en el prototipo, aunque no puede considerarse eliminado. Primero, la temperatura de inferencia se fija en 0.0 para reducir la variabilidad de las respuestas. Segundo, la búsqueda RAG queda acotada a fragmentos del corpus normativo de Castilla y León procedentes del Boletín Oficial de Castilla y León (BOCYL) y del Boletín Oficial del Estado (BOE). Tercero, si el modelo local no responde o supera el umbral temporal configurado, se activa una respuesta alternativa determinista construida a partir de plantillas, reglas activadas y metadatos de la Capa 2.

2.7. Sistemas y referencias relacionadas

El sistema AIDR (Artificial Intelligence for Disaster Response) demostró la utilidad de combinar aprendizaje automático y participación humana para clasificar mensajes de

crisis en redes sociales (Imran, Castillo, Lucas, Meier, y Vieweg, 2014). La iniciativa TREC (Text REtrieval Conference) Incident Streams proporcionó benchmarks y colecciones de prueba para la clasificación estructurada de crisis y estimación de urgencia (McCreadie, Buntain, y Soboroff, 2021). Por su parte, el GDACS (Global Disaster Alert and Coordination System) integra alertas globales multirriesgo e información geoespacial para la coordinación internacional (2025b). Copernicus Emergency Management Service aporta cartografía rápida y productos para apoyar la respuesta (Copernicus Emergency Management Service, 2025). Finalmente, las revisiones estratégicas del JRC (Joint Research Centre de la Comisión Europea) y SAPEA (Science Advice for Policy by European Academies) subrayan el potencial de la IA en gestión de crisis, pero también la necesidad de control humano, explicabilidad y robustez (Joint Research Centre, 2025a; Science Advice for Policy by European Academies, 2025).

Ninguna de estas referencias resuelve exactamente el problema abordado aquí: priorizar incidentes 112 individuales en Castilla y León mediante una escala académica P1–P4, con variables trazables, RuleFit interpretable, explicación normativa y supervisión humana. Las plataformas existentes se enfocan predominantemente en alertas de carácter global o en la clasificación de mensajería informal en redes sociales. Por el contrario, la propuesta de este TFM se centra de manera exclusiva en estructurar el flujo de decisión interno de una sala de despacho autonómica conforme a su corpus regulatorio específico.

2.8. Brecha identificada

A partir de la revisión anterior, la brecha del TFM puede formularse así: falta un prototipo académico, reproducible y explicable que combine incidentes reales 112, etiqueta P1–P4 académica, NLP en español, supervisión débil, RuleFit interpretable, explicación normativa con LLM local, herramientas MCP y evaluación orientada a seguridad del operador. Los trabajos previos abordan estos componentes de forma aislada, sin proponer una canalización integrada y local de procesamiento. De este modo, la presente propuesta busca unificar estos elementos en un único flujo de trabajo evaluado funcional y experimentalmente dentro del alcance académico definido.

La propuesta cubre esa brecha con una arquitectura sobria. La Capa 1 estructura el incidente; la Capa 2 recomienda prioridad; la Capa 3 explica; el operador decide; y el sistema registra todo para auditoría. Esta cadena preserva el control humano y evita que

Sistema o enfoque	Qué aporta	Limitación frente al TFM	Relación con la propuesta
AIDR	Clasificación colaborativa de mensajes de crisis	Mensajes de redes sociales, no incidentes 112 consolidados	Inspira colaboración humano-máquina
TREC-IS	Criticidad e información útil en crisis	Prioriza mensajes, no incidentes con normativa local	Justifica tareas de criticidad y evaluación
CrisisTransformers	NLP especializado para textos de crisis	No incorpora prioridad P1-P4 ni reglas normativas	Referente para Capa 1 NLP
GDACS	Alerta global multirriesgo	Escala internacional, no sala 112 autónoma	Inspira amenaza, exposición y vulnerabilidad
Copernicus EMS	Cartografía y productos geoespaciales	No decide prioridad ni explica normativa	Fuente futura de contexto geoespacial
RuleFit	Modelo interpretable basado en reglas ponderadas	Requiere etiquetas y control de sparsity	Núcleo de Capa 2
LLM + RAG + MCP	Explicación y acceso a corpus/herramientas	Riesgo de alucinación si no se acota	Capa 3 explicativa, no decisoria

Tabla 2.1: Comparación sintética entre enfoques relacionados y propuesta del TFM.

la IA aparezca como autoridad autónoma.

2.9. Conclusiones del estado del arte

La revisión permite extraer cinco conclusiones. Primera, la gestión de emergencias exige sistemas que ayuden a priorizar bajo incertidumbre, no solo a acumular información. Segunda, el NLP es necesario para estructurar texto, pero no suficiente para decidir prioridad. Tercera, la ausencia de etiquetas oficiales P1-P4 obliga a construir una etiqueta académica mediante supervisión débil y validación explícita. Cuarta, RuleFit ofrece un equilibrio adecuado entre aprendizaje y explicabilidad para el núcleo de decisión. Quinta, los LLM locales con RAG y MCP pueden mejorar la comunicación de la recomendación, siempre que se mantengan subordinados al modelo interpretable y a la supervisión humana, un principio de diseño human-centered y de human-in-the-loop alineado con las directrices de Kim et al. Kim y cols. (2024) para preservar el control y responsabilidad del operador sobre las decisiones automáticas.

Estas conclusiones preparan el tránsito al Capítulo 3, donde se desarrolla el marco operativo y normativo de Castilla y León que fundamenta las variables, reglas y citas del sistema. La definición precisa de este entorno normativo es crucial para nutrir la base

de conocimientos del RAG de la Capa 3. Con ello se asegura que el apoyo a la decisión del operador esté firmemente respaldado por las directrices de los planes especiales de protección civil.

3. Marco operativo y normativo del dominio de emergencias

3.1. Finalidad del capítulo

El sistema de apoyo a la decisión propuesto en este Trabajo Fin de Máster se sitúa en un dominio especialmente regulado: la atención de emergencias, la protección civil y la gestión de información sensible en los primeros minutos de un incidente. Por ello, antes de describir la arquitectura técnica del prototipo resulta necesario fijar el marco operativo y normativo que justifica sus variables, sus reglas de prioridad y sus límites de uso.

Este capítulo no pretende realizar un estudio jurídico exhaustivo. Su función es más concreta: extraer de la normativa estatal, autonómica y europea los criterios que pueden convertirse en decisiones de diseño. En particular, interesa identificar qué elementos normativos respaldan la detección de riesgo vital, la valoración de víctimas, la vulnerabilidad, la progresión del incidente, la coordinación entre recursos, la trazabilidad de las recomendaciones, la privacidad y la supervisión humana.

La línea de trabajo adoptada tras el rediseño del proyecto se centra en Castilla y León. El caso empírico se apoya en el Registro de Emergencias del 112 de Castilla y León, correspondiente al período 2008–2022, y el marco autonómico principal queda definido por la Ley 4/2007, de Protección Ciudadana de Castilla y León, el Plan Territorial de Protección Civil de Castilla y León (PLANCAL) y los planes especiales incorporados al corpus normativo del prototipo (Cortes de Castilla y León, 2007; Junta de Castilla y León, 2019, s. f.). Sobre esta base se construye una escala académica P1–P4, no oficial, orientada a priorizar incidentes de forma explicable y auditable.

3.2. Sistema español de protección civil

La protección civil en España se configura como un sistema público orientado a proteger a las personas, los bienes y el medio ambiente ante situaciones de grave riesgo, catástrofe o calamidad pública (Jefatura del Estado, 2015). Su organización combina competencias estatales, autonómicas y locales, de modo que la respuesta a una emergencia no depende de una única autoridad ni de un único centro operativo, sino de una red de estructuras de

mando, coordinación y apoyo técnico.

Desde la perspectiva del sistema propuesto, esta configuración tiene tres consecuencias. En primer lugar, la prioridad de un incidente no puede deducirse solo de su categoría nominal: un accidente de tránsito, un incendio o una incidencia sanitaria pueden exigir tratamientos muy distintos según víctimas, localización, propagación, vulnerabilidad o simultaneidad con otros avisos. En segundo lugar, la respuesta se produce bajo incertidumbre: durante los primeros minutos el operador dispone de texto libre, categoría preliminar, localización aproximada y señales parciales, no de una fotografía completa de la emergencia. En tercer lugar, cualquier recomendación automatizada debe ser subordinada a la decisión humana, porque el sistema no moviliza recursos ni declara situaciones operativas.

La Ley 17/2015 aporta el marco conceptual general: riesgo, emergencia, afectación a personas, protección de bienes, servicios esenciales, deberes de colaboración y coordinación entre administraciones (Jefatura del Estado, 2015). Estos conceptos justifican que el prototipo no se limite a detectar palabras graves en el texto, sino que estructure la información en variables operativas: riesgo vital, número estimado de víctimas, gravedad de lesiones, población vulnerable, emplazamiento crítico, multirriesgo o accesibilidad de recursos.

La Norma Básica de Protección Civil, aprobada mediante el Real Decreto 524/2023, refuerza esta lógica al ordenar la planificación por riesgos, establecer criterios comunes para los planes y situar la gestión de emergencias dentro de una arquitectura graduada de respuesta (Ministerio del Interior, 2023). Para este TFM, su utilidad no consiste en trasladar mecánicamente las situaciones operativas al modelo, sino en justificar que la prioridad debe entenderse como una gradación: hay incidentes leves, incidentes relevantes, incidentes graves e incidentes críticos, y el sistema debe distinguirlos con criterios reproducibles.

El Plan Estatal General de Emergencias de Protección Civil (PLEGEM) completa el marco estatal al describir la coordinación ante emergencias de interés nacional o de dimensión supraautonómica (Ministerio del Interior, 2020). Aunque el prototipo no pretende activar mecanismos estatales, el PLEGEM resulta útil para modelar señales de complejidad: multirriesgo, avisos simultáneos, insuficiencia potencial de medios ordinarios o necesidad de coordinación ampliada.

3.3. Marco autonómico de Castilla y León

Castilla y León constituye el ámbito territorial de referencia del prototipo por dos razones complementarias. La primera es empírica: existe un registro público de emergencias del 112 que permite trabajar con incidentes reales y evitar una validación basada exclusivamente en ejemplos simulados (Junta de Castilla y León, s. f.). La segunda es normativa: la comunidad autónoma dispone de una ley propia de protección ciudadana y de planes territoriales y especiales que permiten anclar la interpretación operativa de las variables del sistema.

3.3.1. Ley 4/2007 de Protección Ciudadana de Castilla y León

La Ley 4/2007, de Protección Ciudadana de Castilla y León, proporciona el marco autonómico general para la organización de la protección civil, la coordinación de emergencias y la actuación de los servicios públicos en la comunidad (Cortes de Castilla y León, 2007). Para el sistema propuesto, su interés principal es que sitúa la atención de emergencias dentro de un esquema institucional donde la rapidez de respuesta, la coordinación y la información al ciudadano son elementos centrales.

Desde el punto de vista del modelado, esta ley respalda variables relacionadas con la inmediatez y la capacidad operativa, especialmente la accesibilidad de recursos (V15), la existencia de emplazamientos críticos (V07) y la necesidad de registrar la actuación para auditoría posterior. También refuerza una idea metodológica importante: el sistema recomienda prioridades, pero la decisión final corresponde siempre a personal humano integrado en la organización competente.

3.3.2. PLANCAL como ancla de la escala P1–P4

El Decreto 4/2019 aprueba el Plan Territorial de Protección Civil de Castilla y León (PLANCAL), pieza central para conectar el marco normativo con la escala académica de prioridad utilizada en este TFM (Junta de Castilla y León, 2019). PLANCAL no define una etiqueta P1–P4 para el dataset, ni el proyecto afirma que exista una equivalencia oficial. Su aportación consiste en ofrecer una lógica de fases, situaciones y coordinación que permite construir una guía de etiquetado razonada.

La escala P1–P4 del prototipo debe entenderse como una abstracción funcional. P1 representa incidentes con riesgo vital, víctimas graves, atrapamiento, intoxicación peligro-

sa, propagación severa o necesidad de atención inmediata. P2 agrupa incidentes relevantes con potencial de deterioro o afectación significativa, pero sin la criticidad inmediata de P1. P3 recoge situaciones que requieren gestión ordinaria o seguimiento, y P4 corresponde a incidentes de baja urgencia operativa o sin afectados. Esta escala se utiliza para entrenamiento, evaluación y explicación, pero no sustituye categorías oficiales de mando.

3.3.3. Planes especiales: INFOCAL, INUNCYL y MPCyL

Los planes especiales de Castilla y León aportan criterios sectoriales que enriquecen la interpretación de incidentes concretos. INFOCAL, aprobado por el Decreto 6/2025, resulta relevante para incendios forestales, propagación, amenaza a núcleos habitados, simultaneidad de focos y condiciones que pueden elevar la prioridad de una incidencia inicialmente limitada (Junta de Castilla y León, 2025). En el prototipo, este marco se relaciona con V12 (`riesgo_propagacion`) y con señales textuales como `signal_incendio`.

INUNCYL, plan de protección civil ante el riesgo de inundaciones en Castilla y León, aporta el marco conceptual para valorar episodios de inundación, avenidas, desbordamientos y afectación territorial (Junta de Castilla y León, 2010). Las variables de enriquecimiento meteorológico e hidrológico asociadas a INUNCYL se difieren como ampliación futura, pero la norma permanece en el marco teórico y en el corpus RAG porque justifica una línea natural de extensión.

MPCyL, plan de protección civil ante el riesgo de transportes de mercancías peligrosas, es relevante para incidentes con sustancias químicas, cisternas, fugas, intoxicaciones o riesgos tecnológicos en transporte (Junta de Castilla y León, 2008). Se utiliza como anclaje normativo de las reglas asociadas a `signal_intoxicacion` y a escenarios de mercancías peligrosas. No obstante, el corpus solo dispone del decreto de aprobación, no del plan técnico completo en una fuente oficial indexable. El prototipo emplea un fragmento controlado de contingencia vinculado a PLANCAL para mantener una recuperación mínima en consultas químicas. Esta medida no sustituye el documento ausente ni permite afirmar una cobertura normativa completa.

3.4. Normativa de datos, comunicaciones e inteligencia artificial

El dominio no solo exige priorizar bien; exige hacerlo de forma trazable, privada y compatible con la supervisión humana. Por este motivo, el marco normativo del proyecto incluye también normas sobre comunicaciones de emergencia, protección de datos e inteligencia artificial.

La Ley 11/2022, General de Telecomunicaciones, resulta relevante por el papel de los servicios de emergencia, la localización de llamadas y el tratamiento de información asociada a comunicaciones (Jefatura del Estado, 2022). En el prototipo, esta norma no se traduce en una integración técnica con sistemas de telecomunicaciones, sino en una cautela de diseño: la localización se trata como dato operativo sensible y solo se conserva o transforma cuando aporta valor a la priorización y a la trazabilidad.

El Reglamento General de Protección de Datos y la Ley Orgánica 3/2018 imponen principios de minimización, limitación de finalidad, seguridad y responsabilidad proactiva (Parlamento Europeo y Consejo de la Unión Europea, 2016; Jefatura del Estado, 2018). Estos principios justifican el rechazo de variables innecesarias, el uso de hashes en los logs de inferencia, la separación entre datos de entrada y resultados del sistema, y la exclusión de campos que puedan revelar decisiones posteriores o resultados clínicos. Esta restricción conecta directamente con la política anti-*leakage*: el sistema no debe aprender a priorizar usando información que en la realidad solo estaría disponible después de la decisión inicial.

El Reglamento (UE) 2024/1689 de Inteligencia Artificial introduce un marco de especial relevancia para sistemas aplicados a servicios esenciales, emergencias y apoyo a decisiones con posible impacto sobre personas (Parlamento Europeo y Consejo de la Unión Europea, 2024). El TFM no afirma que el prototipo sea un producto certificado ni listo para despliegue. Su posición es más prudente: el diseño se alinea con requisitos de alto nivel como supervisión humana, trazabilidad, transparencia, gestión del riesgo, calidad de datos y robustez. Por ello, la arquitectura se formula como sistema de apoyo a la decisión: recomienda, explica y registra, pero no decide ni moviliza recursos de forma autónoma.

3.5. Situaciones operativas y escala académica P1–P4

Las situaciones operativas de protección civil ordenan el mando, la coordinación y la movilización de recursos ante emergencias. Su finalidad es institucional y organizativa. La prioridad P1–P4 del sistema, en cambio, es una escala académica diseñada para ordenar incidentes por urgencia relativa en el contexto del prototipo.

Esta diferencia debe quedar clara para evitar una confusión metodológica. Una situación operativa puede referirse al estado global de una emergencia en un territorio, mientras que P1–P4 se asigna a un incidente concreto. Un accidente con una persona atrapada puede ser P1 aunque no exista una situación territorial de emergencia elevada. Del mismo modo, un escenario de prealerta territorial puede contener avisos individuales de baja prioridad. La relación entre ambas escalas es, por tanto, inspiracional y funcional, no jurídica ni uno a uno.

La escala P1–P4 se construye con tres objetivos. Primero, permitir que los tres autores generen etiquetas débiles comparables sobre el conjunto de datos real. Segundo, entrenar y evaluar un motor interpretable, basado en RuleFit y comparado con una línea base experta. Tercero, generar explicaciones comprensibles para el operador, citando reglas activadas y normas de referencia. Esta formulación mantiene el sistema dentro de la línea de trabajo del proyecto: núcleo explicable, supervisión humana y trazabilidad normativa.

3.6. Taxonomía operativa de incidentes

El motor necesita una taxonomía de incidentes porque la prioridad no se interpreta igual en todos los dominios. Una llamada por incendio forestal requiere evaluar propagación, simultaneidad y amenaza a población o infraestructuras. Un accidente de tráfico exige valorar atrapamiento, heridos, accesibilidad y número de afectados. Una fuga química requiere identificar intoxicación, transporte de mercancías peligrosas y potencial de escalado. Por tanto, la categoría preliminar no es una etiqueta decorativa, sino una entrada que ayuda a activar las reglas correctas.

La taxonomía se deriva de dos fuentes: el catálogo de riesgos y categorías operativas recogido en la normativa, y los campos textuales del Registro 112 CyL. El campo estructurado de tipo de incidente resulta útil como orientación inicial, pero el sistema no depende exclusivamente de él. La Capa 1 aplica NLP simbólico: detección semántica mediante re-

glas y diccionarios operativos, tratamiento de negaciones, normalización de variables y estimación de confianza. De este modo obtiene señales auditables de fallecimiento, herido grave, atrapamiento, intoxicación, incendio, accidente de tráfico, rescate o inundación. El prototipo no presenta como validado un clasificador estadístico de Capa 1; su evolución hacia modelos aprendidos queda condicionada a disponer de un modelo congelado y una evaluación específica.

La taxonomía cumple tres funciones. Primero, reduce ambigüedad al normalizar incidentes heterogéneos. Segundo, conecta cada incidente con variables operativas V01–V15. Tercero, mejora la explicabilidad, porque permite justificar la prioridad con factores coherentes con la naturaleza del suceso. Esta taxonomía se desarrolla en el Anexo A y se utiliza de forma transversal en los capítulos de diseño, datos y evaluación.

3.7. Fuentes de datos y corpus normativo

El prototipo combina dos tipos de fuentes. Por un lado, el Registro de Emergencias del 112 de Castilla y León aporta incidentes reales, texto operativo, fechas, localización y campos útiles para probar la ingesta, limpieza y extracción de señales (Junta de Castilla y León, s. f.). Por otro, el corpus normativo CyL alimenta la capa RAG y las herramientas MCP encargadas de recuperar citas legales, explicar reglas y sostener normativamente las recomendaciones.

La Tabla 3.1 resume el rol de las fuentes principales en el sistema.

El uso del Registro 112 CyL requiere una cautela esencial: el dataset no contiene una prioridad oficial P1–P4. Por ello, la etiqueta empleada en el proyecto es académica y se construye mediante supervisión débil a partir de varios anotadores, reglas y criterios derivados de la guía de etiquetado. Esta decisión evita presentar como verdad institucional una prioridad que no existe en la fuente original.

El corpus normativo, por su parte, no se utiliza para entrenar directamente el motor de prioridad. Su función principal es sostener la capa de explicación: buscar fragmentos relevantes, recuperar bases legales, citar normas y mostrar al operador por qué una regla o una prioridad tienen respaldo documental. Esta separación entre datos empíricos, reglas de priorización y fuentes normativas es clave para mantener la trazabilidad del sistema.

Fuente	Rol en el TFM	Uso principal
Registro 112 CyL	Fuente empírica real	Ingesta, limpieza, texto libre, coordenadas, señales operativas y validación del pipeline
Ley 17/2015 y RD 524/2023	Marco estatal	Conceptos de riesgo, emergencia, planificación, catálogo de riesgos y gradación de respuesta
Ley 4/2007 CyL y PLANCAL	Marco autonómico	Coordinación, inmediatez, guía de etiquetado P1–P4 y trazabilidad territorial
INFOCAL, INUNCYL, MPCyL	Riesgos específicos	Incendios forestales, inundaciones y mercancías peligrosas; reglas y citas normativas
RGPD, LOPDGDD, Ley 11/2022	Datos y comunicaciones	Minimización, localización, seguridad, logs y exclusión de variables sensibles o no necesarias
Reglamento UE 2024/1689	IA responsable	Supervisión humana, transparencia, trazabilidad, gestión del riesgo y robustez

Tabla 3.1: Fuentes principales y función dentro del sistema.

3.8. Trazabilidad normativa de variables y reglas

La Tabla 3.2 sintetiza la traducción del marco normativo a criterios de modelado. No debe leerse como una equivalencia jurídica exacta, sino como una matriz de trazabilidad: indica qué norma justifica cada grupo de variables o reglas dentro del prototipo.

Norma / fuente	Criterio operativo	Variable o señal	Uso en el sistema
Ley 17/2015	Protección de la vida, daños personales, vulnerabilidad	V01, V02, V03, V05, <code>signal.herido_grave</code> , <code>signal.atrapado</code>	Reglas duras P1 y aumento de prioridad
RD 524/2023	Catálogo de riesgos y planificación	V04	Taxonomía y normalización de tipo de incidente
PLEGEM	Coordinación ampliada y multirriesgo	V13, V14	Señales de escalado y complejidad
Ley 4/2007 CyL	Coordinación, inmediatez y capacidad de respuesta	V07, V15	Ajuste por emplazamiento crítico y accesibilidad
PLANCAL	Fases, situaciones y lógica territorial de respuesta	Escala P1–P4 académica	Guía de etiquetado y explicación
INFOCAL	Incendio forestal y propagación	V12, <code>signal.incendio</code>	Reglas P2/P1 según riesgo de propagación
INUNCYL	Inundación y riesgo territorial	V09, V10, <code>signal.meteo_inundacion</code>	Anclaje para ampliación futura; contexto RAG actual
MPCyL	Mercancías peligrosas y riesgo químico	<code>signal.intoxicacion</code>	Regla de alta prioridad para fuga, intoxicación o cisterna
Registro 112 CyL	Incidentes reales y texto operativo	Título, descripción, fecha, provincia, coordenadas	Fuente empírica; no contiene etiqueta P1–P4
RGPD y LOPDGDD	Minimización y protección de datos	Política de exclusión	Logs, hashes, retención y no reidentificación
Reglamento UE 2024/1689	Supervisión humana y trazabilidad	Arquitectura HITL, logs, explicaciones	Recomendación no vinculante y auditoría

Tabla 3.2: Trazabilidad normativa entre criterios, variables y uso previsto en el prototipo.

3.9. Alcance del prototipo y elementos diferidos

El alcance prioriza un núcleo evaluable: variables textuales y operativas centrales, RuleFit como motor interpretable, explicación con LLM local, RAG normativo y supervisión humana. Se activan las variables V01–V07 y V12–V15, junto con las señales textuales necesarias para detectar riesgo vital, heridos, atrapamiento, intoxicación, incendio, rescate,

accidente de tráfico, varias llamadas y riesgo meteorológico textual.

Quedan diferidas las variables que requieren integraciones contextuales más costosas: avisos AEMET, condición meteorológica adversa, zonas inundables SNCZI y proximidad a instalaciones Seveso. Mantienen su anclaje normativo, pero no forman parte del núcleo entrenado y evaluado. Esta exclusión preserva la reproducibilidad y evita dependencias externas dinámicas, aunque puede reducir la capacidad de priorización en inundaciones o riesgos tecnológicos muy específicos. La supervisión humana sigue siendo necesaria en esos escenarios.

3.10. Conclusiones del capítulo

El marco operativo y normativo analizado permite fijar cinco conclusiones clave para el desarrollo del resto de este Trabajo Fin de Máster. Estas deducciones metodológicas sintetizan la relación entre la práctica operacional y las limitaciones predictivas del sistema. Las lecciones extraídas se detallan en los siguientes puntos:

En primer lugar, el sistema debe entenderse como apoyo a la decisión, no como sustituto del operador. Esta conclusión deriva tanto de la naturaleza de la protección civil como del marco europeo de inteligencia artificial.

En segundo lugar, la prioridad operativa no puede reducirse a una única señal. La gravedad actual, la vulnerabilidad, la exposición, la propagación, la simultaneidad, la accesibilidad y la incertidumbre informativa deben combinarse mediante contratos y reglas trazables.

En tercer lugar, la escala P1–P4 es académica y funcional. Se inspira en la lógica de gradación de la normativa, especialmente PLANCAL, pero no equivale a situaciones operativas oficiales ni pretende reemplazarlas.

En cuarto lugar, el Registro 112 CyL aporta realismo empírico, pero no una verdad supervisada de prioridad. Por eso el proyecto necesita supervisión débil, una muestra revisada internamente por los tres autores y comparación explícita entre la línea base experta, RuleFit-lite y una ejecución diagnóstica de `imodels`.

En quinto lugar, la trazabilidad normativa no es un adorno documental: es parte de la arquitectura. Cada recomendación debe poder conectarse con variables, reglas, citas legales, versión de modelo y decisión humana final. Esta exigencia enlaza directamente con los capítulos siguientes, donde se desarrollan la metodología, la arquitectura de tres

capas, el diseño de datos y la evaluación del prototipo.

4. Objetivos y metodología de trabajo

4.1. Introducción al capítulo

Este capítulo conecta el problema descrito en los capítulos anteriores con la estrategia seguida para resolverlo. El TFM no plantea una herramienta genérica de emergencias, sino un prototipo software de apoyo a la decisión para priorización temprana de incidentes 112 en Castilla y León. La línea de trabajo se articula alrededor de datos reales abiertos, una etiqueta académica P1–P4 construida mediante supervisión débil, una Capa 2 interpretable basada en RuleFit-lite y una Capa 3 orientada a explicar la recomendación con trazabilidad normativa.

La finalidad del capítulo es fijar con claridad qué se pretende conseguir, qué preguntas guían el desarrollo, qué aportación de inteligencia artificial realiza el trabajo y cómo se ha organizado el equipo para avanzar de forma incremental sin perder coherencia entre prototipo, evaluación y memoria.

4.2. Objetivo general

El objetivo general de este Trabajo Fin de Máster es:

Diseñar, implementar y evaluar un prototipo software modular de apoyo a la decisión para la priorización inicial de incidentes 112 en Castilla y León, capaz de transformar texto operativo y datos parciales en una recomendación P1–P4 explicable, trazable y revisable, mediante una arquitectura de tres capas que combine extracción NLP, aprendizaje interpretable con RuleFit-lite, explicación normativa local y supervisión humana obligatoria.

El objetivo es específico porque delimita dominio, territorio, usuario y salida esperada. Es medible porque la Capa 2 se evalúa mediante métricas reproducibles como macro-F1, sensibilidad P1, matriz de confusión, falsos negativos críticos, estabilidad temporal y análisis por subgrupos. Es alcanzable porque se apoya en datos abiertos del Registro 112 Castilla y León, procedimientos reproducibles y un prototipo académico acotado. Es relevante porque aborda una decisión de alto impacto en emergencias sin sustituir al operador. Y es temporalmente delimitado porque se concreta en una evaluación cerrada

dentro del alcance del TFM.

4.3. Objetivos específicos

El objetivo general se descompone en ocho objetivos específicos:

- OE1. Analizar el problema de la priorización temprana de incidentes 112, identificando necesidades del operador, restricciones de información y riesgos de automatización en un dominio crítico.
- OE2. Revisar el marco normativo estatal y autonómico aplicable a Castilla y León, extrayendo criterios de gravedad, coordinación, escalado y trazabilidad que fundamentan el sistema.
- OE3. Definir la taxonomía operativa, la escala académica P1–P4 y las variables V01–V15, separando variables disponibles en primera decisión de variables contextuales diferidas o potencialmente sujetas a *leakage*.
- OE4. Auditar el Registro de Emergencias 112 de Castilla y León, construir el conjunto de datos limpio, documentar limitaciones y generar etiquetas académicas P1–P4 mediante supervisión débil.
- OE5. Diseñar e implementar una Capa 2 interpretable, comparar una línea base heurística con RuleFit-lite y una ejecución diagnóstica de `imodels`, seleccionar el modelo mediante la partición de validación y reservar la partición de prueba para la estimación final.
- OE6. Diseñar una Capa 3 de explicación que convierta reglas, probabilidades, evidencias y citas normativas en una justificación comprensible para el operador, sin delegar la decisión en un LLM.
- OE7. Integrar las capas mediante contratos versionados, servicio web auditable, respuesta alternativa determinista, registros de inferencia y mecanismos de retroalimentación humana.
- OE8. Evaluar el prototipo con una partición estratificada y otra temporal, control de fugas de información, estudio de errores P1, análisis por subgrupos, revisión interna de

una muestra de casos, evaluación automatizada de fidelidad explicativa y evaluación exploratoria con participantes.

En relación con OE5, la Capa 2 queda preparada para su consumo por Capa 3 mediante una salida explicable que incluye prioridad recomendada, reglas activadas, detalles de decisión y contexto estructurado para explicación. Esta salida permite que Capa 3 genere una explicación operativa sin recalcular ni sustituir la prioridad asignada por el modelo interpretable.

En relación con OE8, los tres autores han revisado conjuntamente una muestra de 119 casos, compuesta por 59 falsos negativos P1 y 60 casos equilibrados adicionales. Esta revisión interna es cualitativa y no equivale a tres anotaciones independientes ni a una validación externa con operadores del 112. De forma separada, la fidelidad de las explicaciones se evalúa automáticamente sobre esos mismos casos mediante un juez determinista reproducible. La evaluación se completa con un estudio exploratorio de nueve participantes, cuyos resultados describen utilidad percibida y comprensibilidad sin pretensión de representatividad estadística.

Esta secuencia mantiene una progresión lógica: primero se delimita el dominio, después se construye una base empírica defendible, a continuación se implementa el modelo interpretable y finalmente se evalúa su comportamiento desde una perspectiva técnica, explicativa y humana.

4.4. Preguntas de investigación

Las preguntas de investigación orientan el diseño y la evaluación del sistema:

- PI1. ¿Puede construirse una etiqueta académica P1–P4 defendible cuando el conjunto abierto no contiene prioridad oficial?
- PI2. ¿Qué aporta un modelo interpretable como RuleFit-lite frente a una línea base heurística basada en señales textuales y reglas operativas?
- PI3. ¿Es posible mantener una sensibilidad P1 suficiente sin convertir el sistema en una herramienta excesivamente conservadora que degrade el rendimiento global?
- PI4. ¿Hasta qué punto los resultados se mantienen estables en una partición temporal posterior?

Obj.	Evidencia principal	SopORTE documental	Criterio de cumplimiento
OE1	Planteamiento del problema, usuario y riesgos de automatización	Capítulos 1 y 4	Dominio, alcance y supervisión humana delimitados
OE2	Marco estatal, autonómico y europeo	Capítulo 3; Tabla de fuentes normativas	Normas vinculadas a variables, reglas y límites
OE3	Taxonomía, variables V01–V15 y política anti- <i>leakage</i>	Anexos A y B; Capítulo 7	Variables disponibles y prohibidas documentadas
OE4	Conjunto limpio, auditoría, particiones y etiquetas débiles	Capítulo 7; Anexo C	Conjunto reproducible y etiqueta académica trazable
OE5	Línea base heurística, RuleFit-lite y comparativa con alternativa externa	Capítulo 9; Anexo E	Modelo seleccionado en validación y salida consumible por Capa 3
OE6	Explicación con LLM local, RAG, MCP y respuesta alternativa determinista	Capítulos 6 y 8; Anexo L	Capa 3 explica sin recalcular prioridad
OE7	Integración Capa 1–Capa 2–Capa 3 y prueba de funcionamiento	Capítulos 8 y 9	5/5 escenarios integrados y 4/4 casos con LLM local
OE8	Evaluación final, errores P1, revisión interna, fidelidad automatizada y estudio exploratorio	Capítulo 9; Anexo D	59 falsos negativos P1, 119 casos revisados y nueve participantes

Tabla 4.1: Relación entre objetivos específicos, evidencias y criterios de cumplimiento.

Fuente: elaboración propia.

PI5. ¿Qué errores críticos aparecen, destacando falsos negativos P1, y qué evidencia debe mostrarse para que puedan ser revisados por humanos?

PI6. ¿Las explicaciones generadas por Capa 3 son fieles a las reglas, probabilidades y evidencias producidas por Capa 2?

Estas preguntas evitan presentar el TFM como una promesa de automatización total. El foco está en demostrar si una arquitectura responsable puede producir recomendaciones útiles, explicables y auditables dentro de un prototipo académico.

4.5. Contribución en inteligencia artificial

La contribución de IA comprende la transformación de información operativa en variables estructuradas, la construcción de etiquetas mediante supervisión débil, la comparación de alternativas interpretables y la separación entre priorización y explicación. La evaluación se respalda con métricas, evidencias reproducibles, una muestra revisada internamente y un análisis automatizado de fidelidad.

La selección de RuleFit-lite se justifica por su rendimiento en validación, su sensibilidad ante P1 y la posibilidad de exportar reglas. La implementación canónica alternativa se emplea únicamente como contraste diagnóstico con una muestra de ajuste reducida, por lo que sus costes no permiten establecer una comparación computacional en condiciones equivalentes. La partición de prueba se reserva para estimar el rendimiento final del modelo ya seleccionado.

4.6. Enfoque metodológico

El desarrollo sigue un enfoque iterativo e incremental adaptado a un TFM grupal. El equipo ha trabajado por bloques trazables: definición del dominio, datos, arquitectura, Capa 2, Capa 3, integración, evaluación y redacción. Este enfoque permitió contrastar la línea base heurística con RuleFit-lite y una alternativa externa de la familia RuleFit.

La metodología adopta una lógica incremental: cada fase genera una evidencia verificable, se contrasta con el objetivo correspondiente y se integra en la secuencia experimental. Este enfoque resulta adecuado porque el TFM combina investigación aplicada, desarrollo de un prototipo y redacción académica.

La metodología prioriza la evidencia reproducible frente a afirmaciones operativas no verificadas. Cada decisión relevante se vincula con una evidencia académica: conjunto limpio, guía de etiquetado, particiones, línea base heurística, RuleFit-lite, evaluación final y pruebas integradas. Esta trazabilidad permite defender que los resultados no dependen de una narración posterior, sino de un flujo experimental documentado.

4.7. Fases de desarrollo

El trabajo se ha estructurado en siete fases:

1. **Delimitación del dominio.** Análisis del problema 112, marco normativo estatal y autonómico, alcance territorial CyL y principios de supervisión humana.
2. **Datos y variables.** Auditoría del Registro 112 CyL, definición de V01–V15, identificación de columnas prohibidas por *leakage* y construcción del conjunto de datos limpio.
3. **Supervisión débil.** Generación de etiquetas académicas P1–P4, medición de acuerdo, ablación anti-circularidad y construcción de particiones estratificada y temporal.
4. **Capa 2 interpretable.** Implementación de la línea base heurística, RuleFit-lite y una alternativa externa; extracción de reglas, pesos, probabilidades y métricas por clase.
5. **Capa 3 explicativa e integración.** Arquitectura explicativa, trazabilidad, registro auditable e integración del flujo de inferencia.
6. **Evaluación y trazabilidad.** Evaluación final, análisis por subgrupos, errores P1, revisión interna conjunta, fidelidad automatizada y síntesis de evidencias.
7. **Redacción y coherencia final.** Alineación de capítulos, anexos, métricas, limitaciones y trabajo futuro para que la defensa refleje exactamente el sistema construido.

4.8. Consideraciones éticas

El sistema se diseña para un dominio de alto impacto, por lo que incorpora salvaguardas desde el principio. La primera es la supervisión humana: el prototipo recomienda, pero no moviliza recursos ni activa planes. La segunda es la explicabilidad: toda recomendación

debe acompañarse de reglas, probabilidades, evidencias y, cuando proceda, citas normativas. La tercera es el control anti-*leakage*: se excluyen campos posteriores a la decisión para no entrenar un modelo que aprenda consecuencias del operativo. La cuarta es la soberanía del dato: la inferencia se concibe en local y sin dependencia de APIs externas para datos sensibles.

También se documenta el uso de herramientas de IA generativa como apoyo a la elaboración del TFM. Dichas herramientas se han empleado para organización, redacción preliminar y revisión de coherencia, pero las decisiones técnicas, metodológicas y académicas corresponden al equipo y se contrastan con las evidencias reproducibles del proyecto.

4.9. Conclusiones del capítulo

Los objetivos, preguntas y metodología definidos en este capítulo fijan una línea de trabajo coherente con el resto de la memoria: un prototipo académico, territorialmente centrado en Castilla y León, que usa datos reales abiertos, supervisión débil, un modelo interpretable y explicaciones trazables. Esta formulación permite que los capítulos posteriores no dependan de promesas abstractas, sino de evidencias concretas: conjunto limpio, particiones, modelos, métricas, revisión preparada y evaluación final.

5. Requisitos del sistema

5.1. Introducción al capítulo

En un TFM de desarrollo software, los requisitos son el puente entre el análisis del dominio y la implementación. Este capítulo traduce el problema de priorización temprana de incidentes 112 en especificaciones funcionales, no funcionales y restricciones de alcance. La versión final del sistema se concibe como un prototipo académico de apoyo a la decisión para Castilla y León, no como una plataforma productiva de despacho ni como un sustituto del operador.

Las decisiones recogidas aquí condicionan la arquitectura descrita en el Capítulo 6, el tratamiento de datos del Capítulo 7 y la evaluación experimental del Capítulo 9. Por ello, los requisitos se formulan ya alineados con la línea técnica consolidada: Capa 1 NLP, Capa 2 RuleFit-lite, Capa 3 LLM+RAG+MCP, supervisión humana, anti-*leakage* y trazabilidad reproducible.

5.2. Definición formal del problema

El sistema aborda el siguiente problema: dado un incidente 112 descrito mediante texto libre, categoría preliminar, localización, fecha y datos operativos parciales, se necesita generar una recomendación inicial de prioridad P1–P4 que ayude al operador a formar una primera valoración, sin sustituir su criterio profesional.

La unidad de análisis es el incidente individual. La prioridad P1–P4 no es una etiqueta oficial del Registro 112 de Castilla y León; es una construcción académica del prototipo, creada para estudiar la viabilidad de una recomendación explicable basada en variables operativas, supervisión débil y aprendizaje interpretable. La recomendación debe ir acompañada de evidencia suficiente para que pueda ser aceptada, corregida o rechazada por una persona.

El sistema se diferencia de un clasificador automático convencional en tres aspectos. Primero, opera en condiciones de información incompleta. Segundo, debe evitar usar datos posteriores a la primera decisión. Tercero, debe explicar la salida de forma comprensible, porque en emergencias la confianza depende tanto del resultado como de la capacidad de auditarlo.

5.3. Usuario objetivo y contexto de uso

El usuario objetivo es un responsable de coordinación, jefe de sala, operador avanzado o perfil equivalente que deba valorar incidentes en un entorno 112. Se presupone conocimiento del dominio y capacidad para interpretar una recomendación como apoyo, no como orden automática. El prototipo puede utilizarse sobre registros históricos, cargas controladas o entradas manuales, siempre dentro de un entorno académico o de prueba.

El sistema no moviliza recursos, no activa planes, no envía alertas y no toma decisiones jurídicamente vinculantes. Su función es ordenar la información, proponer una prioridad inicial y mostrar las razones principales de esa propuesta.

5.4. Requisitos funcionales

RF1. Recepción y normalización del incidente El sistema debe recibir incidentes desde la carga de conjuntos de datos o la entrada textual manual y transformarlos en un registro normalizado con identificador, texto operativo, categoría, fecha, provincia, municipio, coordenadas cuando existan y campos auxiliares permitidos. La transcripción local de audio se conserva como entrada experimental sometida a revisión antes de la inferencia.

RF2. Extracción de variables y señales La Capa 1 debe extraer variables operativas V01–V15 y señales textuales relevantes para la priorización. La extracción aplica NLP simbólico y auditable: detección semántica mediante reglas y diccionarios, patrones de negación, normalización y estimación de confianza. Las variables V08–V11 quedan como extensión futura cuando se integren AEMET, SNCZI y Seveso. La posible incorporación de un clasificador aprendido requerirá un modelo congelado y una evaluación independiente antes de considerarse parte evaluada del prototipo.

RF3. Control de columnas prohibidas El sistema debe excluir de entrenamiento e inferencia los campos posteriores a la decisión o que reflejen consecuencias del operativo, como `MediosMov`, `PacientesAten`, `IncidenteCerrado` o `ultimaActualizacion`. Este requisito es obligatorio para evitar fuga de información.

RF4. Generación de etiqueta académica Cuando no exista prioridad oficial P1–P4, el sistema debe construir etiquetas académicas mediante supervisión débil, usando fuentes de señal separadas y midiendo acuerdo. La etiqueta resultante debe documentarse como aproximación metodológica, no como verdad operativa oficial.

RF5. Recomendación de prioridad P1–P4 La Capa 2 debe generar una recomendación de prioridad mediante un modelo interpretable. El modelo seleccionado es RuleFit-lite, comparado con una línea base experta y con una ejecución diagnóstica de `imodels`. La salida debe incluir prioridad, probabilidades por clase, reglas o señales activadas e identificación del modelo.

RF6. Cálculo de confianza e incertidumbre El sistema debe exponer información sobre confianza o incertidumbre asociada a la recomendación, especialmente cuando falten variables relevantes o cuando la predicción se apoye en señales débiles. La confianza no debe confundirse con gravedad.

RF7. Generación de explicación La Capa 3 debe generar una explicación breve y trazable que conecte la prioridad recomendada con reglas, probabilidades, evidencias disponibles y, cuando proceda, citas normativas recuperadas del corpus CyL. El LLM no decide la prioridad: explica la salida de Capa 2.

RF8. Validación humana El sistema debe permitir que una persona (operador del 112) revise la recomendación del DSS y registre una decisión explícita (aceptación, modificación o rechazo). Esta intervención humana (HITL) debe ser obligatoria para cerrar el caso y guardarse a nivel de base de datos mediante la persistencia del contrato estructurado `OperatorDecision`, vinculando la prioridad asignada y la justificación de cualquier discrepancia.

RF9. Registro auditable Cada inferencia debe quedar registrada y asociada a su entrada original, variables extraídas por la Capa 1, modelo de Capa 2 y su versión, prioridad recomendada, probabilidades calculadas, explicación de Capa 3, y la decisión humana final (`OperatorDecision`) si ya fue registrada. Esta persistencia aporta la trazabilidad técnica prevista en el diseño y se alinea con principios aplicables a sistemas de IA de alto riesgo

(Parlamento Europeo y Consejo de la Unión Europea, 2024), sustentando la auditoría técnica y la defensa académica.

RF10. Reevaluación El sistema debe poder reevaluar un incidente cuando cambien los datos de entrada, conservando el historial de recomendaciones para reconstruir la evolución del caso.

5.5. Requisitos no funcionales

5.5.1. Explicabilidad

La recomendación debe ser interpretable para un operador. Este requisito justifica que la Capa 2 use un modelo con reglas exportables y que la Capa 3 traduzca esas evidencias a lenguaje operativo. No basta con predecir una clase; el sistema debe mostrar por qué la propone.

5.5.2. Trazabilidad

Toda salida debe poder reconstruirse desde los datos de entrada hasta la explicación final. La trazabilidad incluye los procedimientos de preparación de datos, las etiquetas débiles, las particiones, el modelo entrenado, las reglas activas, las métricas, los registros de inferencia y las decisiones humanas registradas.

5.5.3. Supervisión humana

Ninguna recomendación debe ejecutarse automáticamente. La persona responsable conserva la decisión final y puede corregir la prioridad propuesta. Este principio es coherente con el Reglamento Europeo de Inteligencia Artificial (Parlamento Europeo y Consejo de la Unión Europea, 2024) y con la prudencia exigible en un dominio de alto impacto.

5.5.4. Robustez ante información incompleta

El sistema debe funcionar con información parcial, porque esa es la situación habitual en la primera decisión. Cuando la información sea insuficiente, la herramienta debe indicarlo y evitar presentar una certeza artificial.

5.5.5. Reproducibilidad

Los resultados deben poder regenerarse mediante procedimientos versionados. Esto incluye auditoría del conjunto de datos, construcción de etiquetas, particiones, entrenamiento, evaluación, análisis de errores, revisión interna de la muestra y síntesis final.

5.5.6. Soberanía del dato

El prototipo debe priorizar ejecución local y evitar dependencias cloud para datos sensibles. Las herramientas generativas se tratan como apoyo explicativo, no como mecanismo autónomo de decisión.

5.6. Restricciones y supuestos

5.6.1. Restricciones metodológicas y del prototipo

La primera restricción es que se trabaja con un prototipo académico, no con un sistema certificado ni desplegado en una sala 112 real. La segunda es que el Registro 112 de Castilla y León no contiene prioridad oficial P1–P4, por lo que la evaluación se realiza contra una etiqueta académica de supervisión débil. La tercera es que no se dispone todavía de validación externa con operadores del 112; por eso se prepara una muestra para revisión interna y se documenta como paso previo.

La cuarta restricción es que algunas variables contextuales de alto interés, como AE-MET histórico, inundabilidad SNCZI y proximidad Seveso, quedan diferidas como ampliación futura. La quinta es que la evaluación no mide reducción real del tiempo de decisión en sala, sino rendimiento técnico, estabilidad temporal, errores críticos, fidelidad explicativa y trazabilidad documental.

Estas restricciones delimitan el alcance del trabajo y evitan extrapolar los resultados más allá de la evidencia disponible. También establecen un punto de partida verificable para futuras ampliaciones y evaluaciones externas.

5.6.2. Supuestos y dependencias tecnológicas

El funcionamiento del prototipo depende de varios supuestos tecnológicos específicos de ejecución local. En primer lugar, se emplean contratos de datos desarrollados con `Pydantic` para comprobar tipos y restricciones en tiempo de ejecución, reduciendo el riesgo

de incompatibilidades entre capas. En segundo lugar, la explicación generativa requiere la disponibilidad de Ollama con el modelo local Llama 3.1:8B (o el equivalente configurado Qwen 2.5:7B-instruct). Esta configuración busca generar explicaciones coherentes, pero no elimina por completo el riesgo de error o alucinación; por ello se mantienen recuperación normativa, validación contractual y una respuesta alternativa determinista.

Existe un riesgo tecnológico relevante asociado a la latencia y la disponibilidad: si el hardware local no dispone de recursos suficientes para ejecutar Ollama, el tiempo de inferencia del LLM puede aumentar o la generación puede fallar. En ese caso, el prototipo recurre a una respuesta alternativa basada en plantillas deterministas. Este mecanismo se ha comprobado en el entorno académico, sin que ello implique disponibilidad certificada para un contexto operativo.

5.7. Trazabilidad entre requisitos y componentes

Req.	Descripción resumida	Componente asociado	Evidencia
RF1	Recepción y normalización	Pipeline de datos y backend	Dataset limpio y contratos
RF2	Extracción de variables	Capa 1 NLP	Variabes V01–V15 y señales
RF3	Anti- <i>leakage</i>	Pipeline y Capa 2	Columnas prohibidas excluidas
RF4	Etiquetas débiles P1–P4	Supervisión débil	Acuerdo y ablación
RF5	Prioridad P1–P4	RuleFit-lite	Modelo, reglas y métricas
RF6	Confianza	Capa 2 e inferencia	Probabilidades por clase
RF7	Explicación	Capa 3 LLM+RAG+MCP	Explicación y citas
RF8	Revisión humana	Interfaz y retroalimentación	Muestra de revisión interna
RF9	Registro auditable	Backend y logs	InferenceLog
RF10	Reevaluación	Orquestador	Historial de inferencias

Tabla 5.1: Trazabilidad entre requisitos y componentes del sistema.

Fuente: elaboración propia.

5.8. Conclusiones del capítulo

Los requisitos definidos convierten el problema operativo en una especificación coherente con la arquitectura final. El sistema debe recibir incidentes, extraer variables, evitar leakage, recomendar prioridad mediante Capa 2 interpretable, explicar la salida mediante Capa 3, registrar la trazabilidad y mantener siempre la decisión humana en el centro.

El siguiente capítulo desarrolla la arquitectura que materializa estos requisitos: una

Juan Carlos Albert Fillol, Ancor González Carballo y Brian Mathias Pesci Juliani
Máster Universitario en Inteligencia Artificial

solución modular de tres capas, preparada para evaluación reproducible y para una futura validación externa con personal experto.

6. Arquitectura y diseño del sistema inteligente

Este capítulo describe la arquitectura de software y el diseño detallado del sistema inteligente de priorización. En primer lugar, se enuncian los principios de diseño que rigen todo el desarrollo, tales como la explicabilidad y el control humano de la decisión. A continuación, se detalla la organización modular del sistema estructurada en tres capas diferenciadas: extracción textual, modelo predictivo e interpretación normativa. Por último, se describe la especificación de las interfaces y los contratos de datos que garantizan la consistencia del flujo de información a lo largo de toda la canalización.

6.1. Finalidad del capítulo

Este capítulo presenta el diseño técnico y analítico del sistema propuesto. Tras haber fijado el problema, el estado del arte y el marco normativo, aquí se describe cómo se transforma un incidente 112 en una recomendación de prioridad P1–P4 explicable, auditable y revisable por un operador humano. El modelado en tres capas independientes constituye la respuesta técnica a la necesidad de aislar la toma de decisiones estadísticas de la generación lingüística explicativa.

La versión actual del TFM abandona el diseño inicial basado únicamente en reglas duras y *scoring*. Esta decisión responde a la necesidad de dotar al prototipo de una mayor capacidad de generalización sobre registros reales. En consecuencia, la arquitectura final se organiza en tres capas de inteligencia artificial, coordinadas mediante contratos de datos versionados:

- **Capa 1: NLP operativo.** Extrae variables V01–V15 y señales textuales desde el título, descripción, categoría preliminar y contexto básico del incidente.
- **Capa 2: priorización interpretable.** Produce una recomendación P1–P4 mediante RuleFit-lite, entrenado sobre etiquetas académicas generadas por supervisión débil, y comparado con una línea base experta y una ejecución diagnóstica con `imodels`.
- **Capa 3: explicación normativa.** Genera una explicación breve para el operador

mediante LLM local, recuperación aumentada sobre corpus normativo de Castilla y León y herramientas MCP.

El resultado no es un sistema autónomo de despacho, sino un sistema de apoyo a la decisión. La prioridad recomendada no sustituye el criterio profesional; se ofrece como una propuesta estructurada, con reglas activadas, probabilidad, confianza, citas legales y registro auditable. Al delegar la responsabilidad final en el operador, se asegura el alineamiento con las directrices regulatorias europeas sobre el uso ético de algoritmos de decisión.

6.2. Principios de diseño

El diseño se apoya en seis principios que conectan los capítulos previos con la implementación.

Primero, supervisión humana. El operador acepta, modifica o rechaza la recomendación. El sistema nunca moviliza recursos por sí mismo ni declara situaciones operativas oficiales.

Segundo, explicabilidad desde el núcleo. La prioridad se calcula mediante un modelo interpretable, no mediante un LLM generativo. El LLM explica una decisión ya producida por Capa 2; no decide la prioridad.

Tercero, contratos antes que integración. Cada capa intercambia objetos Pydantic versionados. Esto reduce ambigüedad, facilita pruebas y permite que los tres bloques de trabajo avancen en paralelo.

Cuarto, soberanía del dato. La inferencia se plantea en local. No se envían incidentes a APIs externas en producción, y la Capa 3 usa un LLM cuantizado ejecutado en hardware propio.

Quinto, trazabilidad normativa. Las variables, reglas y explicaciones se vinculan con normas del corpus CyL: Ley 17/2015, RD 524/2023, Ley 4/2007 CyL, PLANCAL, INFOCAL, INUNCYL, MPCyL, RGPD, LOPDGDD y Reglamento UE 2024/1689.

Sexto, prevención de *leakage*. El sistema no utiliza columnas posteriores a la decisión, como medios movilizados, pacientes atendidos o cierre del incidente. Estas variables pueden analizarse solo como información ex post de evaluación, nunca como entrada de Capa 1 o Capa 2.

6.3. Vista general de la arquitectura

La arquitectura se representa como una cadena de transformaciones controladas. La entrada inicial es un `IncidentInput`; la Capa 1 produce `IncidentFeatures`; la Capa 2 produce `PriorityRecommendation`; la Capa 3 produce `OperatorRecommendation`; y la decisión final del operador se registra como `OperatorDecision`. Todo el proceso queda recogido en un `InferenceLog`. Esta secuencia evita dependencias circulares entre las fases de inferencia. De forma opcional, la interfaz puede proponer la entrada a partir de audio de prueba mediante reconocimiento automático del habla (ASR) con `faster-whisper`; el resultado debe revisarse y no se presenta como transcripción validada de llamadas reales.




Figura 6.1: Arquitectura integrada de tres capas con contratos versionados y componentes locales.

Esta separación evita mezclar responsabilidades. La Capa 1 no decide prioridad; estructura el incidente. La Capa 2 no redacta explicaciones normativas extensas; recomienda prioridad y devuelve reglas activadas. La Capa 3 no recalcula el resultado; explica lo recibido, cita normas y advierte de incertidumbres.

6.4. Contratos de datos

Los contratos son la pieza que convierte la arquitectura en un sistema verificable. Cada contrato define campos, restricciones e invariantes. La Tabla 6.1 resume los objetos principales.

Contrato	Momento de uso	Función principal
IncidentInput	Entrada inicial	Representa texto, categoría, localización, fecha, provincia y operador antes de cualquier inferencia
IncidentFeatures	Salida Capa 1	Contiene variables V01–V15, señales textuales, confianza y metadatos de extracción
Priority Recommendation	Salida Capa 2	Contiene prioridad P1–P4, probabilidades, reglas activadas, nivel de confianza y modelo usado
Operator Recommendation	Salida Capa 3	Contiene explicación textual, citas legales, recomendaciones no vinculantes y resumen de reglas
OperatorDecision	Retroalimentación humana	Registra prioridad final asignada por el operador y posible divergencia
InferenceLog	Auditoría	Conserva snapshots, latencias, versiones de modelo, herramientas invocadas y hash de entrada

Tabla 6.1: Contratos principales del flujo de inferencia.

El uso de contratos tiene una consecuencia metodológica importante: la memoria puede justificar el sistema sin depender de detalles accidentales de implementación. Lo relevante no es solo que exista código, sino que cada capa tenga entradas, salidas e invariantes comprobables. Asimismo, esta formalización facilita la validación cruzada y la auditoría interna de los componentes del software.

6.5. Entrada del sistema: IncidentInput

La entrada representa lo que el operador o un cliente externo proporciona en los primeros minutos del incidente. Incluye título, descripción, categoría preliminar, localización opcional, provincia, fecha y operador. En el caso del dataset de Castilla y León, estos campos se derivan de columnas como `Titulo`, `DescripcionBlob`, `FechaIncidente`, `Localidad` y coordenadas.

El contrato exige dos invariantes básicos. Primero, si existe latitud debe existir longitud, y viceversa. Segundo, el título o la descripción deben contener información textual mínima. Esta restricción evita ejecutar una cadena de inferencia sobre entradas vacías o inútiles.

La entrada también es el primer punto de defensa contra *leakage*. Si el cliente incluye campos como medios movilizados o pacientes atendidos, el backend debe rechazarlos con error explícito. Esta decisión protege la validez del sistema: un motor de primera decisión no puede aprender de información que solo aparece después de decidir.

6.6. Capa 1: extracción NLP de variables operativas

La Capa 1 transforma texto libre y metadatos básicos en una representación estructurada del incidente. Su salida, `IncidentFeatures`, contiene las variables operativas V01–V15, las señales textuales y metadatos de inferencia.

6.6.1. Variables activas y diferidas

El alcance evaluado activa V01–V07 y V12–V15. Las variables V08–V11 permanecen en el contrato como extensión futura, pero no se entrenan ni se exigen para la evaluación principal. Esta decisión mantiene el sistema reproducible y evita depender de integraciones geoespaciales o meteorológicas todavía no consolidadas.

Var.	Nombre operativo	Función en el sistema	Estado evaluado
V01	Riesgo vital	Detectar amenaza directa a la vida	Activa
V02	Número de víctimas estimado	Aproximar magnitud humana	Activa
V03	Gravedad de lesiones	Distinguir leve, grave o crítica	Activa
V04	Tipo de incidente normalizado	Conectar texto con taxonomía	Activa
V05	Población vulnerable	Elevar sensibilidad por colectivos vulnerables	Activa
V06	Número de llamadas	Captar confirmación o simultaneidad	Activa
V07	Emplazamiento crítico	Identificar hospitales, colegios, residencias u otros puntos sensibles	Activa
V08– V11	AEMET, inundabilidad, Seveso	Enriquecimiento contextual avanzado	Diferidas
V12	Riesgo de propagación	Captar incendios u otros incidentes expansivos	Activa
V13	Multirriesgo	Detectar concurrencia de amenazas	Activa
V14	Avisos simultáneos en zona	Aproximar presión operativa y confirmación externa	Activa
V15	Accesibilidad de recursos	Modular complejidad de intervención	Activa

Tabla 6.2: Variables operativas del sistema y alcance evaluado.

6.6.2. Señales textuales

Además de variables estructuradas, la Capa 1 extrae señales textuales booleanas con confianza asociada. Las señales críticas representan lesiones graves, atrapamiento, intoxicación, fallecimiento o riesgo vital. Otras aportan contexto sobre incendios, accidentes de tráfico, rescates, avisos simultáneos y fenómenos meteorológicos o inundaciones. La correspondencia con los identificadores de software se documenta en el Anexo F.

La Capa 1 se implementa mediante NLP simbólico y auditable. La detección semántica basada en reglas y diccionarios operativos, los patrones de negación, la normalización y la estimación de confianza permiten reconocer señales de alto impacto, como atrapamiento, herido grave, incendio, intoxicación o riesgo vital textual. Esta decisión reduce dependencias externas, facilita los tests de contrato y evita presentar como validado un modelo neuronal que no dispone de checkpoint congelado. El uso de modelos transformer para extracción contextual queda reservado como línea futura, condicionada a entrenamiento, versionado y evaluación específica.

6.7. Capa 2: priorización interpretable con RuleFit

La Capa 2 consume `IncidentFeatures` y produce `PriorityRecommendation`. Es el núcleo decisorio del sistema. Su responsabilidad es asignar una prioridad P1–P4, generar probabilidades por clase, devolver reglas activadas y comunicar nivel de confianza.

6.7.1. Escala P1–P4

La escala P1–P4 es académica y funcional, no oficial. P1 representa incidentes críticos con riesgo vital, lesiones graves, atrapamiento, intoxicación, fallecimiento, propagación grave o amenaza inmediata. P2 representa alta prioridad, potencial de deterioro o afectación significativa. P3 recoge incidentes que requieren gestión o seguimiento sin criticidad inmediata. P4 se reserva para baja urgencia relativa.

La escala no equivale a situaciones operativas 0–3. Una situación operativa es una categoría institucional de mando y coordinación; P1–P4 ordena incidentes individuales dentro del prototipo. Esta distinción evita confundir una herramienta académica de priorización con una declaración jurídica de emergencia.

6.7.2. Supervisión débil

Como el Registro 112 CyL no contiene prioridad oficial P1–P4, el entrenamiento de Capa 2 requiere construir una etiqueta académica. La estrategia es la supervisión débil: cuatro funciones de etiquetado heurísticas y correlacionadas generan votos que se agregan en una etiqueta final con confianza. Todas comparten una puntuación programática de gravedad, con variaciones en el uso de la categoría y en patrones de intensificación, vulnerabilidad, emplazamiento y negación. En la ejecución evaluada no intervienen un modelo NER entrenado, un algoritmo de agrupamiento semántico ni un LLM anotador.

La etiqueta débil no se presenta como verdad institucional. Es un recurso metodológico que permite entrenar y comparar modelos sobre datos reales abiertos. Por ello debe acompañarse de acuerdo entre fuentes de etiquetado, análisis de discrepancias y una ablación anti-circularidad que compare el resultado sin la fuente de reglas heurísticas.

6.7.3. RuleFit como modelo principal

RuleFit se selecciona porque combina aprendizaje estadístico e interpretabilidad. El modelo genera o utiliza reglas derivadas de árboles y las pondera mediante regularización, produciendo un conjunto de reglas con coeficientes inspeccionables (Friedman y Popescu, 2008). En este TFM se impone una restricción de parsimonia: el modelo seleccionado debe mantener como máximo 30 reglas activas con peso distinto de cero.

Esta restricción es académica, no estética. Un modelo con cientos de reglas sería difícil de defender ante un operador o un tribunal. En cambio, un conjunto reducido de reglas permite revisar por qué P1 aumenta, qué variables influyen y qué anclajes normativos sostienen la recomendación.

6.7.4. Línea base experta, RuleFit-lite e imodels

La Capa 2 no se evalúa en aislamiento. Se compara con dos referencias. La línea base experta es un conjunto de reglas transparentes basadas en señales y variables V01–V15, con anclaje normativo. Sirve como referencia mínima: RuleFit debe aportar mejora cuantitativa sin perder explicabilidad.

La segunda referencia es `imodels.RuleFitClassifier`, utilizada como implementación canónica de RuleFit. Dado que la librería trabaja en clasificación binaria, se adopta un esquema one-vs-rest P1–P4. La versión evaluada del TFM selecciona RuleFit-lite por-

que mantiene la filosofía RuleFit, respeta el límite de reglas activas y obtiene el mejor rendimiento de validación en la configuración ensayada.

La alternativa externa se conserva como contraste diagnóstico de la familia RuleFit. El modelo RuleFit-lite se ajusta sobre un submuestreo estratificado y reproducible de 3.000 registros de los 6.512 disponibles, mientras que `imodels` se limita a 50 registros por su coste local. La diferencia de tamaños impide atribuir a RuleFit-lite una superioridad computacional en condiciones equivalentes; la selección se apoya en el rendimiento de validación, la interpretabilidad y la reproducibilidad de la configuración efectivamente evaluada.

6.7.5. Probabilidad, confianza e invariantes

La salida de Capa 2 incluye una distribución de probabilidad sobre P1–P4. El contrato exige que las probabilidades sumen 1, que la prioridad recomendada coincida con el `argmax` y que los incidentes P1/P2 incluyan al menos una regla activada cuando el modelo usado sea RuleFit o la línea base. Este requerimiento de consistencia matemática y lógica impide la generación de clasificaciones contradictorias. Asimismo, obliga a que toda asignación crítica cuente con un sustento explícito y auditable en forma de predicados lógicos.

El nivel de confianza se deriva estrictamente de la probabilidad máxima del vector contractual: alta si $p_{max} \geq 0,80$, media entre 0,60 y 0,80, baja entre 0,40 y 0,60, y desconocida por debajo de 0,40. Esta confianza no mide la gravedad física del suceso. Un incidente puede ser P1 con confianza baja o media si hay indicios críticos pero información fragmentaria; del mismo modo, un caso P4 puede tener confianza alta si las señales disponibles son claras.

6.7.6. Puerta de Seguridad

Para reforzar la alineación conceptual con PLANCAL y la Ley 17/2015 de Protección Civil, el diseño de la Capa 2 incorpora un posprocesador denominado Puerta de Seguridad (*Safety Gate*). Este componente aplica una salvaguarda determinista y trazable sobre la salida del modelo. Kollipara et al. Kollipara, Gupta, O'Neill, y cols. (2025) describen el uso de puertas de decisión verificables como mecanismo de control frente a errores graves en sistemas de aprendizaje automático de dominios críticos. En este TFM su aplicación constituye una decisión de diseño conservadora, no una garantía certificada de seguridad operacional.

Técnicamente, la Puerta de Seguridad actúa como un filtro duro sobre el argmax probabilístico generado por RuleFit-lite. Su función no es sustituir el modelo interpretable, sino reducir el riesgo de que determinados patrones predecisionales de alta gravedad queden infrapriorizados por ruido textual, escasez de muestras o ambigüedad. Para ello evalúa condiciones deterministas basadas en los criterios documentados del proyecto. Su efecto se comprueba mediante escenarios funcionales, mientras que las métricas comparativas de RuleFit-lite se calculan sin este posprocesamiento para no mezclar el rendimiento del estimador con la salvaguarda.

Conceptualmente, RuleFit-lite produce la prioridad

$$\hat{y} = \arg \max_{c \in \{P1, P2, P3, P4\}} p(c).$$

La Puerta de Seguridad evalúa después un conjunto de predicados deterministas $S_i(x)$ sobre las variables de entrada. Cuando se activa un predicado crítico, la prioridad se fuerza a $P1$ o $P2$, se incorpora una regla de seguridad con peso alto y se adjuntan anclajes normativos para la explicación posterior. El vector de probabilidad se redistribuye de forma determinista:

$$p'(y_{seguro}) = 0,97, \quad p'(c \neq y_{seguro}) = 0,01.$$

La Puerta de Seguridad fuerza $P1$ ante riesgo vital, fallecido, riesgo vital textual, multirriesgo en emplazamiento crítico, incendio forestal con propagación, incendio con propagación en emplazamiento crítico, intoxicación grave, rescate complejo con baja accesibilidad o múltiples víctimas estimadas. Fuerza $P2$ cuando existen señales operativas relevantes como herido grave, atrapamiento, intoxicación, rescate activo o episodio meteorológico/inundación en emplazamiento crítico, siempre que no se cumpla un criterio $P1$. Esta lógica mantiene el principio de prudencia: ante indicadores predecisionales críticos, el sistema prefiere elevar la prioridad y exigir revisión humana.

La regla inyectada por la Puerta de Seguridad se incorpora a `activated_rules` con identificadores como `SAFE-GATE-P1-RIESGO-VITAL` o `SAFE-GATE-P2-OPERATIVO`. De este modo, Capa 3 puede explicar que la recomendación no procede solo del argmax estadístico, sino también de una salvaguarda determinista trazable. La salida forzada marca `requires_human_attention=true`, reforzando que el operador conserva la decisión final.

6.8. Capa 3: explicación normativa con LLM, RAG y MCP

La Capa 3 convierte la recomendación de Capa 2 en una salida útil para el operador. Produce `OperatorRecommendation`, que incluye prioridad, explicación textual, citas legales, resumen de reglas activadas, sugerencias no vinculantes y metadatos del LLM.

6.8.1. LLM local

El LLM local se utiliza para redactar explicaciones breves y consistentes. La inferencia se plantea con temperatura 0 para reducir variabilidad y mejorar reproducibilidad. El modelo no recibe el mandato de decidir prioridad; recibe la prioridad ya calculada, las reglas activadas y el contexto normativo recuperado.

Esta separación es clave para la seguridad del diseño. Un LLM puede redactar bien, pero no debe ser la autoridad decisoria en un dominio crítico. Si el LLM falla, la recomendación P1-P4 de Capa 2 sigue siendo válida y el sistema puede operar en modo degradado.

6.8.2. RAG sobre corpus normativo CyL

La recuperación aumentada conecta la explicación con documentos oficiales. El corpus incluye normativa estatal, autonómica, europea y fuentes de datos: Ley 17/2015, RD 524/2023, PLEGEM, Ley 4/2007 CyL, PLANCAL, INFOCAL, INUNCYL, MPCyL, Ley 11/2022, Registro 112 CyL, RGPD, LOPDGDD y Reglamento UE 2024/1689.

La función del RAG no es entrenar el modelo de prioridad. Su papel es proporcionar fragmentos normativos para que la explicación cite fundamentos relevantes. Esto reduce el riesgo de explicaciones genéricas y refuerza la trazabilidad del sistema.

6.8.3. Herramientas MCP

La Capa 3 expone tres herramientas MCP para la búsqueda normativa, la consulta del detalle de reglas y la construcción controlada de citas. La consulta meteorológica contextual queda diferida como ampliación futura. Estas funciones definen el catálogo básico de operaciones que el asistente puede realizar de forma controlada.

Estas herramientas permiten consultar el corpus, recuperar el detalle de reglas y construir citas legales. El uso de MCP separa la capacidad del LLM de las funciones verificables del sistema: buscar, citar y explicar reglas son operaciones con entradas y salidas controladas. Esta separación facilita la auditoría del proceso de generación de explicaciones a

nivel de llamada API.

6.8.4. Caché de sesión en Capa 3

La Capa 3 incorpora una caché de sesión para evitar llamadas redundantes al LLM cuando se procesa el mismo texto operativo con la misma prioridad recomendada. La clave de la caché se genera mediante SHA-256 a partir de la concatenación del texto del incidente y la prioridad: `sha256(texto || prioridad)`. Esta decisión reduce latencia en demostraciones y pruebas repetidas, sin alterar la recomendación de Capa 2 ni los contratos de salida.

El resultado almacenado en caché es un objeto Pydantic `OperatorRecommendation`. Como ese objeto conserva el `incident_id` del primer incidente que generó la explicación, la implementación clona el objeto mediante `model_copy(update={...})` cuando el `incident_id` de la nueva inferencia es distinto. Esta copia evita colisiones en los logs de auditoría cruzada y mantiene la consistencia contractual: cada `InferenceLog` conserva hijos con el mismo identificador de incidente.

6.9. Orquestador, fallback y latencia

El backend actúa como orquestador. Recibe la entrada, valida el contrato, ejecuta Capa 1, invoca Capa 2, llama a Capa 3 si procede, registra latencias y devuelve la recomendación al cliente. También gestiona errores, timeouts y modo degradado.




Figura 6.2: Secuencia de inferencia desde la entrada del incidente hasta la decisión humana.

El diseño contempla varios mecanismos de contingencia para mantener una respuesta del prototipo cuando se detectan fallos en componentes individuales. En concreto, el

orquestador implementa las siguientes salvaguardas:

- Si Capa 1 produce baja confianza, Capa 2 puede apoyarse en la línea base experta o en una respuesta conservadora.
- Si RuleFit no está disponible, se puede usar la línea base experta.
- Si Capa 3 supera el umbral temporal configurado o el LLM no está disponible, se devuelve una explicación estática basada en reglas activadas.
- Si la entrada contiene campos prohibidos, el sistema rechaza la solicitud en lugar de degradar silenciosamente.

Los objetivos internos de latencia se fijaron en un p95 igual o inferior a 500 ms para Capa 1 y Capa 2, y por debajo de 2 s p95 para el flujo completo con Capa 3. Son referencias de diseño para orientar la optimización, no un acuerdo de nivel de servicio del 112 ni garantías de despliegue productivo.

La latencia media observada en el entorno experimental con el LLM local es de 4,898 s por inferencia completa. Esta cifra supera el objetivo interno y muestra la limitación del hardware no dedicado. Como contingencia, si el modelo local no responde o supera el tiempo esperado, Capa 3 genera una explicación determinista basada en reglas activadas, probabilidades y plantillas, con latencia submilisegundo en las pruebas controladas. Así, la recomendación de Capa 2 no queda bloqueada por el componente generativo; este resultado acredita funcionamiento técnico, no cumplimiento de un acuerdo de nivel de servicio operativo.

6.10. Trazabilidad y auditoría

Cada inferencia genera un **InferenceLog**. El log incluye hash de entrada, snapshots de las salidas por capa, versiones de modelo, latencias, herramientas invocadas, timestamp y decisión del operador si existe. Esta información permite reconstruir por qué el sistema recomendó una prioridad y qué hizo finalmente la persona responsable. La persistencia de **OperatorDecision** y la conservación de snapshots por capa materializan los principios de supervisión humana y trazabilidad exigibles en sistemas de alto impacto, en coherencia con el Reglamento Europeo de Inteligencia Artificial (Parlamento Europeo y Consejo de la Unión Europea, 2024).

La trazabilidad sirve para tres fines. Primero, auditoría técnica: comprobar que el sistema usó los modelos y contratos esperados. Segundo, evaluación académica: medir errores, falsos negativos P1, calibración y divergencias operador-sistema. Tercero, alineación responsable del diseño: documentar supervisión humana, registro de decisiones y control de cambios, sin atribuir al prototipo una conformidad regulatoria certificada.

6.11. Ejemplo de funcionamiento

Considérese el incidente:

Varón inconsciente tras choque frontal en N-122, herido grave atrapado en el habitáculo. Han llamado varios testigos.

La Capa 1 detecta atrapamiento, lesión grave, riesgo vital probable, avisos simultáneos y un accidente de tráfico. La Capa 2 recomienda P1 cuando RuleFit activa las reglas asociadas a atrapamiento y lesión grave. La Capa 3 recupera normativa relacionada con la protección de personas y PLANCAL, y redacta una explicación breve:

Prioridad P1 por indicios de riesgo vital. La descripción menciona herido grave y persona atrapada tras choque frontal, con varios avisos de testigos. La recomendación se basa en reglas de afectación a personas y requiere supervisión inmediata del operador.

El operador puede aceptar la prioridad, modificarla o rechazarla. En cualquier caso, la divergencia queda registrada para evaluación posterior. Este registro histórico constituye una valiosa fuente de datos para el reentrenamiento y ajuste del modelo.

6.12. Evaluación del diseño

El Capítulo 9 mide si el diseño cumple sus objetivos. Las métricas principales de Capa 2 son F1 macro, sensibilidad P1, parsimonia del modelo, latencia, rendimiento temporal, análisis por subgrupos y matriz de confusión. El objetivo crítico es una sensibilidad P1 igual o superior a 0,85, porque los falsos negativos graves son el riesgo más importante. La calibración ECE queda identificada como mejora futura, y RuleFit debe respetar el límite de 30 reglas activas.

La Capa 3 se evaluará por validez contractual, latencia, presencia de citas en P1/P2 y fidelidad de explicación respecto a reglas activadas. La validación interna entre autores servirá para comparar etiquetas humanas, etiqueta débil y recomendación del sistema sobre un subconjunto de casos. Ambas líneas de evaluación permiten contrastar la coherencia de la arquitectura antes de planificar un piloto controlado.

6.13. Conclusiones

La arquitectura definida en este capítulo materializa la idea central del TFM: un sistema de apoyo a la decisión para incidentes 112 en Castilla y León que combina datos reales, normativa, aprendizaje interpretable, explicación local y supervisión humana. Esta propuesta busca superar las limitaciones de rigidez de los sistemas basados puramente en heurísticas. Asimismo, el diseño modular adoptado establece las bases técnicas para incorporar variables contextuales complejas en futuras versiones.

El diseño evita dos extremos poco defendibles. Por un lado, no se queda en reglas manuales rígidas: incorpora supervisión débil, RuleFit y evaluación cuantitativa. Por otro lado, no entrega la decisión a una caja negra ni a un LLM generativo: mantiene la prioridad en un núcleo interpretable y reserva el LLM para explicar y citar. Esta posición intermedia es la que permite aspirar a un TFM excelente: una propuesta ambiciosa, pero acotada; técnica, pero auditable; innovadora, pero prudente en un dominio crítico.

El siguiente capítulo desarrolla el diseño de datos, la auditoría del Registro 112 CyL, la construcción de etiquetas académicas y las garantías anti-*leakage* que alimentan la arquitectura aquí descrita. Este análisis empírico es fundamental para comprender cómo se entrenan y validan los componentes predictivos de la Capa 2. Con ello se asegura el rigor científico y la reproducibilidad de todo el proceso experimental del prototipo.

7. Datos, conjunto de datos y supervisión débil

7.1. Finalidad del capítulo

El capítulo anterior ha definido la arquitectura del sistema. Este capítulo desarrolla la base empírica que permite alimentar, entrenar y evaluar esa arquitectura. En particular, explica el uso del Registro de Emergencias del 112 de Castilla y León, las variables V01–V15, la construcción de la etiqueta académica P1–P4, la supervisión débil, la prevención de fugas de información y las particiones de entrenamiento, validación y prueba.

El proyecto trabaja con registros reales, pero no dispone de una prioridad oficial. Por ello, el conjunto no puede tratarse como una fuente supervisada tradicional. Se adopta un procedimiento metodológico trazable: datos abiertos, limpieza reproducible, variables justificadas, etiqueta académica documentada, modelos interpretables y evaluación prudente.

7.2. Estrategia general de datos

La estrategia de datos del TFM se apoya en el Registro de Emergencias del 112 de Castilla y León como fuente empírica principal (Junta de Castilla y León, s. f.). Esta decisión aporta coherencia territorial y normativa: el conjunto de datos procede de un servicio autonómico 112 real, y el marco de interpretación se apoya en normativa estatal y de Castilla y León, especialmente Ley 4/2007, PLANCAL, INFOCAL, INUNCYL y MPCyL.

El conjunto abierto permite trabajar con texto operativo, fecha, localidad, provincia, coordenadas aproximadas, identificador y categoría preliminar. Sin embargo, no contiene una prioridad oficial P1–P4 ni todas las variables estructuradas requeridas. El objetivo es construir una referencia académica mediante supervisión débil y dejar preparada su revisión humana.

El flujo de datos se organiza en seis pasos:

1. Ingesta y limpieza del Registro 112 CyL.
2. Normalización de texto, fechas, coordenadas y categorías.

3. Extracción de señales textuales y variables V01–V15.
4. Construcción de etiquetas P1–P4 mediante supervisión débil.
5. Generación de particiones de entrenamiento, validación y prueba, incluida una partición temporal.
6. Evaluación de Capa 2 y análisis de sesgos, errores y *leakage*.

7.3. Registro de Emergencias del 112 de Castilla y León

El Registro de Emergencias del 112 de Castilla y León es un conjunto de datos público publicado por la Junta de Castilla y León bajo licencia Creative Commons Reconocimiento 4.0 (Junta de Castilla y León, s. f.). En este TFM se utiliza el fichero histórico 2008–2022 como fuente empírica de incidentes para comprobar el procedimiento de preparación de datos y construir las etiquetas académicas.

Su valor principal es el realismo. Los registros no son ejemplos artificiales creados para el TFM, sino incidentes gestionados por un servicio autonómico 112. Esto permite trabajar con lenguaje operativo, categorías heterogéneas, coordenadas, localidades, duplicidades potenciales, ruido textual y limitaciones propias de datos administrativos reales.

7.3.1. Campos de entrada

La Tabla 7.1 resume los campos principales del conjunto de datos y su relación con la entrada estructurada del sistema.

7.3.2. Auditoría inicial

La auditoría del conjunto de datos documenta volumen, duplicados, nulos, cobertura temporal, cobertura geográfica y distribución por provincia y categoría. El conjunto final conserva 9.380 registros válidos, 41 columnas, cobertura temporal entre 2008-07-28 y 2022-12-31, ausencia de fechas inválidas, 0 identificadores duplicados y cobertura de coordenadas del 99,24 %. Estos datos constituyen la base empírica del entrenamiento y evaluación, siempre diferenciando los datos reales del Registro 112 CyL de la etiqueta académica P1–P4 generada mediante supervisión débil.

La auditoría precede a la presentación de resultados para que las métricas puedan interpretarse a partir de la calidad y las limitaciones de los datos.

Campo original	Uso en el sistema	Observación metodológica
Título	texto_titulo en IncidentInput	Fuente textual breve para señales operativas
DescripcionBlob	texto_descripcion	Requiere limpieza de HTML y normalización
FechaIncidente	fecha_incidente	Permite el análisis y la partición temporal por año
Localidad	localidad	Contexto territorial no siempre equivalente a coordenada exacta
Localidad.1	latitud, longitud	Permite disponibilidad de coordenadas cuando el campo es válido
TipoIncidente	categoria_preliminar	Campo orientativo; no basta para priorizar
Identificador	Trazabilidad interna	No se usa como variable predictiva
MediosMov	Solo evaluación ex post si procede	Variable prohibida como entrada por <i>leakage</i>
PacientesAten	Solo evaluación ex post si procede	Resultado posterior, no disponible en primera decisión
IncidenteCerrado	Exclusión	Estado final del incidente
ultima Actualizacion	Exclusión	Información posterior al inicio

Tabla 7.1: Campos principales del Registro 112 CyL y uso previsto en el sistema.

Elemento auditado	Finalidad
Número de registros	Confirmar volumen útil para entrenamiento y evaluación
Rango temporal	Verificar coherencia 2008–2022 y detectar fechas anómalas
Distribución por año	Identificar cambios de registro o sesgos temporales
Distribución por provincia	Evitar que la evaluación quede dominada por una provincia
Distribución por TipoIncidente	Conocer la heterogeneidad operativa del conjunto de datos
Nulos por columna	Separar campos explotables de campos incompletos
Duplicados o registros equivalentes	Evitar fugas entre entrenamiento y prueba por incidentes repetidos
Cobertura de coordenadas	Medir disponibilidad de localización para variables contextuales
Campos ex post	Identificar columnas prohibidas para evitar <i>leakage</i>

Tabla 7.2: Elementos obligatorios de la auditoría del conjunto de datos.

7.4. Limpieza y normalización

La limpieza transforma el fichero bruto en una representación apta para el análisis. Las operaciones aplicadas son: lectura robusta del histórico; eliminación de columnas vacías o irrelevantes; normalización de nombres; limpieza de HTML; unión de título y descripción en un texto operativo; normalización para extracción de patrones; parseo de fechas; separación de coordenadas; derivación de provincia; mapeo de **TipoIncidente** a categoría preliminar; e identificación de columnas prohibidas.

El resultado conserva trazabilidad con el identificador original. Cada transformación relevante queda documentada para que el entrenamiento y la evaluación puedan reproducirse sin depender de decisiones manuales ocultas.

7.5. Variables V01–V15

El sistema no utiliza directamente todas las columnas del conjunto de datos. La Capa 1 transforma la entrada en **IncidentFeatures**, una representación estructurada que contiene variables V01–V15 y señales textuales. La Tabla 7.3 resume el origen esperado de cada

variable.

Var.	Variable	Origen principal	Estado en el estudio
V01	Riesgo vital	Texto + señales + etiquetado	Activa
V02	Número de víctimas estimado	Texto + etiquetado	Activa
V03	Gravedad de lesiones	Texto + etiquetado	Activa
V04	Tipo de incidente normalizado	Título, descripción y categoría preliminar	Activa
V05	Población vulnerable	Texto + reglas + revisión	Activa
V06	Número de llamadas	Texto, agrupación o indicios de varios avisos	Activa
V07	Emplazamiento crítico	Texto/localidad + reglas	Activa
V08	Aviso AEMET	Fuente externa	Diferida
V09	Condición meteorológica adversa	Texto/fuente externa	Diferida
V10	Zona inundable	Cruce geoespacial	Diferida
V11	Proximidad Seveso	Registro externo	Diferida
V12	Riesgo de propagación	Texto + INFOCAL	Activa
V13	Multirriesgo	Texto + concurrencia de señales	Activa
V14	Avisos simultáneos en zona	Texto/agrupación temporal-geográfica	Activa
V15	Accesibilidad de recursos	Localización + reglas aproximadas	Activa

Tabla 7.3: Variables V01–V15 y estado dentro del alcance evaluado.

Las variables V08–V11 se mantienen como parte del diseño conceptual para preservar la evolución futura del sistema, pero no se emplean como entrada del modelo evaluado ni condicionan sus resultados.

7.6. Señales operativas textuales

Las señales textuales son indicadores derivados del título y la descripción. No son etiquetas oficiales, pero ayudan a alimentar tanto la Capa 1 como los anotadores débiles de Capa 2. Las principales señales cubren fallecimiento, herido grave, atrapamiento, intoxicación, varias llamadas, incendio, accidente de tráfico, rescate, riesgo meteorológico por inundación y riesgo vital textual.

Estas señales deben tratarse como indicios. La palabra “herido”, por ejemplo, no equivale siempre a P1; la expresión “herido grave atrapado” sí tiene un peso operativo mucho mayor. Por eso la extracción textual debe combinar patrones, intensificadores y validación posterior, evitando que una búsqueda literal determine por sí sola la prioridad.

7.7. Etiqueta académica P1–P4

La etiqueta P1–P4 es una construcción académica del TFM. No existe como campo oficial en el Registro 112 CyL y no debe presentarse como prioridad institucional. Su función es permitir entrenamiento, comparación y evaluación del sistema.

La guía de etiquetado define cuatro niveles: P1 crítica, P2 alta, P3 media y P4 baja. La etiqueta se asigna en el momento teórico de la primera decisión. Por tanto, no puede utilizar información posterior como medios movilizados, pacientes atendidos o cierre del incidente. La incertidumbre se refleja en la confianza, no rebajando automáticamente la prioridad.

7.8. Supervisión débil

La supervisión débil permite construir etiquetas de entrenamiento a partir de funciones programáticas imperfectas. En este trabajo se emplean cuatro funciones de etiquetado heurísticas y correlacionadas, todas derivadas de una misma puntuación de gravedad:

1. **Puntuación con categoría:** combina señales textuales, categoría preliminar y variables permitidas.
2. **Puntuación sin categoría:** aplica la misma lógica de gravedad sin utilizar la categoría preliminar.
3. **Réplica heurística con categoría:** reproduce la puntuación con categoría como voto programático adicional.
4. **Puntuación heurística ampliada:** añade patrones de vulnerabilidad, emplazamiento y negación a la puntuación sin categoría.

Los nombres internos conservados en la implementación responden a etapas previstas del diseño, pero no deben interpretarse como cuatro modelos independientes: la ejecución evaluada no utiliza un modelo NER, un algoritmo de agrupamiento semántico ni un LLM anotador. Los votos se agregan mediante votación ponderada con pesos 0,85, 1,00, 0,90 y 1,10, respectivamente. Se suman los pesos recibidos por cada prioridad y, si existe empate, se escoge la prioridad más urgente. La salida conserva los votos, la etiqueta final, la confianza derivada del peso ganador y el acuerdo local.

7.8.1. Acuerdo y control de calidad

El objetivo mínimo es Krippendorff $\alpha \geq 0,67$. La ejecución canónica alcanza $\alpha = 0,899902$, por encima del umbral establecido. Este valor aporta evidencia de consistencia entre funciones, pero debe interpretarse con cautela: las fuentes comparten patrones y dos de ellas emplean una puntuación muy similar, por lo que no constituyen anotadores plenamente independientes.

Además, los tres autores han revisado conjuntamente una muestra interna superior al mínimo previsto. La revisión fue cualitativa y no generó tres anotaciones independientes ni una medida de acuerdo interrevisor; por ello, debe entenderse como auditoría interna y no como validación externa completada.

7.8.2. Ablación anti-circularidad

La supervisión débil introduce el riesgo de que el modelo reproduzca los patrones empleados para construir la propia etiqueta. La ablación sin la fuente de reglas heurísticas mantiene $\alpha = 0,834155$, lo que demuestra que el acuerdo no desaparece al retirar esa fuente. Sin embargo, no garantiza independencia entre la etiqueta y las variables predictivas, porque las funciones restantes comparten señales y criterios con las entradas de Capa 2. Esta dependencia constituye una limitación metodológica del estudio.

7.9. Prevención de leakage

El *leakage* es uno de los riesgos metodológicos más graves del proyecto. Se produce cuando el modelo utiliza información que no estaría disponible en el momento de la primera decisión. En el Registro 112 CyL existen campos que pueden reflejar actuaciones posteriores o resultados finales. La Tabla 7.4 resume las columnas prohibidas.

El sistema excluye de forma explícita variables que no estarían disponibles en el momento de la primera decisión, como recursos movilizadas, pacientes atendidos, estado de cierre o información posterior al desarrollo del incidente. Esta decisión evita *leakage* y mantiene la evaluación alineada con el objetivo de apoyo a la primera decisión.

Estas columnas pueden conservarse para auditoría o evaluación ex post, siempre separadas del entrenamiento y de la inferencia. El control aplicado impide que Capa 1 o Capa 2 dependan de información posterior a la primera decisión.

Columna	Razón de exclusión como entrada
MediosMov	Refleja recursos movilizados, es decir, una consecuencia de la decisión operativa
medios_mov_limpio	Derivado de MediosMov; mantiene la misma fuga
medios_mov_uso_recomendado	Codificación auxiliar ex post; no disponible en primera decisión
PacientesAten	Resultado clínico o asistencia posterior
pacientes_aten_limpio	Derivado de PacientesAten; conserva información posterior
IncidenteCerrado	Estado final del incidente
ultimaActualizacion	Actualización posterior al registro inicial
Enlace al contenido	Identificador externo; útil para trazabilidad, no como predictor
Unnamed: 13	Columna vacía o no informativa

Tabla 7.4: Columnas prohibidas como entrada del motor por riesgo de *leakage*.

Grupo	Columnas o variables	Uso permitido
Texto inicial	Título, DescripcionBlob, texto operativo limpio	Entrada para Capa 1 y extracción de señales
Contexto predecional	Fecha, localidad, provincia, coordenadas, TipoIncidente	Normalización, taxonomía, análisis temporal y territorial
Variables derivadas permitidas	V01–V07, V12–V15 y señales textuales	Entrada de Capa 2 y explicabilidad
Identificadores	Identificador	Trazabilidad, particiones y auditoría; no como predictor
Columnas prohibidas	MediosMov, PacientesAten, IncidenteCerrado, ultimaActualizacion y derivados	Solo auditoría o análisis ex post; nunca entrenamiento ni inferencia

Tabla 7.5: Columnas permitidas y prohibidas según disponibilidad en la primera decisión.

7.10. Particiones de entrenamiento, validación y prueba

La división de datos debe impedir que el modelo vea durante el entrenamiento información demasiado parecida a la partición de prueba. Se plantean dos estrategias complementarias.

7.10.1. Partición estratificada

La partición principal divide el conjunto en 6.512 registros de entrenamiento, 1.415 de validación y 1.453 de prueba, preservando la distribución por prioridad, año y provincia con semilla fija. Para ajustar RuleFit-lite se toma de la partición de entrenamiento un submuestreo proporcional de 3.000 registros, reproducible con semilla 42, mientras que la validación y la prueba se evalúan completas. Esta decisión acota el coste en el entorno local y mantiene fija la configuración experimental, aunque limita el aprovechamiento de los 6.512 registros disponibles. La partición de prueba contiene P1=655, P2=349, P3=375 y P4=74, y es la referencia usada posteriormente en la evaluación final.

Partición	Filas	Distribución P1–P4
Entrenamiento es- tratificado	6.512	P1=3.049; P2=1.504; P3=1.701; P4=258
Validación estratifi- cada	1.415	P1=658; P2=329; P3=374; P4=54
Prueba estratificada	1.453	P1=655; P2=349; P3=375; P4=74
Prueba temporal 2022	735	Evaluación de estabilidad fuera del período principal

Tabla 7.6: Distribución de las particiones adoptadas en el estudio.

7.10.2. Partición temporal

La partición temporal evalúa robustez fuera del período de entrenamiento. La versión ejecutada entrena con registros hasta 2020, valida con 2021 y reserva 2022 como prueba temporal. Los tamaños son 7.935, 710 y 735 registros, respectivamente.

Ambas particiones son necesarias. La estratificada mide rendimiento general controlando la distribución; la temporal mide estabilidad ante cambio de período.

7.11. Uso en entrenamiento y evaluación

El conjunto de datos resultante alimenta tres usos distintos: pruebas de extracción de Capa 1, entrenamiento y evaluación de Capa 2, y evaluación transversal de sesgo, falsos negativos P1, calibración y matriz de confusión. La Capa 3 no se entrena con el conjunto operativo; utiliza las salidas de Capa 2 y el corpus normativo para generar explicaciones.

7.12. Limitaciones del conjunto de datos

Las limitaciones deben quedar explícitadas para evitar sobreprometer. La primera es la ausencia de prioridad oficial. Los resultados obtenidos deben interpretarse en el marco de etiquetas débiles: la etiqueta P1-P4 no procede del servicio 112 ni de una prioridad oficial, sino de una construcción académica trazable y reproducible. Cualquier cambio en la guía de etiquetado, en las particiones o en el conjunto de datos limpio obliga a repetir la evaluación.

La segunda limitación es que las cuatro funciones de etiquetado comparten la misma puntuación heurística y, por tanto, su acuerdo no equivale al de anotadores independientes. La tercera es el submuestreo de 3.000 casos usado para ajustar RuleFit-lite sobre una partición de entrenamiento de 6.512 registros. La cuarta es la granularidad limitada: el conjunto contiene registros administrativos, no la secuencia completa de llamadas minuto a minuto. La quinta es que muchas variables deben inferirse del texto. La sexta es que AEMET, inundabilidad y Seveso quedan fuera del núcleo evaluado. La séptima es que la validación externa con personal operativo del 112 queda como trabajo futuro. La octava es el posible sesgo territorial, temporal o por categoría.

7.13. Conclusiones

El diseño de datos presentado en este capítulo conecta el Registro 112 CyL con la arquitectura de tres capas del sistema. La estrategia evita dos extremos: no inventa un conjunto totalmente sintético, pero tampoco finge disponer de una prioridad oficial que no existe.

La aportación metodológica consiste en convertir datos abiertos reales en un conjunto explotable mediante limpieza, variables operativas, supervisión débil, control de *leakage* y particiones reproducibles. Esta base es la que permite que Capa 2 pueda entrenarse y

evaluarse de forma defendible.

El siguiente capítulo documenta la implementación del prototipo software que ejecuta este flujo: orquestación del sistema, recuperación normativa, trazabilidad, respuesta alternativa determinista e interfaz mínima.

8. Prototipo integrado

Este capítulo presenta de manera detallada el desarrollo e implementación del prototipo software concebido para validar la arquitectura de tres capas. A través de los componentes descritos, se muestra la traducción práctica de los modelos predictivos y las interfaces de datos en una aplicación funcional. De este modo, se demuestra la viabilidad técnica del sistema inteligente en un entorno local y reproducible.

8.1. Introducción

Este capítulo describe cómo se materializa en software la arquitectura definida en el Capítulo 6. El objetivo no es repetir el diseño conceptual, sino mostrar que el prototipo ejecuta una cadena completa: recibe o carga incidentes, estructura variables, aplica la Capa 2 de priorización, genera una explicación mediante la Capa 3 y registra trazabilidad para revisión posterior. Para ello, se examina el flujo de control desde que entra un suceso hasta que el operador valida la recomendación. Con esta descripción se busca cerrar la brecha entre los planteamientos conceptuales previos y la realidad del código fuente implementado.

El prototipo tiene alcance académico. No sustituye al sistema institucional del 112, no moviliza recursos, no activa planes y no toma decisiones autónomas. Su valor reside en demostrar que la propuesta puede ejecutarse de forma reproducible sobre datos reales abiertos y que sus salidas pueden auditarse.

8.2. Arquitectura software

El sistema se organiza en cinco bloques principales:

1. **Pipeline de datos y Capa 1.** Limpia el Registro 112 Castilla y León, normaliza campos, construye variables y, en ejecución, extrae señales textuales predecisionales desde el texto operativo del incidente.
2. **Capa 2 RuleFit.** Implementa supervisión débil, línea base experta, RuleFit-lite, comparativa con `imodels`, evaluación e inferencia.
3. **Capa 3 explicativa.** Genera explicaciones a partir de la salida de la Capa 2, evidencias disponibles y corpus normativo recuperado mediante RAG/MCP. En la versión integrada se ejecuta localmente mediante Ollama.

4. **Backend e interfaz de contratos.** Expone la inferencia y validación del flujo de IA mediante esquemas de validación FastAPI (FastAPI, 2026) y una interfaz Streamlit (Streamlit, 2026) de control del operador.
5. **Trazabilidad y validación.** Registra salidas, métricas, muestra de revisión humana y artefactos de evaluación.

La separación entre capas evita que el LLM decida la prioridad. La prioridad procede de la Capa 2; la Capa 3 traduce esa salida en una explicación revisable. Al desacoplar la lógica de predicción del procesamiento de lenguaje natural, se minimiza el impacto de posibles alucinaciones. Esta decisión arquitectónica refuerza la robustez del sistema frente a comportamientos no deterministas de la inteligencia artificial generativa.

8.3. Componentes de Capa 2

La parte de priorización se estructura en el módulo del motor de reglas y estimadores interpretables. Su lógica contiene la generación de etiquetas académicas P1–P4, la implementación de las reglas expertas que sirven como referencia y el cálculo comparativo con alternativas.

Esta estructura mantiene separado el modelo RuleFit-lite de la preparación de datos y de la lógica de explicación. También facilita comparar alternativas sin alterar el contrato de salida que recibe la Capa 3 y permite revisar cada componente de forma independiente.

En el prototipo integrado, el modelo seleccionado se empaqueta como un artefacto persistente y se carga durante la inferencia. Esta decisión permite separar el entrenamiento de la ejecución del demostrador y evita reentrenamientos accidentales. Además, el módulo incorpora comprobaciones de compatibilidad para asegurar la carga correcta de los parámetros del modelo, protegiendo la reproducibilidad del prototipo ante diferencias menores en el entorno de ejecución.

8.4. Flujo de procesamiento

El flujo funcional del prototipo es el siguiente:

1. Se carga un incidente desde el dataset limpio o desde una entrada controlada.
2. Se extraen variables operativas y señales textuales permitidas.

3. Se verifica que no se usen columnas posteriores a la decisión (leakage).
4. La Capa 2 calcula la prioridad P1–P4, probabilidades y reglas o señales activadas.
5. La Capa 3 genera una explicación breve, apoyada en evidencias y corpus normativo cuando procede.
6. El sistema registra la inferencia para auditoría y revisión humana.

El resultado no es una orden operativa, sino una recomendación estructurada. El operador mantiene la capacidad de aceptar, modificar o rechazar la salida. Esta decisión de diseño preserva el principio de control humano en el lazo de decisión. La posible reducción del tiempo de respuesta o de la carga cognitiva deberá medirse en una validación posterior con personal operativo; no se considera demostrada por las pruebas actuales.

8.5. Prototipo ejecutable

El prototipo dispone de una ejecución integrada del flujo completo: texto del incidente, Capa 1 simbólica, Capa 2 RuleFit-lite, Capa 3 con LLM local y registro de la respuesta. El servicio de inferencia expone contratos de datos para comprobar la entrada y la salida, mientras que la interfaz permite introducir incidentes sintéticos por texto o por voz y visualizar la recomendación de Capa 2 junto con la explicación de Capa 3. El Anexo G conserva solo las capturas indispensables: entrada manual, entrada de voz experimental, resultado P1 y registro de la decisión humana.

Para realizar una evaluación exploratoria con participantes, el equipo habilitó y utilizó un acceso de prueba mediante un cuaderno en Google Colab. Este acceso no se plantea como despliegue productivo ni como integración con sistemas 112, sino como entorno reproducible de demostración: permite lanzar el prototipo, ejecutar casos sintéticos y recoger respuestas mediante un cuestionario estructurado. La finalidad es obtener valoración preliminar de utilidad, comprensibilidad, confianza, trazabilidad y claridad de la supervisión humana sin exponer datos reales ni depender de una sala de operaciones.

La integración generativa se realiza mediante Ollama con un modelo Llama 3.1 de 8.000 millones de parámetros, cuantizado para ejecución local. El LLM no decide la prioridad: recibe la recomendación ya calculada por RuleFit-lite y la convierte en una explicación estructurada. Si Ollama no responde, el prototipo conserva el modo degradado determinista descrito en la sección siguiente.

Como comprobación técnica, se ha ejecutado una prueba funcional P1–P4 contra el servicio web activo. Los resultados se conservan en los reportes reproducibles de evaluación integrada del repositorio. La prueba verifica cuatro incidentes representativos, uno por prioridad, con Capa 2 RuleFit activa y Capa 3 no degradada.

Adicionalmente, tras integrar la Capa 1, se ha regenerado una prueba técnica reproducible Capa 1–Capa 2–Capa 3. Los informes resultantes se conservan como evidencias de evaluación en el repositorio. Su finalidad es comprobar que la salida real de Capa 1 alimenta correctamente el motor RuleFit, incluyendo casos P1 con atrapamiento, inconsciencia, incendio, intoxicación, inundación y una incidencia vial ordinaria con negaciones explícitas como “no hay heridos ni vehículos atrapados”.

8.5.1. Interfaz de voz e inferencia inteligente

Como demostración controlada, la interfaz incorpora un módulo experimental de entrada por voz. El usuario puede grabar audio desde el micrófono o cargar un archivo de audio de prueba; el reconocimiento automático del habla (ASR) se ejecuta localmente mediante `faster-whisper` (SYSTRAN, 2026). La transcripción resultante alimenta un parser estructurado que intenta extraer automáticamente título, descripción, categoría, localidad y provincia. Cuando Ollama está disponible, el parser emplea el modelo local `llama3.1:8b-instruct-q4_K_M` con temperatura 0.0; si el modelo no responde, el sistema utiliza heurísticas locales basadas en palabras clave y patrones de localidad o provincia.

El resultado de esta etapa no se envía directamente como decisión, sino que inicializa reactivamente el estado de sesión de Streamlit mediante el patrón *key-only*. El operador conserva la posibilidad de revisar y corregir los campos antes de lanzar la predicción. Esta funcionalidad pertenece al bloque de interfaz e integración del prototipo y refuerza la orientación práctica del demostrador. No se ha evaluado con llamadas reales, ruido de sala ni un corpus representativo de locutores, por lo que no se presenta como un sistema de transcripción validado.

Tabla 8.1: Prueba funcional integrada del prototipo

Caso	Esperada	Obtenida	Prob. dominante	LLM
Incendio con atrapados	P1	P1	97.35 %	Ollama
Fuga de gas sin heridos	P2	P2	92.21 %	Ollama
Árbol en calzada	P3	P3	93.71 %	Ollama
Consulta vecinal sin riesgo	P4	P4	98.54 %	Ollama

La prueba supera los cuatro casos esperados y observa una latencia media de 4,898 s por inferencia integrada, condicionada por el uso local del LLM. Esta cifra no se interpreta como rendimiento operativo final, sino como primera evidencia de integración funcional del prototipo completo. En el contexto de investigación académica y ejecución sobre hardware doméstico con recursos compartidos, la medida sirve para caracterizar el flujo completo, pero supera el objetivo interno de diseño. Una evolución posterior debería estudiar hardware dedicado, una configuración específica del servidor LLM o el uso de la respuesta alternativa determinista.

La prueba reproducible Capa 1–Capa 2–Capa 3 alcanza 5/5 casos correctos, con modelo RULEFIT disponible, precisión micro de señales 0.733333, recall micro 1.000000 y F1 micro 0.846154 para Capa 1. Las latencias medias observadas son 4.58844 ms en Capa 1, 52.16898 ms en Capa 2 y 0.30748 ms en la explicación degradada de Capa 3. Esta comprobación no sustituye a la prueba con el LLM local, pero deja evidencia automática de que, tras la integración con Ancor, el sistema completo mantiene la coherencia del flujo de datos.

8.6. Contratos y trazabilidad

El prototipo utiliza contratos versionados para separar responsabilidades entre capas. La salida de Capa 2 debe incluir, como mínimo, identificador del incidente, prioridad recomendada, probabilidades por clase, reglas o señales relevantes, versión del modelo y advertencias asociadas. La Capa 3 consume esa información y debe conservar la correspondencia entre explicación y evidencia.

La trazabilidad se apoya en evidencias reproducibles: conjunto de datos auditado, etiquetas débiles, particiones, modelos entrenados, métricas, errores P1, muestra revisada internamente y síntesis final de evaluación. Este diseño permite reconstruir qué datos se usaron, qué modelo produjo la recomendación y qué explicación se generó.

8.7. Modo degradado

El prototipo contempla un modo degradado para la explicación. Si el LLM local no está disponible o no cumple el tiempo esperado, el sistema puede generar una explicación determinista basada en reglas, probabilidades y evidencias de la Capa 2. Este modo evita que la ausencia del componente generativo bloquee la recomendación o fuerce dependencia de servicios externos.

La respuesta alternativa determinista también ha permitido evaluar fidelidad explicativa de forma controlada sobre la muestra de 119 casos revisada conjuntamente por los autores, como se documenta en el Capítulo 9. En las pruebas reproducibles Capa 1–Capa 2–Capa 3, este modo ofrece respuestas submilisegundo y actúa como mecanismo de contingencia cuando el LLM local no está disponible o no cumple el tiempo esperado.

8.8. Relación con la evaluación

El prototipo no se evalúa por apariencia visual, sino por su capacidad para producir evidencias verificables. La evaluación experimental utiliza los mismos procedimientos, variables de entrada, particiones y modelos declarados por la arquitectura. Por eso los resultados del Capítulo 9 pueden enlazarse con el diseño del Capítulo 6, los datos del Capítulo 7 y los anexos de evaluación.

Un índice maestro estructurado actúa como registro de trazabilidad de esta relación entre prototipo, resultados y documentación. En este archivo de control se indexan las huellas de los conjuntos de datos de prueba, los pesos del modelo y las métricas calculadas. Esta estructura facilita la comprobación reproducible de los resultados declarados en la memoria.

8.9. Repositorio del código fuente

El código fuente completo, los scripts de datos, entrenamiento y evaluación, los contratos Pydantic y los artefactos versionados están disponibles en el repositorio público del proyecto junto a un notebook que permite la ejecución del prototipo en Google Colab. La URL de ambos son las siguientes:

https://github.com/jalbfil/tfe_muia_unir_188

[https://colab.research.google.com/drive/
1XKVhjJCWDXH9bjI0Qsj4JCFUa5cwp7_J?usp=sharing](https://colab.research.google.com/drive/1XKVhjJCWDXH9bjI0Qsj4JCFUa5cwp7_J?usp=sharing)

8.10. Conclusiones del capítulo

El prototipo software desarrollado materializa la propuesta del TFM en una cadena ejecutable y auditable. Su diseño mantiene separadas la extracción, la priorización, la

explicación y la validación humana, evitando cualquier tipo de fuga de información o leakage. Gracias a este enfoque, resulta factible comparar diversos modelos interpretables y dejar evidencias suficientes para defender los resultados de forma reproducible.

Con este prototipo, la evaluación del Capítulo 9 no se apoya solo en una descripción teórica, sino en una implementación concreta de la arquitectura. Las métricas expuestas proceden de su ejecución sobre la partición de prueba. Los procedimientos y evidencias conservados permiten reproducir esos resultados en el entorno documentado, sin atribuirles validez operativa externa.

9. Evaluación experimental

Los capítulos anteriores han definido el problema, el marco normativo, la arquitectura del sistema, el conjunto de datos y el procedimiento de construcción de etiquetas académicas P1–P4. Este capítulo cierra el ciclo experimental evaluando la Capa 2 de priorización interpretable sobre un flujo reproducible: conjunto limpio, etiquetas débiles, particiones, línea base heurística, modelos RuleFit y controles contra fugas de información.

La evaluación no pretende demostrar validez operativa en producción. El Registro 112 CyL no contiene una prioridad oficial histórica comparable con la recomendación del sistema. Por tanto, la evaluación mide el comportamiento frente a la etiqueta académica P1–P4 generada por supervisión débil y documenta sus limitaciones. Esta distinción es central para no sobredimensionar los resultados.

9.1. Objetivos de evaluación

La evaluación experimental persigue cinco objetivos:

1. Verificar que la Capa 2 aprende a reproducir la etiqueta académica P1–P4 con mejor rendimiento que una línea base heurística;
2. Comprobar que la sensibilidad de P1 se mantiene por encima del criterio fijado en 0.85;
3. Preservar la interpretabilidad mediante un límite de 30 reglas activas exportadas;
4. Contrastar RuleFit-lite con una implementación externa de la misma familia en una prueba diagnóstica;
5. Verificar que no se utilizan columnas posteriores a la decisión.

Las métricas principales son exactitud, macro-F1, precisión, sensibilidad y F1 por clase, sensibilidad P1, número de reglas activas, tiempo de entrenamiento e inferencia media por fila. La macro-F1 se emplea como métrica de selección porque evita que el rendimiento quede dominado por las clases más frecuentes. La sensibilidad P1 se prioriza por el coste potencial de los falsos negativos en la clase crítica.

9.2. Niveles de evaluación

La evaluación se estructura en tres niveles complementarios. Primero, una evaluación de Capa 2 sobre las particiones definidas, donde se comparan la línea base heurística, RuleFit-lite y una implementación diagnóstica. Segundo, una prueba técnica integrada reproducible de escenarios Capa 1–Capa 2–Capa 3, orientada a comprobar que la cadena completa conserva coherencia funcional. Tercero, una prueba funcional integrada del prototipo con LLM local, cuyo objetivo no es medir rendimiento estadístico, sino comprobar la ejecución extremo a extremo en casos P1–P4.




Figura 9.1: Secuencia metodológica del flujo de evaluación experimental.

9.3. Datos, etiquetas y particiones

El experimento usa el conjunto limpio, formado por 9.380 registros del Registro 112 Castilla y León. La etiqueta objetivo P1–P4 se obtiene mediante supervisión débil con cuatro funciones heurísticas correlacionadas que comparten una puntuación programática

de gravedad. No se trata de anotadores independientes ni de modelos NER, agrupamiento semántico o LLM ejecutados durante el etiquetado. La ejecución principal alcanza Krippendorff $\alpha = 0,899902$, superior al umbral de 0,67. La ablación sin reglas heurísticas mantiene $\alpha = 0,834155$. Este resultado demuestra que el acuerdo no desaparece al retirar una fuente, pero no garantiza independencia entre las etiquetas y las variables predictivas.

Las particiones se generan de forma estratificada por año, provincia inferida y etiqueta P1–P4, con semilla fija 42. La Tabla 9.1 resume los tamaños y la distribución de etiquetas.

Tabla 9.1: Distribución de etiquetas por partición

Partición	Registros	P1	P2	P3	P4
Entrenamiento	6.512	3.049	1.504	1.701	258
Validación	1.415	658	329	374	54
Prueba	1.453	655	349	375	74

Adicionalmente se ha generado una partición temporal alternativa: entrenamiento hasta 2020, validación en 2021 y prueba en 2022. Esta partición se utiliza como prueba de robustez temporal, mientras que el experimento principal usa la partición estratificada por su mayor equilibrio entre años, provincias y etiquetas.

9.4. Política anti-leakage

La evaluación excluye todas las columnas conocidas después de la decisión operativa o derivadas de procesos post-hoc. En particular, no se usan campos relativos a medios movilizados, pacientes atendidos, cierre del incidente, actualizaciones posteriores, enlaces externos ni columnas auxiliares sin significado operativo.

Las variables permitidas se limitan a señales textuales previas a la decisión y a variables categóricas derivadas de la categoría preliminar. La relación completa se documenta en el Capítulo 7. Además, el control reproducible de fugas verifica que el motor de priorización no dependa de columnas prohibidas.

9.5. Modelos evaluados

Se comparan tres aproximaciones:

Línea base heurística. Conjunto de 19 reglas manuales con anclaje normativo, descritas en el Anexo E. Su función es actuar como línea base interpretable a batir.

RuleFit-lite. Modelo seleccionado para Capa 2. Combina reglas de árboles poco profundos con una capa logística dispersa. Se ajusta con un submuestreo estratificado de 3.000 casos de los 6.512 disponibles y exporta 30 reglas activas.

RuleFit externo. Implementación canónica de la familia RuleFit. Como la configuración utilizada trabaja en clasificación binaria, se emplea un esquema one-vs-rest P1–P4. Se ajusta con 50 casos y su papel es exclusivamente diagnóstico; no constituye una comparación equilibrada con RuleFit-lite.

9.6. Selección del modelo

La selección se realiza sobre la partición de validación de la configuración experimental disponible. La Tabla 9.2 muestra que RuleFit-lite obtiene la mejor macro-F1 y mantiene la sensibilidad P1 por encima del umbral de 0,85. No obstante, los resultados de `imodels` deben leerse solo como referencia diagnóstica, dado que su muestra de ajuste es mucho menor.

Tabla 9.2: Comparativa de modelos de Capa 2 en validación

Modelo	Exactitud	Macro-F1	Sensibilidad P1
Línea base heurística	0,717314	0,498785	0,995441
RuleFit-lite	0,881188	0,879592	0,934400
RuleFit externo	0,789250	0,584768	0,910400

La línea base obtiene una sensibilidad P1 muy elevada por su diseño conservador, pero discrimina peor entre las cuatro clases. RuleFit-lite mejora la macro-F1 de validación y ofrece 30 reglas exportables. La alternativa externa presenta menor rendimiento en la ejecución reducida disponible, pero la diferencia de tamaños de ajuste impide inferir superioridad computacional o estadística de RuleFit-lite en condiciones equivalentes.

Por ello, RuleFit-lite se selecciona antes de consultar la evaluación final. La partición de prueba canónica, regenerada posteriormente y formada por 1.453 casos, se utiliza una sola vez para estimar el rendimiento del modelo elegido: exactitud 0,903648, macro-F1 0,905604 y sensibilidad P1 0,909924.

Estas métricas corresponden al estimador RuleFit-lite evaluado sin el posprocesamiento de la Puerta de Seguridad. La salvaguarda se aplica durante la inferencia integrada y se analiza mediante escenarios funcionales, pero no se mezcla con la comparación estadística

entre modelos.

9.7. Métricas por clase del modelo seleccionado

La Tabla 9.3 resume las métricas por clase de RuleFit-lite en la partición de prueba.

Tabla 9.3: Métricas por clase de RuleFit-lite en la partición de prueba

Clase	Precisión	Sensibilidad	F1	Soporte
P1	0.941548	0.909924	0.925466	655
P2	0.822888	0.865330	0.843575	349
P3	0.924119	0.909333	0.916667	375
P4	0.880952	1.000000	0.936709	74

El comportamiento por clase muestra un equilibrio razonable. P1 mantiene sensibilidad y precisión elevadas, un aspecto relevante por el coste potencial de infrapriorizar esta clase. P2 es la clase más difícil, con F1 inferior al resto, un resultado esperable al tratarse de una zona frontera entre gravedad crítica y seguimiento ordinario. P4 obtiene sensibilidad total en la partición de prueba, aunque con menor precisión por su baja frecuencia relativa.

9.8. Matriz de confusión del modelo seleccionado

La Tabla 9.4 muestra la matriz de confusión de RuleFit-lite en la partición de prueba.

Tabla 9.4: Matriz de confusión de RuleFit-lite en la partición de prueba

Referencia / Predicción	P1	P2	P3	P4
P1	596	34	18	7
P2	37	302	10	0
P3	0	31	341	3
P4	0	0	0	74

Los 7 casos P1 clasificados como P4 constituyen el principal riesgo detectado en la evaluación. Aunque el rendimiento global del modelo es alto, estos errores representan infrapriorizaciones críticas y deben tratarse como prioridad de revisión humana, análisis de causas y mejora futura del sistema. El resto de falsos negativos P1 se distribuye en 34 casos P1–P2 y 18 casos P1–P3. La representación gráfica de esta matriz se conserva como evidencia reproducible de evaluación.

9.9. Robustez temporal y sesgo interno

Para comprobar que el rendimiento no depende exclusivamente de la partición estratificada, se evalúa el mismo modelo sobre la partición temporal de 2022. En este escenario se obtienen 735 registros, exactitud 0.884354, macro-F1 0.877594 y sensibilidad P1 0.928767. La estabilidad entre ambos cortes no muestra una degradación temporal relevante en los datos evaluados, aunque no sustituye a una validación prospectiva con datos nuevos.

El análisis por subgrupos se realiza por provincia, año y categoría operativa. En el reporte canónico, las provincias con menor macro-F1 son Segovia 0,887379, León 0,893354 y Salamanca 0,894117. Por categoría, el grupo sanitario presenta macro-F1 0,792966 y sensibilidad P1 0,404255; incendio obtiene 0,861823 y 0,731707; y tráfico, 0,935353 y 0,964727, respectivamente. Estos resultados no demuestran sesgo estructural, pero identifican los casos sanitarios y de incendio como focos prioritarios de revisión. Las gráficas de apoyo se conservan como evidencia complementaria, pero la interpretación principal se recoge en este capítulo.

9.10. Interpretabilidad

RuleFit-lite exporta 30 reglas activas, cumpliendo el requisito de parsimonia. Las reglas combinan señales legibles, por ejemplo riesgo vital textual, accidente de tráfico, rescate, incendio o ausencia de señales críticas. Esta salida facilita su uso por la Capa 3, que puede transformar las reglas activadas en una explicación operativa.

La línea base heurística queda documentada en el Anexo E; la ficha de modelo de Capa 2 y la comparativa completa se recogen en el Anexo L. La evidencia reproducible de cierre enlaza métricas finales, partición temporal, tablas de análisis por subgrupos, falsos negativos P1, muestra de revisión y fidelidad explicativa.

9.11. Revisión interna y trazabilidad

La evaluación automática se complementa con una revisión interna conjunta realizada por los tres autores. Su objetivo es examinar cada recomendación con evidencias suficientes, centrando la atención en los errores críticos y en la trazabilidad de la decisión. Esta revisión cualitativa no equivale a tres anotaciones independientes ni permite calcular acuerdo interrevisor.

Cada ficha preparada muestra el texto operativo minimizado, provincia, fecha, categoría preliminar, etiqueta académica, acuerdo de supervisión débil, recomendación P1–P4, confianza, probabilidades por clase, reglas activadas, variables permitidas, columnas excluidas por anti-*leakage* y, cuando la Capa 3 está disponible, la explicación normativa asociada. Esta ficha permite que el revisor acepte la recomendación, la modifique o la rechace.

La plantilla permite registrar una futura decisión humana independiente asociada a la inferencia, incluyendo identificador del caso, prioridad recomendada, prioridad final asignada, motivo de divergencia, revisor, marca temporal y huella de entrada. En la revisión conjunta de los autores se utilizaron las fichas como instrumento cualitativo, sin emplear esos campos para construir una nueva referencia supervisada. Las divergencias de dos o más niveles se consideran casos de auditoría especial.

La muestra revisada incluye todos los falsos negativos P1 de la partición de prueba estratificada, junto con casos frontera P1/P2, P1/P3, P1/P4 y P2/P3. En la ejecución final se detectan 59 falsos negativos P1: 34 P1–P2, 18 P1–P3 y 7 P1–P4. La muestra contiene 119 casos: los 59 falsos negativos P1 y 60 casos equilibrados, 15 por cada clase P1–P4. La revisión conjunta aporta una auditoría interna centrada en los errores críticos, pero no constituye validación externa con operadores del 112 ni una evaluación independiente entre revisores.

9.12. Fidelidad de explicaciones

Sobre la misma muestra de 119 casos se ejecuta una evaluación automatizada y local de fidelidad. El objetivo es comprobar que la Capa 3 explica lo que realmente entrega la Capa 2: prioridad recomendada, reglas o señales activadas, probabilidades y necesidad de cautela. La evaluación se realiza mediante un juez determinista local y se conserva como evidencia reproducible de fidelidad.

La versión ejecutada utiliza un juez determinista reproducible, no un LLM-as-Judge externo. La Capa 3 se evalúa como sistema de fidelidad explicativa: la explicación generada debe ser coherente con la prioridad y reglas producidas por Capa 2. No se evalúa Capa 3 como modelo alternativo de decisión. La rúbrica verifica seis criterios: alineación con la prioridad recomendada, trazabilidad de reglas, cobertura de señales, citas legales en P1/P2, ausencia de contradicciones y presencia de disclaimer de confianza o respuesta

alternativa determinista. Sobre los 119 casos se obtiene una tasa de cumplimiento de 1,000000, fidelidad media 0,957367 y mínima 0,933333. En los 59 falsos negativos P1, la fidelidad media es 0,952494.

Estos resultados no prueban calidad lingüística ni aceptación por operadores, pero sí aportan evidencia de que, en la muestra evaluada y con respuesta alternativa determinista, las explicaciones no contradicen la salida de Capa 2 y conservan la trazabilidad definida. Una evaluación futura con LLM-as-Judge independiente, en la línea propuesta por Zheng y cols. (2023), puede reutilizar los mismos 119 casos.

9.13. Posicionamiento frente a trabajos relacionados

La Tabla 9.5 contrasta el enfoque propuesto con los trabajos relacionados del estado del arte, siguiendo la recomendación de presentar resultados propios frente a otros autores.

Tabla 9.5: Comparativa del enfoque propuesto frente a trabajos relacionados

Enfoque	Datos reales	Interp.	Expl. norm.	On-prem.	Superv.	Métrica clave
AIDR (Imran y cols., 2014)	Redes sociales	No (DNN)	No	No	Fuerte	Acc. multi-label
CrisisTransf. (Lamsal y cols., 2024)	Crisis real	No (transformer)	No	Parcial	Fuerte	F1 clasificación
TREC-IS (McCreadie y cols., 2021)	Twitter	No (ensemble)	No	No	Fuerte	Benchmarks
Línea base heurística (este TFM)	112 CyL	Sí (reglas)	Parcial	Sí	Débil	F1 0,464; sensibilidad P1 0,998
RuleFit-lite + Capa 3	112 CyL	Sí	Sí	Sí	Débil	F1 0,906; P1 0,910

Fuente: elaboración propia a partir de los trabajos citados.

Las ventajas diferenciales del enfoque son: (1) datos empíricos reales del 112 CyL frente a redes sociales; (2) núcleo interpretable con reglas auditables; (3) explicación normativa local sin APIs externas; y (4) supervisión débil que evita la dependencia de etiquetado manual masivo. La limitación principal es la etiqueta académica P1–P4, no validada por personal operativo.

9.14. Pruebas integradas del prototipo

Además de la evaluación offline de Capa 2, se han ejecutado dos pruebas integradas del prototipo. La primera comprueba la cadena reproducible Capa 1–Capa 2–Capa 3 con respuesta alternativa determinista sobre escenarios curados. La segunda verifica la ejecución completa con LLM local. Ninguna sustituye a las métricas de la partición de prueba ni a la validación externa, pero ambas verifican que la cadena software real funciona de extremo a extremo: texto del incidente, extracción de señales en Capa 1, priorización RuleFit-lite en Capa 2, explicación en Capa 3 y respuesta consumible por la interfaz.

Tras integrar la Capa 1, el sistema supera 5/5 escenarios curados con RuleFit-lite activo: incendio urbano con atrapados, accidente de tráfico con inconsciente, fuga química con intoxicación, inundación sin víctimas e incidencia vial ordinaria. Este último caso incluye negaciones explícitas (“no hay heridos ni vehículos atrapados”) y confirma que Capa 1 no activa falsos positivos de atrapamiento tras el saneamiento realizado.

La ejecución confirma la disponibilidad del LLM local. Los cuatro casos representativos P1–P4 se clasifican conforme a la prioridad esperada, con RuleFit activo y sin recurrir al modo alternativo determinista de Capa 3. La latencia media observada es 4,90 s por inferencia integrada.

Tabla 9.6: Resultado de la prueba funcional integrada P1–P4 con LLM local

Caso	Esperada	Obtenida	Distribución principal
Incendio con atrapados	P1	P1	P1 97.35 %, P2 2.61 %
Fuga de gas sin heridos	P2	P2	P2 92.21 %, P3 5.03 %
Árbol en calzada	P3	P3	P3 93.71 %, P2 3.79 %
Consulta vecinal sin riesgo	P4	P4	P4 98.54 %, P3 1.40 %

Esta evidencia permite separar la evaluación cuantitativa de Capa 2, ya realizada sobre la partición de prueba estratificada y temporal, de la prueba técnica del prototipo completo, todavía limitada a escenarios curados y ejecución controlada.

La Tabla 9.7 resume la prueba reproducible posterior a la integración de Capa 1. En ella, las latencias medias son 4.58844 ms para Capa 1, 52.16898 ms para Capa 2 y 0.30748 ms para Capa 3 degradada. Las métricas micro de señales de Capa 1 son precisión 0.733333, sensibilidad 1.000000 y F1 0.846154. Estas cifras proceden de cinco escenarios curados y solo acreditan coherencia funcional del flujo.

Tabla 9.7: Prueba reproducible Capa 1–Capa 2–Capa 3

Caso	Prioridad	OK	Señales clave
Incendio urbano con atrapados	P1	Sí	atrapado, incendio, varias llamadas, riesgo vital
Accidente de tráfico grave	P1	Sí	herido grave, atrapado, tráfico
Fuga química en nave industrial	P2	Sí	intoxicación, riesgo vital textual
Inundación en garajes	P2	Sí	meteo/inundación
Árbol caído en carretera secundaria	P3	Sí	tráfico, sin falso atrapamiento

9.15. Evaluación exploratoria con participantes

Como complemento de la evaluación técnica, se realizó un estudio exploratorio breve para analizar la utilidad percibida y la comprensibilidad del prototipo. Se aplicó un muestreo no probabilístico e intencional de nueve participantes, con acceso controlado mediante Google Colab, casos representativos y un cuestionario de respuesta breve. El instrumento empleó una escala Likert de 1 a 5 para valorar la razonabilidad de la prioridad, la claridad de la explicación, la confianza aportada por las señales y la visibilidad de la decisión humana, además de una pregunta abierta.

La muestra se distribuye en tres grupos de tres perfiles. El Grupo A reúne profesionales vinculados a puestos de mando, comunicaciones críticas y emergencias; el Grupo B, usuarios técnicos familiarizados con herramientas de IA; y el Grupo C, usuarios no especializados en IA con distintos niveles de familiaridad operativa. Esta segmentación permite contrastar perspectivas operativas, técnicas y de comprensibilidad general. El Grupo A no se presenta como una muestra de operadores del 112: dos de sus perfiles se especializan principalmente en comunicaciones y sistemas CIS, mientras que uno aporta experiencia más próxima al despliegue de puestos de mando en emergencias. Los perfiles funcionales anonimizados A1–C3 se detallan en el Anexo D.

La Tabla 9.8 presenta las medias observadas. La dimensión mejor valorada es la claridad de que la decisión final corresponde a una persona, con una media global de 4,63. La razonabilidad de la prioridad alcanza 4,14, mientras que la claridad de la explicación y la confianza aportada por las señales obtienen 4,04. Estos valores indican una percepción favorable del principio de supervisión humana y una aceptación preliminar de la recomen-

dación y su explicación.

Tabla 9.8: Resultados agregados de la evaluación exploratoria con participantes

Dimensión evaluada	Grupo A	Grupo B	Grupo C	Global
Prioridad recomendada razonable	4,47	4,13	3,83	4,14
Explicación clara	4,17	4,37	3,60	4,04
Señales o reglas aumentan la confianza	4,50	4,23	3,40	4,04
Decisión humana claramente identificada	4,93	4,43	4,53	4,63

El análisis por perfiles aporta matices relevantes. El Grupo A valora especialmente la supervisión humana (4,93) y la trazabilidad proporcionada por las señales (4,50); el Grupo B otorga su mayor puntuación a la claridad de la explicación (4,37); y el Grupo C presenta las valoraciones más bajas en señales o reglas (3,40) y explicación (3,60). Los comentarios abiertos son coherentes con este patrón: los perfiles operativos destacan la trazabilidad y la visibilidad de las señales críticas, los perfiles técnicos solicitan una separación clara entre priorización y explicación, y los no especializados demandan un lenguaje más directo.

La evaluación constituye evidencia descriptiva de utilidad percibida, no una validación de aceptación ni una prueba operativa. El tamaño de la muestra, su selección intencional y la ausencia de operadores del 112 impiden generalizar los resultados o inferir efectos sobre el desempeño en una sala de emergencias.

9.16. Limitaciones

La evaluación presenta ocho limitaciones principales:

1. La referencia P1–P4 es académica y débil, no una etiqueta operativa oficial del 112.
2. El acuerdo de la supervisión débil es alto, pero las cuatro funciones comparten una puntuación heurística y no equivalen a anotadores independientes; tampoco sustituyen a una validación externa con personal experto del servicio.
3. RuleFit-lite se ajusta con 3.000 de los 6.512 casos disponibles y la alternativa RuleFit externa con 50. Esta diferencia obliga a tratar `imodels` como prueba diagnóstica y no permite comparar eficiencia en condiciones equivalentes.
4. El error de calibración esperado (*Expected Calibration Error*, ECE) con objetivo $ECE \leq 0,10$ queda pendiente de una evaluación específica (Guo, Pleiss, Sun, y

Weinberger, 2017).

5. Las variables externas diferidas (AEMET histórico, SNCZI y Seveso) no participan en esta evaluación.
6. Las pruebas integradas aportan evidencia de funcionamiento técnico P1–P4 y compatibilidad Capa 1–Capa 2 sobre 5 escenarios, pero su tamaño sigue siendo pequeño y la latencia media con LLM local, 4,90 s, requiere optimización antes de una demostración exigente.
7. Los 7 errores P1–P4 de la partición de prueba estratificada son el principal foco de riesgo del modelo y deben analizarse individualmente antes de cualquier validación operativa externa.
8. La evaluación exploratoria incluye nueve participantes seleccionados de forma intencional y no incorpora operadores del 112. Sus resultados describen percepciones de la muestra, pero no son estadísticamente generalizables ni acreditan aceptación operativa.

Pese a estas limitaciones, la evaluación permite concluir que la Capa 2 seleccionada obtiene una macro-F1 superior a la línea base heurística en las particiones evaluadas y mantiene la sensibilidad P1 por encima del umbral fijado y respeta las restricciones de interpretabilidad y anti-leakage. Por ello, RuleFit-lite se adopta como núcleo interpretable de Capa 2, siempre dentro del alcance académico del TFM. La evaluación se realiza frente a etiquetas débiles P1–P4 y no frente a prioridades oficiales del 112, por lo que la validación externa con personal experto sigue siendo necesaria antes de cualquier uso operativo.

Tabla 9.9: Síntesis final de la evaluación experimental

Elemento	Resultado principal	Interpretación y alcance
Línea base heurística	19 reglas; exactitud 0,694425; macro-F1 0,464284; sensibilidad P1 0,998473	Referencia transparente y conservadora; detecta P1 con alta sensibilidad, pero discrimina peor entre las cuatro clases.
RuleFit-lite	Ajuste con 3.000 de 6.512 registros; exacti- tud 0,903648; macro-F1 0,905604; sensibilidad P1 0,909924; 30 reglas	Modelo seleccionado por su rendimien- to de validación e interpretabilidad. Las métricas corresponden al estimador sin Puerta de Seguridad.
RuleFit externo	Ajuste diagnóstico con 50 registros; exacti- tud 0,768385; macro-F1 0,568239; sensibilidad P1 0,902778	Contraste externo reducido. No permite inferir superioridad estadística ni compu- tacional en condiciones equivalentes.
Prueba temporal 2022	735 casos; exactitud 0,884354; macro-F1 0,877594; sensibilidad P1 0,928767	Primera evidencia de estabilidad tempo- ral; no sustituye una validación prospecti- va.
Falsos negativos P1	59 casos: 34 P1-P2, 18 P1-P3 y 7 P1-P4	Los siete errores P1-P4 constituyen el principal riesgo y requieren especial aten- ción.
Puerta de Seguri- dad	Posprocesamiento deter- minista comprobado en escenarios funcionales inte- grados	Salvaguarda separada de la evaluación estadística; su efecto no está incluido en las métricas offline de RuleFit-lite.
Evaluación explo- ratoria	Nueve participantes; me- dias globales entre 4,04 y 4,63 sobre 5	Indicios descriptivos favorables, con ma- yor dificultad de comprensión de señales y reglas entre perfiles no especializados.
Limitaciones prin- cipales	Etiquetas académicas; fun- ciones heurísticas correla- cionadas; submuestreo de ajuste; contraste externo reducido; revisión interna conjunta	Los resultados son académicos y repro- ducibles, pero no acreditan validación operativa, acuerdo entre revisores inde- pendientes ni uso en un servicio 112 real.

10. Conclusiones y trabajo futuro

Este capítulo presenta las conclusiones generales derivadas del diseño, la implementación y la evaluación del sistema de apoyo a la decisión para la priorización de incidentes 112 en Castilla y León. En primer lugar, se analiza el grado de consecución de los objetivos generales y específicos propuestos al inicio del trabajo. A continuación, se detallan las principales contribuciones técnicas y metodológicas del proyecto, seguidas de una discusión sobre los resultados obtenidos, las limitaciones detectadas en esta fase de desarrollo y las líneas prioritarias de trabajo futuro para consolidar la arquitectura propuesta.

10.1. Respuesta al objetivo del TFM

El objetivo de este TFM era diseñar, implementar y evaluar un sistema de apoyo a la decisión para la priorización inicial de incidentes 112 en Castilla y León, manteniendo explicabilidad, trazabilidad, supervisión humana y prudencia metodológica. La respuesta obtenida es positiva dentro del alcance de un prototipo académico: el sistema no sustituye al operador ni pretende certificar prioridad operativa oficial, pero demuestra que es viable construir una cadena reproducible que transforma registros reales en recomendaciones P1–P4 revisables. Asimismo, este desarrollo aporta evidencia técnica, dentro de un entorno académico controlado, sobre la integración de modelos interpretables y explicaciones en lenguaje natural.

La aportación central no reside en una única métrica, sino en la coherencia del conjunto: Registro 112 CyL como fuente empírica, limpieza trazable, variables V01–V15, supervisión débil, control de fugas de información, Capa 2 interpretable, explicación normativa local, contratos de datos y registro de la decisión humana.

Esta respuesta cierra los objetivos formulados en el Capítulo 4. El trabajo analiza el dominio 112 y su marco normativo, define variables y prioridad académica, audita el conjunto de datos de Castilla y León, construye etiquetas débiles, compara alternativas interpretables, integra una capa explicativa y evalúa el resultado con métricas, errores críticos y trazabilidad. Por tanto, la defensa del TFM no depende de una promesa de despliegue operativo, sino de una cadena de evidencia verificable.

Además, el sistema se ha comprobado como prototipo ejecutable de extremo a extremo: Capa 1 extrae señales desde texto, Capa 2 prioriza con RuleFit-lite, Capa 3 explica con

Ollama local y el backend devuelve una respuesta consumible por la interfaz. Tras integrar la Capa 1, se ha regenerado además una prueba técnica reproducible Capa 1–Capa 2–Capa 3 que supera 5/5 escenarios curados y confirma que el flujo integrado no rompe los resultados de la Capa 2. Este hito aporta evidencia de compatibilidad entre capas dentro de los escenarios ensayados, sin equivaler a una validación operativa.

10.2. Trazabilidad de objetivos específicos

Para evidenciar el grado de consecución del trabajo, la Tabla 10.1 enlaza cada objetivo específico definido en el Capítulo 4 con su resultado y la evidencia que lo respalda. Todos los objetivos planteados se consideran alcanzados dentro del alcance académico definido.

OE	Estado	Grado de consecución	Evidencia
OE1	Logrado	Se analiza el problema de priorización temprana 112, necesidades del operador, restricciones de información y riesgos de automatización.	Caps. 1, 2
OE2	Logrado	Se revisa el marco normativo estatal y autonómico CyL y se construye la tabla de trazabilidad norma–criterio–variable–regla.	Cap. 3
OE3	Logrado	Se define la taxonomía operativa, la escala académica P1–P4 y las variables V01–V15 con separación anti- <i>leakage</i> .	Anexos A, B, C
OE4	Logrado	Se audita el Registro 112 CyL (9.380 registros limpios) y se generan etiquetas P1–P4 por supervisión débil con acuerdo Krippendorff $\alpha = 0,899902$.	Cap. 7, Anexo C
OE5	Logrado	Se implementa la Capa 2 interpretable: línea base heurística, RuleFit-lite y alternativa externa; se selecciona RuleFit-lite (macro-F1 0,905604; sensibilidad P1 0,909924).	Cap. 9, Anexos E, L
OE6	Logrado	Se diseña la Capa 3 de explicación con LLM local, RAG normativo y MCP, sin delegar la decisión de prioridad en el LLM.	Cap. 8, Anexo L
OE7	Logrado	Se integran las capas mediante contratos de datos, trazabilidad de la inferencia, respuesta alternativa determinista y registro de la decisión humana.	Cap. 8
OE8	Logrado	Se evalúa con particiones estratificada y temporal, control de fugas, 59 falsos negativos P1, fidelidad explicativa y un estudio exploratorio con nueve participantes.	Cap. 9, Anexo D

Tabla 10.1: Trazabilidad entre objetivos específicos, grado de consecución y evidencia.

Fuente: elaboración propia.

10.3. Principales contribuciones

A lo largo de su desarrollo, este proyecto ha permitido consolidar una serie de aportes tanto teóricos como prácticos en el campo de los sistemas de soporte a la decisión en emergencias. Estas aportaciones abordan desde la estructuración de datos abiertos hasta la implementación de una arquitectura modular basada en la interpretabilidad y la supervisión humana. En particular, el trabajo realizado aporta siete contribuciones principales que se detallan a continuación.

1. **Arquitectura en tres capas.** Se ha definido una arquitectura formada por Capa 1 NLP, Capa 2 RuleFit-lite y Capa 3 LLM+RAG+MCP, separando extracción, priorización y explicación normativa.
2. **Uso realista de datos abiertos.** El sistema se apoya en 9.380 registros limpios del Registro 112 de Castilla y León 2008–2022, con auditoría de calidad, cobertura temporal y control de campos ex post.
3. **Etiqueta académica P1–P4 mediante supervisión débil.** Ante la ausencia de prioridad oficial en el conjunto de datos, se construye una etiqueta académica con cuatro funciones heurísticas correlacionadas. El acuerdo alcanza Krippendorff $\alpha = 0,899902$, y la ablación sin reglas heurísticas mantiene $\alpha = 0,834155$.
4. **Modelo interpretable seleccionado.** RuleFit-lite supera a la línea base heurística en macro-F1, mantiene la sensibilidad P1 por encima del criterio fijado y conserva 30 reglas activas exportadas.
5. **Evaluación reproducible y anti-leakage.** Los resultados se obtienen sobre particiones reproducibles, con prueba estratificada y prueba temporal, evitando columnas posteriores a la decisión.
6. **Prototipo integrado local.** Se ha comprobado una primera cadena ejecutable con API, interfaz, RuleFit-lite y Ollama local `llama3.1:8b-instruct-q4_K_M`, sin delegar la prioridad al LLM. También se ha comprobado la integración reproducible Capa 1–Capa 2–Capa 3 sobre cinco escenarios curados, con RuleFit activo y salida coherente en todos los casos.
7. **Trazabilidad y evaluación complementaria.** Se documenta una revisión conjunta de los tres autores sobre 119 casos, incluyendo los 59 falsos negativos P1 detectados

en la prueba estratificada, y se evalúa la fidelidad de las explicaciones de Capa 3 sobre esa misma muestra. Además, nueve participantes aportan una primera valoración descriptiva de la utilidad y la comprensibilidad del prototipo.

10.4. Resultados principales

La evaluación confirma que RuleFit-lite es la alternativa más equilibrada para la Capa 2. En la partición de prueba estratificada alcanza exactitud 0.903648, macro-F1 0.905604 y sensibilidad P1 0.909924. Estos valores superan a la línea base heurística de 19 reglas en macro-F1, que obtiene 0.464284, aunque la línea base conserva una sensibilidad P1 de 0.998473 por su comportamiento conservador.

RuleFit-lite se ajusta con un submuestreo estratificado y reproducible de 3.000 casos de los 6.512 disponibles. La ejecución de `imodels` usa 50 casos y se conserva como prueba diagnóstica, de modo que no permite concluir que RuleFit-lite sea más eficiente en condiciones equivalentes.

Estas métricas corresponden a RuleFit-lite sin la Puerta de Seguridad. La salvaguarda determinista pertenece a la inferencia integrada y se comprueba de forma separada mediante escenarios funcionales, para no atribuir al estimador los efectos del posprocesamiento.

La prueba temporal sobre registros de 2022 mantiene resultados estables: exactitud 0.884354, macro-F1 0.877594 y sensibilidad P1 0.928767. Esta estabilidad no demuestra validez prospectiva en producción, pero reduce el riesgo de que el resultado dependa solo de una partición estratificada favorable.

El análisis de errores identifica 59 falsos negativos P1: 34 clasificados como P2, 18 como P3 y 7 como P4. La presencia de 7 casos P1 infrapriorizados como P4 representa un riesgo crítico de seguridad que queda documentado para su revisión. Este resultado es importante: el sistema cumple el criterio de sensibilidad P1, pero los errores P1–P4 constituyen el principal foco de mejora antes de cualquier validación externa.

La evaluación de fidelidad de explicaciones aporta una comprobación complementaria. Sobre los 119 casos de la muestra revisada internamente, el juez determinista sin conexión obtiene una tasa de cumplimiento 1.000000, fidelidad media 0.957367 y fidelidad mínima 0.933333. En los 59 falsos negativos P1, la fidelidad media es 0.952494. Esto no equivale a una evaluación externa de calidad lingüística, pero aporta evidencia de que las explica-

ciones deterministas evaluadas no contradicen la recomendación de Capa 2 y conservan la trazabilidad definida.

El cierre documental de la evaluación se recoge en un reporte maestro de trazabilidad que actúa como índice de métricas, evidencias, revisión interna, fidelidad explicativa y capítulos/anexos que sostienen los resultados.

La evaluación exploratoria con nueve participantes aporta una perspectiva complementaria sobre utilidad percibida y comprensibilidad. Las medias globales son 4,14 para la razonabilidad de la prioridad, 4,04 para la claridad de la explicación, 4,04 para la confianza aportada por señales o reglas y 4,63 para la claridad de la decisión humana. El resultado más sólido es, por tanto, la comprensión del control humano; la principal oportunidad de mejora es simplificar la presentación de probabilidades y reglas para perfiles no especializados. Por el tamaño y la selección de la muestra, estas puntuaciones son descriptivas y no acreditan aceptación operativa.

Como comprobación integrada del prototipo, la prueba funcional P1–P4 obtiene 4 aciertos en 4 casos representativos: incendio con atrapados como P1, fuga de gas sin heridos como P2, árbol en calzada como P3 y consulta vecinal sin riesgo como P4. La prueba confirma RuleFit activo, el LLM local disponible y explicación generativa. La latencia media observada en el entorno experimental es 4,898 s, valor que caracteriza la integración funcional, pero queda pendiente de optimización si se quisiera una demo más fluida.

La prueba reproducible Capa 1–Capa 2–Capa 3 complementa esta comprobación con 5 casos curados y resultado 5/5. Su valor principal es demostrar que la salida real de Capa 1 alimenta correctamente a RuleFit-lite, incluyendo un caso ordinario con negaciones explícitas que antes podía provocar falsos positivos de atrapamiento. Las latencias medias son 4.58844 ms en Capa 1, 52.16898 ms en Capa 2 y 0.30748 ms en Capa 3 degradada.

10.5. Cumplimiento de principios de diseño

El prototipo respeta la línea de trabajo definida desde los capítulos iniciales. La prioridad no la decide un LLM generativo, sino una Capa 2 interpretable. El LLM se reserva para explicar y citar normativa. La inferencia se concibe en local, sin enviar incidentes a APIs externas. La arquitectura mantiene contratos versionados y registra la decisión humana mediante `OperatorDecision` e `InferenceLog`.

También se cumple el principio anti-*leakage*: se excluyen los campos relativos a medios

movilizados, pacientes atendidos, cierre del incidente y actualizaciones posteriores. Esta decisión es esencial para que el modelo represente el momento de primera decisión y no información generada durante el operativo.

La Capa 1 se mantiene deliberadamente acotada. Aplica NLP simbólico mediante detección semántica basada en reglas y diccionarios operativos, tratamiento de negaciones, normalización y estimación de confianza para transformar texto libre en señales auditables. Su evaluación oficial se limita a cinco escenarios curados y, por tanto, acredita integración funcional, no rendimiento generalizable. Aunque el código contempla una vía experimental para cargar un clasificador aprendido, no se dispone de un modelo congelado ni de una evaluación suficiente para presentarlo como componente validado. Esta delimitación preserva la coherencia entre memoria, código y evidencia.

10.6. Limitaciones

A pesar de los resultados favorables obtenidos en la fase experimental, el prototipo actual presenta restricciones que impiden interpretar sus resultados como evidencia de viabilidad inmediata en producción. Documentar estas limitaciones aporta transparencia y orienta las futuras iteraciones del sistema:

1. La etiqueta P1–P4 es académica y débil; no existe una prioridad oficial equivalente en el Registro 112 CyL.
2. La validación técnica es interna. La evaluación exploratoria incorpora nueve participantes, pero no un panel externo de operadores o responsables del 112.
3. RuleFit-lite se ha ajustado con 3.000 de los 6.512 casos disponibles y la ejecución `imodels` con 50. Esta última se limita a una configuración diagnóstica y no sustenta una comparación de eficiencia en condiciones equivalentes.
4. La calibración ECE queda pendiente de una pasada final si el modelo se congela para una demostración cerrada.
5. Las variables V08–V11, asociadas a AEMET histórico, inundabilidad SNCZI y proximidad Seveso, permanecen diferidas como ampliación futura.
6. El prototipo no mide impacto operativo real sobre tiempos de decisión, coordinación de recursos o carga cognitiva en sala.

7. Las pruebas integradas tienen tamaño reducido: cuatro casos con Ollama y cinco escenarios reproducibles Capa 1–Capa 2–Capa 3. La evaluación exploratoria añade nueve participantes seleccionados intencionalmente, pero no incluye operadores del 112 ni equivale a una validación de aceptación operativa.
8. La muestra de revisión interna contiene 119 casos, incluidos los 59 falsos negativos P1, y ha sido examinada conjuntamente por los tres autores. Al no existir tres anotaciones independientes, no permite calcular acuerdo interrevisor ni sustituye una validación externa.

10.7. Trabajo futuro

La continuación natural del proyecto se organiza en siete líneas.

1. **Validación externa con personal del 112.** Revisar una muestra de casos con operadores o responsables expertos, comparando etiqueta académica, recomendación del sistema y criterio profesional.
2. **Revisión independiente.** Registrar por separado el criterio de cada revisor sobre los 119 casos del Anexo D, calcular acuerdo entre autores y documentar patrones de divergencia.
3. **Calibración probabilística.** Evaluar ECE y aplicar calibración si el modelo se congela como demostrador estable.
4. **Variables contextuales avanzadas.** Incorporar AEMET histórico, SNCZI/zonas inundables y Seveso como variables V08–V11, manteniendo el control anti-*leakage*.
5. **Evaluación de explicaciones con juez independiente.** Desarrollar la propuesta de implementar un LLM-as-Judge local independiente para evaluar de forma ciega las explicaciones de la Capa 3, usando la muestra de 119 casos y comparando sus puntuaciones de fidelidad y calidad lingüística con el juez determinista offline.
6. **Optimización del prototipo integrado y entrada de voz.** Reducir la latencia del LLM local mediante instrucciones más compactas, respuesta progresiva, cuantización o ejecución acelerada; evaluar experimentalmente el reconocimiento automático del habla con **faster-whisper** sobre un corpus autorizado y representativo antes de atribuirle validez sobre llamadas reales.

7. **Piloto controlado ampliado.** Extender la evaluación del prototipo en un entorno de prueba controlado y con una muestra representativa para medir utilidad percibida, carga cognitiva, tiempo de revisión y aceptación de recomendaciones.

10.8. Cierre

El TFM alcanza una conclusión equilibrada: es posible construir un sistema inteligente de apoyo a la priorización 112 que sea técnicamente ambicioso y, al mismo tiempo, prudente en un dominio crítico. RuleFit-lite aporta rendimiento superior a la línea base experto sin renunciar a interpretabilidad; la prueba temporal aporta una primera evidencia de estabilidad; y la revisión interna conjunta abre el camino para contrastar el sistema con criterio humano.

El prototipo no es un producto operativo, pero constituye una base académica sólida de investigación aplicada. Su valor está en haber unido datos reales, normativa, aprendizaje interpretable, explicación local y supervisión humana en una arquitectura reproducible y auditable. Esa combinación permite defender el proyecto por su rigor metodológico y por delimitar con claridad hasta dónde puede llegar la IA responsable en una primera decisión de emergencia.

Referencias

- Anthropic. (2024). *Introducing the Model Context Protocol*. Anthropic News. Descargado de <https://www.anthropic.com/news/model-context-protocol> (Publicado el 25 de noviembre de 2024)
- Araujo, L., Silva, F., Ito, K., y cols. (2026). Explainable artificial intelligence frameworks for ai-soar decision support: Building trust and auditability in emergency management systems. *IEEE Transactions on Intelligent Systems*, 52(1), 45–68. doi: 10.1109/TIS.2026.10258
- Caragea, C., McNeese, N., Jaiswal, A., Traylor, G., Kim, H.-W., Mitra, P., ... Yen, J. (2011). Classifying text messages for the Haiti earthquake. En *Proceedings of the 8th international ISCRAM conference*. Lisbon, Portugal.
- Comes, T., Hiete, M., Wijngaards, N., y Schultmann, F. (2011). Decision maps: A framework for multi-criteria decision support under severe uncertainty. *Decision Support Systems*, 52(1), 108–118. doi: 10.1016/j.dss.2011.05.008

- Comfort, L. K. (2007). Crisis management in hindsight: Cognition, communication, coordination, and control. *Public Administration Review*, 67(s1), 189–197. doi: 10.1111/j.1540-6210.2007.00827.x
- Copernicus Emergency Management Service. (2025). *Copernicus emergency management service: Mapping and rapid mapping*. European Union Copernicus Programme. Descargado de <https://mapping.emergency.copernicus.eu/about/rapid-mapping-manual/product-overview/> (Consulta de documentacion oficial del servicio)
- Cortes de Castilla y León. (2007). *Ley 4/2007, de 28 de marzo, de Protección Ciudadana de Castilla y León*. Boletín Oficial del Estado, núm. 111, de 9 de mayo de 2007. (Referencia BOE-A-2007-9097)
- Docker Inc. (2024). *Docker Desktop MCP Toolkit: Model Context Protocol server suite*. Herramienta de software. Docker Inc. Descargado de <https://www.docker.com/products/docker-desktop/> (Incluye servidores MCP `paper-search` y `duckduckgo`. Accedido en 2024–2026)
- Endsley, M. R. (1995). Toward a theory of situation awareness in dynamic systems. *Human Factors: The Journal of the Human Factors and Ergonomics Society*, 37(1), 32–64. doi: 10.1518/001872095779049543
- FastAPI. (2026). *FastAPI documentation*. Documentacion oficial de software. Descargado de <https://fastapi.tiangolo.com/> (Accedido en 2026)
- Friedman, J. H., y Popescu, B. E. (2008). Predictive learning via rule ensembles. *The Annals of Applied Statistics*, 2(3), 916–954. doi: 10.1214/07-AOAS148
- Ghaffarian, S., Taghikhah, F. R., y Maier, H. R. (2023). Explainable artificial intelligence in disaster risk management: Achievements and prospective futures. *International Journal of Disaster Risk Reduction*, 98, 104123. doi: 10.1016/j.ijdr.2023.104123
- GitHub. (2024). *GitHub Spec Kit: Specification-driven development framework*. Herramienta de software. GitHub Inc. Descargado de <https://github.com/github/spec-kit> (Marco de desarrollo controlado por especificaciones. Accedido en 2024–2026)
- GitHub, y Microsoft. (2023). *GitHub Copilot: Your AI pair programmer*. Servicio en línea. Microsoft Corporation / GitHub Inc. Descargado de <https://github.com/features/copilot> (Extension integrada en Visual Studio Code. Accedido en 2024–2026)
- Google. (2026). *Gemini for developers*. Documentacion oficial de software. Descargado

- de <https://ai.google.dev/> (Accedido en 2026)
- Grattafiori, A., Dubey, A., y cols. (2024). *The Llama 3 herd of models*. arXiv preprint arXiv:2407.21783. (Llama Team, AI @ Meta) doi: 10.48550/arXiv.2407.21783
- Guo, C., Pleiss, G., Sun, Y., y Weinberger, K. Q. (2017). On calibration of modern neural networks. En *Proceedings of the 34th international conference on machine learning (ICML)* (Vol. 70, pp. 1321–1330). PMLR. (arXiv:1706.04599)
- Gutiérrez-Fandiño, A., Armengol-Estapé, J., Pàmies, M., Llop-Palao, J., Silveira-Ocampo, J., Carrino, C. P., ... Villegas, M. (2022). MarIA: Spanish language models. *Procesamiento del Lenguaje Natural*, 68, 39–60. doi: 10.26342/2022-68-3
- Imran, M., Castillo, C., Diaz, F., y Vieweg, S. (2015). Processing social media messages in mass emergency: A survey. *ACM Computing Surveys*, 47(4), 67:1–67:38. doi: 10.1145/2771588
- Imran, M., Castillo, C., Lucas, J., Meier, P., y Vieweg, S. (2014). AIDR: Artificial intelligence for disaster response. En *Proceedings of the 23rd international conference on world wide web companion* (pp. 159–162). doi: 10.1145/2567948.2577034
- Jefatura del Estado. (2015). *Ley 17/2015, de 9 de julio, del Sistema Nacional de Protección Civil*. Boletín Oficial del Estado, núm. 164, de 10 de julio de 2015. (Referencia BOE-A-2015-7730)
- Jefatura del Estado. (2018). *Ley orgánica 3/2018, de 5 de diciembre, de Protección de Datos Personales y garantía de los derechos digitales*. Boletín Oficial del Estado, núm. 294, de 6 de diciembre de 2018. (Referencia BOE-A-2018-16673)
- Jefatura del Estado. (2022). *Ley 11/2022, de 28 de junio, General de Telecomunicaciones*. Boletín Oficial del Estado, núm. 155, de 29 de junio de 2022. (Referencia BOE-A-2022-10757)
- Joint Research Centre. (2025a). *Artificial intelligence for disaster risk management and emergency response*. European Commission, Joint Research Centre. Descargado de <https://joint-research-centre.ec.europa.eu/>
- Joint Research Centre. (2025b). *Multi-hazard early warning system: Global disaster alert and coordination system (GDACS)* (Inf. Téc.). Publications Office of the European Union. Descargado de <https://publications.jrc.ec.europa.eu/repository/handle/JRC141661> doi: 10.2760/1461943
- Junta de Castilla y León. (2008). *Acuerdo 3/2008, de 17 de enero, por el que se aprueba el Plan de Protección Civil ante el Riesgo de Transportes de Mercancías Peligrosas*

- por Carretera y Ferrocarril en Castilla y León (MPCyL)*. Boletín Oficial de Castilla y León, núm. 15, de 23 de enero de 2008. (Identificador BOCYL-D-23012008-8)
- Junta de Castilla y León. (2010). *Acuerdo 19/2010, de 25 de febrero, por el que se aprueba el Plan de Protección Civil ante el Riesgo de Inundaciones en Castilla y León (INUNCYL)*. Boletín Oficial de Castilla y León, núm. 42, de 3 de marzo de 2010. (Identificador BOCYL-D-03032010-14)
- Junta de Castilla y León. (2019). *Decreto 4/2019, de 7 de febrero, por el que se aprueba el Plan Territorial de Protección Civil de Castilla y León (PLANCAL)*. Boletín Oficial de Castilla y León, núm. 29, de 11 de febrero de 2019. (Identificador BOCYL-D-11022019-1)
- Junta de Castilla y León. (2025). *Decreto 6/2025, de 27 de marzo, por el que se aprueba el Plan Especial de Protección Civil ante Emergencias por Incendios Forestales en Castilla y León (INFOCAL)*. Boletín Oficial de Castilla y León, núm. 62, de 31 de marzo de 2025. (Identificador BOCYL-D-31032025-2)
- Junta de Castilla y León. (s. f.). *Registro de emergencias del 112*. Portal de Datos Abiertos de Castilla y León. Descargado de <https://datosabiertos.jcyl.es/web/jcyl/set/es/sector-publico/emergencias-ultimo-ano/1285074931225> (Conjunto de datos público bajo licencia Creative Commons Reconocimiento 4.0. Fichero 2008–2022 empleado como fuente empírica de apoyo para el diseño y prueba del pipeline de datos)
- Kim, J., Maathuis, H., y Sent, D. (2024). Human-centered evaluation of explainable ai applications: a systematic review. *Frontiers in Artificial Intelligence*, 7, 1456486. doi: 10.3389/frai.2024.1456486
- Kollipara, S., Gupta, N., O'Neill, S., y cols. (2025). Trustworthy machine learning in mission-critical systems: Assurance patterns, uncertainty quantification, and decision gates. *IEEE Software*, 42(2), 28–38. doi: 10.1109/MS.2025.10125
- Lamsal, R., Rodriguez Read, M., y Karunasekera, S. (2024). CrisisTransformers: Pre-trained language models and sentence encoders for crisis-related social media texts. *Knowledge-Based Systems*, 296, 111916. doi: 10.1016/j.knosys.2024.111916
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., . . . Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. En *Advances in neural information processing systems* (Vol. 33, pp. 9459–9474). Curran Associates. (arXiv:2005.11401)

- McCreadie, R., Buntain, C., y Soboroff, I. (2021). Incident streams 2021: Trec incident streams track overview. En *Proceedings of the thirtieth text retrieval conference (TREC 2021)*. Descargado de <https://trec.nist.gov/pubs/trec30/papers/Overview-2021.pdf>
- Ministerio del Interior. (2020). *Resolución de 16 de diciembre de 2020, de la subsecretaría, por la que se publica el acuerdo del consejo de ministros de 15 de diciembre de 2020, por el que se aprueba el Plan Estatal General de Emergencias de Protección Civil (PLEGEM)*. Boletín Oficial del Estado, núm. 328, de 17 de diciembre de 2020. (Referencia BOE-A-2020-16349)
- Ministerio del Interior. (2023). *Real Decreto 524/2023, de 20 de junio, por el que se aprueba la Norma Básica de Protección Civil*. Boletín Oficial del Estado, núm. 147, de 21 de junio de 2023. (Referencia BOE-A-2023-14679)
- Minulescu, D.-E., y Toma, Ș.-A. (2025). Whisper based speech recognition for emergency services. En *2025 16th international conference on electronics, computers and artificial intelligence (ecai)*. doi: 10.1109/ECAI65401.2025.11095458
- Parlamento Europeo, y Consejo de la Unión Europea. (2016). *Reglamento (UE) 2016/679, de 27 de abril de 2016, relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales y a la libre circulación de estos datos*. Diario Oficial de la Unión Europea, L 119, de 4 de mayo de 2016. (Reglamento General de Protección de Datos)
- Parlamento Europeo, y Consejo de la Unión Europea. (2024). *Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo, de 13 de junio de 2024, por el que se establecen normas armonizadas en materia de inteligencia artificial (Reglamento de Inteligencia Artificial)*. Diario Oficial de la Unión Europea, L 2024/1689, de 12 de julio de 2024.
- Pydantic. (2026). *Pydantic documentation*. Documentacion oficial de software. Descargado de <https://docs.pydantic.dev/> (Accedido en 2026)
- Quarantelli, E. L. (1988). Disaster crisis management: A summary of research findings. *Journal of Management Studies*, 25(4), 373–385. doi: 10.1111/j.1467-6486.1988.tb00043.x
- Qwen Team. (2024). *Qwen2.5 technical report*. arXiv preprint arXiv:2412.15115. doi: 10.48550/arXiv.2412.15115
- Ratner, A., Bach, S. H., Ehrenberg, H. R., Fries, J. A., Wu, S., y Ré, C. (2020). Snorkel:

- rapid training data creation with weak supervision. *The VLDB Journal*, 29, 709–730. doi: 10.1007/s00778-019-00552-1
- Reimers, N., y Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-Networks. En *Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP)* (pp. 3982–3992). Association for Computational Linguistics. doi: 10.18653/v1/D19-1410
- Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), 206–215. doi: 10.1038/s42256-019-0048-x
- Sandeboina, P., Chen, W., Kumar, A., y cols. (2026). Retrieval-augmented generation reliability in high-stakes systems: Factual grounding, confidence scoring, and hallucination benchmarks. *ACM Transactions on Machine Learning and Systems*, 15(2). doi: 10.1145/3810025.3810052
- Science Advice for Policy by European Academies. (2025). *Artificial intelligence in emergency and crisis management: Rapid evidence review report* (Inf. Téc.). Scientific Advice Mechanism to the European Commission. Descargado de <https://scientificadvice.eu/scientific-outputs/artificial-intelligence-in-emergency-and-crisis-management-rapid-evidence-review-report/>
- Singh, C., Nasser, K., Tan, Y. S., Tang, T., y Yu, B. (2021). imodels: a python package for fitting interpretable models. *Journal of Open Source Software*, 6(61), 3192. doi: 10.21105/joss.03192
- Streamlit. (2026). *Streamlit documentation*. Documentación oficial de software. Descargado de <https://docs.streamlit.io/> (Accedido en 2026)
- SYSTRAN. (2026). *faster-whisper: faster Whisper transcription with CTranslate2*. Repositorio de software. Descargado de <https://github.com/SYSTRAN/faster-whisper> (Accedido en 2026)
- Szabelka, H., Nowak, J., O’Brien, S., y cols. (2025). Digital sovereignty through ai: Privacy-by-design and governance frameworks for local inference in critical systems. *International Journal of Information Security*, 24(3), 512–540. doi: 10.1007/s10207-025-00892
- Turoff, M., Chumer, M., Van de Walle, B., y Yao, X. (2004). The design of a dynamic emergency response management information system (DERMIS). *Journal of*

Information Technology Theory and Application, 5(4), 1–35.

- Vieweg, S., Hughes, A. L., Starbird, K., y Palen, L. (2010). Microblogging during two natural hazards events: What Twitter may contribute to situational awareness. En *Proceedings of the SIGCHI conference on human factors in computing systems* (pp. 1079–1088). ACM. doi: 10.1145/1753326.1753486
- Zheng, L., Chiang, W.-L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., . . . Stoica, I. (2023). Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. En *Advances in neural information processing systems* (Vol. 36, pp. 46595–46623). Curran Associates. (arXiv:2306.05685)

A. Taxonomía de incidentes CyL

Este anexo presenta detalladamente la estructura de la taxonomía operativa diseñada para clasificar y agrupar los sucesos históricos del Registro 112 de Castilla y León. A través de las familias definidas, se facilita el procesamiento estructurado y la extracción de variables clave para el motor predictivo. Con esta ordenación conceptual se busca proporcionar un marco de referencia coherente que conecte los textos libres con el catálogo de riesgos de protección civil.

A.1. Finalidad del anexo

Este anexo documenta la taxonomía operativa utilizada por el prototipo para agrupar incidentes del Registro 112 de Castilla y León. Su finalidad no es crear un catálogo jurídico oficial, sino proporcionar una clasificación funcional para la extracción de variables, la supervisión débil, la Capa 2 RuleFit-lite y la explicación normativa de la Capa 3.

La taxonomía se alinea con el marco descrito en el Capítulo 3: Ley 17/2015, Ley 4/2007 de Castilla y León, PLANCAL, INFOCAL, INUNCYL, MPCyL y normativa Seveso. La variable relacionada es V04, descrita en el Anexo B.

A.2. Criterios de construcción

La taxonomía se ha construido aplicando cuatro criterios:

- **Coherencia normativa:** cada familia debe poder vincularse con riesgos o funciones reconocidas en protección civil.
- **Utilidad predictiva:** cada categoría debe aportar información a la priorización P1–P4 o a la explicación.
- **Disponibilidad en datos abiertos:** la categoría debe poder inferirse desde texto, tipo preliminar o campos disponibles del Registro 112 CyL.
- **Anti-leakage:** la categoría no puede depender de medios movilizados, pacientes atendidos, cierre administrativo ni información posterior.

A.3. Familias principales

A.4. Relación con variables y señales

La taxonomía alimenta directamente las variables categóricas usadas por la Capa 2: tráfico, incendio, rescate, sanitario, meteorología, seguridad y otros. La familia tecnológica se conserva como categoría conceptual de alto interés, aunque su cobertura automática queda limitada por la ausencia de integración completa de variables V08–V11.

A.5. Limitaciones y riesgos

La taxonomía es una herramienta académica y funcional. No sustituye la codificación interna de un servicio 112 ni agota toda la casuística real. Algunos incidentes pueden pertenecer a varias familias; en esos casos se priorizan las señales de mayor urgencia para la Capa 2 y se conservan las evidencias relevantes para la explicación.

Las familias tecnológica, meteorológica avanzada e inundación completa se beneficiarían de integrar AEMET histórico, SNCZI y Seveso. Se documentan como línea futura para evitar sobrerrepresentar información que todavía no está disponible de forma reproducible.

En consecuencia, las familias asociadas a riesgos meteorológicos o industriales complejos actúan de forma pasiva: pueden influir cuando aparecen como señales en el texto operativo, pero no mediante enriquecimiento automático con fuentes externas. Esta decisión reduce falsos positivos derivados de contexto no verificado. El mapeo del tipo de incidente a la taxonomía se apoya en un analizador textual optimizado para señales predecionales, pero los incidentes multirriesgo, por ejemplo una colisión con incendio y heridos, requieren revisión manual para confirmar que la familia dominante no oculta otros riesgos relevantes.

Tabla A.1: Taxonomía operativa principal del prototipo

Código	Familia	Descripción operativa	Anclaje
CAT-SAN	Sanitario	Urgencias médicas, heridos, intoxicaciones, fallecidos o situaciones con posible riesgo vital.	Ley 17/2015; PLANCAL
CAT-TRAF	Tráfico	Accidentes de circulación, atropellos, vehículos implicados, cortes o riesgos viarios.	PLANCAL; Registro 112 CyL
CAT-INC	Incendio	Incendios urbanos, industriales, de vehículo, vegetación o interfaz urbano-forestal.	INFOCAL; PLANCAL
CAT-RES	Rescate y salvamento	Atrapamientos, rescates en altura, agua, espacios confinados, búsquedas o personas desaparecidas.	PLANCAL; Ley 4/2007 CyL
CAT-MET	Meteorológico e inundación	Lluvias, nieve, viento, tormentas, inundaciones, balsas de agua o efectos de fenómenos adversos.	INUNCYL; PLANCAL
CAT-SEG	Seguridad	Agresiones, amenazas, altercados, presencia policial o situaciones con riesgo para personas.	Ley 17/2015; coordinación multiagencia
CAT-TEC	Tecnológico o industrial	Fugas, sustancias peligrosas, incidentes industriales, Seveso o infraestructuras críticas.	MPCyL; RD 840/2015
CAT-OTR	Otros y asistencia	Consultas, incidencias menores, asistencia técnica, animales, servicios municipales o información.	Registro 112 CyL

Tabla A.2: Relación entre taxonomía, señales y uso en Capa 2

Familia	Señales textuales típicas	Efecto esperado	Variable Capa 2
Sanitario	fallecido, herido grave, inconsciente, intoxicación	Eleva probabilidad P1/P2 si hay gravedad personal	<code>cat_sanitario</code>
Tráfico	accidente, colisión, atropello, atrapado	P2/P3; P1 si hay riesgo vital o atrapamiento grave	<code>cat_trafico</code>
Incendio	fuego, humo, vivienda, nave, forestal	P2/P3; P1 si hay atrapados, víctimas o propagación crítica	<code>cat_incendio</code>
Rescate	atrapado, rescate, desaparecido, barranco, río	P1/P2 según riesgo vital y vulnerabilidad	<code>cat_rescate</code>
Meteorológico	inundación, nieve, viento, lluvia intensa	P2/P3 según afectación y llamadas múltiples	<code>cat_meteorologico</code>
Seguridad	agresión, amenaza, violencia, pelea	P2/P3 según riesgo activo para personas	<code>cat_seguridad</code>
Otros	consulta, asistencia, animal, incidencia técnica	Normalmente P3/P4 salvo señales críticas	<code>cat_otros</code>

B. Variables V01–V15 de priorización

Este anexo define las quince variables académicas utilizadas para estructurar la información del incidente y conectar la extracción de señales de Capa 1 con la priorización de Capa 2.

B.1. Finalidad del anexo

Este anexo especifica las variables V01–V15 utilizadas como marco común entre datos, etiquetas débiles, Capa 2, explicación y revisión humana. La matriz no debe interpretarse como un formulario operativo oficial, sino como una representación académica de factores relevantes para priorizar incidentes 112 en Castilla y León.

El alcance distingue entre variables implementadas de forma reproducible con el Registro 112 CyL y variables previstas como ampliación futura. Esta distinción es clave para evitar fuga de información y para no atribuir al modelo datos contextuales que todavía no se han integrado.

B.2. Matriz de variables

B.3. Variables implementadas en Capa 2

El modelo RuleFit-lite seleccionado no consume directamente todas las variables V01–V15 como campos completos. Consume un conjunto compacto de señales predecionales derivadas del texto y de la categoría preliminar. Estas señales se obtienen mediante NLP simbólico y auditable en Capa 1: detección semántica basada en reglas, tratamiento de negaciones, normalización y confianza:

- señales de fallecimiento, herido grave, atrapamiento e intoxicación;
- llamadas múltiples, incendio, accidente de tráfico, rescate y riesgo meteorológico o de inundación;
- riesgo vital expresado en el texto;

- variables categóricas normalizadas derivadas de la taxonomía.

Esta decisión mantiene reproducibilidad y evita introducir variables contextuales incompletas. Las variables V08–V11 se conservan en el diseño porque son relevantes para una ampliación futura, pero no se contabilizan como evidencia disponible en la evaluación actual.

B.4. Columnas prohibidas por leakage y políticas de privacidad

El sistema excluye rigurosamente del entrenamiento e inferencia cualquier variable o columna que refleje decisiones ex post o información administrativa y clínica posterior a la primera decisión de despacho. En particular, queda prohibido el uso de:

- `MediosMov` y derivados de recursos reales movilizados.
- `PacientesAten` y registros de atención sanitaria o traslados.
- `IncidenteCerrado` y estado final de resolución del caso.
- `ultimaActualizacion` y marcas de tiempo de modificación del log central.
- Enlaces, identificadores de despacho y metadatos ex post.

La exclusión de estas columnas ex post posee una justificación metodológica crítica: si el modelo RuleFit tuviera acceso a variables como el número de ambulancias movilizadas o el estado de cierre del incidente, aprendería consecuencias operativas posteriores en lugar de señales tempranas de riesgo. Esto provocaría fuga de la variable objetivo (*target leakage*) e invalidaría la utilidad del sistema en el momento de la primera decisión.

En alineación con los principios de minimización del Reglamento General de Protección de Datos (RGPD) (Parlamento Europeo y Consejo de la Unión Europea, 2016) y de la Ley Orgánica 3/2018 (LOPDGDD) (Jefatura del Estado, 2018), el diseño contempla anonimización y tratamiento restringido de datos. Las coordenadas geográficas exactas del Registro 112 CyL pueden reducirse a precisión municipal para limitar el riesgo de reidentificación. Estas medidas son decisiones de diseño académico y no constituyen una certificación de conformidad regulatoria.

B.5. Ausencia de datos

La ausencia de una variable no debe rellenarse con información posterior. Cuando el dato no está disponible, el sistema debe:

- emitir la recomendación con las señales presentes;
- reducir o matizar la confianza cuando falten variables relevantes;
- mostrar la ausencia en la explicación si afecta a la interpretación;
- registrar el caso para revisión si la ausencia coincide con un error crítico.

B.6. Limitaciones y riesgos

La matriz V01–V15 es más amplia que la implementación evaluada. Esta decisión documenta la evolución futura sin atribuir al modelo información de AEMET, SNCZI o Seveso que todavía no utiliza.

Existe un riesgo crítico de leakage residual si en el futuro se introducen nuevas variables o integraciones del sistema de despacho sin verificar rigurosamente su disponibilidad temporal en la llamada de entrada. Cualquier campo que se incorpore al modelo debe someterse a una auditoría de línea de tiempo para asegurar que se genera en los primeros instantes de la llamada del ciudadano y no durante la posterior coordinación de la emergencia.

Tabla B.1: Variables V01–V15 del prototipo

ID	Variable	Tipo	Función en el sistema	Estado eva-luado
V01	Riesgo vital inmediato	Binaria	Captura fallecido, inconsciente, herido grave, atrapado crítico o riesgo vital textual.	Implementada por señales
V02	Víctimas confirmadas o probables	Ordinal	Aproxima magnitud humana inicial cuando el texto permite inferir afectados.	Parcial por texto
V03	Tipo de daño principal	Categórica	Diferencia daño a personas, bienes, medioambiente o incidente menor.	Implementada indirecta
V04	Tipo de incidente	Categórica	Mapa el incidente a la taxonomía del Anexo A.	Implementada
V05	Población vulnerable	Binaria	Identifica menores, mayores, dependientes o colectivos especialmente expuestos.	Parcial por texto
V06	Personas en riesgo estimadas	Ordinal	Representa exposición potencial más allá de víctimas confirmadas.	Parcial
V07	Emplazamiento crítico	Categórica	Hospitales, residencias, centros educativos, infraestructuras o lugares sensibles.	Parcial por texto
V08	Nivel de aviso AEMET	Ordinal	Contexto meteorológico oficial para elevar riesgo cuando sea pertinente.	Diferida
V09	Fenómeno meteorológico activo	Categórica	Lluvia, nieve, viento, tormenta, temperatura u otro fenómeno coherente.	Diferida
V10	Peligrosidad por inundación	Binaria	Cruce territorial con zonas inundables SNCZI.	Diferida
V11	Proximidad Seveso	Binaria	Identifica instalaciones sujetas a RD 840/2015 o riesgo tecnológico.	Diferida
V12	Tendencia del incidente	Ordinal	Estable, agravamiento, mejora o desconocida; orienta escalado.	Parcial por texto
V13	Fiabilidad del informador	Ordinal	Modula confianza, no gravedad.	No disponible directa
V14	Número de avisos simultáneos	Ordinal	Varias llamadas elevan confianza y posible impacto.	Implementada por señal
V15	Accesibilidad al punto	Ordinal	Dificultad de acceso, entorno rural, montaña o rescate complejo.	Parcial por texto

C. Guía de etiquetado P1–P4

C.1. Finalidad del anexo

Este anexo documenta la guía empleada para construir mediante supervisión débil la escala académica P1–P4. El Registro 112 Castilla y León no contiene una prioridad oficial equivalente; por ello, la guía define un criterio reproducible para entrenar, comparar y evaluar la Capa 2 sin atribuir validez institucional a la etiqueta.

La guía se apoya en la decisión metodológica de tratar P1–P4 como escala académica, no jurídica ni institucional. La muestra revisada internamente por los tres autores se documenta en el Anexo D.

C.2. Principios generales

1. **Momento de primera decisión.** La etiqueta debe reflejar la urgencia con la información disponible al inicio, no con el desenlace final del incidente.
2. **Prioridad como urgencia relativa.** P1–P4 ordena necesidad de atención temprana; no equivale a una declaración formal de situación operativa.
3. **Precaución razonable.** Ante información incompleta, se evita tanto minimizar señales críticas como asumir siempre el peor caso.
4. **Trazabilidad.** Toda etiqueta debe poder vincularse a texto, categoría, señales, variables o reglas.
5. **Independencia anti-*leakage*.** No se usan medios movilizados, pacientes atendidos, cierre ni información posterior para etiquetar la primera decisión.

C.3. Definición de niveles

C.4. Reglas de etiquetado

Las reglas siguientes operativizan la asignación académica como funciones de etiquetado reproducibles. Su finalidad es producir votos débiles, no representar una verdad institucional del servicio 112:

Tabla C.1: Definición académica de prioridades P1–P4

Nivel	Nombre	Criterio operativo	Ejemplos de señales
P1	Crítica	Riesgo vital confirmado o altamente probable, fallecido, atrapamiento grave, múltiples víctimas o evolución potencialmente crítica.	fallecido, inconsciente, herido grave, atrapado crítico, intoxicación grave
P2	Alta	Gravedad relevante o potencial de escalado sin riesgo vital inmediato confirmado. Requiere atención rápida y seguimiento.	herido, atrapado no crítico, incendio en vivienda, rescate, varias llamadas
P3	Media	Incidente que requiere gestión activa, pero sin señales claras de riesgo vital ni escalado alto.	accidente leve, incendio contenido, incidencia viaria, meteo limitada
P4	Baja	Consulta, incidencia menor, asistencia diferible o caso sin urgencia operativa aparente.	consulta, información, incidencia técnica menor, sin señales críticas

C.5. Resolución de conflictos

Cuando varias señales sugieren prioridades diferentes, se aplica la prioridad más alta compatible con la información inicial. La incertidumbre no debe rebajar una prioridad: debe reflejarse como menor confianza o como caso para revisión humana. Si la evidencia solo permite una lectura ambigua entre dos niveles, se selecciona el nivel superior cuando existan señales de personas afectadas, vulnerabilidad o posible escalado.

Los conflictos más relevantes son:

- **P1/P2:** se decide por la presencia de riesgo vital, fallecido, atrapamiento crítico o gravedad personal extrema.
- **P2/P3:** se decide por potencial de escalado, personas expuestas, varias llamadas, incendio habitado o necesidad de rescate.
- **P3/P4:** se decide por existencia de gestión activa frente a consulta o incidencia menor.

Tabla C.2: Reglas principales para etiquetado débil

Regla	Nivel mínimo	Criterio
R-P1-FALLECIDO	P1	El texto menciona fallecido, muerto, cadáver o equivalente.
R-P1-RIESGO-VITAL	P1	Riesgo vital textual, inconsciencia, parada, herido muy grave o situación crítica.
R-P1-ATRAPADO-CRITICO	P1	Atrapamiento con indicios de gravedad, rescate urgente o imposibilidad de salida.
R-P2-HERIDO-GRAVE	P2	Herido grave sin confirmación suficiente para P1.
R-P2-INTOXICACION	P2	Intoxicación, humo o exposición a sustancias con posible afectación personal.
R-P2-INCENDIO-HABITADO	P2	Incendio en vivienda, edificio, local habitado o entorno con personas expuestas.
R-P2-RESCATE	P2	Rescate o salvamento sin señal P1 confirmada.
R-P3-TRAFICO	P3	Accidente de tráfico sin señales críticas ni heridos graves.
R-P3-INCENDIO-SIN-VICTIMAS	P3	Incendio sin víctimas ni atrapados descritos.
R-P4-SIN-URGENCIA	P4	Consulta, información o incidencia menor sin señales operativas de gravedad.

C.6. Funciones de etiquetado, agregación y acuerdo

Cuatro funciones de etiquetado heurísticas y correlacionadas forman la etiqueta final. Todas comparten una puntuación programática de gravedad: dos incorporan la categoría, otra la excluye y la cuarta añade patrones de vulnerabilidad, emplazamiento y negación. Algunos nombres internos proceden del diseño experimental inicial, pero en la ejecución evaluada no se emplean un modelo NER, un agrupamiento vectorial ni un LLM anotador. Se trata, por tanto, de votos programáticos correlacionados y no de anotaciones humanas independientes ni de una verdad institucional.

Los votos se agregan mediante suma ponderada. Los pesos son 0,85, 1,00, 0,90 y 1,10, respectivamente. Si varias prioridades obtienen el mismo peso, se selecciona la más urgente. La ejecución canónica alcanza Krippendorff $\alpha = 0,899902$; la ablación sin reglas heurísticas mantiene $\alpha = 0,834155$.

Estos valores respaldan la consistencia del procedimiento, pero no demuestran independencia entre funciones: varias comparten patrones y señales con las variables que posteriormente utiliza RuleFit-lite. La ablación confirma que el acuerdo no desaparece al retirar una fuente, no que se haya eliminado por completo la circularidad.

C.7. Limitaciones

La guía reduce subjetividad, pero no elimina la necesidad de revisión humana. La evaluación final identifica 59 falsos negativos P1, incluidos 7 casos P1–P4, que constituyen la prioridad de la muestra revisada. Estos casos permiten estudiar límites de la guía, señales insuficientes o decisiones del modelo con riesgo de infrapriorización. La muestra completa se documenta en el Anexo D.

La validación externa con operadores del 112 queda como trabajo futuro. Hasta entonces, P1–P4 debe citarse siempre como escala académica del prototipo.

D. Muestra y protocolo de revisión interna

D.1. Finalidad del anexo

Este anexo documenta la muestra empleada para revisar recomendaciones P1–P4 sobre casos reales del Registro 112 Castilla y León. Los tres autores realizaron una revisión conjunta y cualitativa centrada en los casos de riesgo, las discrepancias y la trazabilidad de las evidencias mostradas.

La revisión interna no equivale a una validación externa completada. Tampoco constituye tres anotaciones independientes, porque los autores examinaron la muestra conjuntamente y no calcularon acuerdo interrevisor. Por ello, no sustituye una validación formal con operadores del 112.

D.2. Muestra de revisión

La selección de casos combina dos criterios:

- inclusión de los 59 falsos negativos P1 detectados en la partición de prueba estratificada;
- inclusión de una muestra equilibrada adicional de 60 casos, con 15 casos por clase P1, P2, P3 y P4.

El total resultante es de 119 casos. Los tres autores revisaron conjuntamente las fichas y la muestra se reutiliza como entrada de la evaluación automatizada de fidelidad descrita en la Sección D.6. Los campos previstos para decisiones independientes no se emplearon para crear una nueva referencia supervisada; la evidencia documenta una revisión humana interna y cualitativa, no una validación externa.

D.3. Plantilla de revisión humana

Cada fila del fichero de validación representa un caso revisado. La plantilla incluye identificación, referencia académica, predicción del sistema, evidencias mostradas y campos

Tabla D.1: Composición de la muestra revisada internamente

Tipo de caso	Número de casos
Falsos negativos P1	59
Muestra equilibrada P1	15
Muestra equilibrada P2	15
Muestra equilibrada P3	15
Muestra equilibrada P4	15
Total	119

reservados para la decisión humana.

Tabla D.2: Campos principales de la plantilla de revisión

Campo	Función
Identificador de revisión	Código interno de caso, con formato REV-NNN
Tipo de muestra	Falso negativo P1 o muestra equilibrada
Identificador del incidente	Referencia trazable del Registro 112 CyL
Texto operativo	Texto minimizado del incidente, usado para revisar la decisión
Etiqueta académica	Prioridad P1–P4 generada por supervisión débil
Recomendación del sistema	Prioridad P1–P4 recomendada por RuleFit-lite
Probabilidades	Distribución normalizada por clase
Acuerdo local	Consistencia entre fuentes débiles
Reglas o señales mostradas	Evidencias principales de la clase predicha
Contexto de explicación	Prioridad, margen, evidencias y avisos usados por Capa 3
Decisión del revisor	Aceptar, modificar o rechazar la recomendación
Prioridad final del revisor	Prioridad asignada por el revisor interno
Motivo de divergencia	Justificación obligatoria si se modifica o rechaza
Auditoría especial	Marca casos que requieren revisión prioritaria

D.4. Casos reales seleccionados

La Tabla D.3 muestra una muestra compacta de casos incluidos en el CSV. Los casos REV-061–REV-068 son falsos negativos P1 y, por tanto, tienen prioridad de revisión.

D.5. Procedimiento de revisión

Los tres autores revisaron conjuntamente el texto operativo, la etiqueta débil, la recomendación del sistema, las probabilidades, las señales activadas y, cuando estaba disponible, la explicación normativa de Capa 3. La plantilla conserva tres valores para una futura

Tabla D.3: Ejemplos de casos reales seleccionados para revisión

Caso	Tipo	Incidente	Etiqueta débil	Sistema	Conf.	Categoría
REV-001	Equilibrado P1	1228180006005	P1	P1	0.712510	tráfico
REV-016	Equilibrado P2	1264142203135	P2	P2	0.673363	sanitario
REV-031	Equilibrado P3	1284226557820	P3	P3	0.953758	sanitario
REV-046	Equilibrado P4	1284154490226	P4	P4	0.985624	sanitario
REV-061	FN P1	1244182009991	P1	P3	0.893565	incendio
REV-062	FN P1	1248678215637	P1	P2	0.552789	incendio
REV-064	FN P1 crítico	1255644701359	P1	P4	0.985624	sanitario
REV-068	FN P1 crítico	1279887542362	P1	P4	0.985624	sanitario
REV-069	FN P1 crítico	1284166596701	P1	P4	0.985624	sanitario
REV-080	FN P1 crítico	1284268940694	P1	P4	0.857180	sanitario
REV-098	FN P1 crítico	1284746951651	P1	P4	0.985624	sanitario
REV-118	FN P1 crítico	1285206245620	P1	P4	0.985624	sanitario

revisión independiente y formalizada:

- **Aceptar:** la recomendación del sistema se considera adecuada.
- **Modificar:** el revisor asigna otra prioridad P1–P4 y justifica el cambio.
- **Rechazar:** el caso revela una recomendación no útil o evidencia insuficiente para sostenerla.

Las divergencias de dos o más niveles se consideran casos de auditoría especial. En particular, los casos P1 clasificados como P3 o P4 deben analizarse antes de una futura validación externa, porque representan infraestimaciones relevantes. En la versión evaluada aparecen 7 casos P1–P4, que requieren especial atención por representar infrapriorizaciones críticas. Su análisis debe comprobar si el error procede de la guía de etiquetado, de una extracción incompleta de señales, de la ponderación del modelo o de una falta de evidencia explícita en el texto operativo.

D.6. Evaluación automatizada de fidelidad

La fidelidad de las explicaciones se comprueba de forma separada sobre los 119 casos mediante un juez determinista local. La rúbrica verifica seis criterios: mención de la prioridad, trazabilidad de reglas, cobertura de señales, presencia de soporte normativo en P1/P2, ausencia de contradicciones y advertencia de supervisión humana. Esta prueba evalúa si Capa 3 refleja la salida de Capa 2; no revisa si la etiqueta académica o la prioridad recomendada son correctas desde el punto de vista operativo.

La ejecución obtiene una tasa de cumplimiento de 1,000000, fidelidad media de 0,957367 y fidelidad mínima de 0,933333. En los 59 falsos negativos P1, la fidelidad media es 0,952494. Estos resultados proceden de una comprobación automatizada sobre explicaciones deterministas y no deben confundirse con valoración humana ni con validación externa.

D.7. Evaluación exploratoria con participantes

Como complemento a la evaluación técnica, se realizó una evaluación breve del producto mínimo viable (MVP) con nueve participantes. El acceso se facilitó mediante un enlace de prueba basado en Google Colab, casos representativos y un cuestionario estructurado sobre comprensibilidad, utilidad percibida, confianza y claridad de la supervisión humana. La selección responde a un muestreo no probabilístico e intencional: se eligieron tres perfiles por grupo para contrastar perspectivas operativas, técnicas y no especializadas, sin pretender representatividad estadística.

Para preservar la privacidad, los participantes se identificaron mediante códigos A1–C3 y descripciones funcionales, sin recoger nombres, destinos concretos ni otros datos personales innecesarios. El Grupo A incluye perfiles profesionales vinculados a puestos de mando, comunicaciones críticas y emergencias; el Grupo B, usuarios técnicos familiarizados con herramientas de IA; y el Grupo C, usuarios no especializados en IA con distintos niveles de familiaridad operativa. La Tabla D.4 resume el diseño de la muestra.

La denominación del Grupo A evita atribuir a todos sus integrantes la condición de expertos en gestión civil de emergencias. A1 y A3 aportan principalmente experiencia en puestos de mando, redes y sistemas CIS, mientras que A2 ofrece la perspectiva más próxima al despliegue operativo en emergencias. Esta precisión limita el alcance de las conclusiones y evita equiparar la muestra con personal profesional del servicio 112.

El cuestionario empleó una escala Likert de 1 a 5, donde 1 expresa desacuerdo total y 5 acuerdo total. Las cuatro afirmaciones valoraron si la prioridad recomendada resulta razonable, si la explicación es clara, si las señales o reglas aumentan la confianza y si queda claro que la decisión final corresponde a una persona. Una pregunta abierta permitió recoger la principal fortaleza, dificultad o mejora percibida sin alargar la prueba. La Tabla D.5 recoge las puntuaciones consolidadas y anonimizadas de cada participante.

Tabla D.4: Diseño intencional de perfiles para la evaluación exploratoria del MVP

Código	Grupo	Perfil funcional	Rol en la evaluación
A1	A: PM/CIS/emergencias	Sargento del Ejército de Tierra, especialidad Transmisiones, responsable de comunicaciones y sistemas CIS.	Coherencia operativa, flujo de mando y trazabilidad.
A2	A: PM/CIS/emergencias	Sargento de la UME, con experiencia en montaje de puestos de mando en emergencias.	Utilidad en contexto de emergencia y claridad de prioridad crítica.
A3	A: PM/CIS/emergencias	Sargento del Ejército de Tierra, especialista en informática y redes de puestos de mando.	Trazabilidad técnica, continuidad y comprensión del sistema.
B1	B: técnicos con IA	Técnico de telecomunicaciones especialista en radio, usuario habitual de IA.	Claridad técnica y utilidad desde las comunicaciones radio.
B2	B: técnicos con IA	Técnico de telecomunicaciones especialista en satélite, usuario habitual de IA.	Claridad ante conectividad degradada y sistemas distribuidos.
B3	B: técnicos con IA	Ingeniero informático y desarrollador, usuario habitual de IA.	Arquitectura, separación de capas y reproducibilidad.
C1	C: no especializados	Técnico de montaje de puestos de mando, sin uso técnico habitual de IA.	Comprensión del MVP desde un perfil técnico no IA.
C2	C: no especializados	Usuario no técnico, sin uso habitual de IA.	Comprensibilidad general para personas no técnicas.
C3	C: no especializados	Policía Nacional, sin uso especializado de IA.	Percepción desde seguridad pública y supervisión humana.

Tabla D.5: Puntuaciones individuales anonimizadas de la evaluación exploratoria

Código	Prioridad	Explicación	Señales/reglas	Decisión humana
A1	4,5	4,2	4,5	5,0
A2	4,7	4,3	4,4	5,0
A3	4,2	4,0	4,6	4,8
B1	4,0	4,2	4,1	4,5
B2	4,1	4,3	4,2	4,5
B3	4,3	4,6	4,4	4,3
C1	4,0	3,8	3,7	4,6
C2	3,5	3,3	3,0	4,4
C3	4,0	3,7	3,5	4,6

Las respuestas muestran una valoración global favorable, especialmente en la claridad de la supervisión humana. Los perfiles del Grupo A destacaron la trazabilidad, la visibilidad de las señales críticas y el mantenimiento del criterio del mando; el Grupo B valoró la separación entre el motor de prioridad y la explicación generada; y el Grupo C comprendió

la finalidad general, aunque manifestó mayor dificultad ante las probabilidades, las reglas y el vocabulario técnico. Esta síntesis agrupa los comentarios abiertos sin atribuir citas literales a participantes identificables.

D.8. Limitaciones

La muestra procede de etiquetas académicas generadas por supervisión débil. Por tanto, la revisión conjunta de los autores puede detectar incoherencias del sistema o de la propia etiqueta, pero no certifica validez operativa ni aporta acuerdo entre revisores independientes. La validación externa con personal del 112 sigue siendo una línea prioritaria de trabajo futuro.

La evaluación exploratoria no constituye validación operativa. Su tamaño reducido, el muestreo intencional y la ausencia de operadores del 112 limitan el análisis a indicios descriptivos sobre utilidad percibida y comprensión. Por tanto, los resultados no son estadísticamente generalizables ni permiten inferir mejoras en tiempos de decisión, carga cognitiva o desempeño profesional.

E. Línea base heurística de priorización

E.1. Objetivo

Este anexo documenta la línea base heurística empleada como primera referencia de Capa 2. Fue diseñada por el equipo a partir de criterios operativos y normativos, pero no ha sido validada por un panel externo de expertos. Toma exclusivamente señales previas a la decisión y las variables activas V01–V07 y V12–V15.

El criterio es conservador: las reglas priorizan la detección de incidentes P1, aunque ello reduzca la precisión en clases intermedias. Su función es proporcionar una referencia transparente para determinar si RuleFit-lite aporta una mejora global.

E.2. Reglas heurísticas

La Tabla E.1 recoge las 19 reglas activas. Sus anclajes se apoyan en la Ley 17/2015, PLANCAL, INUNCYL y la Ley 4/2007 de Castilla y León (Jefatura del Estado, 2015; Junta de Castilla y León, 2019, 2010; Cortes de Castilla y León, 2007). Su inclusión en el anexo permite entender el criterio de comparación sin trasladar al cuerpo principal detalles de implementación.

E.2.1. Agregación y desempate

Cada clase parte de una puntuación inicial: $P1=0,15$, $P2=0,25$, $P3=0,35$ y $P4=0,25$. A continuación se suman los pesos de las reglas activadas. Si existe alguna regla P1, su puntuación se eleva 0,75 por encima del mayor valor; si no existe P1 pero sí P2, esta se eleva 0,35. Finalmente, las puntuaciones se normalizan y se selecciona la clase con mayor probabilidad.

Los pesos son decisiones heurísticas del equipo, no parámetros aprendidos ni estimaciones de probabilidad calibrada. Este detalle limita la interpretación de sus salidas probabilísticas, aunque mantiene el procedimiento completamente auditable.

E.3. Métricas principales

La evaluación se realiza frente a las etiquetas académicas P1–P4 generadas por supervisión débil y con las mismas particiones que el modelo final. La Tabla E.2 resume su comportamiento.

La línea base de 19 reglas alcanza en prueba macro-F1 0,464284 y sensibilidad P1 0,998473. Su elevada sensibilidad responde al diseño conservador, pero su discriminación global entre las cuatro clases es limitada. RuleFit-lite obtiene macro-F1 0,905604 y sensibilidad P1 0,909924, un equilibrio más adecuado entre rendimiento global, detección de P1 e interpretabilidad.

E.4. Limitaciones

- La línea base refleja criterios operativos y normativos codificados manualmente por el equipo; por tanto, puede sobrerrepresentar escenarios críticos y reducir precisión en P2/P3.
- Las reglas se validan contra etiquetas débiles académicas, no contra prioridad operativa real del 112, inexistente en el conjunto de datos público.
- El modelo no aprende interacciones no previstas por las reglas. Esa es precisamente la función de la comparativa con RuleFit.
- No utiliza columnas post-decisión como recursos movilizados, pacientes atendidos o cierre administrativo, para evitar leakage.

La línea base debe entenderse como referencia comparativa. Su tendencia conservadora puede sobreactivar P1 y reducir la discriminación entre clases intermedias. Por ello, el modelo seleccionado no busca únicamente maximizar la sensibilidad P1, sino mantener un comportamiento interpretable y más equilibrado en el conjunto de clases P1–P4.

La mejora de macro-F1 obtenida por RuleFit-lite, manteniendo una sensibilidad P1 alta, respalda su selección para el prototipo académico.

Tabla E.1: Reglas de la línea base heurística de Capa 2

ID	P	Peso	Condición	Anclaje
EXP-P1-FALLECIDO	P1	3.8	signal_fallecido	Ley 17/2015; PLANCAL
EXP-P1-RIESGO-VITAL	P1	3.4	riesgo_vital o riesgo_vital_textual	Ley 17/2015; PLANCAL
EXP-P1-CRITICO-ATRAPADO	P1	2.7	signal_herido_grave y signal_atrapado	Ley 17/2015; PLANCAL
EXP-P1-MULTIVICTIMA	P1	2.5	Víctimas estimadas ≥ 3 y riesgo vital	Ley 17/2015; PLANCAL
EXP-P2-HERIDO-GRAVE	P2	2.1	signal_herido_grave	Ley 17/2015; PLANCAL
EXP-P2-ATRAPADO	P2	2.0	signal_atrapado	PLANCAL
EXP-P2-INTOXICACION	P2	1.9	signal_intoxicacion	MPCyL; PLANCAL
EXP-P2-INCENDIO-VIVIENDA	P2	1.8	Incendio en vivienda, edi- ficio o entorno habitado	PLANCAL; Ley 4/2007 CyL
EXP-P2-RESCATE	P2	1.7	Rescate o salvamento	PLANCAL
EXP-P2-TRAFICO-GRAVE	P2	1.6	Tráfico y herido grave	Ley 17/2015; Registro 112 CyL
EXP-P2-METEORO-ALTO-IMPACTO	P2	1.4	Meteo/inundación y va- rias llamadas	INUNCYL; PLANCAL
EXP-P3-SANITARIO-ORDINARIO	P3	1.2	Traslado o ambulancia ordinaria	Registro 112 CyL
EXP-P3-ACCIDENTE-TRAFICO	P3	1.0	Accidente de tráfico	Registro 112 CyL
EXP-P3-VARIAS-LLAMADAS	P3	0.9	Varias llamadas	Registro 112 CyL
EXP-P3-INCENDIO-SIN-VICTIMAS	P3	0.9	Incendio sin víctimas explícitas	Ley 4/2007 CyL; PLAN- CAL
EXP-P3-METEO-INUNDACION	P3	0.8	Meteo o inundación	INUNCYL
EXP-P4-INCENDIO-MENOR	P4	1.5	signal_incendio y conte- nedor/basura/papelera	Registro 112 CyL
EXP-P4-ACCIDENTE-MENOR	P4	1.5	signal_accidente_ trafico sin heridos	Registro 112 CyL
EXP-P4-SIN-SENALES-CRITICAS	P4	0.8	Sin señales críticas y lla- mada única	Registro 112 CyL

Tabla E.2: Métricas de la línea base heurística

Partición	Exactitud	Macro-F1	Sensibilidad P1
Entrenamiento	0.701014	0.465140	0.995736
Validación	0.717314	0.498785	0.995441
Prueba	0.694425	0.464284	0.998473

Tabla E.3: Comparación resumida entre la línea base y RuleFit-lite

Modelo	Macro-F1 en prueba	Sensibilidad P1 en prueba
Línea base heurística	0.464284	0.998473
RuleFit-lite	0.905604	0.909924

F. Conceptos y software

F.1. Finalidad

Este anexo relaciona los conceptos académicos utilizados en la memoria con su materialización en el prototipo y con las evidencias que permiten comprobarlos. Su objetivo es mantener el cuerpo principal centrado en el problema, la metodología y los resultados, sin perder la trazabilidad hacia la implementación reproducible.

La correspondencia no implica que cada concepto se reduzca a una clase de software. Por ejemplo, la interpretabilidad de la Capa 2 depende conjuntamente del diseño del modelo, de las variables permitidas, de las reglas exportadas y del análisis de errores. Del mismo modo, la supervisión humana comprende tanto el contrato de decisión como el procedimiento de revisión y registro.

F.2. Correspondencia principal

Tabla F.1: Correspondencia entre conceptos académicos, software y evidencias

Concepto académico	Implementación software	Evidencia principal	Responsable
Extracción NLP simbólica y auditable	Extractores semánticos de señales, patrones de negación, normalización y confianza	Prueba funcional sobre cinco escenarios curados y salida estructurada de variables predecisionales	Ancor
Supervisión débil	Funciones de etiquetado y contrato <code>WeakLabel</code>	Guía P1–P4, acuerdo de Krippendorff y ablación de fuentes débiles	Juan Carlos
Prevención de fugas de información	Validadores y lista de columnas excluidas	Auditoría de variables disponibles antes de la primera decisión y pruebas de exclusión	Juan Carlos
Línea base heurística	Motor de 19 reglas expertas	Métricas sobre las mismas particiones que el modelo seleccionado	Juan Carlos
Priorización interpretable	<code>RuleSetClassifierModel</code> , implementación local de <code>RuleFit-lite</code>	Comparación con la línea base y con <code>RuleFit</code> externo; reglas, pesos y métricas por clase	Juan Carlos
Salvaguarda conservadora	Función de post-procesamiento <code>.apply_safety_gate</code>	Escenarios funcionales de inferencia integrada; se evalúa separadamente del estimador	Juan Carlos
Recuperación normativa	Índice semántico local y herramientas de consulta controlada	Corpus de fuentes oficiales, pruebas de recuperación y limitación documental declarada	Brian
Explicación generativa local	Orquestador de explicaciones con LLM local y respuesta alternativa determinista	Prueba funcional integrada y rúbrica automatizada de fidelidad	Brian
Entrada de voz experimental	Reconocimiento automático del habla con <code>faster-whisper</code> y estructuración de campos	Demostración en interfaz con audio de prueba; sin validación sobre llamadas reales	Brian
Supervisión humana y trazabilidad	Contratos <code>OperatorDecision</code> e <code>InferenceLog</code>	Muestra de 119 casos revisada conjuntamente y registro auditable de inferencias	Equipo

F.3. Contratos entre capas

La arquitectura se apoya en contratos de datos tipados (Pydantic, 2026). La entrada normalizada del incidente se transforma en variables predecisionales; la Capa 2 produce la prioridad, las probabilidades y las reglas activadas; y la Capa 3 genera una explicación subordinada a esa salida. La decisión final corresponde siempre a la persona operadora.

Tabla F.2: Secuencia conceptual de los contratos del prototipo

Contrato	Papel metodológico
IncidentInput	Representa la información inicial disponible sobre el incidente.
IncidentFeatures	Contiene variables y señales predecisionales extraídas por la Capa 1.
Priority Recommendation	Conserva la recomendación de Capa 2, sus probabilidades y la traza- bilidad de reglas.
Operator Recommendation	Presenta la explicación de Capa 3 sin recalcular la prioridad.
OperatorDecision	Registra la aceptación, modificación o rechazo por parte de la persona operadora.
InferenceLog	Permite reconstruir entradas, salidas, tiempos y decisiones asociadas.

F.4. Criterio de interpretación

Las evidencias enumeradas acreditan reproducibilidad y funcionamiento técnico en el entorno experimental. No equivalen a validación operativa en un centro 112, a certificación de seguridad ni a conformidad regulatoria. Esta distinción permite relacionar conceptos, software y resultados sin trasladar a la memoria principal un inventario de carpetas, rutas o ficheros internos.

G. Evidencias del prototipo

G.1. Alcance

Este anexo reúne únicamente las capturas indispensables para comprender el flujo del demostrador: entrada del incidente, entrada de voz experimental, recomendación interpretable y registro de la decisión humana. Las pantallas proceden de una ejecución local con casos sintéticos y no contienen datos personales ni información operativa real del servicio 112.

Las capturas acreditan la existencia de una interfaz funcional, pero no sustituyen la evaluación cuantitativa del Capítulo 9 ni constituyen una prueba de usabilidad con operadores profesionales.

G.2. Entrada del incidente

La Figura G.1 muestra el formulario empleado para introducir un caso controlado. El texto y los campos auxiliares se revisan antes de ejecutar la cadena de inferencia.

The screenshot displays the 'Centro de Emergencias 112 Cyl' interface. On the left, a sidebar contains 'Configuración del Sistema' (with 'Servidor API Conectado' status), 'Plantillas de Escenarios', and 'Cargar escenario de ejemplo' (set to 'Escenario 1: Accidente Tráfico'). The main area is titled 'DSS de Priorización Temprana y Caracterización Explicable' and 'Entrada del Incidente'. It features a 'Grabar en vivo' button and a 'Grabar llamada' section with a 'Subir audio' button and a 'Streamlit 1.38 requerido. Púlsalo el micrófono y habla.' message. Below this is a 'Datos del incidente' section with fields for 'Titulo del Incidente' (filled with 'Choque frontal N-122 con atrapados'), 'Descripción en texto libre (operador 112)' (filled with 'Colisión frontal entre dos turistas en N-122 km 150. Hay un varón inconsciente herido grave atrapado en el vehículo.'), 'Categoría operativa preliminar' (set to 'ACCIDENTE TRAFICO'), 'Incluir coordenadas GPS' (checked), 'Latitud' (41,65210), 'Longitud' (-2,46320), 'Localidad' (Golmayo), 'Provincia' (SORIA), and 'ID del Operador' (OP_ANCOR). A 'Cuadro de Mando del Decision Support' panel on the right prompts the user to 'Ingresar un incidente a la izquierda y haga clic en Analizar Incidente para comenzar.'

Figura G.1: Entrada manual de un incidente sintético en la interfaz del prototipo.

G.3. Entrada de voz experimental

El módulo de reconocimiento automático del habla (ASR) permite grabar o cargar audio de prueba y proponer una transcripción para completar el formulario. La persona usuaria debe revisar y corregir el resultado antes de solicitar una recomendación. Esta funcionalidad es experimental y no ha sido validada con llamadas reales, ruido de sala ni locutores representativos.





Figura G.2: Módulo experimental de entrada por voz mediante **faster-whisper**.

G.4. Recomendación interpretable

La Figura G.3 recoge las dos partes de la salida para un escenario P1. La interfaz separa la recomendación y distribución de probabilidades de Capa 2 de la explicación generada por Capa 3. El modelo de lenguaje no modifica la prioridad.

G.5. Registro de la decisión humana

La última evidencia muestra el formulario de retroalimentación. Su finalidad es registrar si la recomendación se acepta, modifica o rechaza y conservar la justificación correspondiente. La muestra de 119 casos fue revisada cualitativamente y de forma conjunta por los tres autores; el formulario queda disponible para una futura evaluación independiente y trazable, sin que la revisión interna equivalga a validación externa.



(a) Prioridad y probabilidades.

(b) Reglas, explicación y contexto.

Figura G.3: Resultado de un incidente sintético clasificado como P1.

Figure G.4 shows a form titled "Validación e Intervención Humana (HITL)". The form has a green checkmark icon and the text "Decisión registrada correctamente en el log de auditoría." Below this, there is a button labeled "Crear nuevo análisis".

Figura G.4: Formulario para registrar la decisión humana y una posible discrepancia.

H. Declaración de uso de inteligencia artificial generativa

H.1. Declaración

Durante el desarrollo del TFM se utilizaron asistentes de inteligencia artificial generativa como herramientas auxiliares de programación, consulta y revisión textual. Su uso se realizó bajo supervisión de los autores y no sustituyó las decisiones metodológicas, la ejecución de experimentos, la comprobación de resultados ni la responsabilidad sobre la versión final de la memoria.

H.2. Herramientas, finalidad y control

Tabla H.1: Uso declarado de herramientas de IA generativa

Herramienta	Uso auxiliar	Control aplicado
GitHub Copilot (GitHub y Microsoft, 2023)	Completado de código, apoyo en depuración y revisión de comentarios técnicos.	Revisión manual, ejecución de pruebas y aceptación expresa de cada cambio.
Asistentes basados en LLM, incluido Google Gemini (Google, 2026)	Consulta técnica, contraste de alternativas, corrección lingüística y apoyo en LaTeX.	Verificación contra código, resultados experimentales y fuentes primarias.
Herramientas de búsqueda asistida	Localización inicial de bibliografía y normativa oficial.	Validación posterior de autoría, fecha, DOI y procedencia oficial.

El equipo utilizó además un enfoque de desarrollo guiado por especificaciones para coordinar tareas y conservar trazabilidad. Esta organización no genera resultados académicos por sí misma: las métricas incluidas en la memoria proceden de ejecuciones reproducibles y fueron revisadas por los autores.

H.3. Límites y responsabilidad

Las herramientas generativas no asignaron las etiquetas P1–P4 finales, no eligieron el modelo de Capa 2 y no determinaron las conclusiones del estudio. La auditoría del conjunto de datos, el diseño de supervisión débil, el entrenamiento, la evaluación y el análisis de errores fueron ejecutados mediante procedimientos controlados por el equipo.

Los autores asumen la responsabilidad sobre el código, la selección de fuentes, los resultados numéricos y la redacción final. El historial del repositorio conserva la trazabilidad del desarrollo:

https://github.com/jalbfil/tfe_muia_unir_188

L. Fichas de las capas

L.1. Alcance

Este anexo resume la finalidad, entradas, salidas, evaluación y limitaciones de las tres capas. La separación de responsabilidades es esencial: Capa 1 estructura el texto, Capa 2 recomienda la prioridad y Capa 3 explica esa recomendación. La persona operadora mantiene la decisión final.

Los detalles anteriormente distribuidos entre los anexos técnicos de recuperación normativa y configuración del LLM se consolidan aquí para ofrecer una visión académica única y evitar inventarios de rutas, clases o ficheros.

L.2. Capa 1: extracción NLP simbólica

Finalidad. Transformar el título y la descripción del incidente en variables predecionales estructuradas. El procedimiento combina detección semántica mediante reglas y diccionarios operativos, tratamiento de negaciones, normalización de valores y estimación de confianza. La salida conserva la señal activada y su procedencia para facilitar la auditoría.

Evaluación. Sobre cinco escenarios curados obtiene precisión micro (0,733333), sensibilidad micro (1,000000), F1 micro (0,846154) y latencia media (4,58844) ms. Es una comprobación funcional reducida, no una validación sobre llamadas reales ni sobre un conjunto de referencia etiquetado por el 112.

Limitación. La versión evaluada no contiene un clasificador aprendido congelado ni se le atribuyen entrenamientos o métricas procedentes de la Capa 2. La posible incorporación de modelos aprendidos queda como trabajo futuro y requeriría una evaluación específica.

L.3. Capa 2: priorización interpretable

L.3.1. Datos y etiqueta objetivo

La Capa 2 se entrena y evalúa con 9.380 registros limpios del Registro 112 Castilla y León. La prioridad P1–P4 no existe en la fuente: es una etiqueta académica construida mediante supervisión débil. El acuerdo principal alcanza un alfa de Krippendorff de $\alpha =$

0,899902. Las particiones utilizadas exclusivamente para Capa 2 son 6.512 registros de entrenamiento, 1.415 de validación y 1.453 de prueba; la prueba temporal de 2022 contiene 735 registros.

Las variables de entrada se limitan a señales disponibles antes de la primera decisión: fallecimiento, herido grave, atrapamiento, intoxicación, llamadas múltiples, incendio, accidente de tráfico, rescate, meteorología o inundación, riesgo vital textual y categoría preliminar normalizada. Se excluyen recursos movilizados, pacientes atendidos, cierre del incidente y cualquier información posterior, con el fin de evitar fugas de información.

L.3.2. Alternativas y selección

Se comparan una línea base de 19 reglas expertas, RuleFit-lite y una implementación externa de RuleFit mediante `imodels` (Singh y cols., 2021). RuleFit-lite se ajusta con un submuestreo estratificado y reproducible de 3.000 registros de los 6.512 disponibles, mientras que la alternativa externa usa 50 registros y se limita a una prueba diagnóstica. La selección se realiza con la partición de validación y la estimación final se obtiene una sola vez sobre la partición de prueba.

Tabla L.1: Resultados de los modelos de Capa 2 en la partición de prueba

Modelo	Exactitud	Macro-F1	Sensibilidad P1	Reglas
Línea base heurística	0,694425	0,464284	0,998473	19
RuleFit-lite	0,903648	0,905604	0,909924	30
RuleFit externo	0,768385	0,568239	0,902778	30

RuleFit-lite se selecciona porque presenta la mejor macro-F1, mantiene una sensibilidad P1 superior al umbral interno de (0,85) y conserva reglas exportables. La diferencia entre los tamaños de ajuste impide afirmar que su coste sea inferior al de la alternativa en condiciones equivalentes. En la prueba temporal alcanza exactitud (0,884354), macro-F1 (0,877594) y sensibilidad P1 (0,928767).

Estas métricas corresponden al estimador RuleFit-lite **sin Puerta de Seguridad**. La salvaguarda es una función determinista de posprocesamiento aplicada durante la inferencia integrada; se comprueba mediante escenarios funcionales y no se mezcla con la comparación estadística de modelos.

L.3.3. Riesgos y trazabilidad

La matriz de confusión identifica 59 falsos negativos P1: 34 casos clasificados como P2, 18 como P3 y 7 como P4. Los siete errores P1–P4 constituyen el riesgo principal y forman parte de la muestra de 119 casos revisada conjuntamente por los tres autores. La revisión es cualitativa y no equivale a tres anotaciones independientes ni a una validación externa con operadores del 112.

L.4. Capa 3: explicación local y recuperación normativa

Finalidad. Capa 3 recibe la prioridad, las probabilidades, las reglas activadas y el contexto explicativo generado por Capa 2. Produce una explicación estructurada y evidencias normativas, pero no recalcula ni modifica la prioridad.

Recuperación. El sistema utiliza un índice semántico local sobre normativa estatal y de Castilla y León. Los documentos se segmentan y representan con el modelo multilingüe `paraphrase-multilingual-MiniLM-L12-v2`. La cobertura incluye la legislación de protección civil y los planes territoriales y especiales disponibles. No se dispone del texto técnico completo de MPCyL, por lo que la recuperación en escenarios químicos debe interpretarse con cautela y completarse en una versión futura con la fuente oficial íntegra.

Generación y salvaguardas. El LLM se ejecuta localmente con temperatura (0,0). Las instrucciones exigen mantener la prioridad de Capa 2, utilizar solo las reglas y evidencias recibidas, declarar incertidumbre y evitar hechos o citas no recuperados. Las herramientas de consulta normativa y detalle de reglas se exponen de forma controlada mediante Model Context Protocol. Si el modelo no responde o incumple el contrato, se genera una explicación alternativa determinista que conserva la salida de Capa 2.

Evaluación. La prueba funcional con LLM local resuelve correctamente cuatro escenarios P1–P4 y observa una latencia media de (4,898) s en el entorno experimental. La evaluación automatizada de fidelidad sobre los 119 casos revisados alcanza una tasa de cumplimiento de (1,000000), fidelidad media (0,957367) y mínima (0,933333). Se trata de un juez determinista sobre explicaciones controladas, no de una evaluación humana ni de un LLM-as-Judge independiente.

L.5. Entrada de voz experimental

La interfaz incorpora reconocimiento automático del habla mediante **faster-whisper**. Su salida propone texto y campos normalizados que deben revisarse antes de ejecutar la inferencia. Esta función se ha utilizado como demostración con audio de prueba; no se reportan tasas de error de palabra ni validación con llamadas reales, ruido de sala o diversidad de locutores.

L.6. Limitaciones comunes

- La referencia P1–P4 es académica y débil, no una prioridad oficial del 112.
- Las pruebas integradas muestran compatibilidad técnica en escenarios controlados, no utilidad operativa ni cumplimiento de un acuerdo de nivel de servicio.
- La Puerta de Seguridad es una salvaguarda conservadora no certificada y debe evaluarse separadamente del modelo estadístico.
- La muestra de 119 casos ha sido revisada conjuntamente por los tres autores, pero no contiene tres anotaciones independientes ni permite calcular acuerdo interrevisor.
- Los resultados no acreditan conformidad regulatoria ni autorizan el uso del prototipo en un servicio de emergencias real.